

فصل سوم

روش تحقیق

۱-۳ مقدمه

این فصل روش پژوهش را چنان شرح می‌دهد که خواننده بتواند آن را بازتولید کند. ترتیب بخش‌ها از داده به سوی مدل و سپس به سوی سنجش پیش می‌رود، زیرا هر حلقه از این زنجیره اعتبار حلقه‌های پس از خود را تعیین می‌کند: ماتریس ویژگی آلوده، هر مدلی را که از آن تغذیه کند بی‌اعتبار می‌سازد، و چارچوب اعتبارسنجی سهل‌گیر، هر عدد دقتی را که تولید کند خوش‌بینانه می‌کند.

بخش ۲-۳ شش فرض بنیادی پژوهش را — همان‌گونه که در پیشنهادی مصوب صورت‌بندی شده‌اند — می‌آورد و از همان آغاز روشن می‌کند که شواهد فصل‌های چهارم و پنجم کدام یک از آن‌ها را تأیید نکرده‌اند. **بخش ۳-۳** داده‌ها را معرفی می‌کند: مجموعه داده بنچمارک EPEX-DE که تمام نتایج پایان‌نامه بر آن استوار است، مجموعه‌ی داده‌ی زنده که تنها برای آزمون برون‌توزیعی و ابزار عملیاتی به کار می‌رود، و تحلیل اکتشافی‌ای که تصمیم‌های روش‌شناختی پس از خود را توجیه می‌کند. **بخش ۴-۳** مهندسی ویژگی و قید علی حاکم بر آن را تشریح می‌کند.

بخش ۵-۳ چارچوب اعتبارسنجی، معیارهای دقت و آزمون معناداری را تعریف می‌کند. اینکه این بخش پیش از معرفی مدل‌ها می‌آید تصادفی نیست: معیارها و پروتکل ارزیابی پیش از دیده‌شدن هر نتیجه‌ای تثبیت شده‌اند، و همین پیش‌تعهد است که به اعداد فصل چهارم اعتبار می‌بخشد. بخش‌های ۶-۳ و ۷-۳ به ترتیب مدل‌های پایه (ساده، SARIMAX، LEAR-LASSO) و مدل‌های یادگیری ماشین و یادگیری عمیق (LSTM، LightGBM) را معرفی می‌کنند، و **بخش ۸-۳** مدل ترکیبی و وزن‌دهی گروهی رژیم‌محور را.

سه قید در سرتاسر این فصل تکرار می‌شود و بهتر است از همین جا صریح باشد. نخست، هم‌سانی: همه‌ی مدل‌ها از یک منبع یکتای ویژگی تغذیه می‌شوند، بر یک پروتکل یکسان رانده می‌شوند و با یک پیمانه‌ی معیار سنجیده می‌شوند، تا اختلاف عملکرد به خودِ مدل بازگردد و نه به تفاوت در شرایط. دوم، هم‌ارزی با پروتکل منتشرشده‌ی لاگو و همکاران [۱]، که مقایسه‌ی فصل چهارم با اعداد مرجع را ممکن می‌کند. سوم، ثبت انحراف‌ها: هر جا پیاده‌سازی از پروتکل مرجع فاصله گرفته است — به‌ویژه در آهنگ واسنجی SARIMAX و LSTM — این فاصله در متن تصریح شده است، به‌جای آنکه در کد پنهان بماند.

۲-۳ فرضیات بنیادی پژوهش

هر پژوهش تجربی بر فرض‌هایی استوار است که اگر ناگفته بمانند، خواننده نمی‌داند نتایج تا کجا معتبرند. شش فرض زیر همان‌هایی است که در پیشنهادی مصوب این پایان‌نامه صورت‌بندی شده است. آن‌ها را در همین جا کامل می‌آوریم و برای هر یک تصریح می‌کنیم که شواهد این پژوهش آن را تأیید کرده‌اند یا نه. این تصریح، عقب‌نشینی از پیشنهاد نیست؛ بازگشت مستند به آن است، و **بخش ۵-۲** حلقه‌ی همین بازگشت را می‌بندد.

فرض یکم: ایستایی

فرض می‌شود ساختار آماری سری قیمت — یا دست‌کم آن بخشی از آن که مدل‌ها بر آن تکیه می‌کنند — در طول دوره‌ی آموزش و آزمون به‌قدر کافی پایدار است که الگوی آموخته‌شده بر گذشته، بر آینده نیز برقرار بماند.

این فرض در صورت قوی خود برقرار نیست، و پژوهش نیز به آن نیازی ندارد. میانگین سالانه‌ی قیمت در دوره‌ی مطالعه از 42.89 یورو بر مگاوات‌ساعت در سال ۲۰۱۲ به 28.98 در سال ۲۰۱۶ افت می‌کند و سپس به 34.20 در سال ۲۰۱۷ بازمی‌گردد؛ سطح قیمت آشکارا ثابت نیست. آنچه پژوهش در عمل فرض می‌کند صورت ضعیف‌تر آن است: واسنجی مجدد روزانه بر پنجره‌ی غلطان ۱۰۹۲ روزه (**بخش ۳-۵**) مدل را پیوسته با سطح جاری بازار هم‌تراز نگه می‌دارد، به‌طوری‌که تنها ایستایی محلی لازم است و نه ایستایی سراسری. این تمایز در فصل پنجم اهمیت پیدا می‌کند، آنجا که مدل‌ها بدون هیچ واسنجی مجدد به کار گرفته می‌شوند.

فرض دوم: در دسترس بودن داده

فرض می‌شود داده‌های لازم برای پیش‌بینی — قیمت‌های تاریخی و پیش‌بینی‌های روزپیش‌بار و تولید تجدیدپذیر — پیش از مبدأ پیش‌بینی در دسترس‌اند.

این فرض برقرار است، و در **بخش ۳-۴** به قیدی آزموده ترجمه شده است: هر ستون ماتریس ویژگی باید تاریخ در دسترس بودن خود را اعلام کند، وگرنه ساخت ماتریس متوقف می‌شود. با این‌همه فرض دوم یک هزینه‌ی ثبت‌شده دارد. چند متغیر که ادبیات آن‌ها را مؤثر می‌داند — به‌ویژه قیمت سوخت — در این پژوهش در دسترس نبودند، زیرا سری‌های مرجعشان تجاری و دارای مجوزند. **بخش ۳-۲** این محدودیت و دلیل آن را ثبت می‌کند؛ آنچه اینجا اهمیت دارد این است که فرض دوم برای مجموعه‌ی

ویژگی به کاررفته برقرار است، نه برای هر مجموعه‌ی ویژگی مطلوب.

فرض سوم: کیفیت داده

فرض می‌شود داده‌های ورودی از خطای اندازه‌گیری، جافتادگی و ناسازگاری تعریفی مبرا هستند. برای مجموعه‌داده بنچمارک این فرض برقرار است: 52,416 سطر ساعتی، بدون هیچ مقدار گم‌شده و بدون هیچ برچسب زمانی تکراری. اما برای مجموعه‌ی داده‌ی زنده — که تنها در آزمون برون‌توزیعی به کار می‌رود — این فرض نقض شده است، و نقض آن یکی از یافته‌های همین پژوهش است. متغیر برون‌زای نخست در دوره‌ی آموزش پیش‌بینی بارِ ناحیه‌ی کنترلی Amprion است و در دوره‌ی سرویس‌دهی پیش‌بینی بارِ ملی آلمان: دو تعریف متفاوت زیر یک نام. اندازه‌ی این ناهم‌خوانی سنجیده شده و در **بخش ۲-۵** گزارش می‌شود.

تصریح این نکته در همین جا اهمیت دارد، چون تعیین می‌کند شکست برون‌توزیعی فصل پنجم را باید به کدام فرض نسبت داد. ناهم‌خوانی تعریفی، نقصی در مسیر داده‌ی خودِ ماست و ذیل همین فرض سوم می‌نشیند، نه ذیل فرض پنجم.

فرض چهارم: تعمیم‌پذیری مدل

فرض می‌شود مدلی که بر داده‌ی تاریخی آموزش دیده، بر داده‌ای که ندیده است نیز عملکرد قابل‌قبولی دارد.

درون دوره‌ی بنچمارک این فرض برقرار است: دوره‌ی آزمون دوساله‌ی ۷۲۸ مبدأیی به‌طور کامل کنار گذاشته شده و هیچ مدلی در هیچ مرحله‌ای — نه در برازش، نه در تنظیم ابرپارامتر و نه در برازش وزن‌های ترکیبی — آن را ندیده است.

بیرون از آن دوره، این فرض برقرار نیست. مدل‌های تثبیت‌شده بر دوره‌ی بنچمارک، هنگام ارزیابی بر ۱۷۳ روز داده‌ی زنده‌ی سال ۲۰۲۶، همگی از مدل ساده‌ی مرجع عقب می‌مانند و ترتیب آن‌ها وارونه می‌شود. این صریح‌ترین نقض فرض در سرتاسر پژوهش است، و نکته‌ی مهم آنکه بر هر دو خوانش ممکن برقرار می‌ماند: چه بخشی از افت را به تغییر بازار نسبت دهیم و چه به ناهم‌خوانی تعریفی فرض سوم، در هر دو حالت مدل‌ها در شرایطی که برای آن آموزش ندیده بودند شکست خورده‌اند. **بخش ۲-۵** اعداد آن را می‌آورد.

فرض پنجم: پایداری شرایط بازار

فرض می‌شود شرایط کلان بازار میان دوره‌ی آموزش و دوره‌ی کاربرد به‌قدر کافی پایدار می‌ماند. این فرض درباره‌ی بازار است، و همین آن را از فرض چهارم جدا می‌کند.

نسبت‌دادن کامل شکست برون‌توزیعی به این فرض، خطایی است که این پژوهش عاقدانه از آن پرهیز می‌کند. بخشی از آن افت — و بر پایه‌ی سنجش، بخش عمده‌ی سهم قابل اندازه‌گیری آن — از ناهم‌خوانی تعریفی مسیر سرویس‌دهی خود ما برمی‌خیزد، یعنی از فرض سوم، و نه از حرکت بازار آلمان. آنچه با صداقت می‌توان گفت این است: فرض پنجم تنها با آن باقی‌مانده‌ای به چالش کشیده می‌شود که پس از کنارگذاشتن سهم ناهم‌خوانی برجای می‌ماند، و این پژوهش آن باقی‌مانده را جدا نکرده است. سهم بازار در این افت — برخلاف سهم ناهم‌خوانی — به‌طور مستقل کمی نشده است، و **بخش ۵-۲** آن را به همین صورت گزارش می‌کند، نه صفر و نه غالب.

فرض ششم: تفسیرپذیری مدل

فرض می‌شود می‌توان سهم ویژگی‌ها در خروجی مدل را به‌صورتی قابل‌فهم استخراج کرد.

در پیشنهادی مصوب، تفسیرپذیری یک فرض بود؛ در این پژوهش به یک تحویل‌دانی بدل شده است. مرورهای اخیر نیز تفسیرپذیری را در کنار کیفیت داده و تعمیم‌پذیری از چالش‌های همچنان گشوده‌ی این حوزه برمی‌شمارند [۴]. **بخش ۴-۶** تحلیل SHAP را با دو قید صریح ارائه می‌کند: این تحلیل تنها بازوی درختی مدل را پوشش می‌دهد و درباره‌ی اطلاعاتی که مدل خطی یا شبکه‌ی بازگشتی به کار می‌گیرند ادعایی نمی‌کند، و مدلی که تفسیر می‌شود همزاد وفادار مدل گزارش‌شده است و نه خود آن. فرض ششم با این دو قید برقرار است.

جمع‌بندی

از شش فرض بالا، فرض‌های دوم و ششم بی‌قید برقرارند؛ فرض یکم تنها در صورت ضعیف و محلی خود لازم و برقرار است؛ فرض سوم برای داده‌ی بنچمارک برقرار و برای داده‌ی زنده نقض شده است؛ فرض چهارم درون دوره‌ی بنچمارک برقرار و بیرون از آن نقض شده است؛ و فرض پنجم تنها تا اندازه‌ای به چالش کشیده می‌شود که این پژوهش آن را از فرض سوم جدا نکرده است. **بخش ۵-۲** با شواهد عددی به همین فهرست بازمی‌گردد.

۳-۳ داده‌ها و بازار مورد مطالعه

این پژوهش از دو مجموعه‌ی داده استفاده می‌کند که نقش آن‌ها را نباید با یکدیگر اشتباه گرفت. مجموعه‌ی نخست، داده‌ی بنچمارک باز EPEX-DE است که لاگو و همکاران آن را همراه پروتکل ارزیابی خود منتشر کرده‌اند [۱]؛ تمام اعداد دقت، آزمون‌های معناداری و تحلیل تفسیرپذیری این پایان‌نامه بر همین مجموعه تولید شده‌اند. مجموعه‌ی دوم، داده‌ی زنده‌ی سامانه‌ی Energy-Charts است که کاربرد آن به دو مورد محدود می‌ماند: آزمون برون‌توزیعی بخش ۵-۲ و ابزار عملیاتی بخش ۵-۳.

این تفکیک یک قاعده‌ی ثبت‌شده‌ی پژوهش است و نه ترتیبی اتفاقی. هیچ عددی از مجموعه‌ی دوم وارد جدول‌های نتایج فصل چهارم نمی‌شود، زیرا آن جدول‌ها باید با اعداد منتشرشده‌ی مرجع هم‌مقیاس بمانند. بخش ۳-۳-۱ مجموعه‌ی بنچمارک را معرفی می‌کند، بخش ۳-۳-۲ مجموعه‌ی زنده و محدوده‌ی مجاز استفاده از آن را، و بخش ۳-۳-۳ تحلیل اکتشافی‌ای را که تصمیم‌های روش‌شناختی بخش‌های بعدی از آن برمی‌خیزد.

۳-۳-۱ مجموعه‌داده بنچمارک EPEX-DE

ساختار و دامنه

داده‌ی اصلی این پژوهش، سری ساعتی قیمت بازار روز-پیش آلمان در بورس EPEX است، که در قالب مجموعه‌داده‌ی باز لاگو و همکاران و همراه با پروتکل ارزیابی آن منتشر شده است [۱]. انتخاب این مجموعه به‌جای گردآوری مستقل داده، یک تصمیم روش‌شناختی است: تنها در این حالت است که اعداد فصل چهارم را می‌توان مستقیماً و بدون هیچ ابهام تعریفی در کنار اعداد منتشرشده‌ی مرجع نشانند. مجموعه از ۹ ژانویه ۲۰۱۲ تا ۳۱ دسامبر ۲۰۱۷ را پوشش می‌دهد و شامل 52,416 سطر ساعتی است. هر سطر سه متغیر دارد:

- price — قیمت تسویه‌ی ساعتی بازار روز-پیش، به یورو بر مگاوات-ساعت؛ متغیر هدف پژوهش.

- exog_1 — پیش‌بینی روزپیش بار مصرفی برای ناحیه‌ی کنترلی Amprion.

- exog_2 — پیش‌بینی روزپیش تولید بادی و خورشیدی.

هر دو متغیر برون‌زا پیش‌بینی هستند و نه مقدار محقق‌شده، و پیش از حراج روز-پیش منتشر می‌شوند. این نکته صرفاً توصیفی نیست؛ مبنای مجاز بودن استفاده از مقادیر خودِ روز هدف این دو متغیر در ماتریس ویژگی است، که بخش ۳-۴ آن را به تفصیل توجیه می‌کند.

نام ناحیه‌ای متغیر نخست را باید به‌خاطر سپرد. $exog_1$ بار ناحیه‌ی Amprion است و نه بار ملی آلمان — تمایزی که در دوره‌ی بنچمارک هیچ اثری ندارد، چون آموزش و آزمون هر دو روی همان تعریف انجام می‌شوند، اما در آزمون برون‌توزیعی **بخش ۵-۲** به هسته‌ی اصلی یافته بدل می‌شود.

تقسیم آموزش و آزمون

تقسیم داده مطابق پروتکل مرجع انجام می‌شود: دو سال پایانی به‌طور کامل به‌عنوان دوره‌ی آزمون کنار گذاشته می‌شود. دوره‌ی آزمون از ۴ ژانویه‌ی ۲۰۱۶ تا ۳۱ دسامبر ۲۰۱۷ ادامه دارد و شامل ۷۲۸ مبدأ پیش‌بینی و ۱۷,۴۷۲ ساعت است؛ دوره‌ی آموزش ۳۴,۹۴۴ ساعت (۱,۴۵۶ روز) پیش از آن را در بر می‌گیرد.

این کنارگذاری کامل است. هیچ مشاهده‌ای از دوره‌ی آزمون در برازش مدل‌ها، در تنظیم ابرپارامترها، در برازش وزن‌های مدل ترکیبی و در تعیین آستانه‌ی رژیم نقشی ندارد. پنجره‌ی تنظیم ابرپارامتر (۵ ژانویه‌ی ۲۰۱۵ تا ۳ ژانویه‌ی ۲۰۱۶) و پنجره‌ی برازش وزن‌ها (۱۲ ژانویه‌ی ۲۰۱۵ تا ۳ ژانویه‌ی ۲۰۱۶) هر دو اکیداً پیش از آغاز دوره‌ی آزمون پایان می‌یابند، و این قید در کد با یک تابع تصریحی اعمال می‌شود، نه صرفاً رعایت می‌گردد (**بخش ۳-۵**).

آمار توصیفی قیمت

میانگین قیمت در کل دوره ۳۴.۶۸ یورو بر مگاوات‌ساعت با انحراف معیار ۱۵.۹۴ است، و میانه ۳۳.۴۵ — یعنی توزیع در ناحیه‌ی مرکزی تقریباً متقارن است. اما دنباله‌های آن چنین نیستند: کمینه منفی ۲۲۱.۹۹ و بیشینه ۲۱۰.۰۰ یورو بر مگاوات‌ساعت است، چولگی منفی ۰.۵۲ و کشیدگی ۱۶.۲۷. کشیدگی بسیار بالا در کنار چولگی منفی، تصویر روشنی می‌دهد: سری بیشتر وقت‌ها آرام است و گاه با جهش‌های شدید — به‌ویژه رو به پایین و تا ناحیه‌ی منفی — از آن آرامش خارج می‌شود.

قیمت‌های منفی در این بازار پدیده‌ای واقعی‌اند و نه خطای داده: ۵۳۸ ساعت از کل دوره (۱.۰۳ درصد) قیمت منفی دارند، که ۲۹۷ ساعت آن در دوره‌ی آموزش و ۲۴۱ ساعت در دوره‌ی آزمون قرار می‌گیرد. نسبت آن‌ها در دوره‌ی آزمون بیشتر است (۱.۳۸ در برابر ۰.۸۵ درصد)، یعنی پدیده در طول دوره تشدید می‌شود. ادبیات نیز همین ویژگی‌ها — نوسان شدید، جهش‌های ناگهانی و ناهمگنی واریانس — را از خصوصیات ذاتی سری قیمت برق برمی‌شمارد [۲].

وجود قیمت منفی یک پیامد مستقیم بر انتخاب معیار دارد: هر معیاری که بر خود قیمت تقسیم کند، در همسایگی صفر تعریف‌ناپذیر یا انفجاری می‌شود. **بخش ۳-۵** بر همین پایه MAPE را کنار می‌گذارد.

سطح قیمت در طول دوره ثابت نمی‌ماند. میانگین سالانه از 42.89 در سال ۲۰۱۲ به 37.78 در ۲۰۱۳، 32.76 در ۲۰۱۴، 31.63 در ۲۰۱۵ و 28.98 در ۲۰۱۶ کاهش می‌یابد و آنگاه در ۲۰۱۷ به 34.20 بازمی‌گردد. این روند نزولی و بازگشت آن، همان چیزی است که فرض ایستایی در صورت قوی خود را رد می‌کند (بخش ۲-۳) و واسنجی مجدد روزانه را ضروری می‌سازد.

کیفیت و بازتولیدپذیری

مجموعه‌ی داده کامل است: هیچ مقدار گم‌شده‌ای در هیچ یک از سه ستون وجود ندارد و هیچ برچسب زمانی تکراری نیست. این وضعیت با اسکرپت واریس مستقلی راستی‌آزمایی می‌شود که پیش از هر اجرای نتایج، ابعاد، بازه‌ی زمانی و پیوستگی نمایه‌ی ساعتی را می‌سنجد.

بازتولیدپذیری در این پژوهش با یک قاعده‌ی سخت اداره می‌شود: داده‌ی بیرونی یک‌بار دریافت و در یک تصویر ثابت با اثر انگشت sha256 ثبت می‌شود، در مخزن پروژه نگهداری می‌گردد، و از آن پس تنها از همان‌جا خوانده می‌شود. علت این سخت‌گیری آن است که یک واسط برنامه‌نویسی زنده فردا ممکن است پاسخ دیگری بدهد و این کار را در سکوت انجام دهد؛ آنگاه نتایج منتشرشده دیگر بازتولیدپذیر نیستند بی‌آنکه کسی متوجه شود. دریافت مجدد این مجموعه در ۲۹ اوت ۲۰۲۶ بایت‌به‌بایت با تصویر ثبت‌شده یکسان بود.

افزون بر آن، کد مهندسی ویژگی از دسترسی به شبکه منع شده است و این منع با آزمون خودکار اعمال می‌شود، نه با قرارداد. توضیح این سازوکار در بخش ۴-۳ آمده است.

۲-۳-۳ داده زنده Energy-Charts

دامنه مجاز استفاده

مجموعه‌ی دوم این پژوهش از سامانه‌ی Energy-Charts مؤسسه‌ی Fraunhofer ISE دریافت شده است. کاربرد آن به‌صراحت محدود است و این محدودیت باید پیش از هر توصیفی ثبت شود: این داده تنها در آزمون برون‌توزیعی بخش ۲-۵ و در ابزار عملیاتی بخش ۳-۵ به کار می‌رود، و هیچ عددی از آن وارد جدول‌های نتایج فصل چهارم نمی‌شود.

دلیل این تفکیک، حفظ هم‌مقیاسی مقایسه است. تمام ادعاهای دقت فصل چهارم در برابر اعداد منتشرشده‌ی مرجع سنجیده می‌شوند و این سنجش تنها بر همان مجموعه‌داده، همان دوره و همان تعریف متغیرها معنا دارد. آمیختن دو منبع، مقایسه را در سکوت بی‌اعتبار می‌کند.

مشخصات

داده از ناحیه‌ی پیشنهاددهی DE-LU گرفته شده و ۱۷۳ روز کامل سال ۲۰۲۶، معادل 4,343 سطر ساعتی و بدون جافتادگی، را پوشش می‌دهد. واسط برنامه‌نویسی این سامانه بدون کلید و بدون ثبت‌نام در دسترس است، که آن را با قاعده‌ی بازتولیدپذیری پژوهش سازگار می‌کند. داده‌های اخیر با تفکیک پانزده دقیقه‌ای عرضه می‌شوند و در بارگذار پروژه به تفکیک ساعتی تجمیع می‌گردند تا با شمای مشترک دو مجموعه هم‌شکل شوند.

یک ناپیوستگی تعریفی در سطح ناحیه نیز شایان ذکر است: ناحیه‌ی پیشنهاددهی پیش از یکم اکتبر ۲۰۱۸ DE-AT-LU بوده و پس از آن به DE-LU تفکیک شده است. دوره‌ی بنچمارک پیش از این تفکیک و دوره‌ی زنده پس از آن قرار می‌گیرد.

انتشار این داده تحت پروانه‌ی CC BY 4.0 است و اسناد آن، ذکر منبع را الزامی می‌کند. عبارت ارجاع، به شکلی که پروانه اقتضا می‌کند، چنین است:

Data: Energy-Charts (Fraunhofer ISE) / Bundesnetzagentur SMARD.de, CC BY 4.0

یک ناهم‌خوانی تعریفی که باید همین‌جا ثبت شود

میان این مجموعه و مجموعه‌ی بنچمارک دو ناهم‌خوانی وجود دارد که خواننده باید پیش از رسیدن به نتایج فصل پنجم از آن‌ها آگاه باشد. ثبت کردن آن‌ها در همین‌جا — یعنی پیش از آنکه نتیجه‌ای گزارش شود — تصمیمی آگاهانه است: این ناهم‌خوانی سازوکار اصلی یافته‌ی منفی **بخش ۵-۲** است، و اگر تنها در کنار همان نتیجه معرفی شود، شبیه توجیه پس از وقوع به نظر می‌رسد.

ناهم‌خوانی نخست جغرافیایی است. متغیر برون‌زای بار در دوره‌ی آموزش پیش‌بینی بار ناحیه‌ی کنترلی Amprion است، حال آنکه در دوره‌ی سرویس‌دهی پیش‌بینی بار ملی آلمان دریافت می‌شود. سهم Amprion از بار آلمان حدود چهل درصد است، پس دو سری زیر یک نام در دو مقیاس متفاوت قرار می‌گیرند. اندازه‌ی دقیق این اختلاف و پیامد آن برای هر مدل در **بخش ۵-۲** سنجیده و گزارش می‌شود. ناهم‌خوانی دوم در دامنه‌ی متغیرهاست. سطح قیمت در سال ۲۰۲۶ به‌مراتب بالاتر از دوره‌ی بنچمارک است و بازه‌ی نوسان آن نیز گسترده‌تر؛ یعنی مدل‌ها در دوره‌ی سرویس‌دهی با مقادیری روبه‌رو می‌شوند که در دوره‌ی آموزش نظیری نداشته‌اند.

هیچ‌یک از این دو، آزمون برون‌توزیعی را بی‌اعتبار نمی‌کند؛ اما هر دو معنای آن را تغییر می‌دهند. آن آزمون، ترکیبی از تغییر واقعی بازار و ناهم‌خوانی مسیر داده‌ی خود را می‌سنجد، و **بخش ۵-۲** این

دو را تا آنجا که سنجش اجازه می‌دهد از هم تفکیک می‌کند.


بازتولیدپذیری و اسناد

همان قاعده‌ی تصویر ثابت که در بخش ۳-۳-۱ برای مجموعه‌ی بنچمارک شرح داده شد، بر این مجموعه نیز حاکم است: پنجره‌ی ۱۷۳ روزه یک‌بار دریافت، با اثر انگشت sha256 ثبت و در مخزن نگهداری شده است، و ارزیابی‌های بخش ۵-۲ تنها از همان تصویر خوانده می‌شوند. بدون این قید، آزمون برون‌توزیعی با هر بار اجرا عدد دیگری می‌داد و هیچ‌یک از آن اعداد قابل استناد نبود.

۳-۳-۳ تحلیل اکتشافی داده

هدف این بخش توصیف داده به‌خاطر خودِ توصیف نیست. هر یک از شش الگوی زیر، تصمیمی روش‌شناختی را در بخش‌های بعدی توجیه می‌کند، و همین پیوند است که تحلیل اکتشافی را از یک ضمیمه‌ی تشریفاتی جدا می‌سازد.

توزیع قیمت




شکل ۳-۱: توزیع قیمت‌های ساعتی بازار روز-پیش EPEX-DE در دوره‌ی ۲۰۱۲ تا ۲۰۱۷، شامل ناحیه‌ی قیمت‌های منفی.

شکل ۳-۱: توزیع قیمت‌های ساعتی را نشان می‌دهد. توده‌ی اصلی توزیع در بازه‌ی تقریبی ۲۰ تا ۵۰ یورو بر مگاوات‌ساعت متمرکز است، اما دنباله‌ی چپ تا ناحیه‌ی منفی امتداد می‌یابد و دنباله‌ی راست تا بیش از دو برابر میانگین. کشیدگی ۱۶.۲۷ در برابر مقدار سه برای توزیع نرمال، سنجش‌ای عددی از همین دنباله‌های سنگین است.


قیمت‌های منفی — ۵۳۸ ساعت، معادل ۱.۰۳ درصد کل دوره — پیامد ساختاری نفوذ بالای

تجدیدپذیرها هستند و نه نوفه‌ی داده [۴]. این ویژگی دو پیامد روش‌شناختی دارد که در بخش ۳-۵ به آن‌ها بازمی‌گردیم: کنارگذاشتن MAPE، و انتخاب معیارهایی که به علامت مخرج حساس نباشند.

فصلی‌بودن چندگانه



شکل ۳-۲: نیم‌رخ درون‌روزی قیمت: میانگین قیمت به تفکیک ساعت شبانه‌روز.



شکل ۳-۳: نیم‌رخ هفتگی قیمت: میانگین قیمت به تفکیک روز هفته.

سری قیمت برق هم‌زمان در سه مقیاس فصلی است، و شکل‌های ۲-۳ تا ۴-۳ هر سه را نشان می‌دهند. این چندلایگی از خصوصیات شناخته‌شده‌ی این سری است [۲].

در مقیاس شبانه‌روزی، میانگین قیمت از کمینه‌ی ۲۲.۷۸ در ساعت سه بامداد تا بیشینه‌ی ۴۶.۰۱ در ساعت نوزده نوسان می‌کند — یعنی بیش از دو برابر. الگو دو قله دارد: یک قله‌ی صبحگاهی حوالی ساعت هشت (۴۲.۲۰) و قله‌ی اصلی عصرگاهی. همین دامنه‌ی وسیع، دلیل تصمیمی است که در بخش‌های ۳-۶ و ۳-۷ تکرار می‌شود: به جای یک مدل واحد برای همه‌ی ساعت‌ها، به‌ازای هر ساعت شبانه‌روز یک مدل مستقل برازش می‌شود، چون رفتار آماری ساعت سه بامداد و ساعت نوزده یکی نیست.




شکل ۳-۴: نیم‌رخ سالانه‌ی قیمت در سراسر دوره‌ی مطالعه.

در مقیاس هفتگی، تفاوت میان روزهای کاری و تعطیل چشمگیر است: میانگین یکشنبه 23.33 و شنبه 30.08 در برابر 38.70 برای سه‌شنبه، پرقیمت‌ترین روز هفته. این شکاف، هم متغیرهای مجازی روز هفته در ماتریس ویژگی (بخش ۳-۴) و هم قاعده‌ی رفتاری مدل ساده‌ی مرجع را توجیه می‌کند؛ آن قاعده برای دوشنبه به آخرین روز کاری و برای تعطیلات به هم‌تای هفته‌ی پیشین ارجاع می‌دهد، دقیقاً چون میانگین یکشنبه از میانگین دوشنبه بسیار دور است.

در مقیاس سالانه، روند نزولی ۲۰۱۲ تا ۲۰۱۶ و بازگشت سال ۲۰۱۷ که در بخش ۳-۱-۳ گزارش شد، در شکل ۳-۴ دیده می‌شود.

خوشه‌بندی نوسان و مقادیر حدی




شکل ۳-۵: خوشه‌بندی نوسان: دوره‌های آرام و پرتلاطم به‌صورت خوشه‌ای در زمان کنار هم می‌نشینند.

شکل ۳-۵ خوشه‌بندی نوسان را نشان می‌دهد: دوره‌های آرام و دوره‌های پرتلاطم به‌صورت خوشه‌ای کنار هم می‌نشینند و به‌طور تصادفی در زمان پراکنده نیستند. این ناهمگنی واریانس، ویژگی شناخته‌شده‌ی سری قیمت برق است [۳].

این مشاهده مستقیماً به **بخش ۳-۸** راه می‌برد. اگر رفتار بازار میان دوره‌های آرام و پرتنش به‌قدر کافی متفاوت باشد، مجموعه‌ی وزنی که در حالت آرام بهینه است لزوماً در حالت پرتنش بهینه نیست — و همین، منطقی وزن‌دهی گروهی رژیم‌محور است. تعریف عملیاتی دو رژیم و آستانه‌ی تفکیک آن‌ها در **بخش ۳-۸** می‌آید، نه اینجا: آستانه بر پایه‌ی داده‌ی اعتبارسنجی و با قاعده‌ای تصریح‌شده تعیین می‌شود، و استخراج آن از یک نمودار اکتشافی همان انتخاب درون‌نمونه‌ای است که پژوهش از آن پرهیز می‌کند.

ساختار خودهمبستگی



شکل ۳-۶: توابع خودهمبستگی و خودهمبستگی جزئی سری قیمت ساعتی.

شکل ۳-۶ توابع خودهمبستگی (ACF)^۱ و خودهمبستگی جزئی (PACF)^۲ را نشان می‌دهد. خودهمبستگی در وقفه‌ی یک ساعت 0.9337، در وقفه‌ی ۲۴ ساعت 0.6598 و در وقفه‌ی ۱۶۸ ساعت (یک هفته) 0.5855 است.


قله‌های آشکار در وقفه‌های ۲۴ و ۱۶۸ ساعت، دو دوره‌ی تناوب روزانه و هفتگی را تأیید می‌کنند و مبنای دو تصمیم‌اند. نخست، انتخاب وقفه‌های قیمتی ماتریس ویژگی — روزهای D-1، D-2، D-3 و D-7 — که همان قرارداد مرجع است [۱] و اینجا شاهد تجربی خود را در داده می‌یابد. دوم، انتخاب مرتبه‌ی فصلی هفت‌روزه برای مدل SARIMAX در **بخش ۳-۶**: بُعد شبانه‌روزی پیشاپیش با تفکیک

^۱ Autocorrelation Function

^۲ Partial Autocorrelation Function

۲۴ گانه‌ی مدل‌ها جذب شده است، پس آنچه برای مؤلفه‌ی فصلی باقی می‌ماند تناوب هفتگی است.

متغیرهای برون‌زا



شکل ۳-۷: همبستگی قیمت با دو متغیر برون‌زا: پیش‌بینی روزپیش بار و پیش‌بینی روزپیش تولید بادی و خورشیدی.




شکل ۳-۸: همبستگی غلتان قیمت با متغیرهای برون‌زا در طول زمان؛ شدت رابطه ثابت نمی‌ماند.

شکل ۳-۷ رابطه‌ی قیمت با دو متغیر برون‌زا را نشان می‌دهد و علامت‌ها همان است که نظریه‌ی دستور تولید انتظار دارد. همبستگی قیمت با پیش‌بینی بار مثبت و برابر 0.6109 است: تقاضای بیشتر، واحدهای گران‌تر را وارد مدار می‌کند. همبستگی آن با پیش‌بینی تولید بادی و خورشیدی منفی و برابر 0.3885 است: تولید تجدیدپذیر با هزینه‌ی نهایی نزدیک به صفر، منحنی عرضه را به سمت راست می‌راند و قیمت تسویه را پایین می‌آورد.


شکل ۳-۸ همین همبستگی‌ها را به‌صورت غلتان در طول زمان نشان می‌دهد و روشن می‌کند که شدت آن‌ها ثابت نیست. این ناپایداری رابطه، یکی از دلایلی است که واسنجی مجدد روزانه را ضروری می‌کند: ضرایبی که بر داده‌ی سال ۲۰۱۳ برازش شده‌اند، برای سال ۲۰۱۷ همان ضرایب درست نیستند.

شکست‌های ساختاری و سری روزانه

شکل ۳-۹ کل سری را همراه با شکست‌های ساختاری آن نشان می‌دهد. وجود این شکست‌ها، تصمیم استفاده از پنجره‌ی واسنجی غلتان ۱۰۹۲ روزه به‌جای آموزش بر کل تاریخچه را توجیه می‌کند: پنجره‌ی



شکل ۳-۹: کل سری قیمت ساعتی به همراه شکست‌های ساختاری شناسایی شده.



شکل ۳-۱۰: سری بار پایه‌ی روزانه: میانگین ۲۴ قیمت ساعتی هر روز.

غلتان، داده‌ی کهنه‌ی متعلق به رژیم‌های پیشین بازار را به تدریج کنار می‌گذارد.

شکل ۳-۱۰ سری بار پایه‌ی روزانه — یعنی میانگین ۲۴ قیمت ساعتی هر روز — را نشان می‌دهد. این سری ۲,۱۸۴ روز دارد، با میانگین ۳۴.۶۸، انحراف معیار ۱۱.۹۷، کمینه‌ی منفی ۵۶.۸۷ و بیشینه‌ی ۱۰۱.۹۲. انحراف معیار آن به روشنی کمتر از انحراف معیار سری ساعتی (۱۵.۹۴) است، چون میانگین‌گیری بخشی از نوسان درون‌روزی را حذف می‌کند.

همین کاهش نوسان، پرسش پژوهشی چهارم را می‌سازد. اگر هدف روزانه ذاتاً هموارتر از هدف ساعتی است، آیا بهتر است آن را مستقیماً مدل کرد، یا از میانگین‌گیری ۲۴ پیش‌بینی ساعتی به دست آورد؟ هر دو مسیر در این پژوهش ساخته و در **بخش ۴-۴** با هم سنجیده می‌شوند.

۳-۴ مهندسی ویژگی

تنظیم مسئله

صورت‌بندی مسئله در این پژوهش چنین است: در مبدأ پیش‌بینی، یعنی روز O و پیش از بسته‌شدن حراج روز-پیش، هر بیست و چهار قیمت ساعتی روز $O+1$ پیش‌بینی می‌شود. خروجی هر مدل یک بردار ۲۴ مؤلفه‌ای است و نه یک عدد؛ همین انتخاب، افق پیش‌بینی را با ساختار واقعی حراج هم‌شکل می‌کند،

چون در بازار روز-پیش نیز هر بیست و چهار ساعت به صورت یک جا و در یک حراج تسویه می شوند. ماتریس ویژگی حاصل ۲۱۷۷ سطر و ۲۴۷ ستون دارد. هر سطر یک روز هدف است و هر ستون یک ویژگی. این ماتریس، منبع یکتای ویژگی برای هر پنج مدل پژوهش است: مدل ساده، SARIMAX، LEAR-LASSO، LightGBM و LSTM همگی از همین ماتریس تغذیه می شوند و هیچ یک مسیر ویژگی سازی اختصاصی ندارد.

این یکتایی، تصمیمی روش شناختی است و نه سهولت مهندسی. اگر هر مدل ماتریس خودش را می ساخت، دو هزینه پدید می آمد. نخست، هر مسیر تازه سطح تازه ای برای نشت اطلاعات می گشود که آزمون های این بخش آن را پوشش نمی دادند. دوم، و مهم تر، بخشی از اختلاف دقت فصل چهارم دیگر به خود مدل نسبت دادنی نبود؛ می توانست از تفاوت در ورودی برخاسته باشد. مقایسه ی منصفانه ایجاب می کند که تنها یک متغیر میان مدل ها تغییر کند، و آن متغیر خود مدل باشد.

قید علی: خط قرمز پژوهش

قاعده ی حاکم بر کل این بخش یک جمله است: هیچ ویژگی ای نباید از اطلاعات پس از مبدأ پیش بینی استفاده کند.

نقض این قاعده، شایع ترین و مخرب ترین خطای این حوزه است، چون بی سروصدا رخ می دهد. مدلی که یک ستون آلوده دریافت کرده باشد، بدون هیچ خطا یا هشدار آموزش می بیند، اعداد دقت چشمگیری تولید می کند، و آن اعداد در عمل بی معنا هستند. تفاوت میان یک پژوهش معتبر و یک پژوهش بی اعتبار در این حوزه، اغلب یک ستون است.

به همین دلیل این قاعده در پروژه به صورت قرارداد رعایت نمی شود، بلکه با دو سازوکار اجرایی اعمال می گردد.

سازوکار نخست: اعلان تصریحی در دسترس بودن. هر ستون ماتریس ویژگی باید در یک سامانه ی ثبت، منبع خود و میزان وقفه اش نسبت به روز هدف را اعلام کند. سپس تابعی تصریحی کل مجموعه ی ستون ها را می پیماید و در صورت یافتن ستونی که اعلان نشده باشد، یا ستونی که اعلانش با نامش نخواند، اجرا را با خطا متوقف می کند. نکته ی طراحی مهم آنکه حالت پیش فرض این واریسی سخت گیرانه است: ستونی که فراموش شده اعلام شود، مجاز فرض نمی شود، بلکه مردود است. سامانه ای که ستون ناشناخته را در سکوت بپذیرد، دقیقاً همان چیزی است که باید از آن محافظت کند.

سازوکار دوم: آزمون خودکار. یک آزمون در مجموعه ی آزمون های پروژه، این ادعا را بر ماتریس

واقعی و با پیکربندی واقعی می‌سبجد، نه بر نمونه‌ای ساختگی. آزمون دومی نیز دسترسی کد مهندسی ویژگی به شبکه را ممنوع می‌کند. علت آن، هم بازتولیدپذیری است و هم همین قید علی: کدی که بتواند در زمان ساخت ویژگی به یک واسط زنده وصل شود، می‌تواند مقداری متأخرتر از مبدأ پیش‌بینی را دریافت کند، بی‌آنکه در متن برنامه چیزی به آن اشاره کند.

چهار خانواده ویژگی

مجموعه‌ی ویژگی‌ها عیناً از قرارداد مدل مرجع LEAR پیروی می‌کند [۱، ۱۹]. این پیروی، انتخابی آگاهانه و محدودکننده است: می‌شد مجموعه‌ی غنی‌تری ساخت، اما آنگاه مقایسه‌ی فصل چهارم با اعداد منتشرشده دیگر هم‌مقیاس نبود و هر تفاوتی در دقت را می‌شد به تفاوت در ورودی نسبت داد، نه به مدل. ساختار ۲۴۷ ستون به شرح زیر است.

وقفه‌های قیمت (۹۶ ستون)

بردار کامل ۲۴ ساعته‌ی قیمت برای چهار روز گذشته نسبت به روز هدف: D-1، D-2، D-3 و D-7. چهار روز ضربدر ۲۴ ساعت، ۹۶ ستون می‌شود. انتخاب همین چهار وقفه — و نه مثلاً پنج یا ده — دو توجیه دارد که یکدیگر را تقویت می‌کنند. توجیه نخست، هم‌ارزی با قرارداد مرجع است. توجیه دوم تجربی است و در بخش ۳-۳-۳ نشان داده شد: تابع خودهمبستگی قلّه‌های آشکاری در وقفه‌های ۲۴ و ۱۶۸ ساعت دارد (به‌ترتیب 0.6598 و 0.5855)، یعنی روز پیشین و همان روز در هفته‌ی پیشین بیشترین اطلاع را درباره‌ی روز هدف دارند. وقفه‌های D-2 و D-3 فاصله‌ی میان این دو را پر می‌کنند و برای دوشنبه‌ها نقش ویژه دارند، چون آخرین روز کاری پیش از دوشنبه، جمعه است.

وقفه‌های متغیرهای برون‌زا (۹۶ ستون)

بردار ۲۴ ساعته‌ی دو متغیر برون‌زا — پیش‌بینی بار و پیش‌بینی تولید بادی و خورشیدی — برای دو وقفه‌ی D-1 و D-7. دو متغیر ضربدر دو وقفه ضربدر ۲۴ ساعت، ۹۶ ستون.

متغیرهای برون‌زای خودِ روز هدف (۴۸ ستون)

دو متغیر برون‌زا برای خودِ روز هدف، یعنی روزی که قیمتش هنوز پیش‌بینی نشده است. دو متغیر ضربدر ۲۴ ساعت، ۴۸ ستون.

این خانواده تنها جایی است که ماتریس ویژگی مقداری از روز هدف را در بر می‌گیرد، و بنابراین تنها جایی است که خواننده حق دارد از نشت اطلاعات بپرسد. پاسخ در ماهیت این دو سری است و باید صریح گفته شود.

exog_1 و exog_2 مقدار محقق‌شده‌ی بار و تولید تجدیدپذیر نیستند؛ پیش‌بینی روز پیش آن‌ها هستند، که بهره‌بردار شبکه پیش از بسته‌شدن حراج روز-پیش منتشر می‌کند. یعنی در مبدأ پیش‌بینی، این اعداد پیشاپیش منتشر شده و در دسترس هر شرکت‌کننده‌ی بازار هستند. استفاده از آن‌ها نه تنها نشت نیست، بلکه بازتاب همان اطلاعاتی است که یک معامله‌گر واقعی در همان لحظه در اختیار دارد. مدلی که آن‌ها را نادیده بگیرد، از اطلاعات مجاز در دسترس استفاده نکرده است.

تمایز کلیدی میان «مقدار محقق‌شده‌ی روز هدف» و «پیش‌بینی منتشرشده‌ی روز هدف» است. اولی نشت است، دومی نیست. سامانه‌ی اعلان در دسترس بودن نیز همین تمایز را رمزگذاری می‌کند: این ستون‌ها با وقفه‌ی صفر اما با منبع «پیش‌بینی منتشرشده» اعلام می‌شوند، و ستونی که مقدار محقق‌شده با وقفه‌ی صفر اعلام کند، مردود می‌شود.

متغیرهای مجازی روز هفته (۷ ستون)

هفت متغیر مجازی دودویی برای روز هفته‌ی روز هدف. **بخش ۳-۳-۳** شکاف بزرگی میان روزهای هفته نشان داد — میانگین یکشنبه 23.33 در برابر 38.70 برای سه‌شنبه — که وجود این ستون‌ها را توجیه می‌کند. با این‌همه، تحلیل تفسیرپذیری **بخش ۴-۶** نشان خواهد داد که سهم آن‌ها در حضور وقفه‌های قیمتی ناچیز است؛ یعنی اطلاعات روز هفته پیشاپیش در خود قیمت‌های گذشته رمزگذاری شده است. جمع چهار خانواده: ۹۶ به‌علاوه‌ی ۹۶ به‌علاوه‌ی ۴۸ به‌علاوه‌ی ۷ برابر ۲۴۷ ستون. این تطابق عددی با فرمول ویژگی خود کتابخانه‌ی مرجع، در کد راستی‌آزمایی می‌شود و صرفاً ادعا نمی‌شود.

آنچه عمده‌اً در مجموعه ویژگی نیست

چند متغیر که ادبیات آن‌ها را مؤثر می‌داند در این ماتریس نیستند، و تصریح دلیل آن، بخشی از صداقت روش‌شناختی این پژوهش است.

قیمت سوخت. پژوهش‌ها نشان داده‌اند که قیمت حامل‌های انرژی از عوامل تعیین‌کننده‌ی قیمت برق است و لحاظ‌کردن آن می‌تواند دقت را بهبود دهد [۵، ۲۷]. با این‌حال، سری‌های مرجع گاز و زغال‌سنگ تجاری و دارای مجوزند و در چارچوب بازتولیدپذیری این پژوهش قابل استفاده نبودند؛

منابعی هم که سری‌های مشتق‌شده از آن‌ها را بازنشر می‌کنند، در این پژوهش به‌عنوان مرجع استناد به کار می‌روند و نه به‌عنوان منبع داده. پیامد مستقیم این محدودیت آن است که شاخص‌های حاشیه‌ی سوخت — مانند اسپرد تمیز — در این پایان‌نامه ساختنی نبودند.

هواشناسی و جریان‌های مرزی. این دو نیز عمداً کنار گذاشته شده‌اند، اما به دلیلی متفاوت: افزودن آن‌ها هم‌مقیاسی مقایسه با اعداد منتشرشده‌ی مرجع را از میان می‌برد. این تصمیم، مبادله‌ای آگاهانه است و نه غفلت. پژوهش، دقتِ ممکن را در ازای امکانِ مقایسه‌ی معتبر محدود کرده است، و **بخش ۴-۵** افزودن این متغیرها را به‌عنوان مسیر طبیعی پژوهش‌های آینده پیشنهاد می‌کند.

ساختار کد این امکان را حفظ کرده است: بلوک‌های ویژگی فیزیکی به‌صورت افزودنی و به‌طور پیش‌فرض خاموش پیاده‌سازی شده‌اند، به‌طوری‌که مسیر پیش‌فرض ساخت ویژگی دقیقاً همان مجموعه‌ی ۲۴۷ ستونی است که نتایج تثبیت‌شده‌ی فصل چهارم از آن تولید شده‌اند. بلوکی که به داده‌ی ثبت‌نام‌محور نیاز دارد نیز، به‌جای جایگزین کردن یک سری تقریبی، با خطا متوقف می‌شود؛ یعنی نبودِ داده در سکوت به یک عدد ساختگی بدل نمی‌گردد.

هدف روزانه

افزون بر هدف ساعتی، پژوهش هدف دومی نیز دارد: میانگین بار پایه‌ی روزانه، یعنی میانگین ۲۴ قیمت ساعتی هر روز. این هدف از دو مسیر متفاوت ساخته می‌شود، و همین دوگانگی است که پرسش پژوهشی چهارم را پاسخ می‌دهد.

مسیر نخست، مدل‌سازی مستقیم است: هدف روزانه به‌عنوان یک متغیر تک‌مؤلفه‌ای تعریف و مدل مستقیماً بر آن برازش می‌شود. مسیر دوم، تجمیع است: مدل ساعتی پیش‌بینی خود را تولید می‌کند و سپس از ۲۴ مؤلفه‌ی آن میانگین گرفته می‌شود.

برای آنکه مقایسه‌ی این دو مسیر معنادار بماند، هر دو از همان ماتریس ویژگی، همان مبادی پیش‌بینی و همان بودجه‌ی تنظیم ابرپارامتر استفاده می‌کنند. اگر مسیر مستقیم بودجه‌ی تنظیم کمتری می‌گرفت، هر برتری مسیر تجمعی می‌توانست صرفاً بازتاب همان نابرابری باشد. برابری بودجه، همان چیزی است که مقایسه‌ی **بخش ۴-۴** را از یک مصنوع طراحی مصون می‌دارد.

۳-۵ چارچوب اعتبارسنجی و معیارهای ارزیابی

اعتبارسنجی پیش‌رونده

در پیش‌بینی قیمت برق، ترتیب زمانی داده‌ها خود اطلاعات است. هر شکلی از تقسیم تصادفی داده به مجموعه‌های آموزش و آزمون، اطلاعات آینده را به گذشته نشت می‌دهد و خطای مدل را به‌صورتی غیرواقع‌بینانه کم برآورد می‌کند. از این رو در این پژوهش، مطابق پروتکل مرجع لاگو و همکاران [۱]، منحصراً از اعتبارسنجی پیش‌رونده با مبدأ غلتان استفاده شده است.

سازوکار چنین است: برای هر مبدأ پیش‌بینی، یعنی روز D ، مدل تنها بر پنجره‌ی واسنجی انتهایی شامل ۱۰۹۲ روز متوالی منتهی به روز پیش از مبدأ آموزش می‌بیند و بردار ۲۴ مؤلفه‌ای قیمت‌های ساعتی روز $D+1$ را پیش‌بینی می‌کند؛ سپس مبدأ یک روز جلو می‌رود و کل فرایند تکرار می‌شود. طول پنجره‌ی واسنجی — ۱۰۹۲ روز، معادل سه سال ۳۶۴ روزه — مقدار پیش‌فرض خود پیاده‌سازی مرجع است و نه انتخابی از سوی نگارنده؛ همین هم‌ارزی دقیق با پروتکل منتشرشده، مبنای منصفانه‌بودن مقایسه‌ی فصل چهارم با اعداد مرجع است.

دوره‌ی آزمون، مطابق همان مرجع، دو سال کامل ۲۰۱۶ و ۲۰۱۷ است: ۷۲۸ مبدأ پیش‌بینی و ۱۷,۴۷۲ ساعت به‌ازای هر مدل.

جداسازی سخت‌گیرانه‌ی پنجره‌ی اعتبارسنجی از آزمون

برای تنظیم ابرپارامترها (۵۰ آزمایش Optuna به‌ازای هر مدل؛ بخش ۳-۷) پنجره‌ی ۳۶۴ روزه از انتهای داده‌ی آموزش جدا می‌شود. قید بنیادین آن است که این پنجره اکیداً پیش از آغاز دوره‌ی آزمون پایان یابد.

این قید صرفاً یک قرارداد نیست. در کد با تابعی تصریحی اعمال می‌شود که در صورت هر تخطی — از جمله پنجره‌ی تهی، که قابل راستی‌آزمایی نیست — اجرای برنامه را متوقف می‌کند. آزمون یکپارچه‌ای نیز با مقادیر واقعی پیکربندی می‌سجد که حتی یک روز از دوره‌ی آزمون در پنجره‌ی آموزش نخستین مبدأ حضور نداشته باشد. بدین ترتیب ادعای «اعتبارسنجی اکیداً پیش از آزمون» در این پایان‌نامه ادعایی آزموده است، نه فرضی ضمنی.

سه مصنوع مدل، و اینکه کدام عددی را تولید می کند

مخزن این پژوهش سه دسته مصنوع مدل نگه می دارد که کاربرشان کاملاً متفاوت است. چون یکی از آن ها بر پنجره های آموزش دیده که دوره ی آزمون را در بر می گیرد، تفکیک آن ها باید پیش از هر عدد دقتی و به صراحت انجام شود؛ در غیر این صورت خواننده حق دارد نشت اطلاعات را فرض بگیرد.

یکم: مدل های چارچوب پیش رونده — تنها منبع اعداد فصل چهارم. در این چارچوب، به ازای هر یک از ۷۲۸ مبدأ، مدل بر پنجره ی ۱۰۹۲ روزه ای برازش می شود که اکیداً پیش از همان مبدأ پایان می یابد، و تنها روز بعد از آن را پیش بینی می کند. تمام معیارهای دقت و تمام آزمون های معناداری فصل چهارم از همین مسیر می آیند. هیچ عدد گزارش شده ای در فصل چهارم به مدلی تکیه ندارد که روز مورد پیش بینی را دیده باشد.

دوم: مدل تثبیت شده بر کل داده — هیچ عددی از آن گزارش نمی شود. این مصنوع بر پنجره ی ۱۰۹۲ روزه ی منتهی به ۳۱ دسامبر ۲۰۱۷ برازش شده است، یعنی پنجره ای که دوره ی آزمون را در بر می گیرد. به همین دلیل این مدل هرگز برای تولید هیچ معیار دقتی به کار نمی رود. کاربرد آن تنها ابزار عملیاتی **بخش ۳-۵** است، که برای پیش بینی فردا باید از تازه ترین داده ی موجود استفاده کند و اساساً در وضعیت ارزیابی قرار ندارد.

سوم: مدل تفسیر — برازشی جداگانه، اکیداً پیش از دوره ی آزمون. تحلیل SHAP در **بخش ۴-۶** نه بر مدل های چارچوب پیش رونده انجام می شود و نه بر مدل تثبیت شده بر کل داده. دلیل کنارگذاشتن مورد دوم روشن است: توضیح دادن روزهایی که مدل آن ها را در آموزش دیده، تفسیری درون نمونه ای است. پس **بخش ۴-۶** مدلی مستقل را تفسیر می کند که پنجره ی آموزشش هم طول همان ۱۰۹۲ روز است اما اکیداً پیش از مرز دوره ی آزمون پایان می یابد، و بنابراین هر روزی که توضیح داده می شود واقعاً دیده نشده است. این تضمین در کد زندگی می کند و با آزمون خودکار سنجیده می شود؛ پیاده سازی حتی از برازش بر پنجره ای کوتاه تر سر باز می زند، تا این همزاد در سکوت از مدل گزارش شده فاصله نگیرد.

خلاصه ی قابل واریسی: اعداد از مصنوع نخست می آیند، ابزار از مصنوع دوم، و نمودارهای تفسیرپذیری از مصنوع سوم. تنها مصنوعی که دوره ی آزمون را دیده است، هیچ عددی در این پایان نامه تولید نمی کند.

معیارهای ارزیابی

چهار معیار دقت گزارش می شود. برای پیش بینی $\hat{p}_i$ و مقدار واقعی p_i بر N نقطه:

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |p_i - \hat{p}_i| \quad (1-3)$$

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (p_i - \hat{p}_i)^2} \quad (2-3)$$

$$\text{sMAPE} = \frac{100}{N} \sum_{i=1}^N \frac{|p_i - \hat{p}_i|}{(|p_i| + |\hat{p}_i|) / 2} \quad (3-3)$$

$$\text{rMAE} = \frac{\text{MAE}}{\text{MAE}_{\text{naive}}} \quad (4-3)$$

که در آن‌ها N شمار نقاط ارزیابی، p_i قیمت محقق‌شده، $\hat{p}_i$ قیمت پیش‌بینی‌شده، و $\text{MAE}_{\text{naive}}$ خطای مطلق میانگین یک پیش‌بینی ساده‌ی مرجع است. مقدار rMAE کوچک‌تر از یک یعنی مدل از آن مرجع بهتر است و مقدار بزرگ‌تر از یک یعنی بدتر.

دو مدل ساده که نباید با هم اشتباه شوند

نکته‌ای که اگر تصریح نشود شبیه تناقض به نظر می‌رسد: مدل ساده‌ی این پژوهش rMAE برابر 0.849 دارد، یعنی ظاهراً مرجعی را که خودش تعریف می‌کند شکست می‌دهد. توضیح آن است که دو مدل ساده‌ی متفاوت در کار است و هر دو استاندارد. مدل ساده‌ی گزارش‌شده در جدول‌های فصل چهارم، قاعده‌ی «روز مشابه» است که [بخش ۳-۶](#) آن را تعریف می‌کند. اما مخرج معیار rMAE بنا بر تعریف مرجع، پیش‌بینی ساده‌ی وقفه‌ی هفتگی است: همان ساعت در هفته‌ی پیش. پس 0.849 یعنی قاعده‌ی روز مشابه حدود پانزده درصد از وقفه‌ی هفتگی محض بهتر عمل می‌کند — که دقیقاً همان چیزی است که باید بکند، و سنجه‌ای از ارزش منطق رفتاری روز هفته.

چرا MAPE گزارش نمی‌شود، و چرا sMAPE با آن ناسازگار نیست

از گزارش MAPE متعارف آگاهانه صرف‌نظر شده است. در بازار برق آلمان قیمت‌های منفی واقعاً رخ می‌دهند — ۲۹۷ ساعت در داده‌ی آموزش و ۲۴۱ ساعت در دوره‌ی آزمون — و MAPE بر خود p_i تقسیم می‌کند؛ مخرجی که هم علامت‌پذیر است و هم در صفر تعریف‌ناپذیر. یک ساعت نزدیک به صفر کافی است تا این معیار بدون کران منفجر شود.

اما sMAPE گزارش می‌شود، و باید توضیح داد چرا این دو رفتار متفاوتی دارند. مخرج sMAPE میانگین قدرمطلق مقدار واقعی و پیش‌بینی است، پس تنها در حالتی مشکل‌ساز می‌شود که هر دو هم‌زمان به صفر نزدیک باشند — حالتی به مراتب نادرتر.

شاهد تجربی این تفاوت در خود داده‌ی مرجع موجود است: بر پیش‌بینی‌های یکسان، مقاله‌ی مرجع مقادیر MAPE در بازه‌ی تقریبی ۷۷ تا ۱۳۷ درصد را در برابر sMAPE در بازه‌ی ۱۴ تا ۱۷ درصد گزارش می‌کند — حدود ده برابر — و خود آن مقاله نیز MAPE را در این بازار نامطمئن می‌داند [۱].

با این همه، جمله‌ی تعیین‌کننده این است: هیچ نتیجه‌ای در این پایان‌نامه بر $sMAPE$ استوار نیست. تمام آزمون‌های معناداری بر زیان قدرمطلق محاسبه می‌شوند و هر ادعای سرشناسی بر MAE یا rMAE بنا شده است؛ sMAPE تنها برای امکان مقایسه با جدول منتشرشده گزارش می‌گردد. پیاده‌سازی هر چهار معیار مستقیماً از کتابخانه‌ی مرجع فراخوانی می‌شود و بازنویسی نشده است، تا اعداد فصل چهارم بدون هیچ ابهام پیاده‌سازی با اعداد منتشرشده هم‌مقیاس بمانند.

آزمون معناداری دیبولد-ماریانو

برتری عددی یک مدل بر مدل دیگر ممکن است محصول نوفه باشد. برای هر زوج مدل، آزمون دیبولد-ماریانو^۳ بر سری تفاضل زیان روزانه اجرا می‌شود. اگر d_t تفاضل زیان دو مدل در روز t باشد، آماره‌ی آزمون چنین است:

$$DM = \frac{\bar{d}}{\sqrt{\widehat{\text{Var}}_{\text{HAC}}(\bar{d})}} \quad (۵-۳)$$

که در آن $\bar{d}$ میانگین تفاضل زیان و مخرج، خطای معیار آن با تصحیح HAC است. این تصحیح

^۳ Diebold–Mariano

ضروری است: خطاهای پیش‌بینی در روزهای متوالی همبسته‌اند و نادیده گرفتن این همبستگی، معناداری را به صورت کاذب بزرگ نشان می‌دهد. تمام p -مقادیرهای این پایان‌نامه یک‌طرفه و تصحیح‌شده‌اند، و هیچ‌جا مقدار تصحیح‌نشده نقل نمی‌شود.

دو خانوادگی آزمون: تأییدی و اکتشافی

بخش ۴-۵-۱ ماتریسی هفت در هفت از مقایسه‌های زوجی گزارش می‌کند، که ۲۱ آزمون مستقل می‌شود. در چنین شماری، در سطح معناداری پنج درصد به‌طور میانگین حدود یک برنده‌ی کاذب انتظار می‌رود. اعلام‌نکردن این نکته، هر نتیجه‌ی نزدیک به مرز را بی‌اعتبار می‌کند.

از این رو، پیش از آنکه هیچ p -مقداری نقل شود، دو خانوادگی آزمون به‌صراحت تفکیک می‌شوند. **خانوادگی تأییدی، شامل یک فرضیه‌ی از پیش تعیین‌شده:** مقایسه‌ی وزن‌دهی رژیم‌محور با وزن‌دهی ایستا. این فرضیه در دفتر تصمیمات پروژه ثبت شده است، در تاریخی که هنوز مدل ترکیبی رژیم‌محور ساخته نشده و هیچ مدل ترکیبی‌ای بر دوره‌ی آزمون سنجیده نشده بود. پس این فرضیه نمی‌توانسته با نگاه کردن به نتایج انتخاب شده باشد. یک فرضیه‌ی واحد از پیش تعیین‌شده در سطح پنج درصد و بدون تصحیح آزموده می‌شود؛ این رویه‌ی استاندارد است و مدخل تاریخ‌دار همان چیزی است که آن را قابل واریسی می‌کند.

خانوادگی اکتشافی، شامل کل ماتریس ۲۱ تایی: برای این خانواده، هم p -مقدار خام و هم p -مقدار تصحیح‌شده با روش هولم-بونفرونی گزارش می‌شود. گزارش کردن تنها مقدار خام نادرست است و پنهان کردن آن گریزگرایانه به نظر می‌رسد؛ پس هر دو ستون می‌آید.

پیامد عملی این تفکیک در **بخش ۴-۵-۱** دیده می‌شود و به سود پژوهش نیست: یکی از تفاوت‌هایی که در نگاه نخست معنادار می‌نماید، پس از تصحیح دوام نمی‌آورد و در متن نیز به‌عنوان تفاوت معنادار گزارش نمی‌شود.

تکرارپذیری

بذر تصادفی سراسری ۴۲ در تمام اجزای تصادفی — نمونه‌گیر جست‌وجوی ابرپارامتر، مدل‌های درختی و شبکه‌های عصبی — تثبیت شده و در کد به‌گونه‌ای تحمیل می‌شود که هیچ فایل پیکربندی یا ابرپارامتر تنظیم‌شده‌ای نتواند آن را بازنویسی کند. هر تصمیم غیربديهی روش‌شناختی نیز با تاریخ در دفتر ثبت تصمیمات پروژه مستند شده است، تا مسیر رسیدن به هر انتخاب پس از پایان کار نیز قابل بازسازی

باشد.

۳-۶ مدل‌های پایه

هر سه مدل این بخش بر یک واسط مشترک پیاده‌سازی شده‌اند و همگی از منبع یکتای ویژگی بخش ۳-۴ تغذیه می‌کنند. در نتیجه چارچوب اعتبارسنجی بخش ۳-۵ هر سه را بدون هیچ حالت خاصی می‌راند، و تفاوت عملکرد تنها به خودِ مدل بازمی‌گردد و نه به تفاوت در خوراک داده.

این یکدستی، تصمیم طراحی آگاهانه‌ای است و نه راحتی مهندسی. هر مدلی که مسیر ویژگی‌سازیِ مخصوص خود را داشته باشد، سطح تازه‌ای برای نشت اطلاعات می‌گشاید که آزمون بخش ۳-۴ آن را پوشش نمی‌دهد؛ و هر تفاوتی در پنجره‌ی آموزش یا ترتیب ستون‌ها، بخشی از اختلاف دقت را به عاملی جز خودِ مدل نسبت می‌دهد. سه مدل این بخش، مرجع‌هایی هستند که مدل‌های بخش ۳-۷ در برابر آن‌ها سنجیده می‌شوند؛ اعتبار آن سنجش تماماً به یکسان‌بودن شرایط بستگی دارد.

مدل ساده‌ی مرجع

مدل ساده‌ی «روز مشابه»، مطابق تعریف مرجع [۱]، چنین است: برای سه‌شنبه تا جمعه، قیمت‌های ۲۴‌گانه‌ی روز پیش (D-1)؛ برای دوشنبه، قیمت‌های جمعه‌ی پیش (D-3)؛ و برای شنبه و یکشنبه، قیمت‌های همان روز در هفته‌ی پیش (D-7).

منطق این قاعده رفتاری است و شاهد تجربی‌اش در بخش ۳-۳-۳ آمد: دوشنبه با یکشنبه‌ی پیش از خود شباهت ساختاری ندارد، پس به آخرین روز کاری ارجاع داده می‌شود، و روزهای تعطیل به هم‌تای خود در هفته‌ی پیشین.

این مدل هیچ پارامتری برازش نمی‌کند و صرفاً انتخاب ستون از ماتریس ویژگی مشترک است؛ متد برازش آن عامدانه بی‌اثر است و تنها برای پایبندی به واسط مشترک وجود دارد. لازمه‌ی آن این است که فهرست وقفه‌های قیمتی در پیکربندی، دربردارنده‌ی وقفه‌های ۱، ۳ و ۷ باشد، که پیکربندی پیش‌فرض آن را برآورده می‌کند.

نقش این مدل دوگانه است: کفِ عملکرد برای سنجش سایر مدل‌ها، و نقطه‌ی مرجعِ تفسیر معیار rMAE. بر دوره‌ی آزمون، MAE ساعتی آن 7.750 و rMAE آن 0.849 است. درباره‌ی اینکه چرا این عدد برابر یک نیست، بخش ۳-۵ توضیح داده است.

مدل SARIMAX

به عنوان نماینده‌ی رویکرد کلاسیک آماری، ۲۴ مدل SARIMAX مستقل — یکی به ازای هر ساعت شبانه‌روز — برازش می‌شود. این تجزیه‌ی ساعت به ساعت با ساختار مدل LEAR-LASSO هم‌قرینه است و با ادبیات بازار برق سازگار، زیرا هر ساعت از شبانه‌روز رفتار آماری متمایزی دارد [۲]؛ بخش ۳-۳ دامنه‌ی این تفاوت را نشان داد.

مرتبه‌ی مدل (۱, ۱, ۱) و مرتبه‌ی فصلی (۱, ۰, ۱) با دوره‌ی تناوب هفت‌روزه انتخاب شده است — یعنی فصلی بودن در مقیاس هفته و نه شبانه‌روز، چرا که بعد ساعتی پیشاپیش با تفکیک ۲۴ گانه‌ی مدل‌ها جذب شده است. متغیرهای برون‌زا، پیش‌بینی‌های روزپیش‌بار و تولید تجدیدپذیر برای خودِ روز هدف‌اند که، بنا بر استدلال بخش ۳-۴، پیش از مبدأ منتشر می‌شوند و استفاده از آن‌ها نشت اطلاعات نیست.

برخلاف دو مدل دیگر این بخش، SARIMAX افزوده‌ی خود این پژوهش است و در فهرست مدل‌های مقاله‌ی مرجع جایی ندارد؛ نقش آن، تأمین یک مرجع کلاسیک و تفسیرپذیر در کنار مرجع خطی ادبیات است.

انحراف ثبت شده از پروتکل واسنجی روزانه. برازش کامل ۲۴ مدل فصلی در ۷۲۸ مبدأ، یعنی نزدیک به هفده هزار و پانصد برازش، عملی نیست؛ و برخلاف LEAR، سابقه‌ای در ادبیات مرجع برای آهنگ واسنجی SARIMAX وجود ندارد که رعایت آن الزامی باشد. لذا برازش کامل هر هفت روز انجام می‌شود و در میانه‌ی آن از به‌روزرسانی ارزان فضای حالت استفاده می‌گردد: مشاهدات تازه به فیلتر افزوده می‌شوند و حالت مدل پیش می‌رود، بی‌آنکه پارامترها دوباره بهینه شوند.

نکته‌ی مهم آنکه پیش‌بینی همچنان برای هر مبدأ روزانه تولید می‌شود — گام چارچوب پیش‌رونده همچنان یک روز است — پس شمار و افق پیش‌بینی‌ها میان مدل‌ها یکسان و مقایسه‌ی روزانه منصفانه باقی می‌ماند؛ تنها پارامترهای برازشی خود SARIMAX است که میان دو بازبرازش ثابت نگه داشته می‌شود. این تصمیم با تاریخ در دفتر تصمیمات ثبت شده است، به جای آنکه در سکوت در کد بماند.

بر دوره‌ی آزمون، MAE ساعتی این مدل 4.351 و rMAE آن 0.477 است: به‌روشنی بهتر از مدل ساده، اما ضعیف‌ترین عضو در میان مدل‌های برازشی.

مدل LEAR-LASSO

مدل LEAR، یعنی رگرسیون خودتوضیح با تنظیم لاسو، مدل خطی مرجع ادبیات این حوزه است [۱، ۱۹]. به ازای هر ساعت، یک رگرسیون لاسو بر ۲۴۷ ویژگی **بخش ۳-۴** برازش می‌شود. تابع هدف لاسو برای بردار ضرایب β چنین است:

$$\hat{\beta} = \arg \min_{\beta} \left\{ \sum_{t=1}^T (p_t - x_t^T \beta)^2 + \lambda \sum_{j=1}^J |\beta_j| \right\} \quad (۳-۶)$$

که در آن p_t قیمت محقق شده در روز t ، بردار ویژگی همان روز، T شمار روزهای پنجره‌ی واسنجی، J شمار ویژگی‌ها و λ ضریب جریمه است. جمله‌ی دوم، مجموع قدرمطلق ضرایب را جریمه می‌کند و در نتیجه بسیاری از آن‌ها را دقیقاً صفر می‌کند؛ همین ویژگی است که لاسو را برای ماتریسی با ۲۴۷ ستون و پنجره‌ای با ۱۰۹۲ سطر مناسب می‌سازد.

ضریب λ با معیار اطلاعات آکائیکه انتخاب می‌شود و واسنجی مدل روزانه است. پنجره‌ی واسنجی ۱۰۹۲ روز است، همان مقداری که در فایل پیکربندی ارزیابی به عنوان منبع یکتای این عدد برای کل خط لوله تعریف شده است. نکته‌ی مهم آنکه λ در هر برازش از نو انتخاب می‌شود؛ یعنی این مدل ابرپارامتر دستی تنظیم شده‌ای ندارد و برخلاف مدل‌های **بخش ۳-۷** نیازمند جست‌وجوی Optuna نیست.

پیاده‌سازی از واسط سطح پایین خود کتابخانه‌ی مرجع استفاده می‌کند، اما ماتریس‌های ویژگی از خط لوله‌ی نشت آزموده‌ی **بخش ۳-۴** به آن داده می‌شود و نه از سازنده‌ی داخلی خود کتابخانه. علت این انتخاب همان اصل ابتدای بخش است: اعتماد به یک سازنده‌ی ویژگی دوم، مسیر دومی برای نشت می‌ساخت که آزمون‌های ما آن را نمی‌پوشاند. ترتیب و شمار ستون‌ها دقیقاً با فرمول ویژگی مرجع منطبق است.

راستی آزمایی زنجیره‌ی کامل. صحت کل زنجیره — بارگذار داده، مهندسی ویژگی، چارچوب پیش‌رونده و پیاده‌سازی مدل — با مقایسه‌ی مستقیم خروجی این مدل با پیش‌بینی‌های خام منتشرشده‌ی خود مقاله‌ی مرجع بر همان دوره‌ی آزمون راستی آزمایی شد.

نخست هم‌سانی داده احراز شد: بیشینه‌ی اختلاف مطلق میان سری قیمت واقعی دو خط لوله، بر تمام 17,472 ساعت، صفر بود. سپس MAE ساعتی مدل ما 3.899 در برابر 3.930 برای گونه‌ی منتشرشده‌ی LEAR 1092 به دست آمد — یعنی بازتولیدی وفادار با همان پروتکل و همان داده.

قیدی که باید همراه این عدد بیاید. این هم‌ترازی را نباید به ادعای «شکست بنچمارک» تعمیم داد. در همان مقایسه، گونه‌های ترکیبی منتشرشده همچنان پیش‌اند: DNN Ensemble^۴ با 3.413 و LEAR Ensemble با 3.609. آنچه این بخش مجاز به ادعای آن است «کیفیت بازتولید» است و نه برتری. همین قید، مبنای تصمیم‌ایست‌بازرسی میانی پروژه بود که خط دفاعی پژوهش را از شکست بنچمارک به مسیر نوآوری محور تغییر داد. جدول کامل و آزمون‌های معناداری آن در بخش ۴-۵-۲ می‌آید.

۷-۳ مدل‌های یادگیری ماشین و یادگیری عمیق

دو مدل غیرخطی در این پژوهش به کار می‌روند: LightGBM به‌عنوان نماینده‌ی خانواده‌ی درختی و LSTM به‌عنوان نماینده‌ی خانواده‌ی یادگیری عمیق. این دو، پرکاربردترین خانواده‌های غیرخطی در ادبیات اخیر پیش‌بینی قیمت برق‌اند [۳، ۴].

فهرست مدل‌ها عامدانه کوتاه است. جنگل تصادفی، XGBoost، ماشین بردار پشتیبان و GRU همگی بررسی و از دامنهی پژوهش کنار گذاشته شدند. منطق این محدودسازی آن است که افزودن گونه‌های بیشتر از یک خانواده، به‌جای پاسخ به پرسش «کدام خانواده‌ی مدل در این بازار بهتر عمل می‌کند»، بودجه‌ی تنظیم و توان تحلیل را میان گونه‌هایی پخش می‌کند که رفتار مشابهی دارند. یک نماینده‌ی خوب تنظیم‌شده از هر خانواده، اطلاعات بیشتری می‌دهد تا پنج نماینده‌ی کم‌تنظیم. سه قید بر هر دو مدل این بخش یکسان اعمال می‌شود، و همین یکسانی است که مقایسه‌ی آن‌ها را معنادار می‌کند.

نخست، بودجه‌ی برابر تنظیم: هر دو مدل با ۵۰ آزمایش Optuna تنظیم شده‌اند، بر پنجره‌ی اعتبارسنجی یکسان که اکیداً پیش از دوره‌ی آزمون قرار دارد. این برابری، پاسخ پیشاپیش پرسشی است که به‌درستی پرسیده خواهد شد: آیا مدل عمیق صرفاً کم‌تنظیم نشده است؟ بودجه یکسان بوده و در متن ثبت شده است.

دوم، تابع زیان هم‌تراز: هر دو مدل بر زیان قدرمطلق آموزش می‌بینند، هم‌راستا با معیار سرشناس گزارش در فصل چهارم. بدون این هم‌ترازی، بخشی از اختلاف میان دو مدل به تفاوت در تابع زیان بازمی‌گشت و مقایسه به مصنوعی از انتخاب زیان بدل می‌شد.

سوم، منبع یکتای ویژگی: هر دو از همان ماتریس ۲۴۷ ستونی بخش ۳-۴ تغذیه می‌کنند و هیچ‌یک مسیر ویژگی‌سازی اختصاصی ندارد.

بخش ۱-۷-۳ مدل درختی و **بخش ۲-۷-۳** مدل عمیق را شرح می‌دهد. در هر دو، آهنگ واسنجی، رویه‌ی تنظیم و سازوکارهای تضمین بازتولیدپذیری به تفصیل می‌آید، چون همین جزئیات‌اند که تعیین می‌کنند اعداد فصل چهارم تکرارپذیر باشند یا نه.

LightGBM ۱-۷-۳

نخستین مدل غیرخطی این پژوهش LightGBM است: پیاده‌سازی کارآمدی از تقویت گرادیانی بر درخت‌های تصمیم، که در ادبیات پیش‌بینی قیمت برق به‌عنوان نماینده‌ی استاندارد خانواده‌ی مدل‌های درختی به کار می‌رود [۲، ۴]. انتخاب آن — به جای جنگل تصادفی یا XGBoost که هر دو آگاهانه از دامنه‌ی پژوهش کنار گذاشته شدند — بر دو ملاحظه استوار است: کارایی محاسباتی، که واسنجی روزانه را در ۷۲۸ مبدأ ممکن می‌سازد، و توان بالای آن در داده‌های جدولی با ویژگی‌های ناهمگن، که دقیقاً ساختار ماتریس ویژگی **بخش ۳-۴** است.

ساختار مدل

به‌ازای هر ساعت شبانه‌روز یک رگرسور مستقل برازش می‌شود؛ یعنی ۲۴ مدل مجزا که هیچ‌یک از دیگری اطلاعی ندارد. این تصمیم عامدانه با ساختار ساعت‌به‌ساعت LEAR-LASSO و SARIMAX (**بخش ۳-۶**) هم‌قرینه است، تا اختلاف عملکرد میان مدل خطی و مدل درختی به خود خانواده‌ی مدل بازگردد و نه به تفاوت در نحوه‌ی تجزیه‌ی افق پیش‌بینی.

هر یک از این ۲۴ مدل، کل ماتریس ویژگی مشترک را دریافت می‌کند: هر ۲۴۷ ستون، شامل وقفه‌های قیمتی، وقفه‌ها و مقادیر روزپیش متغیرهای برون‌زا، و متغیرهای مجازی روز هفته. هیچ مسیر ویژگی‌سازی جداگانه‌ای برای این مدل وجود ندارد و در نتیجه سطح دومی برای نشت اطلاعات ایجاد نمی‌شود.

یادداشت پیاده‌سازی: پیمانه‌ی این مدل عامدانه نامی متفاوت از خود بسته‌ی LightGBM دارد، تا در هیچ شرایطی با آن اشتباه گرفته نشود یا آن را سایه نیندازد.

آهنگ واسنجی

برخلاف SARIMAX که برازش کامل آن در هر مبدأ عملی نبود (**بخش ۳-۶**)، LightGBM بر پنجره‌ی واسنجی ۱۰۹۲ روزه در چند ثانیه برازش می‌شود. از این رو هیچ مصالحه‌ای در آهنگ واسنجی لازم نیست و مدل در هر مبدأ به‌طور کامل بازبرازش می‌گردد — یعنی دقیقاً همان پروتکل واسنجی روزانه‌ای

که مدل مرجع LEAR از آن پیروی می‌کند [۱]. این هم‌ترازی، مقایسه‌ی مستقیم دو مدل را از شبهه‌ی «تفاوت در تازگی برازش» پاک می‌کند.

تنظیم ابرپارامترها

ابریارامترها با ۵۰ آزمایش Optuna تنظیم شده‌اند. پنجره‌ی اعتبارسنجی، از ۵ ژانویه ۲۰۱۵ تا ۳ ژانویه ۲۰۱۶، اکیداً پیش از دوره‌ی آزمون قرار دارد، و پنجره‌ی برازش آن، از ۱۶ ژانویه ۲۰۱۲ تا ۴ ژانویه ۲۰۱۵، پیش از خود پنجره‌ی اعتبارسنجی است. بدین ترتیب هیچ مشاهده‌ای از دوره‌ی آزمون در انتخاب ابریارامترها نقشی ندارد. بذر نمونه‌برداری جست‌وجو نیز ۴۲ تثبیت شده تا خود فرایند تنظیم بازتولیدپذیر بماند.

تابع هدف بر زیان قدرمطلق تنظیم شده است تا زیان آموزش با معیار سرشناسی گزارش هم‌راستا باشد؛ همین انتخاب برای LSTM نیز تکرار می‌شود تا مقایسه‌ی آن دو مخدوش نشود. بهترین پیکربندی یافت‌شده، با MAE اعتبارسنجی 3.7316، چنین است: شمار درخت‌ها ۹۶۳، نرخ یادگیری 0.0245، شمار برگ‌ها ۱۵، کمینه‌ی نمونه در برگ ۱۱، نسبت ویژگی 0.542، نسبت نمونه‌گیری 0.513 با تناوب ۳، و جریمه‌های L1 و L2 به ترتیب 0.316 و $7.04e-08$.

جهت‌گیری این جست‌وجو خود گویاست. نسبت به مقادیر پیش‌فرض، شمار برگ‌ها از ۶۳ به ۱۵ کاهش و در مقابل شمار درخت‌ها از ۵۰۰ به ۹۶۳ افزایش یافته و نرخ یادگیری نصف شده است. یعنی جست‌وجو به سمت مدلی کوچک‌تر، منظم‌تر و آهسته‌تر حرکت کرده — الگویی که با ماهیت پرنوفه‌ی سری قیمت برق و خطر بیش‌برازش بر ویژگی‌های فراوان سازگار است.

تضمین بازتولیدپذیری

سه پارامتر، فارغ از محتوای فایل پیکربندی یا نتیجه‌ی تنظیم، در خود کد تحمیل می‌شوند: بذر تصادفی ۴۲، پرچم جبرگرایی، و مهم‌تر از هر دو، شمار ثابت نخ‌های پردازش.

علت تثبیت صریح شمار نخ‌ها — به جای واگذاری آن به مقدار خودکار — ظریف و ضروری است: تضمین جبرگرایی این کتابخانه تنها به‌ازای شمار نخ یکسان برقرار است. اگر این مقدار با مشخصات ماشین شناور بماند، اجرای همان کد بر سخت‌افزاری دیگر می‌تواند اعدادی متفاوت تولید کند، و آنگاه ادعای بازتولیدپذیری نتایج تثبیت‌شده بی‌اعتبار می‌شود. این مقدار پس از آنکه آزمایش‌های تک‌نخی تنظیم به درازا کشید افزایش یافت، و تغییر آن به‌عنوان یک انتخاب ثبت‌شده و نه یک تنظیم محیطی، در دفتر تصمیمات درج شده است.

عملکرد و ارجاع به فصل چهارم

بر دوره‌ی آزمون ۷۲۸ مبدأیی، MAE ساعتی این مدل 3.968 و rMAE آن 0.435 است؛ جدول کامل در **بخش ۲-۴** می‌آید. دو ملاحظه‌ی صادقانه باید همین‌جا ثبت شود.

نخست آنکه این مدل غیرخطی، مدل خطی LEAR-LASSO را در MAE ساعتی پشت سر نمی‌گذارد: 3.968 در برابر 3.899. برتری روش‌های انعطاف‌پذیر بر مدل خطی مرجع، در این بازار و این دوره محقق نشده است.

دوم آنکه در آزمون برون‌توزیعی فصل پنجم، همین مدل بیشترین افت را در میان تمام مدل‌ها نشان می‌دهد، با rMAE برابر 1.828. تفسیر این دو یافته در کنار یکدیگر — یعنی اینکه انعطاف‌پذیری بالاتر در درون‌دوره مزیتی نساخت اما در برون‌توزیع هزینه‌ی سنگین‌تری تراشید — در **بخش ۲-۵** می‌آید.

LSTM ۲-۷-۳

بازوی یادگیری عمیق این پژوهش یک شبکه‌ی حافظه‌ی کوتاه‌مدت بلند است. انگیزه‌ی انتخاب آن، ساختار توالی‌وار سری قیمت است: قیمت هر روز نه یک بردار منفرد، بلکه حلقه‌ای از زنجیره‌ای است که روزهای پیشین آن را شکل داده‌اند، و لایه‌ی بازگشتی سازوکاری صریح برای مدل‌سازی همین وابستگی زمانی در اختیار می‌گذارد [۲۹، ۲۰] — چیزی که نه مدل خطی LEAR و نه مدل درختی LightGBM به‌صراحت ندارند و تنها از طریق ویژگی‌های وقفه‌ای به آن دسترسی می‌یابند.

معماری دوشاخه

شبکه دو ورودی مجزا دارد که در میانه‌ی مسیر به هم می‌پیوندند.

شاخه‌ی توالی. به‌ازای هر وقفه‌ی قیمتی پیکربندی‌شده — به‌ترتیب از کهنه به تازه: D-7، D-3، D-2 و D-1 — یک گام زمانی ساخته می‌شود و محتوای هر گام، بردار ۲۴ ساعته‌ی قیمت همان روز وقفه است. حاصل، دنباله‌ای چهارگامی با بُعد ۲۴ در هر گام است که به لایه‌ی بازگشتی خوراند می‌شود. انتخاب ستون‌ها صریحاً بر اساس نام ستون انجام می‌گیرد و هرگز بر پایه‌ی موقعیت آن؛ اگر ستونی از قلم بیفتد، مدل با خطا متوقف می‌شود و به‌آرامی روی ستون اشتباه برآزش نمی‌شود. این تمایز اهمیت دارد، چون برآزش بر ستون اشتباه هیچ نشانه‌ی بیرونی ندارد.

شاخه‌ی ایستا. تمام ستون‌های باقی‌مانده‌ی ماتریس ویژگی — وقفه‌های متغیرهای برون‌زا، پیش‌بینی‌های روزپیش خود روز هدف، و متغیرهای مجازی روز هفته — به‌صورت یک بردار مسطح وارد می‌شوند.

خروجی لایه‌ی بازگشتی با بردار ایستا الحاق می‌شود، از یک لایه‌ی چگال با تابع فعال‌ساز ^۵ReLU می‌گذرد، و در نهایت به لایه‌ی چگال ^{۲۴}تایی می‌رسد که همان بردار قیمت ساعتی روز $D+1$ است. بهینه‌ساز آموزش ^۶Adam است.

نکته‌ی روش‌شناختی مهم در این معماری آن است که هر دو شاخه از همان ماتریس ویژگی مشترک تغذیه می‌شوند که سایر مدل‌ها مصرف می‌کنند. مسیر جداگانه‌ای برای ساخت توالی وجود ندارد. اگر چنین مسیری ساخته می‌شد، سطح دومی برای نشت اطلاعات پدید می‌آمد که آزمون بخش ۳-۴ آن را پوشش نمی‌داد؛ در عوض، تنها یک منبع ویژگی وجود دارد و همان یک منبع ممیزی شده است.

مقیاس‌بندی

هر سه جزء — دنباله‌ی ورودی، بردار ایستا و خودِ هدف — استاندارد می‌شوند و پیش‌بینی‌ها در انتها به مقیاس اصلی بازگردانده می‌شوند.

تصریح ضروری آن است که این مقیاس‌گرها تنها بر برش آموزش همان بازبرازش برآزش می‌شوند، نه بر کل سری. برآزش مقیاس‌گر بر تمام داده، میانگین و انحراف معیار دوره‌ی آزمون را به مرحله‌ی آموزش نشت می‌داد؛ نشتی ظریف که هیچ خطایی تولید نمی‌کند و تنها نتیجه را به آرامی خوش‌بینانه می‌سازد.

تابع زیان

زیان آموزش، خطای مطلق میانگین است. این انتخاب دو کارکرد دارد: هم‌راستایی با معیار سرشناس گزارش در فصل چهارم، و هم‌ترازی با تابع هدف LightGBM (بخش ۳-۷-۱). بدون این هم‌ترازی، بخشی از اختلاف میان دو مدل به تفاوت در تابع زیان بازمی‌گشت و مقایسه، به جای پاسخ به پرسش «کدام خانواده‌ی مدل بهتر است»، به مصنوعی از انتخاب زیان تبدیل می‌شد.

آهنگ واسنجی و پاسداشت ترتیب زمانی

بازآموزی کامل یک شبکه‌ی عصبی در هر یک از ۷۲۸ مبدأ، بر سخت‌افزار این پژوهش عملی نبود. لذا بازبرازش کامل هر هفت روز انجام می‌شود و شبکه در فاصله‌ی میان دو بازبرازش بدون تغییر به کار می‌رود. با این همه پیش‌بینی همچنان برای هر مبدأ روزانه تولید می‌شود، پس افق و شمار پیش‌بینی‌ها میان مدل‌ها یکسان می‌ماند. این انحراف از پروتکل واسنجی روزانه، هم‌سنگ انحراف ثبت‌شده برای

^۵ Rectified Linear Unit

^۶ Adaptive Moment Estimation

SARIMAX (بخش ۳-۶)، به‌صراحت در دفتر تصمیمات ثبت شده است و نه به‌عنوان جزئیاتی پنهان در پیاده‌سازی.

افزون بر آن، پیاده‌سازی یک پاسبان صریح دارد: اگر پنجره‌ی آموزش درخواستی پایانی پیش از آخرین بازبرازش کامل داشته باشد، مدل با خطا متوقف می‌شود. چنین حالتی به‌معنای پاسخ‌دادن به یک مبدأ گذشته با شبکه‌ای است که بر داده‌ی متأخرتر آموزش دیده — یعنی نشت اطلاعات واقعی. چارچوب پیش‌رونده مبادی را یکنواخت و صعودی تولید می‌کند، پس فعال‌شدن این پاسبان تنها می‌تواند نشانه‌ی اشکال در فراخوان باشد.

تنظیم ابرپارامترها

همانند LightGBM، ۵۰ آزمایش Optuna با بذر نمونه‌بردار ۴۲، بر پنجره‌ی اعتبارسنجی ۵ ژانویه‌ی ۲۰۱۵ تا ۳ ژانویه‌ی ۲۰۱۶ و پنجره‌ی برازش ۱۶ ژانویه‌ی ۲۰۱۲ تا ۴ ژانویه‌ی ۲۰۱۵ — هر دو اکیداً پیش از دوره‌ی آزمون. بهترین پیکربندی: ۲۹ واحد پنهان، ۴۷ دوره‌ی آموزش، اندازه‌ی دسته‌ی ۳۲ و نرخ یادگیری ۰.۰۰۰۸۳، با MAE اعتبارسنجی ۰.۳۶۹۶.

شایان توجه است که جست‌وجو شبکه‌ای کوچک‌تر از پیش‌فرض را برگزید — ۲۹ واحد در برابر ۶۴ — همان جهت‌گیری منظم‌سازانه‌ای که در تنظیم LightGBM نیز دیده شد، و نشانه‌ی محدودبودن اطلاعات قابل استخراج از این سری در برابر ظرفیت مدل است.

جبرگرایی

پیش از هر ساخت و برازش، بذر تصادفی سراسری ۴۲ تثبیت و جبرگرایی عملیات فعال می‌شود؛ شمار نخ‌های پردازش نیز بر مقداری ثابت تنظیم می‌گردد تا هم نتیجه بازتولیدپذیر بماند و هم اجراهای هم‌زمان چارچوب پیش‌رونده بی‌ثبات نشوند. اگر جبرگرایی عملیات در محیطی در دسترس نباشد، پیاده‌سازی هشدار صریح می‌دهد، به‌جای آنکه در سکوت تضمین بازتولیدپذیری را از دست بدهد.

عملکرد، و آنچه درباره‌ی آن نباید ادعا شود

بر دوره‌ی آزمون، MAE ساعتی این مدل ۳.۸۷۳ و rMAE آن ۰.۴۲۴ است — یعنی بهترین مدل منفرد در جدول ۴-۱. اما این عدد به‌تنهایی گمراه‌کننده است و سه قید باید همراه آن بیاید.

نخست، آزمون دیبولد-ماربانو با تصحیح HAC نشان می‌دهد که برتری این مدل بر LEAR-LASSO معنادار نیست: p برابر ۰.۴۰۴. این یک تساوی آماری است، نه یک پیروزی، و در سرتاسر پایان‌نامه به

همین صورت گزارش می‌شود.

برتری آن بر LightGBM نیز، برخلاف آنچه نگاه نخست به p -مقدار خام (0.0405) نشان می‌دهد، از تصحیح چندگانگی جان به در نمی‌برد: در خانواده‌ی اکتشافی ۲۱ تایی که بخش ۳-۵ آن را اعلام کرد، مقدار تصحیح‌شده با روش هولم-بونفرونی برابر 0.1215 است. پس آنچه می‌توان گفت این است که LSTM برآورد نقطه‌ای پایین‌تری دارد، و این تفاوت پس از تصحیح برای چندگانگی دوام نمی‌آورد. خوانش صادقانه آن است که LEAR-LASSO، LightGBM و LSTM متقابلاً تفکیک‌ناپذیرند.

دوم، در آزمون برون‌توزیعی بر داده‌ی زنده‌ی ۲۰۲۶، همین مدل دومین افت شدید را پس از LightGBM نشان می‌دهد: rMAE برابر 1.520 در برابر 1.087 برای LEAR-LASSO. یعنی مدلی که مزیت درون‌دوره‌اش از نظر آماری قابل تفکیک نبود، در برابر تغییر شرایط شکننده‌تر نیز هست.

سوم، تحلیل SHAP بخش ۴-۶ بر یک برازش ایستای انجام شده و نه بر مدلی که در هر مبدأ بازواسنجی می‌شود؛ لذا نمودارهای اهمیت ویژگی، تصویر همان مدلی که اعداد دقت را تولید کرده است نیستند. آن برازش، مطابق تفکیکی که بخش ۳-۵ میان سه مصنوع مدل قائل شد، پنجره‌ی آموزشی اکیداً پیش از مرز دوره‌ی آزمون دارد و بنابراین هر روز توضیح‌داده‌شده برای آن دیده‌نشده است؛ همزادی وفادار است و نه همان مدل. این قید در بخش ۴-۶ نیز تصریح شده است.

جمع‌بندی صادقانه آن است که مدل عمیق در این پژوهش بهترین عدد میانگین را تولید کرد، بدون آنکه برتری‌اش بر مدل خطی مرجع از حد نوسان آماری فراتر رود، و با هزینه‌ای آشکار در تعمیم‌پذیری بیرون از دوره‌ی آموزش. تفصیل این بحث در بخش‌های ۴-۵ و ۵-۲ می‌آید.

۳-۸ مدل ترکیبی

چرا ترکیب

هر یک از چهار مدل برازشی این پژوهش خطای متفاوتی مرتکب می‌شود. مدل خطی در شرایطی می‌لغزد که مدل درختی از پس آن برمی‌آید و بالعکس. ترکیب وزن‌دار، همین ناهم‌بستگی خطاها را به دقت تبدیل می‌کند و در ادبیات پیش‌بینی قیمت برق از راه‌های شناخته‌شده‌ی بهبود دقت است [۲]؛ گونه‌های ترکیبی خود مقاله‌ی مرجع نیز بهترین اعداد آن مقاله‌اند [۱].

این بخش دو مدل ترکیبی معرفی می‌کند: نخست ترکیب ایستا، سپس ترکیب رژیم‌محور که سهم مشارکت پژوهش حاضر است.

ترکیب ایستا

ترکیب ایستا یک بردار وزن ثابت بر چهار مدل برازشی — LightGBM, LEAR-LASSO, SARIMAX و LSTM — اعمال می‌کند. مدل ساده در ترکیب شرکت داده نمی‌شود، چون نقش آن مرجع است و نه عضو.

وزن‌ها با کمینه‌سازی خطای مطلق میانگین بر پنجره‌ی برازش وزن به دست می‌آیند، با دو قید که ترکیب را محدب نگه می‌دارند:

$$\hat{w} = \arg \min_w \frac{1}{N} \sum_{i=1}^N \left| p_i - \sum_{m=1}^M w_m \hat{p}_{m,i} \right| \quad \text{به شرط} \quad w_m \geq 0, \quad \sum_{m=1}^M w_m = 1 \quad (7-3)$$

که در آن M شمار مدل‌های عضو، $\hat{p}_{m,i}$ پیش‌بینی مدل m در نقطه‌ی i و w_m وزن آن مدل است. قید نامنفی بودن و قید جمع‌شدن به یک، هر دو عامدانه‌اند: بدون آن‌ها بهینه‌ساز می‌تواند وزن‌های بزرگ و مخالف‌علامت پیدا کند که بر پنجره‌ی برازش عالی عمل می‌کنند و بیرون از آن ناپایدارند.

پیاده‌سازی در برابر شکست خاموش محافظت شده است: اگر بهینه‌ساز همگرا نشود یا وزن‌هایی بازگرداند که به یک جمع نمی‌شوند، اجرا با خطا متوقف می‌شود، به جای آنکه وزن‌های یکنواخت را در سکوت جایگزین کند و جدول‌های پس از آن همچنان برچسب «وزن‌های بهینه» را حمل کنند.

افشای نخست. وزن‌ها بر پنجره‌ی تنظیم خود اعضا برازش شده‌اند، یعنی بازه‌ای که آن اعضا برپارامترهایشان را از آن گرفته‌اند. این را باید گفت. آنچه آن را مهار می‌کند این است که مقایسه‌ای که این وزن‌ها تغذیه می‌کنند — یعنی رژیم‌محور در برابر ایستا — همین مزیت را به‌طور یکسان به هر دو طرف می‌دهد، پس تفاوت میان آن دو از این بابت مخدوش نمی‌شود. آنچه مخدوش می‌شود مقایسه‌ی ترکیب با تک‌مدل‌هاست، که با احتیاط بیشتری باید خوانده شود.

تعریف رژیم بازار

بخش ۳-۳-۳ نشان داد که نوسان در این سری خوشه‌ای است: دوره‌های آرام و پرتلاطم کنار هم می‌نشینند. اگر رفتار بازار در این دو حالت به‌قدر کافی متفاوت باشد، بردار وزنی که در حالت آرام بهینه است لزوماً در حالت پرتنش بهینه نیست. ترکیب رژیم‌محور بر همین فرض استوار است.

دو رژیم تعریف می‌شود — آرام و پرتنش — و مرز آن‌ها یک آستانه‌ی قیمتی است:

$$\tau = \mu_{\text{train}} + k \cdot \sigma_{\text{train}} \quad (۸-۳)$$

که در آن μ_{train} و σ_{train} میانگین و انحراف معیارِ قیمت بر بخشی از داده‌ی آموزش، و k ضریبی است که باید انتخاب شود. مقادیر عددی چنین است: میانگین 37.6876 و انحراف معیار 16.6742 بر قیمت‌های تا پایان ۴ ژانویه‌ی ۲۰۱۵، که با k برابر 1.5 آستانه‌ی 62.6989 یورو بر مگاوات‌ساعت را می‌دهد. سه ویژگی این تعریف را باید صریح گفت، چون هر سه پرسش‌هایی را پیشاپیش می‌بندند که حتماً پرسیده می‌شوند.

یکم: مبنای محاسبه‌ی آستانه پیش از هر پنجره‌ی آلوده‌کننده تمام می‌شود. برش ۴ ژانویه‌ی ۲۰۱۵ اکیداً پیش از هر دو پنجره‌ای قرار دارد که می‌توانستند آن را آلوده کنند: پنجره‌ی تنظیم ابرپارامتر و پنجره‌ی برازش وزن، که هر دو از ۲۰۱۵ آغاز می‌شوند. آستانه بنابراین نه از دوره‌ی آزمون و نه از پنجره‌های تنظیم، اطلاعی ندارد. این مقدار در آزمون‌های پروژه در برابر داده‌ی خام سنجیده می‌شود، یعنی خاصیت واریسی می‌شود و نه صرفاً در یک توضیح ادعا.

دوم: k با قاعده‌ای صرفاً بر پایه‌ی داده‌ی اعتبارسنجی انتخاب شده است. قاعده این بود: بزرگ‌ترین k از میان مقادیر 2.0، 2.5، 3.0 و 1.5 که به ازای آن هر دو رژیم دست‌کم بیست روز در پنجره‌ی اعتبارسنجی داشته باشند. مقدار 2.0 تنها ده روز پرتنش باقی می‌گذاشت و 1.5 سی‌وهفت روز؛ پس 1.5 انتخاب شد. **دوره‌ی آزمون هرگز در این انتخاب مشورت نشد.** انتخاب آستانه بر پایه‌ی رفتار آن روی دوره‌ی آزمون، گزینش درون‌نمونه‌ای می‌بود و کل نتیجه‌ی **بخش ۴-۵-۱** را بی‌اعتبار می‌کرد. تقسیم حاصل چنین است: در پنجره‌ی اعتبارسنجی ۳۷ روز پرتنش در برابر ۳۲۰ روز آرام (از مجموع ۳۵۷ مبدأ)، و در دوره‌ی آزمون ۷۷ روز پرتنش از مجموع ۷۲۸ روز.

سوم: برچسب رژیم از روز پیش خوانده می‌شود. یک روز زمانی پرتنش برچسب می‌خورد که قیمت‌های محقق‌شده‌ی روز پیش از آن از آستانه عبور کرده باشند. این قید در کد اعمال می‌شود، نه در توضیح. اگر برچسب از قیمت‌های خود روز هدف خوانده می‌شد، خود برچسب حامل اطلاعاتی از آینده می‌بود و کل سازوکار به نشت اطلاعات آلوده می‌گشت.

نکته‌ی اصطلاح‌شناختی: در سطح تقریبی یک‌ونیم انحراف معیار، آنچه علامت‌گذاری می‌شود یک روز بالاتر از معمول است و نه یک جهش قیمتی. برچسب «پرتنش» عامدانه انتخاب شده تا این تمایز حفظ شود.

ترکیب رژیم‌محور

ترکیب رژیم‌محور به‌جای یک بردار وزن، دو بردار دارد: یکی برازش‌شده بر روزهای آرام پنجره‌ی برازش و دیگری بر روزهای پرتنش همان پنجره. در زمان پیش‌بینی، برچسب رژیم روز هدف — که، مطابق بالا، از روز پیش خوانده می‌شود — تعیین می‌کند کدام بردار وزن به کار رود. به‌جز همین سوئیچ، هیچ تفاوت دیگری با ترکیب ایستا وجود ندارد: همان اعضا، همان پنجره‌ی برازش، همان بهینه‌ساز و همان قیدهای محدب.

این طراحی حداقلی عامدانه است. اگر ترکیب رژیم‌محور هم‌زمان اعضای دیگری می‌گرفت یا پنجره‌ی متفاوتی به کار می‌برد، تفاوت عملکرد آن با ترکیب ایستا دیگر به شرطی کردن وزن‌ها قابل نسبت‌دادن نبود.

یادآوری تفکیک **بخش ۳-۵**: پیش‌بینی‌هایی که این وزن‌ها بر آن‌ها اعمال می‌شوند، خروجی مدل‌های چارچوب پیش‌رونده‌اند و نه مدل تثبیت‌شده بر کل داده؛ یعنی هر پیش‌بینی عضو، از مدلی می‌آید که اکیداً پیش از مبدأ خود برازش شده است. وزن‌ها نیز، همان‌گونه که گفته شد، بر پنجره‌ای پیش از دوره‌ی آزمون برازش می‌شوند. پس هیچ مرحله‌ای از این زنجیره دوره‌ی آزمون را نمی‌بیند.

وزن‌های برازش‌شده

جدول ۳-۱ سه بردار وزن را در کنار هم می‌آورد: بردار ایستا، و دو بردار رژیم‌محور آرام و پرتنش. هر سه با همان رویه‌ی بالا و بر همان پنجره‌ی برازش به دست آمده‌اند.

جدول ۳-۱: وزن‌های برازش‌شده‌ی مدل ترکیبی بر پنجره‌ی برازش وزن (۳۵۷ مبدأ، از ۱۲ ژانویه‌ی ۲۰۱۵ تا ۳ ژانویه‌ی ۲۰۱۶). ستون نخست وزن‌های ترکیب ایستا و دو ستون بعد وزن‌های ترکیب رژیم‌محور است. هر ستون به یک جمع می‌شود. تقسیم رژیم‌ی این پنجره ۳۲۰ روز آرام و ۳۷ روز پرتنش است.

رژیم‌محور			
عضو	ایستا	آرام	پرتنش
SARIMAX	0.134	0.140	0.063
LEAR-LASSO	0.245	0.237	0.375
LightGBM	0.382	0.388	0.281
LSTM	0.239	0.235	0.281

مقایسه‌ی دو ستون آخر، خود سازوکار را آشکار می‌کند و از هر توضیح کلامی گویاتر است. در رژیم آرام، بردار وزن عملاً همان بردار ایستاست؛ اختلاف‌ها در حد چند هزارم‌اند. این انتظارپذیر است، چون روزهای آرام اکثریت پنجره‌ی برازش را می‌سازند و بردار ایستا نیز عمدتاً از همان‌ها شکل

می‌گیرد.

در رژیم پرتنش اما آرایش وزن‌ها به‌روشنی جابه‌جا می‌شود. سهم LEAR-LASSO از 0.237 به 0.375 می‌رسد و به بزرگ‌ترین وزن بدل می‌گردد، سهم LightGBM از 0.388 به 0.281 افت می‌کند، و سهم SARIMAX بیش از نصف کاهش می‌یابد و از 0.140 به 0.063 می‌رسد. خوانش این جابه‌جایی چنین است: در روزهای پرتنش، بهینه‌ساز وزن را از مدل درختی به سمت مدل خطی می‌برد. این با مشاهده‌ی RMSE در **بخش ۴-۲** سازگار است، جایی که مدل درختی خطاهای حدی بزرگ‌تری از مدل خطی نشان می‌دهد؛ درخت تصمیم در دنباله‌های توزیع اشباع می‌شود، حال آنکه مدل خطی در همان ناحیه برون‌یابی می‌کند. روزهای پرتنش دقیقاً همان روزهایی‌اند که قیمت به دنباله‌ی توزیع نزدیک می‌شود.

باید تصریح کرد که این تفسیر، پس از دیدن وزن‌ها نوشته شده است و نه پیش از آن؛ بنابراین توضیحی است بر یک الگوی مشاهده‌شده و نه فرضیه‌ای که آزموده شده باشد. آنچه آزموده شده، تنها این است که وزن‌دهی رژیم‌محور دقت را بهبود می‌دهد یا نه، و پاسخ آن در **بخش ۴-۵-۱** می‌آید.

یک مرجع مفید: کران اوراکل

برای آنکه بتوان قضاوت کرد بهبود رژیم‌محوری چه اندازه است، مرجعی لازم است: بهترین دقتی که هر بردار وزن ایستا می‌توانست بر دوره‌ی آزمون به دست آورد، اگر آن را با دانستن پاسخ انتخاب می‌کردیم. این کران اوراکل بر مجموعه‌ی اعضای تثبیت‌شده برابر 3.5580 است.

مقایسه گویاست و در **بخش ۴-۵-۱** بسط می‌یابد: ترکیب ایستای واقعی به 3.5742 می‌رسد، یعنی اندکی بالاتر از کران، که طبیعی است چون وزن‌هایش را بدون دیدن دوره‌ی آزمون برازش کرده است. ترکیب رژیم‌محور به 3.5569 می‌رسد — یعنی به عددی اندکی بهتر از بهترین وزن ایستای ممکن. این خود ادعای **بخش ۳-۸** را می‌سازد: بهبود از شرطی کردن وزن‌ها بر رژیم می‌آید و نه از یافتن وزن ایستای بهتر، چون هیچ وزن ایستایی نمی‌توانست به آن برسد.

بخش ۴-۵-۱ نشان خواهد داد که این بهبود کجا رخ می‌دهد، و پاسخ — تماماً بر روزهای پرتنش — همان چیزی است که این طراحی برای آن ساخته شده بود.