

فصل چهارم

نتایج و تحلیل

۱-۴ مقدمه

این فصل نتایج را گزارش می‌کند. ساختار آن از پرسش‌های پژوهش پیروی می‌کند: **بخش ۲-۴** دقت افق ساعتی، **بخش ۳-۴** دقت افق روزانه، و **بخش ۴-۴** مقایسه‌ی دو مسیر رسیدن به هدف روزانه را می‌آورد. **بخش ۵-۴** آزمون‌های معناداری را در دو سطح ارائه می‌کند: نخست میان مدل‌های خود این پژوهش و سپس در برابر اعداد منتشرشده‌ی مرجع. **بخش ۶-۴** تحلیل تفسیرپذیری و **بخش ۷-۴** پاسخ صریح به چهار پرسش پژوهش را در بر می‌گیرد.

سه قید بر تمام اعداد این فصل حاکم است و یک‌بار در همین جا گفته می‌شود تا در هر بخش تکرار نشود.

قید نخست: اعداد تثبیت شده‌اند. تمام نتایج این فصل از یک نسخه‌ی تثبیت‌شده‌ی نتایج خوانده می‌شوند که پس از تولید، هرگز بازتولید نشده است. دلیل این تثبیت آن است که نگارش بر اعدادی متکی است که باید ثابت بمانند؛ اگر هر بار که متنی نوشته می‌شود مدلی دوباره اجرا شود، هیچ عددی در متن قابل استناد نخواهد بود. همه‌ی اعداد بر دوره‌ی آزمون یکسانی محاسبه شده‌اند: بازار EPEX-DE، از ۴ ژانویه ۲۰۱۶ تا ۳۱ دسامبر ۲۰۱۷، ۷۲۸ مبدأ پیش‌بینی.

قید دوم: مدل عمیق گزارش شده، مدل تک‌بذری است. تمام اعداد سرشناس این فصل، تحلیل تفسیرپذیری **بخش ۶-۴** و آزمون برون‌توزیعی فصل پنجم، بر شبکه‌ی عصبی آموزش‌دیده با بذر تصادفی ۴۲ استوارند. در **بخش ۲-۵-۴** مجموعه‌ای مکمل از اعداد نیز می‌آید که از میانگین‌گیری چند بذر به دست آمده است؛ آن مجموعه به‌صراحت با برچسب «مکمل» جدا شده و هرگز نباید با اعداد سرشناس آمیخته شود.

قید سوم: تمام p-مقادیرها تصحیح شده‌اند. هیچ مقدار تصحیح‌نشده‌ای در این فصل نقل نمی‌شود، و برای خانواده‌ی اکتشافی بیست‌ویک‌تایی که **بخش ۵-۳** اعلام کرد، هر دو ستون خام و تصحیح‌شده گزارش می‌گردد.

چهار یافته‌ی ناخوشایند که این فصل پنهان‌شان نمی‌کند

خواندن این فصل با انتظار یک پیروزی یک‌دست، همراه‌کننده خواهد بود. چهار نتیجه در آن هست که به سود روایت ساده نیستند، و هر چهار به‌صراحت گزارش می‌شوند؛ زیرا هر چهار در ده دقیقه برای یک داور قابل کشف‌اند، و یافته‌ی ناخوشایند گزارش شده به‌مراتب قوی‌تر از یافته‌ی ناخوشایند کشف شده است. نخست، این پژوهش بهترین مدل منتشرشده‌ی مرجع را شکست نمی‌دهد. با دو گونه از پنج گونه‌ی

منتشر شده تفاوت معناداری ندارد و از بهترین آن‌ها عقب می‌ماند [۱]. بخش ۴-۵-۲ این را با عدد و آزمون می‌آورد.

دوم، بهبود حاصل از وزن‌دهی رژیم‌محور، در حالت تجمیعی مرزی است. بخش ۴-۵-۱ آن را همراه با بازه‌ی حساسیتش گزارش می‌کند و نه به‌صورت یک عدد منفرد.

سوم، بهترین مدل آماری و بهترین مدل عمیق از نظر آماری تفکیک‌ناپذیرند. این خود یک یافته است درباره‌ی اینکه یادگیری عمیق در این بازار و این دوره چه چیزی می‌خرد، و در بخش ۴-۵-۱ به همین صورت گزارش می‌شود.

چهارم، مدل‌ها بیرون از دوره‌ی آموزش شکست می‌خورند. جای گزارش کامل آن فصل پنجم است، اما از همین‌جا اعلام می‌شود تا اعداد چشمگیر این فصل بدون آن خوانده نشوند.

۲-۴ نتایج پیش‌بینی ساعتی

این بخش دقت پیش‌بینی بردار ۲۴ مؤلفه‌ای قیمت‌های ساعتی روز بعد را گزارش می‌کند: هدف اصلی پژوهش، و پایه‌ای که نتایج بخش‌های بعدی بر آن بنا می‌شوند. تمام اعداد بر ۷۲۸ مبدأ پیش‌بینی و 17,472 ساعت دوره‌ی آزمون محاسبه شده‌اند.

جدول ۴-۱: دقت پیش‌بینی ساعتی بر دوره‌ی آزمون EPEX-DE، از ۴ ژانویه ۲۰۱۶ تا ۳۱ دسامبر ۲۰۱۷ (۷۲۸ مبدأ). واحد MAE و RMSE یورو بر مگاوات‌ساعت، sMAPE درصد، و rMAE بی‌بعد. مقدار کمتر بهتر است. مدل ساده مرجع است و نه رقیب.

مدل	MAE	RMSE	sMAPE	rMAE
ساده	7.7501	13.2573	28.5954	0.8491
SARIMAX	4.3507	7.1166	18.0349	0.4767
LEAR-LASSO	3.8988	6.4750	16.6572	0.4272
LightGBM	3.9678	7.5024	15.7218	0.4347
LSTM	3.8734	7.0198	15.5994	0.4244
ترکیب ایستا	3.5742	6.6097	14.6710	0.3916
ترکیب رژیم‌محور	3.5569	6.5575	14.6439	0.3897

ترتیب مدل‌ها

بر معیار MAE، ترتیب چنین است: ترکیب رژیم‌محور با 3.5569، ترکیب ایستا با 3.5742، LSTM با 3.8734، LEAR-LASSO با 3.8988، LightGBM با 3.9678، SARIMAX با 4.3507 و مدل ساده با

7.7501

سه مشاهده از این ترتیب برمی خیزد که هر سه در **بخش ۴-۵-۱** با آزمون معناداری سنجیده می شوند؛ در اینجا تنها به عنوان مشاهده‌ی عددی ثبت می گردند.

یکم: فاصله‌ی میان سه مدل میانی بسیار کوچک است. LSTM, LEAR-LASSO و LightGBM در بازه‌ای به پهنای حدود هفت صدم یورو بر مگاوات ساعت جای می گیرند (3.8734 تا 3.9678). در برابر انحراف معیار خود سری قیمت، که 15.94 است، این فاصله ناچیز است. **بخش ۴-۵-۱** نشان می دهد که هیچ یک از تفاوت‌های درون این سه مدل، پس از تصحیح برای چندگانگی، معنادار نیست.

دوم: مدل خطی از مدل درختی جلوتر است. LEAR-LASSO با 3.8988 از LightGBM با 3.9678 بهتر عمل می کند. این نتیجه‌ای است که انتظار متعارف را برآورده نمی کند و باید بی تعدیل گزارش شود: در این بازار و این دوره، انعطاف پذیری مدل درختی به دقت بیشتر ترجمه نشد.

سوم: هر دو ترکیب از تمام اعضایشان بهترند. کوچک ترین MAE در میان تک مدل ها 3.8734 است، حال آنکه ترکیب ایستا به 3.5742 و ترکیب رژیم محور به 3.5569 می رسد. این بهبود از هر بهبودی که میان خود تک مدل ها دیده می شود بزرگ تر است، و برخلاف آن ها از آزمون معناداری نیز عبور می کند.

معیارها همیشه هم داستان نیستند

جدول ۴-۱ یک ناسازگاری آموزنده دارد که پوشاندنش آسان و گزارش کردنش درست تر است: بهترین مدل بر معیار RMSE، ترکیب رژیم محور نیست، بلکه LEAR-LASSO با 6.4750 است.

توضیح در تفاوت این دو معیار نهفته است. RMSE خطاها را به توان دو می رساند و در نتیجه به خطاهای بزرگ حساسیت به مراتب بیشتری دارد تا MAE. یک مدل می تواند میانگین خطای مطلق بهتری داشته باشد و همزمان چند خطای بسیار بزرگ تر مرتکب شود. مقایسه‌ی LEAR-LASSO و LightGBM همین را نشان می دهد: مدل درختی در sMAPE بهتر است (15.7218 در برابر 16.6572) اما در RMSE به روشنی بدتر (7.5024 در برابر 6.4750) — یعنی خطاهای معمولی کوچک تر اما خطاهای حدی بزرگ تر، که با ماهیت درختی و اشباع شدن آن در دنباله ها سازگار است.

این ناسازگاری بر هیچ نتیجه‌ای در این پایان نامه اثر نمی گذارد، چون — همان گونه که **بخش ۳-۵** تصریح کرد — تمام آزمون های معناداری بر زیان قدرمطلق محاسبه می شوند و هر ادعای سرشناسی بر MAE یا rMAE بنا شده است. اما ثبت کردنش لازم است: انتخاب معیار، ترتیب مدل ها را تغییر می دهد، و پژوهشی که تنها معیار مساعد به حال خود را گزارش کند، همین واقعیت را پنهان کرده است.

خواندن معیار rMAE

ستون rMAE همان اطلاعات MAE را در مقیاسی تفسیرپذیر می‌دهد: نسبت خطای مدل به خطای پیش‌بینی ساده‌ی وقفه‌ی هفتگی. مقدار 0.3897 برای ترکیب رژیم‌محور یعنی این مدل حدود شصت و یک درصد از خطای آن مرجع را حذف می‌کند.

مقدار 0.8491 برای مدل ساده نیز، همان گونه که **بخش ۳-۵** توضیح داد، تناقض نیست: مدل ساده‌ی گزارش‌شده قاعده‌ی روز مشابه است، حال آنکه مخرج rMAE پیش‌بینی وقفه‌ی هفتگی محض است، و قاعده‌ی روز مشابه حدود پانزده درصد از آن بهتر عمل می‌کند.

آنچه این بخش ادعا نمی‌کند

اعداد این جدول به یک بازار، یک پنجره‌ی دوساله، یک معماری به‌ازای هر خانواده‌ی مدل و یک بودجه‌ی تنظیم پنجاه‌آزمایشی محدودند. این بخش نمی‌گوید که یادگیری عمیق بر روش‌های آماری برتری دارد یا ندارد؛ می‌گوید که در این شرایط مشخص، اختلاف آن‌ها کوچک بود. تعمیم این مشاهده به یک حکم کلی درباره‌ی خانواده‌های مدل، فراتر از شواهدی است که در دست است.

مقایسه با اعداد منتشرشده‌ی مرجع در **بخش ۴-۵-۲** می‌آید، و پرسش اینکه کدامیک از این تفاوت‌ها معنادارند در **بخش ۴-۵-۱** پاسخ داده می‌شود.

۴-۳ نتایج پیش‌بینی روزانه

هدف دوم پژوهش، میانگین بار پایه‌ی روزانه است: میانگین ۲۴ قیمت ساعتی هر روز. این بخش دقت هر دو مسیر رسیدن به آن را گزارش می‌کند، و **بخش ۴-۴** آن دو را مستقیماً با هم می‌سنجد.

هدف روزانه آسان‌تر از هدف ساعتی است

نخستین مشاهده، مقایسه‌ی این جدول با **جدول ۴-۱** است. بهترین MAE ساعتی 3.5569 بود؛ بهترین MAE روزانه 2.6484 است. یعنی خطا حدود بیست‌وشش درصد کمتر می‌شود.

توضیح این تفاوت در **بخش ۳-۳-۳** آمد: میانگین‌گیری روی ۲۴ ساعت، بخشی از نوسان درون‌روزی را حذف می‌کند. انحراف معیار سری روزانه 11.97 است در برابر 15.94 برای سری ساعتی، پس هدف روزانه ذاتاً هموارتر و قابل پیش‌بینی‌تر است.

جدول ۴-۲: دقت پیش‌بینی بار پایه‌ی روزانه بر همان دوره‌ی آزمون (۷۲۸ روز)، به تفکیک دو مسیر: مدل‌سازی مستقیم هدف روزانه، و میانگین‌گیری از ۲۴ پیش‌بینی ساعتی. مقدار کمتر بهتر است. مدل‌های ترکیبی مسیر مستقیم ندارند، چون اعضایشان ساعتی‌اند.

مدل	MAE		rMAE	
	مستقیم	تجمیعی	مستقیم	تجمیعی
ساده	6.3575	6.3575	0.7949	0.7949
SARIMAX	3.1976	3.2691	0.3998	0.4088
LEAR-LASSO	2.8989	2.8389	0.3625	0.3550
LightGBM	3.3012	2.9928	0.4128	0.3742
LSTM	3.1753	2.7804	0.3970	0.3476
ترکیب ایستا	–	2.6768	–	0.3347
ترکیب رژیم‌محور	–	2.6484	–	0.3311

نکته‌ی مهم آنکه این مقایسه را نباید به‌عنوان برتری یک روش بر روش دیگر خواند. دو هدف متفاوت‌اند و کاربردهای متفاوت دارند: پیش‌بینی ساعتی برای پیشنهاددهی در حراج لازم است و پیش‌بینی روزانه برای قراردادهای بار پایه. سنجه‌ی rMAE نیز همین را تأیید می‌کند که آسان‌تر شدن مسئله تنها بخشی از ماجراست: مدل ساده در افق روزانه rMAE برابر 0.7949 دارد در برابر 0.8491 در افق ساعتی، یعنی خودِ مرجع هم آسان‌تر شده است.

ترتیب مدل‌ها در مسیر تجمیعی

در مسیر تجمیعی، ترتیب چنین است: ترکیب رژیم‌محور 2.6484، ترکیب ایستا 2.6768، LSTM 2.7804، 2.8389 LEAR-LASSO، 2.9928 LightGBM، 3.2691 SARIMAX و مدل ساده 6.3575. این ترتیب با ترتیب افق ساعتی یکسان است، و همین یکسانی خود اطلاعاتی می‌دهد: رتبه‌بندی نسبی خانواده‌های مدل به انتخاب افق حساس نیست. مدلی که در افق ساعتی بهتر بود، در افق روزانه نیز بهتر است.

ترتیب مدل‌ها در مسیر مستقیم، و یک استثنا

در مسیر مستقیم اما ترتیب تغییر می‌کند، و این تغییر موضوع اصلی بخش ۴-۴ است. LEAR-LASSO با 2.8989 بهترین مدل مستقیم است، و SARIMAX با 3.1976 از LightGBM با 3.3012 جلو می‌افتد — در حالی که در مسیر تجمیعی عکس آن برقرار بود. جابه‌جایی SARIMAX از جایگاه آخر در میان مدل‌های برازشی به جایگاه سوم، تصادفی نیست.

مدل مستقیم بر یک سری تک بعدی هموار برازش می‌شود، و این دقیقاً همان ساختاری است که یک مدل کلاسیک سری زمانی برای آن ساخته شده است. مدل درختی و شبکه‌ی عصبی، در مقابل، بخشی از توانشان را در همان ماتریس ۲۴۷ ستونی به کار می‌گیرند که برای هدف ساعتی طراحی شده بود.

ترکیب در افق روزانه نیز کار می‌کند

هر دو مدل ترکیبی، در افق روزانه نیز از تمام اعضایشان بهترند: 2.6484 و 2.6768 در برابر بهترین تک‌مدل تجمیعی با 2.7804. فاصله‌ی میان ترکیب رژیم‌محور و ترکیب ایستا در این افق 0.0284 است، در برابر 0.0173 در افق ساعتی.

با این‌همه، آزمون معناداری رسمی این تفاوت در **بخش ۴-۵-۱** تنها برای افق ساعتی گزارش می‌شود، چون فرضیه‌ی از پیش تعیین‌شده‌ی پژوهش بر همان افق تعریف شده بود. تفاوت روزانه به‌عنوان یک مشاهده‌ی عددی هم‌راستا ثبت می‌گردد و نه به‌عنوان یک نتیجه‌ی آزموده؛ خواندن آن به‌صورت یک ادعای معنادار، همان چیزی است که اعلام خانواده‌ی آزمون در **بخش ۳-۵** برای جلوگیری از آن انجام شد.

آنچه این بخش ادعا نمی‌کند

همان قید **بخش ۴-۲** در اینجا نیز برقرار است. اعداد این جدول به یک بازار و یک پنجره‌ی دوساله محدودند. افزون بر آن، مسیر مستقیم تنها برای چهار مدل برازشی و مدل ساده وجود دارد و برای مدل‌های ترکیبی تعریف نشده است، چون اعضای آن‌ها ساعتی‌اند؛ پس مقایسه‌ی **بخش ۴-۴** نیز به همان چهار مدل محدود می‌ماند.

۴-۴ مقایسه روش مستقیم و تجمیعی

پرسش پژوهشی چهارم مستقیم است: برای پیش‌بینی میانگین بار پایه‌ی روزانه، کدام مسیر دقت بالاتری دارد — مدل‌سازی مستقیم هدف روزانه، یا میانگین‌گیری از ۲۴ پیش‌بینی ساعتی؟ و آیا پاسخ برای همه‌ی مدل‌ها یکسان است؟

پاسخ به بخش دوم پرسش منفی است، و همین آن را به یافته بدل می‌کند.

جدول ۴-۳: مقایسه‌ی مستقیم دو مسیر رسیدن به هدف روزانه بر معیار MAE. ستون «اختلاف» مقدار مسیر تجمیعی منهای مسیر مستقیم است؛ مقدار منفی یعنی تجمیع بهتر بوده است. مدل ساده در هر دو مسیر یکسان است.

مدل	مستقیم	تجمیعی	اختلاف	برنده
SARIMAX	3.1976	3.2691	+0.0715	مستقیم
LEAR-LASSO	2.8989	2.8389	-0.0600	تجمیعی
LightGBM	3.3012	2.9928	-0.3084	تجمیعی
LSTM	3.1753	2.7804	-0.3949	تجمیعی
ساده	6.3575	6.3575	0.0000	یکسان

تجمیع در سه مورد از چهار مورد برنده است

برای LEAR-LASSO، LightGBM و LSTM، میانگین‌گیری از ۲۴ پیش‌بینی ساعتی دقیق‌تر از مدل‌سازی مستقیم است. اندازه‌ی این برتری یکسان نیست: برای LEAR-LASSO تنها 0.0600 است، اما برای LightGBM 0.3084 و برای LSTM 0.3949.

توضیح این الگو در مقدار اطلاعاتی است که هر مسیر در اختیار مدل می‌گذارد. مسیر تجمیعی، مدل را وادار می‌کند ساختار درون‌روزی را یاد بگیرد — یعنی ۲۴ هدف مجزا با ۲۴ الگوی متفاوت — و سپس آن ۲۴ پیش‌بینی را میانگین می‌گیرد. خطاهای ساعت‌های مختلف کاملاً هم‌بسته نیستند، پس بخشی از آن‌ها در میانگین‌گیری یکدیگر را خنثی می‌کنند. مسیر مستقیم، در مقابل، این ساختار را از همان ابتدا دور می‌ریزد و تنها یک عدد در روز را هدف می‌گیرد.

اینکه بیشترین سود از آن دو مدل غیرخطی است نیز با همین توضیح سازگار است: مدل‌های انعطاف‌پذیرتر توان بیشتری برای بهره‌بردن از ۲۴ الگوی مجزا دارند، و در مقابل، وقتی به یک هدف تک‌بعدی محدود شوند بیشترین سهم از ظرفیتشان بلااستفاده می‌ماند.

SARIMAX استثناست، و این استثنا واقعی است

SARIMAX تنها مدلی است که مسیر مستقیم برایش بهتر عمل می‌کند: 3.1976 در برابر 3.2691. این نتیجه را نباید به‌عنوان نوفه کنار گذاشت یا در میانگینی پنهان کرد؛ توضیحی ساختاری دارد. SARIMAX یک مدل کلاسیک سری زمانی است که برای سری‌های تک‌بعدی با ساختار خودهمبستگی و مؤلفه‌ی فصلی طراحی شده است. سری بار پایه‌ی روزانه دقیقاً چنین سری‌ای است: هموار، تک‌بعدی، با تناوب هفتگی روشن. وقتی این مدل مستقیماً بر آن سری برازش می‌شود، در زیستگاه طبیعی خودش قرار دارد.

در مسیر تجمیعی، همین مدل باید ۲۴ سری ساعتی به مراتب پرنوفه‌تر را مدل کند و سپس نتایج را میانگین بگیرد. هر یک از آن ۲۴ برازش، خطای خود را دارد، و برخلاف مدل‌های انعطاف‌پذیرتر، SARIMAX نمی‌تواند از ساختار مشترک میان ساعت‌ها بهره ببرد، چون ۲۴ مدل کاملاً مستقل‌اند. افزون بر آن، همان‌گونه که بخش ۳-۶ ثبت کرد، این مدل تنها هر هفت روز به‌طور کامل بازبرازش می‌شود، و این محدودیت در ۲۴ سری پرنوفه هزینه‌ی بیشتری دارد تا در یک سری هموار.

چرا این مقایسه منصفانه است

اعتبار این بخش تماماً به یک نکته بستگی دارد: هر دو مسیر باید تلاش برابری دریافت کرده باشند. اگر مسیر مستقیم بودجه‌ی تنظیم کمتری می‌گرفت، هر برتری مسیر تجمیعی می‌توانست صرفاً بازتاب همان نابرابری باشد و نه خاصیت خود مسیر.

سه چیز میان دو مسیر یکسان نگه داشته شده است: همان ماتریس ویژگی، همان مبادی پیش‌بینی، و همان بودجه‌ی تنظیم پنجاه‌آزمایشی به‌ازای هر مدل. مسیر مستقیم پیکربندی تنظیم‌شده‌ی مستقل خود را دارد، که با همان شمار آزمایش و بر همان پنجره‌ی اعتبارسنجی به دست آمده است. این برابری، طراحی آگاهانه بوده و همان چیزی است که نتیجه‌ی این بخش را از یک مصنوع طراحی جدا می‌کند.

آنچه این بخش ادعا نمی‌کند

هیچ قاعده‌ی کلی درباره‌ی تجمیع زمانی در پیش‌بینی از اینجا به دست نمی‌آید. چهار مدل، یک بازار، یک پنجره‌ی دوساله. آنچه می‌گوید این است که در این شرایط، تجمیع برای سه مدل از چهار مدل بهتر بود و استثنای چهارم توضیح ساختاری دارد — و اینکه پرسش پژوهشی عامدانه چنان صورت‌بندی شده بود که این استثنا بخشی از پاسخ باشد و نه دردسری برای آن.

۴-۵ آزمون دیبولد-ماریانو

جدول‌های جدول‌های ۱-۴ تا ۳-۴ اختلاف‌های عددی را نشان دادند، اما اختلاف عددی به‌تنهایی چیزی را اثبات نمی‌کند. دو مدل که بر ۷۲۸ مبدأ پیش‌بینی، میانگین خطایی با فاصله‌ی چند صدم یورو دارند، ممکن است صرفاً بازتاب همان نمونه‌ی خاص باشند. آزمون دیبولد-ماریانو دقیقاً همین را می‌سنجد: آیا سری اختلاف زیان دو مدل، میانگینی به‌طور نظام‌مند متفاوت از صفر دارد؟

سه قید که در بخش ۳-۵ تثبیت شد و در سراسر این بخش برقرار است:

- تمام p -مقدارها با تصحیح HAC برای خودهمبستگی و ناهمسانی واریانس محاسبه شده‌اند. p -مقدارهای تصحیح‌نشده در هیچ جای این فصل نقل نمی‌شوند.
- آزمون‌ها یک‌طرفه‌اند. در هر جدول، p احتمال آن است که مدل سطر بهتر از مدل ستون نباشد؛ پس مقدار کوچک یعنی سطر بهتر است.
- دو خانواده‌ی آزمون از پیش اعلام شده‌اند و اینجا از هم جدا می‌مانند.

خانواده‌ی نخست — خانواده‌ی تأییدی — تنها یک فرضیه دارد: اینکه وزن‌دهی رژیم‌محور بر وزن‌دهی ایستا برتری دارد. ثبت آن در دفتر تصمیم‌های پروژه به یازدهم ژوئیه ۲۰۲۶ بازمی‌گردد، یعنی زمانی که هنوز هیچ ترکیبی بر پنجره‌ی آزمون امتیازدهی نشده بود. یک فرضیه‌ی از پیش تعیین‌شده بدون تصحیح در سطح 0.05 آزموده می‌شود.

خانواده‌ی دوم — خانواده‌ی اکتشافی — کل ماتریس ۲۱ تایی مقایسه‌های دوبه‌دوی بخش ۴-۵-۱ است. برای این خانواده، هم p -مقدار خام و هم p -مقدار تصحیح‌شده با روش هولم-بونفرونی گزارش می‌شود، و هر ادعای معناداری تنها بر پایه‌ی ستون تصحیح‌شده بیان می‌گردد. گزارش کردن تنها ستون خام، در ماتریسی با ۲۱ آزمون، به‌طور متوسط یک برنده‌ی کاذب تولید می‌کند.

بخش بخش ۴-۵-۱ مدل‌های این پژوهش را با یکدیگر می‌سنجد و بخش ۴-۵-۲ آن‌ها را در برابر پیش‌بینی‌های منتشرشده‌ی لاگو و همکاران [۱] قرار می‌دهد.

۴-۵-۱ مقایسه مدل‌های این پژوهش

ماتریس کامل مقایسه‌های دوبه‌دو

هفت مدل — پنج مدل منفرد و دو ترکیب — ۲۱ مقایسه‌ی دوبه‌دو تولید می‌کنند. جدول ۴-۴ همه‌ی آن‌ها را می‌آورد. هیچ سلولی حذف نشده است؛ گزینش سلول‌ها پس از دیدن نتیجه، همان کاری است که تصحیح چندگانگی برای مهارش وجود دارد.

ماتریس پس از تصحیح هولم-بونفرونی

اعمال روش هولم-بونفرونی بر هر ۲۱ آزمون، ۱۷ آزمون را دست‌نخورده باقی می‌گذارد و ۴ آزمون را از فهرست نتایج معنادار بیرون می‌برد. جدول ۴-۵ خلاصه‌ی آن است. هیچ مدلی برای این محاسبه بازاجرا نشد؛ تصحیح صرفاً بر همان p -مقدارهای تثبیت‌شده‌ی جدول ۴-۴ انجام گرفته است.

جدول ۴-۴: p-مقدارهای خام آزمون دیبولد-ماریانو با تصحیح HAC، افق ساعتی، ۷۲۸ مبدأ. هر درایه احتمال آن است که مدل سطر بهتر از مدل ستون نباشد؛ مقدار نزدیک به صفر یعنی سطر بهتر است. ستون‌ها به همان ترتیب سطرها شماره گذاری شده‌اند. آنچه می‌آید ستون خام است و به‌تنهایی مبنای هیچ ادعای معناداری قرار نمی‌گیرد — جدول ۴-۵ را ببینید.

مدل	۱	۲	۳	۴	۵	۶	۷
۱ ساده	—	1.000	1.000	1.000	1.000	1.000	1.000
۲ SARIMAX	0.000	—	1.000	0.9999	1.000	1.000	1.000
۳ LEAR-LASSO	0.000	0.000	—	0.2665	0.5964	1.000	1.000
۴ LightGBM	0.000	0.0001	0.7335	—	0.9595	1.000	1.000
۵ LSTM	0.000	0.000	0.4036	0.0405	—	1.000	1.000
۶ ترکیب ایستا	0.000	0.000	0.000	0.000	0.000	—	0.9774
۷ ترکیب رژیم‌محور	0.000	0.000	0.000	0.000	0.000	0.0226	—

جدول ۴-۵: نتیجه‌ی تصحیح هولم-بونفرونی بر خانواده‌ی اکتشافی ۲۱ آزمونه. «مقاوم» یعنی نتیجه پس از تصحیح نیز در سطح 0.05 برقرار می‌ماند.

مقایسه	p خام	p هولم	وضعیت
هر شش مدل در برابر ساده	0.000	0.000	مقاوم
دو ترکیب در برابر هر عضو (۸ آزمون)	$\leq 4.8e-06$	$\leq 3.4e-05$	مقاوم
SARIMAX در برابر سه مدل دیگر	$\leq 1.0e-04$	$\leq 5.1e-04$	مقاوم
ترکیب رژیم‌محور در برابر ایستا	0.0226	0.0903	مقاوم نیست
LSTM در برابر LightGBM	0.0405	0.1215	مقاوم نیست
LEAR-LASSO در برابر LightGBM	0.2665	0.5329	از ابتدا تهی
LEAR-LASSO در برابر LSTM	0.4036	0.5329	از ابتدا تهی

هرچه ساختاری است، دست‌نخورده می‌ماند. اینکه هر چهار مدل آموخته بر مدل ساده برتری دارند و اینکه هر دو ترکیب بر تک‌تک اعضای خود برتری دارند، پس از تصحیح نیز با فاصله‌ی زیادی برقرار است. آنچه از دست می‌رود، دو ادعای مرزی است.

سه مدل که از هم جدا نمی‌شوند

LSTM با 3.8734، LEAR-LASSO با 3.8988 و LightGBM با 3.9678 در فاصله‌ی کمتر از یک‌دهم یورو بر مگاوات‌ساعت از یکدیگر قرار دارند، و آزمون هیچ‌کدام را از دیگری جدا نمی‌کند. مقایسه‌ی LSTM با LEAR-LASSO حتی پیش از تصحیح نیز تهی است: p برابر 0.4036. عددی که جای تفسیر ظریف باقی نمی‌گذارد. بهترین مدل آماری و بهترین مدل یادگیری عمیق این پژوهش، بر این بازار و این پنجره، از یکدیگر تفکیک‌پذیر نیستند. مقایسه‌ی LSTM با LightGBM ظریف‌تر است و باید با دقت نوشته شود. p -مقدار خام 0.0405 است، که در نگاه نخست معنادار به نظر می‌رسد. اما این آزمون در خانواده‌ی اکتشافی ۲۱ تایی قرار دارد و پس از تصحیح هولم به 0.1215 می‌رسد. بنابراین: LSTM برآورد نقطه‌ای پایین‌تری دارد، و این تفاوت تصحیح برای چندگانگی را تاب نمی‌آورد.

این تصمیم‌نویستاری، برخلاف ظاهرش، پاسخ به پرسش پژوهشی نخست را تقویت می‌کند. خوانش صادقانه این می‌شود که سه خانواده‌ی مدلی متفاوت — خطی منظم‌شده، درخت تقویت‌شده و شبکه‌ی بازگشتی — با بودجه‌ی تنظیم برابر به دقتی می‌رسند که آزمون آماری از هم تمیزشان نمی‌دهد؛ و تنها ترکیب است که از این سه فاصله می‌گیرد. ادعای ضعیف‌تر اما مقاوم «تفکیک‌ناپذیرند» بسیار دفاع‌پذیرتر از ادعای قوی‌تر «LSTM بهتر است» است که با یک تصحیح استاندارد فرو می‌ریزد.

ترکیب: تنها جدایی مقاوم

هر دو ترکیب بر تک‌تک اعضای خود برتری دارند، و این هشت مقایسه پس از تصحیح هولم نیز با p حداکثر $3.4e-05$ برقرار می‌مانند. مقاوم‌ترین یافته‌ی این بخش پس از برتری بدیهی بر مدل ساده است. اندازه‌ی این برتری اما متواضع است. ترکیب ایستا 3.5742 و ترکیب رژیم‌محور 3.5569 در برابر بهترین عضو منفرد با 3.8734؛ یعنی بهبودی حدود هشت درصد. بخش ۳-۸ کران‌اوراکل را 3.5580 گزارش کرد: بهترین وزن‌های ایستایی که با دانستن کامل دوره‌ی آزمون قابل انتخاب بودند. ترکیب ایستای واقعی 3.5742 است، پس فاصله تا آن کران کمتر از دو صدم یورو بر مگاوات‌ساعت است. عملاً هیچ وزن‌دهی ایستایی نمی‌توانست از این بهتر عمل کند، و این خود توضیح می‌دهد که چرا گام بعدی

مشروط کردن وزن‌ها به رژیم بود و نه جست‌وجوی وزن‌های بهتر.

وزن‌دهی رژیم‌محور: آزمون تأییدی

تنها فرضیه‌ی خانوادگی تأییدی همین است، و باید با هر سه عددش با هم بیان شود. بر مجموع ۷۲۸ روز، ترکیب رژیم‌محور با 3.5569 در برابر 3.5742 برتری دارد و p برابر 0.0226 است. به‌عنوان یک فرضیه‌ی از پیش ثبت‌شده، این در سطح 0.05 معنادار است. اما دو قید باید بی‌درنگ کنارش بیاید. نخست آنکه اگر همین آزمون از خانوادگی اکتشافی برداشته شده بود، پس از تصحیح هولم به 0.0903 می‌رسید و معنادار نمی‌ماند؛ دفاع از آن تماماً بر ثبت تاریخ‌دارِ پیش از اجرا استوار است، نه بر اندازه‌ی خودِ عدد. دوم آنکه، چنان‌که **جدول ۴-۷** نشان می‌دهد، تحت محافظه‌کارانه‌ترین فرض وابستگی، همین p از 0.05 عبور می‌کند.

جدول ۴-۶ نشان می‌دهد این بهبود از کجا می‌آید، و پاسخ تیزتر از چیزی است که میانگین کل نشان می‌دهد.

جدول ۴-۶: تفکیک برتری ترکیب رژیم‌محور بر ترکیب ایستا به تفکیک رژیم بازار. MAE بر حسب یورو بر مگاوات‌ساعت.

زیرمجموعه	روز	رژیم‌محور	ایستا	p
کل دوره	۷۲۸	3.5569	3.5742	0.0226
روزهای پرتنش	۷۷	5.5132	5.6830	0.0063
روزهای آرام	۶۵۱	3.3255	3.3248	0.8465

تمام بهبود از ۷۷ روز پرتنش می‌آید. آنجا اختلاف 0.1698 یورو بر مگاوات‌ساعت و p برابر 0.0063 است. بر ۶۵۱ روز آرام، ترکیب رژیم‌محور به‌اندازه‌ی ده‌هزارم یورو بدتر است و p برابر 0.8465؛ یعنی هیچ سازوکار دقیقاً برای انجام همین ساخته شده بود. وزن‌های رژیم آرام و وزن‌های ایستا تقریباً یکسان‌اند — **جدول ۳-۱** این را نشان می‌دهد — چون ۳۲۰ روز از ۳۵۷ روز پنجره‌ی برازش آرام بودند و عملاً همان وزن‌ها را تعیین کردند. تفاوت تنها در سبد پرتنش پدید می‌آید. پس بیان درست ادعا این است: مشروط کردن وزن‌ها به رژیم، در روزهای پرتنش کمک می‌کند و در روزهای آرام بی‌اثر است. این ادعایی محدودتر از «ترکیب رژیم‌محور بهتر است» می‌باشد و برخلاف آن، هم با اعداد سازگار است و هم با هدف اعلام‌شده‌ی طراحی.

آزمون مقاومت: بوت استرپ بلوکی

آزمون دیبولد-ماریانو با تصحیح HAC خودهمبستگی سری اختلاف زیان را تا مرتبه‌ای معین جبران می‌کند. برای سنجش حساسیت نتیجه به این فرض، همان مقایسه با بوت استرپ بلوکی در طول‌های بلوک ۳ تا ۱۰ روز نیز اجرا شد.

جدول ۴-۷: حساسیت نتیجه‌ی «رژیم‌محور در برابر ایستا» به طول بلوک در بوت استرپ بلوکی. ستون آخر p-مقدار HAC برای همان زیرمجموعه است و در هر سطر ثابت می‌ماند.

زیرمجموعه	طول بلوک	p بوت استرپ	HAC p
کل دوره ۳	۳	0.0129	0.0226
کل دوره ۵	۵	0.0269	0.0226
کل دوره ۷	۷	0.0396	0.0226
کل دوره ۱۰	۱۰	0.0571	0.0226
پرتنش ۳	۳	0.0081	0.0063
پرتنش ۵	۵	0.0193	0.0063
پرتنش ۷	۷	0.0311	0.0063
پرتنش ۱۰	۱۰	0.0439	0.0063
آرام ۳	۳	0.8525	0.8465
آرام ۱۰	۱۰	0.8399	0.8465

نتیجه‌ی این آزمون باید بی‌کم‌وکاست گزارش شود. بر کل دوره، p از 0.0129 در بلوک‌های سه‌روزه تا 0.0571 در بلوک‌های ده‌روزه تغییر می‌کند — یعنی زیر محافظه‌کارانه‌ترین فرض وابستگی، از آستانه‌ی 0.05 عبور می‌کند. بر زیرمجموعه‌ی پرتنش، بازه 0.0081 تا 0.0439 است و در سراسر آن معنادار می‌ماند. بر روزهای آرام، p در حدود 0.84 تا 0.85 ثابت است.

جمع‌بندی صادقانه چنین است: نتیجه‌ی تجمیع‌شده مرزی است و نتیجه‌ی زیرمجموعه‌ی پرتنش پابرجاست. این دو جمله با هم، همان ادعایی را می‌سازند که این پژوهش می‌تواند از آن دفاع کند، و نوشتن جمله‌ی نخست، جمله‌ی دوم را نیز مشکوک می‌کرد.

۴-۵-۲ مقایسه با نتایج منتشر شده

چه چیزی با چه چیزی سنجیده می‌شود

لاگو و همکاران [۱] علاوه بر جدول‌های مقاله، فایل‌های پیش‌بینی خام مدل‌هایشان را نیز منتشر کرده‌اند. این پژوهش از همان فایل‌ها استفاده می‌کند و آن‌ها را با کد سنجی خود این پژوهش دوباره امتیازدهی می‌نماید. پس مقایسه‌ی زیر بر یک بازار، یک پنجره‌ی آزمون، یک مجموعه‌ی مبادی و یک پیاده‌سازی

واحد سنجها انجام می‌شود. اگر به جای این کار اعداد چاپ‌شده‌ی مقاله در برابر اعداد ما گذاشته می‌شد، دو مسیر محاسبه‌ی متفاوت با هم مقایسه می‌شدند و تفاوت‌های کوچک بی‌معنا می‌بود.

جدول ۴-۸: مدل‌های این پژوهش در برابر منتخبی از گونه‌های منتشرشده‌ی لاگو و همکاران [۱]، بر بازار EPEX-DE و همان دوره‌ی آزمون. تمام اعداد با کد سنج‌ی این پژوهش از فایل‌های پیش‌بینی منتشرشده محاسبه شده‌اند. مرتب‌شده بر پایه‌ی MAE.

مدل	منبع	MAE	rMAE
DNN Ensemble	لاگو و همکاران	3.4135	0.3740
ترکیب رژیم‌محور	این پژوهش	3.5569	0.3897
ترکیب ایستا	این پژوهش	3.5742	0.3916
DNN 4	لاگو و همکاران	3.5917	0.3935
LEAR Ensemble	لاگو و همکاران	3.6091	0.3954
LSTM	این پژوهش	3.8734	0.4244
LEAR-LASSO	این پژوهش	3.8988	0.4272
LEAR 1092	لاگو و همکاران	3.9298	0.4306

نتیجه‌ی آزمون، بدون تلطیف

جدول ۴-۹ چهار مقایسه‌ی مستقیم ترکیب رژیم‌محور با گونه‌های لاگو را می‌آورد.

جدول ۴-۹: آزمون دیبولد-ماریانو با تصحیح HAC، ترکیب رژیم‌محور این پژوهش در برابر گونه‌های منتشرشده. ستون p احتمال آن است که مدل این پژوهش بهتر نباشد.

در برابر	MAE آن‌ها	p	نتیجه
DNN Ensemble	3.4135	0.9873	آن‌ها بهتر است
DNN 4	3.5917	0.3222	تفاوت معنادار نیست
LEAR Ensemble	3.6091	0.1271	تفاوت معنادار نیست
LEAR 1092	3.9298	1.0e-07	آن‌ها بهتر است

جمله‌ای که باید نوشته شود، همین است و نه بیش از آن: این پژوهش بهترین مدل منتشرشده را شکست نمی‌دهد. ترکیب DNN آن‌ها با 3.4135 در برابر 3.5569 برتری دارد و این برتری معنادار است (p برابر 0.0127 در جهت مقابل). در برابر دو گونه‌ی دیگر آن‌ها — DNN 4 و LEAR Ensemble — تفاوت معنادار نیست، یعنی مدل این پژوهش با آن‌ها هم‌تراز است. و بر LEAR 1092 برتری روشن دارد.

چنین نتیجه‌ای در فصل نخست پیش‌بینی نشده بود که رخ ندهد؛ برعکس، پس از نقطه‌ی بازبینی هفته‌ی پنجم، دفاع پروژه آگاهانه از مسیر «بهبود جدول امتیازها» به مسیر «مشارکت روش‌شناختی»

منتقل شد. آنچه این بخش نشان می‌دهد — هم‌ترازی با میانه‌ی گونه‌های منتشرشده، با ترکیبی از خانواده‌های مدلی متفاوت — پشتوانه‌ی همان تصمیم است، نه شاهی بر شکست آن.

یک یافته‌ی بازتولیدپذیری که ارزش ثبت دارد

هنگام امتیازدهی دوباره‌ی فایل‌های منتشرشده، یک ناهم‌خوانی نظام‌مند آشکار شد که شایسته‌ی ثبت است، چون دوباره‌ی خود ادبیات مرجع چیزی می‌گوید.

سطرهای DNN دقیقاً بازتولید می‌شوند. DNN Ensemble در مقاله 3.413 چاپ شده و از فایل‌ها 3.4135 به دست می‌آید؛ DNN 4 در مقاله 3.592 و از فایل‌ها 3.5917. اختلاف تنها در گرد کردن است. سطرهای LEAR بازتولید نمی‌شوند. LEAR Ensemble در جدول مقاله 3.955 است اما از فایل‌های منتشرشده 3.6091 امتیاز می‌گیرد؛ LEAR 1092 در مقاله 4.108 است و از فایل‌ها 3.9298. الگو یکنواخت است: در تمام گونه‌های LEAR، فایل‌های منتشرشده بهتر از جدول چاپ‌شده امتیاز می‌گیرند. انتخاب این پژوهش، استفاده از فایل‌های منتشرشده بوده است. باید توجه داشت که این محافظه‌کارانه‌ترین انتخاب ممکن است: فایل‌ها مدل‌های آن‌ها را بهتر نشان می‌دهند، پس فاصله‌ی این پژوهش تا آن‌ها را بیشتر می‌کند، نه کمتر. اگر اعداد چاپ‌شده مبنا قرار می‌گرفت، ترکیب این پژوهش بر هر دو گونه‌ی LEAR برتری آشکار پیدا می‌کرد. علت این ناهم‌خوانی از بیرون قابل تعیین نیست — می‌تواند نسخه‌ای متفاوت از کد، پنجره‌ای متفاوت یا اشتباهی در نگارش جدول باشد — و این پژوهش هیچ‌یک را ادعا نمی‌کند. آنچه ادعا می‌شود صرفاً همین است که این دو منبع با هم نمی‌خوانند، و پژوهشگری که به یکی از آن‌ها استناد کند نتیجه‌ای متفاوت از دیگری خواهد گرفت.

افزوده‌ی تکمیلی: ترکیب بذرها

آنچه در ادامه می‌آید تکمیلی است و هیچ عددی از آن وارد نتایج اصلی این پایان‌نامه نمی‌شود. تمام جدول‌های بخش ۲-۴ تا بخش ۲-۵-۴، تحلیل بخش ۴-۶ و آزمون برون‌توزیعی بخش ۵-۲ همگی بر مدل LSTM با بذر تثبیت‌شده‌ی ۴۲ استوارند و با این افزوده تغییر نمی‌کنند.

مدل‌های شبکه‌ی عصبی به مقدار اولیه‌ی تصادفی حساس‌اند. برای سنجش اینکه چه مقدار از فاصله‌ی این پژوهش تا لاگو ناشی از همین حساسیت است، LSTM با چهار بذر ۴۲ تا ۴۵ آموزش داده شد و میانگین پیش‌بینی‌های آن‌ها به جای مدل تک‌بذری در ترکیب نشست.

اثر آن قابل توجه است. خود LSTM از 3.8734 به 3.6460 می‌رسد، و ترکیب رژیم‌محور از 3.5569 به 3.4994. مهم‌تر از عدد، تغییر نتیجه‌ی آزمون است: برتری DNN Ensemble که با مدل تثبیت‌شده

جدول ۴-۱۰: اثر میانگین‌گیری بر چهار بذر LSTM. تکمیلی — این اعداد جایگزین نتایج تثبیت‌شده نمی‌شوند و در هیچ جدول دیگری تکرار نمی‌گردند.

MAE	rMAE	پیکربندی
3.8734	0.4244	LSTM، بذر ۴۲ (تثبیت‌شده)
3.6460	0.3995	LSTM، ترکیب چهار بذر
3.5742	0.3916	ترکیب ایستا، با LSTM تثبیت‌شده
3.5260	0.3863	ترکیب ایستا، با ترکیب بذرها
3.5569	0.3897	ترکیب رژیم‌محور، با LSTM تثبیت‌شده
3.4994	0.3834	ترکیب رژیم‌محور، با ترکیب بذرها
3.4135	0.3740	DNN Ensemble (مرجع)

در p برابر 0.0127 معنادار بود، با ترکیب بذرها به 0.0803 می‌رسد و دیگر معنادار نیست.

این نکته را باید با احتیاط خواند. آنچه نشان می‌دهد این نیست که این پژوهش با DNN Ensemble برابر است؛ نشان می‌دهد که بخشی از فاصله‌ی سنجیده‌شده، نوفه‌ی مقداردهی اولیه است و نه تفاوت روش. ضمناً مقایسه به این شکل کاملاً منصفانه نیست، چون گونه‌ی مرجع خود یک ترکیب است و مدل تثبیت‌شده‌ی این پژوهش تک‌اجرا. اما دلیل اینکه این اعداد جای اعداد اصلی را نمی‌گیرند، ساده و انضباطی است: تثبیت نتایج پیش از آغاز نگارش انجام شد، و جابه‌جا کردن پس از آن، هر تضمینی را که آن تثبیت فراهم می‌کند باطل می‌کرد. کرانِ اوراکل برای پیکربندی ترکیب‌بذری 3.5019 است، در برابر 3.5580 برای پیکربندی تثبیت‌شده.

۴-۶ تحلیل تفسیرپذیری SHAP

پرسش، و آنچه این بخش می‌تواند و نمی‌تواند پاسخ دهد

بخش‌های پیشین نشان دادند کدام مدل چقدر دقیق است. پرسش اینجا از جنس دیگری است: مدل بر چه چیزی تکیه می‌کند، و آیا این تکیه‌گاه با تغییر شرایط بازار جابه‌جا می‌شود؟
روش، مقادیر SHAP است [۴۲]: چارچوبی که سهم هر ویژگی در فاصله‌ی میان پیش‌بینی یک نمونه و میانگین پیش‌بینی‌ها را به‌صورت جمعی تجزیه می‌کند. مزیت آن نسبت به شاخص‌های اهمیت سنتی درختی این است که سهم‌ها جمع‌شونده و نمونه‌به‌نمونه‌اند، پس می‌توان آن‌ها را روی هر زیرمجموعه‌ای از روزها میانگین گرفت و مقایسه کرد — و کل این بخش دقیقاً بر همین خاصیت بنا شده است. کاربرد آن در پیش‌بینی قیمت برق سابقه دارد [۳۷].

پیش از هر عددی، سه قید دامنه باید ثبت شود.

یکم: این تحلیل مختص LightGBM است. پیاده‌سازی از TreeExplainer استفاده می‌کند که برای مدل‌های درختی، مقادیر SHAP را دقیق و نه تقریبی محاسبه می‌کند. چهار مدل دیگر این پژوهش تحلیل نمی‌شوند، و هیچ نتیجه‌ای از این بخش به آن‌ها تعمیم داده نمی‌شود. LEAR-LASSO سازوکار تفسیرپذیری خودش را دارد — ضرایبی که بخشی‌شان صفر شده‌اند — و LSTM هیچ‌کدام را ندارد. اینکه سه مدل با دقت آماری تفکیک‌ناپذیر (بخش ۴-۵-۱) از اطلاعات یکسانی استفاده می‌کنند یا نه، پرسشی است که این پژوهش به آن پاسخ نمی‌دهد.

دوم، و مهم‌تر: مدلی که توضیح داده می‌شود، همان شیئی نیست که نتایج از آن گزارش شده است. این نکته باید صریح نوشته شود، چون در غیر این صورت خواننده‌ای که خودش کشفش کند آن را نقص می‌بیند. مدل‌های اعتبارسنجی پیش‌رونده که تمام اعداد بخش ۴-۲ تا بخش ۴-۵-۲ از آن‌ها می‌آید، هر یک تنها تا پیش از مبدأ خود آموزش دیده‌اند. توضیح‌دادن پیش‌بینی آن مدل‌ها روی همان روزهایی که در آموزششان بوده‌اند، توضیحی درون‌نمونه‌ای می‌بود. بنابراین برای این بخش یک برازش جداگانه انجام شده است: LightGBM بر پنجره‌ی متحرک ۱۰۹۲ روزه‌ای که در ۳۱ دسامبر ۲۰۱۷ پایان می‌یابد، با همان ابرپارامترهای تنظیم‌شده و همان بذر ۴۲.

این برازش، همزاد وفادار مدل گزارش‌شده است و نه خود آن. سه چیز میان آن دو یکسان است: پیکربندی ابرپارامترها، ماتریس ویژگی، و طول پنجره‌ی آموزش. آنچه متفاوت است، مبدأ پایانی ثابت به‌جای مبدأ متحرک است. ماژول تحلیل عامدانه از برازش بر پنجره‌ی کوتاه‌تر امتناع می‌کند، دقیقاً برای آنکه این همزاد نتواند بی‌سروصدا از مدل اصلی فاصله بگیرد. بخش ۳-۵ این را به‌عنوان سومین شیء مدلی پروژه تفکیک کرده و گفته است که هیچ عددی از آن وارد جدول‌های دقت نمی‌شود؛ اینجا نیز چنین است. دلیلش صریح است: پنجره‌ی آموزش این همزاد روزه‌ای دوره‌ی آزمون را نیز در بر می‌گیرد، پس برای سنجش دقت معتبر نیست و تنها برای تفسیر به کار می‌رود. مدل‌های گزارش‌شده در بخش ۴-۲ تا بخش ۴-۵-۲، برعکس، هیچ‌یک فراتر از مبدأ خود آموزش ندیده‌اند و قاعده‌ی نشت را نقض نمی‌کنند.

سوم: SHAP نسبت‌دادن است، نه علیت. آنچه اندازه گرفته می‌شود، سهم یک ویژگی در خروجی یک مدل است. اگر مدل بر ویژگی‌ای تکیه کند که تنها همبسته‌ی علت واقعی است، SHAP همان ویژگی همبسته را برجسته نشان می‌دهد. هیچ جمله‌ای در سرتاسر این بخش نباید چنین خوانده شود که «فلان متغیر قیمت برق آلمان را تعیین می‌کند».

تصویر کلی

جدول ۴-۱۱ میانگین قدرمطلق مقادیر SHAP را به تفکیک خانواده‌ی ویژگی و در چهار حالت گزارش می‌کند. واحد، یورو بر مگاوات‌ساعت است، و تفسیر مستقیم دارد: میانگین اندازه‌ی جابه‌جایی که آن خانواده در پیش‌بینی ایجاد می‌کند.


جدول ۴-۱۱: میانگین قدرمطلق مقادیر SHAP به تفکیک خانواده‌ی ویژگی، بر حسب یورو بر مگاوات‌ساعت، برای مدل LightGBM. $exog_1$ پیش‌بینی بار و $exog_2$ پیش‌بینی تولید تجدیدپذیر است؛ پسوند D0 یعنی مقدار خودِ روز هدف و D-n یعنی مقدار n روز پیش. مقادیر پررنگ، بیشترین مقدار هر ستون است.

روزانه		ساعتی		خانواده‌ی ویژگی
پرتنش	آرام	پرتنش	آرام	
5.1335	3.1109	6.1471	3.4833	price_D-1
0.5177	0.3778	1.2550	0.8610	price_D-2
0.3916	0.3328	1.0302	0.8279	price_D-3
1.4784	1.0802	2.1473	1.7454	price_D-7
0.2611	0.2479	0.6735	0.6591	exog_1_D-1
0.3991	0.3699	0.7487	0.7131	exog_1_D-7
3.0130	3.4393	3.3680	3.5197	exog_1_D0
0.3986	0.4077	0.9221	0.9947	exog_2_D-1
0.2754	0.2230	0.7761	0.6740	exog_2_D-7
5.0366	4.4929	5.9761	5.8422	exog_2_D0
0.0379	0.0395	0.1358	0.1464	dow


سه واقعیت از جدول ۴-۱۱ و شکل ۴-۱ بیرون می‌آید.

پیش‌بینی تجدیدپذیر روز هدف، بزرگ‌ترین سهم را دارد. $exog_2_D0$ با 5.8422 در حالت آرام و 5.9761 در حالت پرتنش، در هر دو حالت افق ساعتی بالاترین است. سازوکار بازار همین را انتظار دارد: تولید بادی و خورشیدی پیش‌بینی‌شده، منحنی عرضه‌ی باقی‌مانده را جابه‌جا می‌کند و مستقیماً بر قیمت تسویه اثر می‌گذارد. اینکه مدل چنین وزنی به آن می‌دهد، نشانه‌ی خوبی است که چیزی واقعی را آموخته و صرفاً پایداری سری را دنبال نمی‌کند.

دو ویژگی روز هدف، بیشتر از هر لگی وزن دارند. $exog_2_D0$ و $exog_1_D0$ روی هم بخش بزرگی از کل اهمیت را می‌گیرند. همان استدلالی که **بخش ۳-۴** برای مجاز شمردن ویژگی‌های D0 آورد، اینجا هم برقرار است: پیش‌بینی بار و تجدیدپذیر روز هدف، پیش از بسته‌شدن مزایده در دسترس شرکت‌کنندگان است، پس استفاده از آن‌ها نشت اطلاعات نیست. اگر این ویژگی‌ها کنار گذاشته می‌شدند، مدل از دو مؤثرترین منبع اطلاعاتی خود محروم می‌ماند.




شکل ۴-۱: اهمیت سراسری ویژگی‌ها بر پایه‌ی میانگین قدرمطلق مقادیر SHAP، افق ساعتی.



شکل ۴-۲: نمودار زنبوری (beeswarm) مقادیر SHAP در افق ساعتی: پراکندگی سهم هر ویژگی در تک‌تک نمونه‌ها، نه تنها میانگین آن.

روز هفته تقریباً بی‌اثر است. dow با 0.1464 در افق ساعتی و 0.0395 در افق روزانه، حدود یک‌چهارم بزرگ‌ترین خانواده است. خواندن آن به معنای نبود الگوی هفتگی نادرست است — بخش ۳-۳ نشان داد که چنین الگویی هست — بلکه به این معناست که لگ هفتگی قیمت، price_D-7 با 1.7454، همان اطلاعات را در شکلی غنی‌تر منتقل می‌کند. وقتی لگ‌ها حاضرند، متغیر تقویمی چیزی برای افزودن ندارد.

نیم‌رخ ساعتی




شکل ۳-۴: تفکیک سهم SHAP بر حسب ساعت شبانه‌روز.

شکل ۳-۴ همان تجزیه را بر محور ساعت شبانه‌روز باز می‌کند. تفکیک ساعتی یادآور می‌شود که میانگین‌های جدول ۱۱-۴ روی ۲۴ ساعتِ ناهمگن گرفته شده‌اند: ساعت‌های میانه‌ی روز، که تولید خورشیدی در آن‌ها متمرکز است، رفتاری متفاوت از ساعت‌های شب دارند، و بخش ۳-۳-۳ همین ناهمگنی را در سطح خود قیمت نشان داده بود (کمینه‌ی میانگین در ساعت ۳ و بیشینه در ساعت ۱۹).

آرام در برابر پرتنش: یافته‌ی اصلی این بخش

مقایسه‌ی دو ستون نخست جدول ۱۱-۴ روشن‌ترین یافته‌ی این بخش را می‌دهد، و شکل ۴-۴ همان را به‌صورت تصویری نشان می‌دهد.

اهمیت price_D-1 زیر تنش 76.5 درصد افزایش می‌یابد، از 3.4833 به 6.1471. هیچ خانواده‌ی



شکل ۴-۴: مقایسه‌ی اهمیت ویژگی‌ها میان روزهای آرام و روزهای پرتنش.

دیگری چنین جابه‌جایی‌ای ندارد. وقتی بازار پرتنش است، مدل به‌مراتب سنگین‌تر بر قیمت دیروز تکیه می‌کند.

در جهت مخالف، $exog_1_D0$ — پیش‌بینی بار روز هدف — از 3.5197 به 3.3680 کاهش می‌یابد، یعنی حدود چهار درصد افت. و $exog_2_D0$ با 5.8422 در برابر 5.9761 عملاً ثابت می‌ماند.


خوانش این سه عدد با هم، سازوکار روشنی می‌سازد. در بازار آرام، قیمت را می‌توان تا حد خوبی از بنیان‌های همان روز — بار و تجدیدپذیر — ساخت. وقتی بازار پرتنش می‌شود، همان بنیان‌ها دیگر برای تعیین سطح قیمت کافی نیستند، چون قیمت‌های بالا از کمیابی و رفتار پیشنهاددهی می‌آیند که در متغیرهای بنیادی پیدا نیست. مدل در پاسخ، سطح را از آخرین مشاهده‌ی محقق‌شده می‌گیرد و بنیان‌ها را برای تعیین شکل درون‌روزی نگه می‌دارد.

سایر لگ‌های قیمت نیز در همین جهت حرکت می‌کنند اما با شدت کمتر: $price_D-2$ از 0.8610 به 1.2550 و $price_D-7$ از 1.7454 به 2.1473. پس این افزایش اتکا، مختص یک لگ نیست بلکه به کل بلوک لگ‌های قیمت مربوط است، با بیشترین سهم برای نزدیک‌ترین آن‌ها.

یافته‌ی بالا با نتیجه‌ی بخش ۴-۵-۱ پیوند مستقیم دارد و آن را از سوی دیگری تأیید می‌کند. آنجا نشان داده شد که تمام سود وزن‌دهی رژیم‌محور از همان ۷۷ روز پرتنش می‌آید. اینجا دیده می‌شود که چرا: در آن روزها نه فقط خطای مدل، بلکه رفتارش واقعاً تغییر می‌کند. دو تحلیل کاملاً مستقل —

یکی بر پایه‌ی زیانِ پیش‌بینی و دیگری بر پایه‌ی نسبت‌دادنِ ویژگی — به یک نتیجه می‌رسند. چنین هم‌گرایی‌ای خودِ شاهده‌ی است بر اینکه تفکیک دو رژیم صرفاً یک برشِ دلبخواه داده نبوده است.

ساعتی در برابر روزانه



شکل ۴-۵: مقایسه‌ی اهمیت ویژگی‌ها میان افق ساعتی و افق روزانه.

دو ستون آخر [جدول ۴-۱۱](#) همان تحلیل را برای هدف روزانه تکرار می‌کنند، و الگویی متفاوت اما سازگار پدید می‌آورند.

بیشتر اهمیت‌ها در افق روزانه کوچک‌تر می‌شوند، که انتظار می‌رفت: هدف روزانه میانگین ۲۴ عدد است و دامنه‌ی نوسان آن کمتر، پس اندازه‌ی جابه‌جایی‌ها هم کمتر است. آنچه معنا دارد، نه اندازه‌ی مطلق بلکه نسبت‌هاست.


دو تغییر نسبی برجسته است. نخست، لگ‌های میانی به شدت افت می‌کنند: price_D-2 از 0.8610 به 0.3778 و price_D-3 از 0.8279 به 0.3328، یعنی بیش از نصف. دوم، exog_1_D0 تقریباً دست‌نخورده می‌ماند: 3.5197 در افق ساعتی در برابر 3.4393 در افق روزانه. در واقع پیش‌بینی بار در افق روزانه به بزرگ‌ترین ویژگی در حالت آرام بدل می‌شود.

توضیح، در ماهیت خودِ دو هدف است. بخش بزرگی از کاری که لگ‌های قیمت در افق ساعتی انجام می‌دهند، بازسازیِ شکلِ درون‌روزی است — اینکه ساعت ۱۹ گران‌تر از ساعت ۳ است. در هدف روزانه

این شکل با میانگین‌گیری از میان می‌رود و آن بخش از کارکرد لگ‌ها بی‌مصرف می‌شود. آنچه باقی می‌ماند، تعیین سطح است، که بار و تجدیدپذیر تجمیع‌شده‌ی همان روز آن را به‌خوبی توضیح می‌دهند. تصویر بالا با یافته‌ی بخش ۴-۴ کاملاً هم‌خوان است. آنجا دیده شد که برای سه مدل از چهار مدل، میانگین‌گیری از ۲۴ پیش‌بینی ساعتی بهتر از مدل‌سازی مستقیم هدف روزانه است. اینجا سازوکارش دیده می‌شود: مسیر مستقیم، مدل را از اطلاعات ساختار درون‌روزی محروم می‌کند و همان اطلاعات است که در تحلیل SHAP به‌صورت افت اهمیت لگ‌های میانی خود را نشان می‌دهد.

الگوی رژیمی در افق روزانه نیز تکرار می‌شود: price_D-1 از 3.1109 به 5.1335 می‌رسد، یعنی حدود ۶۵ درصد افزایش، و exog_1_D0 از 3.4393 به 3.0130 افت می‌کند. پس این یافته مختص افق ساعتی نیست.

یک روز، به تفصیل



شکل ۴-۶: نمودار آبخاری برای یک روز منفرد: تجزیه‌ی فاصله‌ی میان پیش‌بینی آن روز و میانگین پیش‌بینی‌ها به سهم تک‌تک ویژگی‌ها.

تمام آنچه تا اینجا آمد، میانگین بر هزاران نمونه بود. شکل ۴-۶ همان تجزیه را برای یک روز منفرد نشان می‌دهد، و کارکردی متفاوت دارد.

میانگین‌ها به پرسش‌های پژوهشی پاسخ می‌دهند، اما در کاربرد عملی، آنچه به کار می‌آید تبیین همان پیش‌بینی خاصی است که پیش‌روست. نمودار آبخاری نشان می‌دهد که پیش‌بینی یک روز مشخص چگونه از میانگین فاصله گرفته و کدام ویژگی‌ها آن را به کدام سو برده‌اند. همین قابلیت است

که ابزار عملیاتی بخش ۵-۳ بر آن بنا شده است: عددی که با تبیین همراه باشد، برای بهره‌بردار قابل ارزیابی است، و عددی که تنها یک عدد باشد، نیست.

آنچه این بخش ادعا نمی‌کند

سه چیز از این تحلیل نتیجه نمی‌شود، و ننوشتنشان دعوت به بدخوانی است.

این‌ها «عوامل تعیین‌کننده‌ی قیمت برق آلمان» نیستند. این‌ها ویژگی‌هایی هستند که یک مدل درختی، آموخته بر یک مجموعه داده و در یک پنجره‌ی زمانی، بیش از بقیه به آن‌ها تکیه کرده است. SHAP خروجی مدل را تجزیه می‌کند، نه بازار را.

این‌ها به چهار مدل دیگر تعمیم نمی‌یابند. LEAR-LASSO، LSTM و SARIMAX تحلیل نشده‌اند. اینکه دقت آن‌ها از LightGBM تفکیک‌پذیر نیست، به هیچ روی به معنای آن نیست که از اطلاعات یکسانی استفاده می‌کنند؛ ممکن است سه مسیر متفاوت به دقتی مشابه رسیده باشند، و این خود پرسشی است که این پژوهش باز می‌گذارد.

هم‌بستگی میان ویژگی‌ها، سهم‌ها را میان اعضای یک خانواده جابه‌جا می‌کند. لگ‌های قیمت به شدت با هم هم‌بسته‌اند، و وقتی چنین است، توزیع اهمیت میان price_D-1 و price_D-2 تا حدی به ساختار خود درخت وابسته است. به همین دلیل تمام تفسیرهای این بخش در سطح خانواده‌ی ویژگی بیان شده‌اند و نه در سطح ستون‌های منفرد، و تمام مقایسه‌ها میان دو حالت همان خانواده انجام شده است — جایی که ساختار هم‌بستگی ثابت می‌ماند و اثرش تا حد زیادی حذف می‌شود.

۷-۴ پاسخ به سؤالات پژوهش

این بخش چهار پرسش پژوهشی فصل نخست را، به ترتیب و در همان دامنه‌ای که پرسیده شده‌اند، پاسخ می‌دهد. هر پاسخ دو بخش دارد: آنچه شواهد پشتیبانی می‌کنند، و آنچه پشتیبانی نمی‌کنند. بخش دوم به اندازه‌ی بخش نخست جدی گرفته شده است، چون فاصله‌ی میان این دو، همان جایی است که یک نتیجه‌ی درست به ادعایی نادرست بدل می‌شود.

یادآوری یک نکته‌ی صوری پیش از پاسخ‌ها: طرح مصوب، پرسش پژوهشی شماره‌گذاری شده ندارد و به جای آن شش هدف و شش فرض را برمی‌شمارد. چهار پرسشی که در ادامه پاسخ داده می‌شود، صورت‌بندی عملیاتی همان اهداف است، نه افزوده‌ای بر آن‌ها.

پرسش نخست: دقت مقایسه‌ای پنج خانواده‌ی مدلی

پنج مدل منتخب تحت یک پروتکل اعتبارسنجی پیش‌رونده‌ی یکسان چه عملکردی نسبت به یکدیگر دارند، و کدام تفاوت‌ها از نظر آماری معنادار است؟

پاسخ. بر ۷۲۸ مبدأ پیش‌بینی از چهارم ژانویه‌ی ۲۰۱۶ تا سی‌ویکم دسامبر ۲۰۱۷، ترتیب MAE در افق ساعتی چنین است: LSTM با 3.8734، LEAR-LASSO با 3.8988، LightGBM با 3.9678، SARIMAX با 4.3507 و مدل ساده با 7.7501.

اما ترتیب، پاسخ نیست. آزمون دیبولد-ماریانو نشان می‌دهد که سه مدل نخست از یکدیگر تفکیک‌پذیر نیستند. LSTM در برابر LEAR-LASSO حتی پیش از هر تصحیحی p برابر 0.4036 می‌دهد. LSTM در برابر LightGBM برآورد نقطه‌ای پایین‌تری دارد، اما این تفاوت پس از تصحیح هولم-بونفرونی بر خانواده‌ی ۲۱ آزمون دوام نمی‌آورد (p خام 0.0405، p تصحیح‌شده 0.1215).

سه نتیجه‌ی مقاوم باقی می‌ماند. هر چهار مدل آموخته بر مدل ساده برتری دارند با p عملاً برابر صفر. SARIMAX از سه مدل دیگر پایین‌تر است، با p تصحیح‌شده‌ی حداکثر $5.1e-04$ و هر دو ترکیب بر تک‌تک اعضای خود برتری دارند، با p تصحیح‌شده‌ی حداکثر $3.4e-05$.

تساوی، خود یافته است. اینکه بهترین مدل آماری و بهترین مدل یادگیری عمیق این پژوهش تفکیک‌ناپذیرند، نتیجه‌ای است درباره‌ی اینکه یادگیری عمیق در این مسئله چه قدر می‌افزاید، و نه ناکامی در جداکردن مدل‌ها. طراحی برابر آزمایش — ماتریس ویژگی یکسان، مبادی یکسان، بودجه‌ی پنجاه‌آزمایشی تنظیم برای هر مدل — همان چیزی است که این تساوی را به یافته بدل می‌کند؛ بدون آن، می‌شد آن را به تنظیم ناکافی یکی از دو طرف نسبت داد.

آنچه ادعا نمی‌شود. این پاسخ نمی‌گوید یادگیری عمیق به‌طور کلی بر روش‌های آماری برتری دارد یا ندارد. یک معماری از هر خانواده، یک بازار، یک پنجره‌ی دوساله، یک بودجه‌ی تنظیم.

پرسش دوم: ترکیب و وزن‌دهی رژیم‌محور

آیا ترکیب وزن‌دار دقت را نسبت به بهترین تک‌مدل بهبود می‌دهد، و آیا مشروط‌کردن وزن‌ها به رژیم بازار بهبود بیشتری نسبت به وزن‌دهی ایستا ایجاد می‌کند؟ این بهبود، در صورت وجود، تحت کدام شرایط بازار پدید می‌آید؟

بخش نخست، بله. ترکیب ایستا با 3.5742 و ترکیب رژیم‌محور با 3.5569 هر دو از بهترین عضو

منفرد — LSTM — با 3.8734 — بهترند، و هر هشت مقایسه‌ی ترکیب با اعضایش پس از تصحیح هولم نیز با p حداکثر $3.4e-05$ برقرار می‌ماند. مقاوم‌ترین یافته‌ی فصل همین است.

بخش دوم، بله اما مشروط. ترکیب رژیم‌محور بر ترکیب ایستا با p برابر 0.0226 برتری دارد. این آزمون، تنها عضو خانواده‌ی تأییدی است و به همین دلیل بدون تصحیح چندگانگی در سطح 0.05 خوانده می‌شود؛ ثبت تاریخ‌دار آن در یازدهم ژوئیه‌ی ۲۰۲۶، پیش از آنکه هر ترکیبی بر پنجره‌ی آزمون امتیاز بگیرد، تنها چیزی است که این خوانش را مجاز می‌کند. دو قید باید همراهش بیاید: اگر همین آزمون از خانواده‌ی اکتشافی می‌آمد، پس از تصحیح به 0.0903 می‌رسید و معنادار نمی‌ماند؛ و بوت‌استرپ بلوکی بر کل دوره بازه‌ی 0.0129 تا 0.0571 می‌دهد، یعنی در بلوک‌های ده‌روزه از آستانه عبور می‌کند.

بخش سوم پرسش، پاسخ تیزی دارد و مهم‌ترین بخش این جواب است. تمام بهبود از ۷۷ روز پرتنش می‌آید، با 5.5132 در برابر 5.6830 و p برابر 0.0063 — که در سراسر بازه‌ی بوت‌استرپ نیز معنادار می‌ماند (0.0081 تا 0.0439). بر ۶۵۱ روز آرام، ترکیب رژیم‌محور به‌اندازه‌ی ده‌هزارم یورو بدتر است و p برابر 0.8465.

نتیجه‌ی تهی روزهای آرام، خود یک یافته است. وزن‌دهی رژیم‌محور بهبودی عمومی نیست؛ سازوکاری است که در شرایط پرتنش کار می‌کند و در شرایط آرام بی‌اثر است. این دقیقاً همان چیزی است که برایش طراحی شده بود، و تحلیل SHAP در **بخش ۴-۶** از راهی کاملاً مستقل همین را تأیید می‌کند: رفتار مدل در روزهای پرتنش واقعاً متفاوت است.

آنچه ادعا نمی‌شود. این پاسخ نمی‌گوید وزن‌دهی رژیم‌محور به‌طور کلی بر وزن‌دهی ایستا برتری دارد. می‌گوید بر این بازار و این پنجره، در روزهای پرتنش برتری داشت و در روزهای آرام نداشت.

پرسش سوم: تفسیرپذیری

کدام خانواده‌های ویژگی بیشترین سهم را در پیش‌بینی دارند، و آیا این سهم میان روزهای آرام و پرتنش، و میان افق ساعتی و روزانه، تغییر می‌کند؟

پاسخ. برای مدل LightGBM، پیش‌بینی تولید تجدیدپذیر روز هدف (exog_2_D0) بزرگ‌ترین سهم منفرد را دارد — 5.8422 در حالت آرام و 5.9761 در حالت پرتنش — و در برابر تغییر رژیم پایدار است.

بله، سهم‌ها میان دو رژیم تغییر می‌کنند، و تغییر یکنواخت نیست. اهمیت price_D-1 زیر تنش 76.5 درصد افزایش می‌یابد، از 3.4833 به 6.1471، در حالی که پیش‌بینی بار روز هدف (exog_1_D0)

از 3.5197 به 3.3680 کاهش می‌یابد. مدل در شرایط پرتنش سطح قیمت را از آخرین مشاهده می‌گیرد و بنیان‌های روز را برای تعیین شکل نگه می‌دارد.

بله، سهم‌ها میان دو افق نیز تغییر می‌کنند. در افق روزانه لگ‌های میانی بیش از نصف اهمیتشان را از دست می‌دهند (price_D-2 از 0.8610 به 0.3778) در حالی که پیش‌بینی بار روز هدف تقریباً دست‌نخورده می‌ماند (3.5197 در برابر 3.4393) و در حالت آرام به بزرگ‌ترین ویژگی بدل می‌شود. روز هفته، وقتی لگ‌ها حاضرند، تقریباً بی‌اثر است: 0.1464 در افق ساعتی.

یک افشای لازم. مدلی که در **بخش ۴-۶** توضیح داده شده، برازشی جداگانه بر پنجره‌ی ۱۰۹۲ روزه‌ی منتهی به سی‌ویکم دسامبر ۲۰۱۷ است و نه همان مدل‌های اعتبارسنجی پیش‌رونده‌ای که اعداد دقت از آن‌ها گزارش شده؛ توضیح‌دادن آن مدل‌ها روی روزهای آموزششان، تحلیلی درون‌نمونه‌ای می‌بود. **آنچه ادعا نمی‌شود.** این‌ها «عوامل قیمت برق آلمان» نیستند و به چهار مدل دیگر تعمیم نمی‌یابند. SHAP خروجی یک مدل را تجزیه می‌کند، نه بازار را.

پرسش چهارم: مسیر مستقیم در برابر مسیر تجمیعی

برای پیش‌بینی میانگین بار پایه‌ی روزانه، کدام مسیر دقت بالاتری دارد، و آیا این نتیجه برای هر پنج مدل یکسان است؟

پاسخ بخش نخست: تجمیع، برای سه مدل از چهار مدل. میانگین‌گیری از ۲۴ پیش‌بینی ساعتی برای LEAR-LASSO (2.8389 در برابر 2.8989)، LightGBM (2.9928 در برابر 3.3012) و LSTM (2.7804 در برابر 3.1753) بهتر عمل می‌کند. مدل ساده در هر دو مسیر یکسان است.

پاسخ بخش دوم: خیر، یکسان نیست. SARIMAX استثناست و مسیر مستقیم برایش بهتر است (3.1976 در برابر 3.2691). استثنا توضیح ساختاری دارد و در **بخش ۴-۴** آمده است: سری بار پایه‌ی روزانه دقیقاً همان نوع سری هموار تک‌بعدی است که مدل‌های کلاسیک سری زمانی برایش ساخته شده‌اند.

اینکه پرسش عامدانه دو بخشی صورت‌بندی شده بود، همین استثنا را به بخشی از پاسخ بدل می‌کند و نه دردسری برای آن.

آنچه ادعا نمی‌شود. این یک قاعده‌ی کلی درباره‌ی تجمیع زمانی در پیش‌بینی نیست. چهار مدل، یک بازار، یک پنجره.

یک یافته که هیچ پرسشی آن را نمی‌پوشاند

آزمون برون‌توزیعی — ارزیابی مدل‌های تثبیت‌شده بر داده‌ی زنده‌ی ۲۰۲۶ — پس از تصویب طرح پیشنهادی به پروژه افزوده شد و به همین دلیل زیر هیچ‌یک از چهار پرسش بالا قرار نمی‌گیرد. با این حال، به گمان این پژوهش، مهم‌ترین یافته‌ی کار است. نتیجه‌ی آن، همراه با آنچه درباره‌ی محدودیت‌های این پژوهش می‌گوید، در [بخش ۵-۲](#) گزارش می‌شود.