

فصل پنجم

جمع‌بندی، بحث و پیشنهادات

۱-۵ جمع‌بندی نتایج

هدف این پژوهش، پیش‌بینی قیمت روز بعد برق در بازار آلمان بود، بر دو افق ساعتی و میانگین روزانه، با پنج خانواده‌ی مدل و دو ترکیب، در چارچوبی که بتوان نتیجه‌اش را هم بازتولید کرد و هم در برابر ادبیات منتشرشده سنجید. بخش ۴-۷ پاسخ‌ها را یک‌به‌یک در برابر پرسش‌های پژوهش گذاشت؛ آنچه در ادامه می‌آید، جمع‌بندی همان پاسخ‌هاست و هیچ عدد تازه‌ای به آن‌ها نمی‌افزاید.

آنچه ساخته شد

خط لوله‌ای کامل از داده‌ی خام تا پیش‌بینی امتیازدهی‌شده: بارگذار داده با دریافت یک‌باره و ثبت اثر انگشت sha256، ماتریس ویژگی ۲۴۷ ستونی که هیچ ستونش از پس از مبدأ پیش‌بینی تغذیه نمی‌شود، تنظیم ابرپارامتر با ۵۰ آزمایش بر پنجره‌ای که کاملاً پیش از دوره‌ی آزمون قرار دارد، و ارزیابی پیش‌رونده بر ۷۲۸ مبدأ از ۴ ژانویه ۲۰۱۶ تا ۳۱ دسامبر ۲۰۱۷. سه شیء مدلی متمایز — پیش‌رونده، تثبیت‌شده، و برازش تفسیری — از یکدیگر تفکیک شدند تا هیچ عددی از مسیر نادرست وارد جدول‌ها نشود.

دقت

بهترین پیکربندی، ترکیب رژیم‌محور بود با MAE برابر 3.5569 یورو بر مگاوات‌ساعت در افق ساعتی، در برابر 7.7501 برای مدل ساده. هر پنج مدل آموزش‌دیده از مدل ساده بهتر بودند و این برتری پس از تصحیح چندگانگی نیز پابرجا ماند. اما میان خودِ مدل‌های خوب، فاصله‌ها بسیار کمتر از چیزی است که جدول‌های مرتب‌شده القا می‌کنند: LSTM و LEAR-LASSO از یکدیگر تفکیک‌پذیر نیستند (p برابر 0.4036)، و برتری عددی LSTM بر LightGBM تصحیح برای چندگانگی را تاب نمی‌آورد. یعنی در این پیکربندی، هزینه‌ی یادگیری عمیق مزیت قابل‌دفاعی بر یک مدل خطی تنظیم‌شده نخرید.

ترکیب و رژیم

هر دو ترکیب از تک‌تک اعضای خود بهتر بودند، با فاصله‌ای که تصحیح چندگانگی را به سادگی تاب می‌آورد. وزن‌دهی رژیم‌محور نیز ترکیب ایستا را بهبود داد، اما دقیقاً آنجا که برای آن طراحی شده بود: تمام بهبود بر ۷۷ روز پرتنش متمرکز است (p برابر 0.0063)، و بر ۶۵۱ روز آرام اثر عملاً صفر است (p برابر 0.8465). نتیجه‌ی تجمیعی — p برابر 0.0226 — به‌عنوان یک فرضیه‌ی پیش‌اعلام‌شده‌ی تأییدی

دفاع می‌شود، و بخش ۴-۵-۱ صریحاً نوشت که همین عدد اگر از خانواده‌ی اکتشافی برداشته می‌شد، از تصحیح هولم عبور نمی‌کرد.

افق روزانه

برای سه مدل از چهار مدل، میانگین‌گیری از پیش‌بینی‌های ساعتی بهتر از آموزش مستقیم بر سری روزانه بود. SARIMAX استثناست و در بخش ۴-۴ استثنا بودنش توضیح داده شد، نه میانگین گرفته شد.

تفسیرپذیری

تحلیل SHAP نشان داد رفتار مدل میان دو رژیم واقعاً تغییر می‌کند: سهم قیمت روز پیش در شرایط پرتنش به شدت بالا می‌رود و سهم پیش‌بینی بار پایین می‌آید. این یافته از مسیری کاملاً مستقل از آزمون‌های آماری به همان نتیجه‌ای می‌رسد که وزن‌دهی رژیم‌محور بر آن استوار است، و همین هم‌گرایی است که آن را از یک همبستگی اتفاقی جدا می‌کند.

آنچه به دست نیامد

سه نتیجه‌ی منفی نیز به همان اندازه بخشی از جمع‌بندی‌اند. نخست، این پژوهش بهترین مدل منتشرشده‌ی مرجع را شکست نمی‌دهد؛ با دو گونه‌ی آن هم‌تراز است و به یکی می‌بازد. دوم، برتری یادگیری عمیق بر خط‌مبناهای خطی قوی در این پیکربندی اثبات‌پذیر نبود. سوم، و مهم‌تر از هر دو، مدل‌های تثبیت‌شده در انتقال به داده‌ی خارج از توزیع شکست خوردند. آن نتیجه ذیل هیچ‌یک از پرسش‌های پژوهش نمی‌گنجد و موضوع بخش ۵-۲ است.

۵-۲ محدودیت‌ها

بخشی از آنچه در این بخش می‌آید، محدودیت به معنای متعارف است: کاری که با داده و زمان در دسترس نمی‌شد کرد. اما مهم‌ترین بند این بخش محدودیت نیست، نتیجه است — نتیجه‌ای منفی که پس از تثبیت مدل‌ها به دست آمد، ذیل هیچ‌یک از پرسش‌های پژوهش نمی‌گنجد، و به گمان این پژوهش مهم‌ترین یافته‌ی آن است.

آزمون خارج از توزیع

مدل‌های تثبیت‌شده‌ی دوره‌ی بنچمارک، بدون هیچ بازآموزی، بر ۱۷۳ روز کامل داده‌ی زنده‌ی سال ۲۰۲۶ اجرا شدند: ۴۳۴۳ ردیف ساعتی، بدون شکاف، از منطقه‌ی مزایده‌ی DE-LU. فاصله‌ی زمانی میان پایان آموزش و این پنجره نزدیک به یک دهه است. هدف این نبود که مدلی خوب جلوه کند؛ این بود که سنجیده شود مدلی که بر شرایط ۲۰۱۷ تثبیت شده، در برخورد با بازار امروز چه می‌کند.

جدول ۱-۵: مدل‌های تثبیت‌شده بر ۱۷۳ روز داده‌ی زنده‌ی ۲۰۲۶، بدون بازآموزی. ستون آخر افزایش MAE نسبت به همان مدل بر دوره‌ی آزمون بنچمارک است. مقادیر rMAE بزرگ‌تر از 1.0 یعنی بدتر از پیش‌بینی ساده. انتساب داده در **بخش ۳-۲-۳** آمده است.

مدل	MAE	RMSE	rMAE	اختلاف MAE
ساده	29.1828	48.7322	0.8076	3.7655
LEAR-LASSO	39.2667	65.3144	1.0867	10.0715
SARIMAX	41.3913	56.5039	1.1455	9.5137
ترکیب رژیم‌محور	42.1713	53.3753	1.1671	11.8561
ترکیب ایستا	44.4331	55.5191	1.2297	12.4315
LSTM	54.9286	67.5062	1.5201	14.1812
LightGBM	66.0582	77.3488	1.8281	16.6485

جمله‌ای که این جدول اجازه می‌دهد، صریح است: **هر پنج مدل آموزش‌دیده و هر دو ترکیب، از یک پیش‌بینی ساده‌ی مبتنی بر تأخیر هفتگی شکست خوردند.** rMAE همه‌ی آن‌ها بالای 1.0 است و تنها مدل ساده زیر آن می‌ماند. بدتر آنکه ترتیب وارونه می‌شود: LightGBM و LSTM که بر بنچمارک در صدر بودند، اینجا در قعرند، و LEAR-LASSO که ساده‌ترین مدل یادگیرنده است، کم‌ترین آسیب را می‌بیند.

تصحیح اریبی: نشانه، نه علت

برای آنکه روشن شود این شکست از چه جنسی است، یک تصحیح اریبی غلتان با پنجره‌ی ۷ روزه بر خروجی‌ها اعمال شد. **جدول ۲-۵** پیش و پس از آن را بر همان ۱۶۶ روزی که این پنجره پشتیبانی می‌کند گزارش می‌کند.

الگو گویاست: تصحیح دقیقاً آنجا بیشترین کمک را می‌کند که شکست بدترین بوده (LightGBM و LSTM)، و به دو مدلی که از ابتدا کم‌اریب‌ترین بودند آسیب می‌زند (ساده و LEAR-LASSO). یعنی سهم بزرگی از خطا یک جابه‌جایی سطح است و نه فروپاشی ساختار آموخته‌شده؛ مدل‌ها هنوز ساعت‌ها را نسبت به هم درست مرتب می‌کنند، فقط اریب‌اند. اما این توصیف نشانه است، نه تشخیص علت، و

جدول ۵-۲: rMAE پیش و پس از تصحیح اریبی غلتان با پنجره‌ی ۷ روزه، بر ۱۶۶ روز مشترک. مقدار مثبت در ستون آخر یعنی تصحیح به آن مدل آسیب زده است.

مدل	rMAE خام	rMAE تصحیح‌شده	تغییر
ساده	0.8035	0.8678	+0.0643
LEAR-LASSO	1.0919	1.1323	+0.0405
SARIMAX	1.1547	1.1295	-0.0252
ترکیب رژیم‌محور	1.1756	0.8946	-0.2809
ترکیب ایستا	1.2390	0.9064	-0.3327
LSTM	1.5354	1.0135	-0.5218
LightGBM	1.8258	1.0784	-0.7474

نوشتن آن به‌تنهایی گمراه‌کننده می‌بود.

سازوکاری که زیر آن نشانه پیدا شد

یک تشخیص پشتیبانی‌ویژگی، توزیع هر سری را در آموزش و در سرویس‌دهی مقایسه کرد. بخش ۳-۲ وجود این ناهم‌خوانی را پیش از گزارش هر نتیجه‌ای ثبت کرده و سنجش اندازه‌ی آن را به همین‌جا سپرده بود؛ آنچه در پی می‌آید، همان سنجش است. نتیجه، خطای خودِ این پژوهش را آشکار می‌کند. $exog_1$ — پیش‌بینی بار، که بخش ۴-۶ آن را در شمار مؤثرترین ویژگی‌ها نشان داد — همپوشانی هیستوگرامی برابر 0.0002 با توزیع آموزشی خود دارد، و 99.86 درصد مقادیر سرویس‌داده‌شده بالاتر از بیشینه‌ی کل دوره‌ی آموزش‌اند. ضرب در یک عدد ثابت، همپوشانی را به 0.8681 باز می‌گرداند و نسبت بیرون‌ازپشتیبانی را به صفر می‌رساند. آن عدد 2.553 است، و سهم منطقه‌ی کنترلی Amprion از بار ملی آلمان حدود ۳۹ درصد است ($1/2.553 = 0.392$). یعنی مدل‌ها بر پیش‌بینی بارِ یک منطقه‌ی کنترلی آموزش دیده‌اند و در سرویس‌دهی، جمعِ ملی به آن‌ها داده شده است. بار مصرفی آلمان در این سال‌ها 2.5 برابر نشده است؛ تعریف متغیر زیر مسیر سرویس‌دهی عوض شده است.

دو روایت با هم سازگارند، و همین نکته است. تغذیه‌ی بار با مقیاس 2.553 یک درخت را در بالاترین آستانه‌ی انشعابش اشباع می‌کند — پس LightGBM با 1.8281 بدترین است — در حالی که یک مدل خطی صرفاً بر امتداد ضریب خود برون‌یابی می‌کند — پس LEAR-LASSO با 1.0867 کم‌آسیب‌ترین. این همان ترتیبی است که انتقال هم‌متغیر پیش‌بینی می‌کند، و نه ترتیبی که یک جابه‌جایی سطح صرفِ قیمت پیش‌بینی می‌کرد. و اریبی سامان‌مندی که از آن پدید می‌آید، همان چیزی است که تصحیح غلتان بعداً برمی‌دارد. پس کارکردنِ تصحیح اریبی شاهده‌ی علیه انتقال هم‌متغیر نیست؛ دقیقاً شکلِ ظاهری آن است پس از یک وصله‌ی سطحی.

جمله‌ی درست این است: ارزیابی خارج از توزیع، تغییر واقعی بازار را با یک ناسازگاری تعریف میان آموزش و سرویس‌دهی در هم می‌آمیزد؛ این تشخیص آن دو را از هم جدا می‌کند؛ و جمله‌ی سنجش‌پذیر غالب، ناسازگاری تعریف است — که قابل تصحیح است و از آن خود ماست.

آنچه ادعا نمی‌شود. اینکه مقیاس‌بندی دوباره پیش‌بینی‌ها را درست می‌کند. هیچ امتیازدهی تازه‌ای انجام نشده است. بازیابی پشتیبانی و ویژگی، بازیابی خطا نیست، و اجرایی که آن را نشان دهد وجود ندارد، چون انجامش نتایج تثبیت‌شده‌ی v1.1-ood را دوباره باز می‌کند. این کار به پژوهش آینده سپرده شده و در **بخش ۴-۵** می‌آید.

محدودیت‌های داده

اسپرد پاک گازی و اسپرد زغالی — دو متغیر توضیحی متعارف در ادبیات قیمت برق — در این پژوهش قابل ساخت نبودند. این کاستی را باید جدی گرفت: پژوهش‌های پیشین، از جمله تحلیلی تفسیرپذیر بر همین بازار آلمان، قیمت حامل‌های انرژی را از عوامل تعیین‌کننده‌ی قیمت برق یافته‌اند [۵، ۳۷]. اما قراردادهای آتی گاز و زغال‌سنگ مجوز تجاری دارند، و منابعی که آزادانه در دسترس‌اند تنها سری‌های مشتق‌شده از آن‌ها را بازنشر می‌کنند، که آن‌ها را به استناد بدل می‌کند و نه به منبع داده. دو منبع دیگر نیز به دلیل شرایط استفاده و بازتولیدناپذیری کنار گذاشته شدند. این یک محدودیت واقعی است و بیان‌ش بهتر از پرسیده‌شدنش است.

سه قید دیگر نیز باید نوشته شود. نخست، تمام نتایج بر یک بازار، یک پنجره‌ی آزمون و یک تاریخ تثبیت به دست آمده‌اند؛ تعمیم آن‌ها به بازارهای دیگر آزموده نشده است. دوم، منطقه‌ی مزایده‌ی آلمان تا اکتبر ۲۰۱۸ شامل اتریش نیز بود، و این گسست میان دوره‌ی آموزش و پنجره‌ی زنده وجود دارد. سوم، وزن‌های ترکیب بر همان پنجره‌ی اعتبارسنجی برآزش شده‌اند که اعضای ترکیب بر آن تنظیم شده بودند؛ این پنجره کاملاً پیش از دوره‌ی آزمون است و نشتی رخ نمی‌دهد، اما وزن‌ها را باید تخمین‌هایی خوش‌بینانه دانست.

بازگشت به شش فرض

بخش ۲-۳ شش فرض رسمی طرح مصوب را نقل کرد. اکنون می‌توان گفت شواهد با کدام یک همراه نشد.

فرض تعمیم‌پذیری مدل صریح‌ترین مورد است و از هر دو روایت آسیب می‌بیند: مدل‌ها در شرایطی

که برایشان آموزش ندیده بودند شکست خوردند، چه آن شرایط را تغییر بازار بدانیم و چه ناسازگاری تعریف. فرض کیفیت داده همان فرضی است که ناسازگاری آموزش و سرویس‌دهی مستقیماً آن را نقض می‌کند، و باید با همین نام نوشته شود.

اما فرض ثبات شرایط بازار را نباید مقصر جلوه داد. آن فرض درباره‌ی بازار است، و یک خطای واحد در مسیر سرویس‌دهی خود ما شاهدهی علیه آن نیست. این فرض تنها به اندازه‌ی باقیمانده‌ای به چالش کشیده می‌شود که پس از رفع ناسازگاری برجا می‌ماند، و این پژوهش آن باقیمانده را جدا نکرده است. پس عبارت درست این است که سهم بازار به‌طور جداگانه کمی نشده است — نه اینکه صفر است و نه اینکه غالب. فرض ایستایی نیز به همین ترتیب و با همان قید زیر پرسش می‌رود.


سه فرض دیگر پابرجا ماندند: داده در دسترس بود، مدل‌ها تفسیرپذیر بودند (بخش ۴-۶)، و کیفیت داده در دوره‌ی بنچمارک — که تمام اعداد گزارش‌شده از آن می‌آید — با بازتولید بایت‌به‌بایت عکس فوری داده تأیید شد.

۳-۵ ابزار EnergyMarket-PriceCast

خروجی کاربردی این پژوهش، یک ابزار تعاملی است که همان خط لوله‌ی فصل سوم را از دریافت داده تا پیش‌بینی ۲۴ ساعت روز بعد، در یک رابط کاربری در دسترس می‌گذارد. هدف از ساختن آن، نشان دادن اجراپذیری روش بود و نه ارائه‌ی یک سامانه‌ی معاملاتی؛ و همان‌طور که در ادامه می‌آید، خود ابزار این تمایز را به کاربرش اعلام می‌کند.

آنچه ابزار انجام می‌دهد

کاربر یک منبع داده را از میان سه گزینه برمی‌گزیند: عکس فوری ذخیره‌شده که بدون اتصال به شبکه کار می‌کند، فراخوانی زنده‌ی API انرژی‌چارتس، یا بارگذاری یک فایل CSV با همان طرحواره. سپس روز هدف را از میان روزهای دارای تاریخچه‌ی کافی انتخاب می‌کند. ابزار برای آن روز ۲۴ قیمت ساعتی تولید می‌کند، آن‌ها را در کنار قیمت‌های محقق‌شده رسم می‌کند، و میانگین روزانه‌ی پیش‌بینی، میانگین روزانه‌ی واقعی، MAE همان روز و بدترین ساعت را گزارش می‌دهد. جدول کامل ۲۴ مقدار نیز در یک بخش بازشونده در دسترس است.



شکل ۵-۱: ابزار EnergyMarket-PriceCast: پیش‌بینی ساعتی روز بعد در برابر قیمت محقق‌شده، به‌همراه هشدار دقتی که خودِ ابزار نمایش می‌دهد.

ساختار

منطق پیش‌بینی از رابط کاربری جدا نگه داشته شده است. لایه‌ی سرویس، مدل LightGBM تثبیت‌شده را از پوشه‌ی مدل‌های منجمد بارگذاری می‌کند، پنجره‌ی تاریخیچه‌ی لازم را می‌سازد، و اگر تاریخیچه برای ساختن ویژگی‌های تأخیری کافی نباشد خطای صریح می‌دهد به‌جای آنکه ورودی ناقص را با مقدار جایگزین پر کند. همین جدایی معنایی بیش از نظم کد دارد: ابزار همان تابع ویژگی‌سازی و همان شیء مدلی را فرامی‌خواند که نتایج فصل چهارم از آن آمده است، پس آنچه روی صفحه دیده می‌شود بازپایه‌سازی تقریبی روش نیست، خودِ آن است. انتساب داده‌ی انرژی‌چارتس نیز، همان عبارتی که پروانه‌ی CC BY 4.0 اقتضا می‌کند، در تمام حالت‌ها در پایین صفحه نمایش داده می‌شود.

هشدار که ابزار درباره‌ی خودش می‌دهد

بالای هر پیش‌بینی، کادری ثابت این جمله را نشان می‌دهد که این پیش‌بینی‌ها بر قیمت‌های امروز دقیق نیستند، و این یک یافته است نه یک ایراد. سپس همان اعداد بخش ۵-۲ را نقل می‌کند: مدل بر شرایط ۳۱ دسامبر ۲۰۱۷ تثبیت شده و بر داده‌ی زنده‌ی ۲۰۲۶ rMAE برابر 1.83 می‌گیرد، یعنی بدتر از پیش‌بینی ساده با 0.81. این اعداد در ابزار نوشته نشده‌اند، بلکه از فایل نتیجه‌ی تثبیت‌شده‌ی همان آزمون خوانده می‌شوند؛ اگر آن نتیجه تغییر کند، متن هشدار نیز تغییر می‌کند و امکان ندارد از آن عقب

بماند.

نمونه‌ی شکل ۱-۵ همین را نشان می‌دهد: منحنی پیش‌بینی، شکل روزانه‌ی قیمت را دنبال می‌کند و اوج عصرگاهی را در جای درست قرار می‌دهد، اما در تراز به‌کلی پایین‌تر از قیمت محقق‌شده می‌ایستد — همان جابه‌جایی سطحی که بخش ۲-۵ سازوکارش را شکافت، این بار به‌جای یک ستون در جدول، در یک نمودار.

قراردادن این هشدار در معرض دید، تصمیمی آگاهانه بود. ابزاری که پیش‌بینی‌های نادرست را بی‌هیچ قیدی نمایش دهد، در بهترین حالت بی‌فایده و در بدترین حالت گمراه‌کننده است. ابزاری که کیفیت خود را اعلام می‌کند، هم مصداقِ اجراپذیریِ روش است و هم مصداقِ برخورد درست با یک نتیجه‌ی منفی.

۴-۵ پیشنهادات برای تحقیقات آینده

پیشنهادهای زیر عمومی نیستند. هر کدام از یک محدودیت مشخص برمی‌خیزد که این پژوهش واقعاً به آن برخورد و در بخش ۲-۵ نامش را برد.

یک: جداکردن دو سازوکار درهم‌آمیخته

مهم‌ترین کارِ نکرده‌ی این پژوهش، اجرای دوباره‌ی آزمون خارج از توزیع با مسیر سرویس‌دهی تصحیح‌شده است. تشخیصِ پشتیبانیِ ویژگی نشان داد که سری بار در آموزش و در سرویس‌دهی دو تعریف متفاوت داشته است، اما هیچ امتیازدهی تازه‌ای انجام نشد، چون این کار نتایج تثبیت‌شده را دوباره باز می‌کرد. پژوهشی که بار را با تعریف یکسان تغذیه کند و سپس همان هفت مدل را دوباره امتیاز دهد، برای نخستین بار باقیمانده را می‌سنجد: آن بخش از افت دقت که پس از رفع ناسازگاری برجا می‌ماند و تنها آن را می‌توان به تغییر بازار نسبت داد. تا پیش از آن اجرا، سهم بازار کمی نشده باقی می‌ماند. این پیشنهاد، مشخص‌ترین و کم‌هزینه‌ترین پیشنهاد این فهرست است: نه مدل تازه‌ای لازم دارد، نه داده‌ی تازه‌ای.

دو: بازآموزی و تصحیح، به‌عنوان یک سیاست مشروط

جدول ۲-۵ نشان داد تصحیح ارببی غلتان به مدل‌هایی که بیشترین انحراف را داشتند کمک چشمگیری می‌کند و به دو مدل کم‌اریب آسیب می‌زند. پس یک سیاستِ «همیشه تصحیح کن» نادرست است.

آنچه لازم است، معیاری است که تصمیم بگیرد تصحیح چه زمانی روشن شود — برای مثال بر پایه‌ی پایش پیوسته‌ی همان سنجه‌ی پشتیبانی ویژگی، که در این پژوهش تنها یک بار و پس از وقوع شکست محاسبه شد. سنجه‌ای که هر روز محاسبه شود می‌تواند پیش از افت دقت هشدار دهد، چون بیرون‌رفتن ورودی از پشتیبانی آموزشی زودتر از بالارفتن خطا دیده می‌شود.

سه: گزارش توزیع بذر، نه یک اجرای منفرد

نتیجه‌ی تکمیلی بخش ۴-۵-۲ نشان داد که تنها با میانگین‌گیری بر چند بذر تصادفی، MAE شبکه‌ی LSTM از 3.8734 به 3.6460 می‌رسد. این تفاوت از فاصله‌ی میان چند مدل رقیب در جدول اصلی بزرگ‌تر است. نتیجه‌ی روشن آن است که یک اجرای تک‌بذری از یک مدل عمیق، پایه‌ی محکمی برای رتبه‌بندی نیست. پژوهش آینده باید مدل‌های عمیق را با توزیعی از بذرها گزارش کند، نه با یک عدد — و آزمون‌های معناداری را نیز بر همان توزیع بنا کند. این پژوهش برای حفظ انسجام با نتایج تثبیت‌شده‌ی خود این کار را نکرد و همان انتخاب را صریح اعلام کرد.

چهار: تکرار بر بازارها و پنجره‌های دیگر

تمام آنچه گزارش شد، بر یک بازار، یک پنجره‌ی آزمون و یک تاریخ تثبیت به دست آمده است. به‌ویژه یافته‌ی رژیم‌محور به تکرار نیاز دارد: کل بهبود آن بر ۷۷ روز پرتنش متکی است، و ۷۷ روز برای توان آماری راحت کم است. تکرار همان روش بر بازاری دیگر — که در این پروژه تنها یک تغییر پیکربندی است — یا بر پنجره‌ای طولانی‌تر، مشخص می‌کند که این یافته خاصیت روش است یا خاصیت این دو سال. همچنین باید آزموده شود که آستانه‌ی رژیم، که اینجا یک عدد ثابت از آمار دوره‌ی آموزش است، در برابر تعریفی که خود در طول زمان به‌روز می‌شود چگونه عمل می‌کند.

پنج: مجموعه‌ی ویژگی غنی‌تر از آنچه بنچمارک اجازه می‌داد

بخش ۳-۴ فهرستی از متغیرهایی را آورد که عمداً در ماتریس ویژگی نیستند، و برای هر کدام دلیلی متفاوت ذکر کرد. قیمت سوخت به دلیل مجوز تجاری کنار ماند، و هواشناسی و جریان‌های مرزی به دلیلی که به داده ربطی نداشت: افزودنشان هم‌مقیاسی مقایسه با اعداد منتشرشده را از میان می‌برد. آن مبادله برای این پژوهش درست بود، چون مقایسه‌پذیری شرط لازم ارزیابی روش بود؛ اما برای پژوهشی که دیگر خود را به پروتکل مرجع مقید نمی‌داند، درست نیست.

بنابراین مسیر طبیعی بعدی، رهاکردن آگاهانه‌ی همان قید و افزودن این متغیرهاست: هواشناسی، جریان‌های مرزی، و — در صورت دسترسی مجاز به داده — شاخص‌های حاشیه‌ی سوخت. ساختار کد این را از پیش‌بینی کرده است: بلوک‌های ویژگی فیزیکی به‌صورت افزودنی و به‌طور پیش‌فرض خاموش پیاده‌سازی شده‌اند، پس افزودن آن‌ها مسیر پیش‌فرضی را که نتایج تثبیت‌شده از آن آمده‌اند تغییر نمی‌دهد. نکته‌ی مهم آن است که چنین پژوهشی دیگر نمی‌تواند نتیجه‌ی خود را مستقیماً در برابر اعداد مرجع بگذارد، و باید این را صریح بنویسد.

شش: از پیش‌بینی نقطه‌ای به پیش‌بینی احتمالاتی

هر عددی در این پایان‌نامه یک پیش‌بینی نقطه‌ای است. اما شکست خارج از توزیع دقیقاً از جنسی بود که یک پیش‌بینی نقطه‌ای نمی‌تواند بیان کند: مدل‌ها با همان اطمینان ظاهری همیشه، اعدادی می‌دادند که به‌طور سامان‌مند پایین بودند. پیش‌بینی احتمالاتی [۴۰] می‌تواند این وضعیت را به شکل بازه‌هایی گزارش کند که هنگام دورشدن ورودی‌ها از دامنه‌ی آموزش پهن می‌شوند، و برای تصمیم‌گیرنده‌ای که با خروجی چنین مدلی کار می‌کند، این پهن‌شدن اطلاعاتی است که یک عدد تنها هرگز نمی‌دهد.

۵-۵ نتیجه‌گیری نهایی

این پایان‌نامه با پرسشی متعارف آغاز شد — اینکه قیمت روز بعد برق آلمان را چگونه می‌توان بهتر پیش‌بینی کرد — و با پاسخی پایان می‌یابد که بخشی از آن مثبت است و بخشی نه. هر دو بخش گزارش شده‌اند، و همین انتخاب، بیش از هر عددی، چیزی است که این کار می‌خواهد از خود بر جای بگذارد.

آنچه این پژوهش افزود

سه چیز.

نخست، وزن‌دهی رژیم‌محور در ترکیب مدل‌ها. این روش ترکیب ایستا را بهبود می‌دهد، اما نه به‌طور یکنواخت: تمام بهبود بر روزهای پرتنش متمرکز است و بر روزهای آرام عملاً هیچ است. همین محدودبودن اثر، ادعای قوی‌تری است تا یک بهبود مبهم سراسری، چون دقیقاً همان چیزی است که روش برای آن طراحی شده بود. تحلیل تفسیرپذیری نیز از مسیری مستقل به همان جا رسید و نشان داد رفتار مدل میان دو رژیم واقعاً تغییر می‌کند.

دوم، آزمون خارج از توزیع و تشخیصی که زیر آن نشست. اجرای مدل‌های تثبیت‌شده بر داده‌ی امروز، شکستی آشکار را نشان داد؛ اما کار آنجا متوقف نشد. سنجش پشتیبانی ویژگی معلوم کرد که بخش سنجش‌پذیر غالب آن شکست، ناسازگاری تعریف در مسیر سرویس‌دهی خود ما بوده است و نه صرفاً دگرگونی بازار. تفکیک این دو، هم نتیجه را دقیق‌تر می‌کند و هم بار مسئولیت را در جای درست می‌گذارد.

سوم، یک زنجیره‌ی کامل و بازتولیدپذیر، از عکس فوری داده با اثر انگشت رمزنگاشتی تا ابزاری که همان مدل تثبیت‌شده را اجرا می‌کند و کیفیت خود را به کاربر اعلام می‌نماید. مقایسه با نتایج منتشرشده نیز بر همان زنجیره و با کد سنجشی واحد انجام شد، نه با نقل اعداد چاپ‌شده.

آنچه این پژوهش نمی‌گوید

این پژوهش بهترین مدل منتشرشده‌ی مرجع را شکست نمی‌دهد. با دو گونه‌ی آن هم‌تراز است و به بهترین گونه‌اش می‌بازد. این نتیجه از آغاز پنهان نشد و مسیر دفاع پروژه پس از ایست‌بازرسی میانی آگاهانه از رقابت بر سر جدول امتیازها به سمت مشارکت روش‌شناختی تغییر کرد.

همچنین نشان داده نشد که یادگیری عمیق در این پیکربندی بر یک مدل خطی تنظیم‌شده مزیت دارد. دو خانواده از یکدیگر تفکیک‌پذیر نبودند، و آنجا که تفاوتی به سود مدل عمیق دیده شد، تصحیح برای چندگانگی آن را باقی نگذاشت. این خود یافته‌ای است درباره‌ی آنکه در این مسئله، پیچیدگی بیشتر چقدر می‌خرد.

و سرانجام، هیچ‌یک از اعداد دقت این پایان‌نامه ادعایی درباره‌ی بازار امروز نیست. آن‌ها بر دوره‌ای معتبرند که مدل‌ها بر آن آموزش دیده و آزموده شده‌اند، و بخش ۵-۲ نشان داد بیرون از آن دوره چه رخ می‌دهد.

جمله‌ی پایانی

اگر قرار باشد از این کار یک نکته بماند، این است که در پیش‌بینی قیمت برق، سختی اصلی نه در ساختن مدلی دقیق‌تر، که در دانستن حدود اعتبار همان مدل است. مدل‌های این پژوهش بر دوره‌ی آزمون خود خوب عمل کردند و در برخورد با شرایطی که برای آن ساخته نشده بودند، از یک قاعده‌ی سرانگشتی هم عقب ماندند. آنچه این فاصله را قابل فهم کرد، نه مدل بهتر بود و نه داده‌ی بیشتر؛ سنجه‌ای بود که پرسید ورودی امروز اصلاً در دامنه‌ای که مدل دیده است قرار دارد یا نه. پیش‌بینی قابل‌اتکا، پیش از آنکه مسئله‌ی دقت باشد، مسئله‌ی دانستن زمان بی‌اعتباری است.