



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)
دانشکده‌ی مهندسی برق

پایان‌نامه کارشناسی‌ارشد
مهندسی برق، گرایش قدرت (سیستم‌های قدرت)

پیش‌بینی قیمت روزانه و ساعتی انرژی الکتریکی در
بازار برق با استفاده از رویکردهای یادگیری ماشین

نگارش
محمد عظیم‌پور چرندابی

استادان راهنما
دکتر سید حسین حسینیان و دکتر بهروز وحیدی

استاد مشاور
دکتر محمدحسن نظری

[ماه و سال دفاع]

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

صفحه فرم ارزیابی و تصویب پایان نامه - فرم تأیید اعضاء کمیته دفاع

در این صفحه فرم دفاع یا تأیید و تصویب پایان نامه موسوم به فرم کمیته دفاع - موجود در پرونده آموزشی - را قرار دهید.

عنوان پایان نامه: پیش بینی قیمت روزانه و ساعتی انرژی الکتریکی در بازار برق با استفاده از رویکردهای یادگیری ماشین

نگارنده: محمد عظیم پور چرندابی

شماره دانشجویی: ۱۴۰۲۱۲۳۰۵۴

مقطع و گرایش: کارشناسی ارشد — مهندسی برق، گرایش قدرت (سیستم های قدرت)

استادان راهنما: دکتر سید حسین حسینیان و دکتر بهروز وحیدی

استاد مشاور: دکتر محمدحسن نظری

تاریخ دفاع: [ماه و سال دفاع]

نکات مهم:

- نگارش پایان نامه/رساله باید به **زبان فارسی** و بر اساس آخرین نسخه دستورالعمل و راهنمای تدوین پایان نامه های دانشگاه صنعتی امیرکبیر باشد. (دستورالعمل و راهنمای حاضر)
- رنگ جلد پایان نامه/رساله چاپی کارشناسی، کارشناسی ارشد و دکترا باید به ترتیب مشکی، طوسی و سفید رنگ باشد.

-
- چاپ و صحافی پایان نامه/رساله بصورت پشت و رو(دورو) بلامانع است و انجام آن توصیه می شود.



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)

به نام خدا

تعهدنامه اصالت اثر

تاریخ: [ماه و سال دفاع]

اینجانب **محمد عظیم پور چرندابی**، دانشجوی مقطع کارشناسی ارشد رشته‌ی مهندسی برق، گرایش قدرت (سیستم‌های قدرت)، به شماره دانشجویی ۱۴۰۲۱۲۳۰۵۴، نویسنده‌ی پایان‌نامه با عنوان «پیش‌بینی قیمت روزانه و ساعتی انرژی الکتریکی در بازار برق با استفاده از رویکردهای یادگیری ماشین»، متعهد می‌شوم که مطالب مندرج در این پایان‌نامه حاصل کار پژوهشی اینجانب تحت نظارت و راهنمایی اساتید دانشگاه صنعتی امیرکبیر بوده و به دستاوردهای دیگران که در این پژوهش از آنها استفاده شده است مطابق مقررات و روال متعارف ارجاع و در فهرست منابع و مآخذ ذکر گردیده است. این پایان‌نامه قبلاً برای احراز هیچ مدرک هم‌سطح یا بالاتر ارائه نگردیده است.

در صورت اثبات تخلف در هر زمان، مدرک تحصیلی صادر شده توسط دانشگاه از درجه اعتبار ساقط بوده و دانشگاه حق پیگیری قانونی خواهد داشت.

کلیه نتایج و حقوق حاصل از این پایان‌نامه متعلق به دانشگاه صنعتی امیرکبیر می‌باشد. هرگونه استفاده از نتایج علمی و عملی، واگذاری اطلاعات به دیگران یا چاپ و تکثیر، نسخه‌برداری، ترجمه و اقتباس از این پایان‌نامه بدون موافقت کتبی دانشگاه صنعتی امیرکبیر ممنوع است. نقل مطالب با ذکر مآخذ بلامانع است.

محمد عظیم پور چرندابی

امضا

تقدیم

اگر این مختصر را ارزشی باشد، آن ارزش تقدیم می‌شود به:

قطب عالم امکان، حضرت صاحب‌الزمان (عجل‌الله‌تعالی‌فرجه‌الشریف)، آیت ربّ ودود و ناجی مُلک وجود؛ آن‌که جهانی در انتظار عدالت و لطف اوست.

پدر و مادر و برادر عزیزم؛ به پاس همه‌ی تلاش‌های محبت‌آمیزی که در دوران گوناگون زندگی‌ام از من دریغ نکردند و با مهربانی، «چگونه زیستن» را به من آموختند.

استادان فرزانه و فرهیخته‌ام، جناب آقای دکتر سید حسین حسینیان، جناب آقای دکتر محمدحسن نظری و جناب آقای دکتر بهروز وحیدی؛ که در راه کسب علم و معرفت مرا یاری نمودند.

شهیدان والامقام دفاع مقدس؛ آنان که برای آزادسازی خاک میهن، جان خویش را فدای آرمان‌های اسلامی و انسانی کردند. این پژوهش را به آنان تقدیم می‌کنم، باشد که از دُرّ گران‌بهای فداکاری‌شان بهره‌ای بَرَم. روحشان شاد و یادشان گرامی باد.

تقدیر و تشکر

سپاس بی‌کران پروردگار یکتا را که فرصت آموختن و توفیق به پایان رساندن این پژوهش را به من ارزانی داشت.

بر خود لازم می‌دانم مراتب سپاس و امتنان صمیمانه‌ی خود را نسبت به استادان راهنمای گران‌قدرم، جناب آقای دکتر سید حسین حسینیان و جناب آقای دکتر بهروز وحیدی، و استاد مشاور ارجمندم، جناب آقای دکتر محمدحسن نظری، ابراز دارم؛ که در تمامی مراحل انجام این پایان‌نامه با راهنمایی‌های ارزشمند، صبوری و همراهی بی‌دریغ خود مرا یاری کردند. بی‌تردید به ثمر رسیدن این پژوهش، بدون دانش، تجربه و حمایت‌های ایشان میسر نمی‌شد.

همچنین از تمامی استادان، دوستان و عزیزانی که در طول انجام این پایان‌نامه به هر نحو مرا یاری و همراهی نمودند، صمیمانه سپاسگزارم.

محمد عظیم‌پور چزندابی
[ماه و سال دفاع]

چکیده

این پایان نامه به پیش‌بینی قیمت روز-پیش انرژی الکتریکی در بازار آلمان (EPEX-DE) می‌پردازد، بر دو افق: بردار ۲۴ تایی قیمت ساعتی برای روز بعد، و میانگین بار پایه‌ی روزانه. پنج خانواده‌ی مدل — ساده، SARIMAX، LEAR-LASSO، LightGBM و LSTM — به همراه یک ترکیب وزنی رژیم‌محور، بر مجموعه داده و پروتکل عمومی لاگو و همکاران پیاده‌سازی و ارزیابی شده‌اند. ارزیابی به صورت پیش‌رونده با واسنجی روزانه انجام شده و سنجه‌های MAE، RMSE، SMAPE و rMAE به همراه آزمون دیبولد — ماریانو با تصحیح HAC و تصحیح چندگانگی هولم — بنفرونی گزارش شده‌اند. افزون بر آن، تفسیرپذیری مدل با SHAP تحلیل شده و مدل‌های تثبیت‌شده در یک آزمون تنش خارج از توزیع بر داده‌ی زنده‌ی سال ۲۰۲۶ سنجیده شده‌اند.

بهترین پیکربندی، ترکیب رژیم‌محور با MAE برابر 3.5569 یورو بر مگاوات‌ساعت در برابر 7.7501 برای مدل ساده است؛ اما بهبود آن بر ۷۷ روز پرتنش متمرکز است (p برابر 0.0063) و بر روزهای آرام عملاً صفر. بهترین مدل عمیق و بهترین مدل خطی از یکدیگر تفکیک‌پذیر نیستند (LSTM در برابر LEAR-LASSO، p برابر 0.4036)، یعنی یادگیری عمیق در این پیکربندی مزیتی قابل دفاع نخرید. این پژوهش بهترین مدل منتشرشده را شکست نمی‌دهد: با دو گونه‌ی مرجع هم‌تراز است و به ترکیب DNN آن‌ها می‌بازد (p برابر 0.0127). تحلیل SHAP نشان می‌دهد قیمت روز پیش مؤثرترین عامل است و سهم آن در شرایط پرتنش به شدت بالا می‌رود. مهم‌ترین یافته اما منفی است: بر داده‌ی ۲۰۲۶، هر مدل آموزش‌دیده از یک پیش‌بینی ساده‌ی هفتگی عقب می‌ماند (rMAE بزرگ‌تر از 1) و ترتیب مدل‌ها وارونه می‌شود.

نتیجه‌ی کلی آن است که پیش‌بینی قابل‌اتکا، به همان اندازه که مسئله‌ی دقت است، مسئله‌ی دانستن زمانی است که یک مدل دیگر معتبر نیست.

واژه‌های کلیدی:

پیش‌بینی قیمت برق، قیمت روزانه، یادگیری ماشین، یادگیری عمیق، بازارهای انرژی، مدل‌سازی پیش‌بینی،

دینامیک بازار، دقت پیش‌بینی.

فهرست مطالب

صفحه

عنوان

۱		۱ مقدمه
۲		۱-۱ انگیزه و اهمیت موضوع
۳		۲-۱ بیان مسئله
۴		۳-۱ سؤالات پژوهش
۵		۴-۱ نوآوری‌ها و دستاوردهای پژوهش
۷		۵-۱ ساختار پایان‌نامه
۸		۶-۱ محدوده و مفروضات کلی پروژه
۱۰		۲ مروری بر پیشینه پژوهش
۱۱		۱-۲ مرورهای نظام‌مند و مطالعات کتاب‌سنجی
۱۲		۲-۲ روش‌های آماری کلاسیک
۱۳		۳-۲ یادگیری ماشین کلاسیک
۱۴		۴-۲ یادگیری عمیق
۱۵		۵-۲ مدل‌های ترکیبی و مکانیزم توجه
۱۶		۶-۲ تفسیرپذیری و هوش مصنوعی توضیح‌پذیر
۱۷		۷-۲ مطالعات کاربردی و بازارهای خاص
۱۸		۸-۲ پیش‌بینی بلندمدت و احتمالاتی
۱۹		۹-۲ شکاف پژوهشی و جایگاه کار حاضر
۲۱		۳ روش تحقیق
۲۲		۱-۳ مقدمه
۲۳		۲-۳ فرضیات بنیادی پژوهش
۲۶		۳-۳ داده‌ها و بازار مورد مطالعه
۲۶		۱-۳-۳ مجموعه داده بنچمارک EPEX-DE
۲۸		۲-۳-۳ داده زنده Energy-Charts
۳۰		۳-۳-۳ تحلیل اکتشافی داده

۳۵	۴-۳ مهندسی ویژگی
۴۰	۵-۳ چارچوب اعتبارسنجی و معیارهای ارزیابی
۴۵	۶-۳ مدل‌های پایه
۴۸	۷-۳ مدل‌های یادگیری ماشین و یادگیری عمیق
۴۹	۱-۷-۳ LightGBM
۵۱	۲-۷-۳ LSTM
۵۴	۸-۳ مدل ترکیبی
۵۹	۴ نتایج و تحلیل
۶۰	۱-۴ مقدمه
۶۱	۲-۴ نتایج پیش‌بینی ساعتی
۶۳	۳-۴ نتایج پیش‌بینی روزانه
۶۵	۴-۴ مقایسه روش مستقیم و تجمیعی
۶۷	۵-۴ آزمون دیبولد-ماریانو
۶۸	۱-۵-۴ مقایسه مدل‌های این پژوهش
۷۲	۲-۵-۴ مقایسه با نتایج منتشرشده
۷۵	۶-۴ تحلیل تفسیرپذیری SHAP
۸۳	۷-۴ پاسخ به سؤالات پژوهش
۸۸	۵ جمع‌بندی، بحث و پیشنهادات
۸۹	۱-۵ جمع‌بندی نتایج
۹۰	۲-۵ محدودیت‌ها
۹۴	۳-۵ ابزار EnergyMarket-PriceCast
۹۶	۴-۵ پیشنهادات برای تحقیقات آینده
۹۸	۵-۵ نتیجه‌گیری نهایی
۱۰۱	کتاب‌نامه
۱۰۷	پیوست

۱۰۸ واژه‌نامه‌ی فارسی به انگلیسی

۱۱۱ واژه‌نامه‌ی انگلیسی به فارسی

فهرست تصاویر

صفحه

شکل

- ۱-۳ توزیع قیمت‌های ساعتی بازار روز-پیش EPEX-DE در دوره‌ی ۲۰۱۲ تا ۲۰۱۷، شامل ناحیه‌ی قیمت‌های منفی. ۳۰
- ۲-۳ نیم‌رخ درون‌روزی قیمت: میانگین قیمت به تفکیک ساعت شبانه‌روز. ۳۱
- ۳-۳ نیم‌رخ هفتگی قیمت: میانگین قیمت به تفکیک روز هفته. ۳۱
- ۴-۳ نیم‌رخ سالانه‌ی قیمت در سراسر دوره‌ی مطالعه. ۳۲
- ۵-۳ خوشه‌بندی نوسان: دوره‌های آرام و پرتلاطم به‌صورت خوشه‌ای در زمان کنار هم می‌نشینند. ۳۲
- ۶-۳ توابع خودهمبستگی و خودهمبستگی جزئی سری قیمت ساعتی. ۳۳
- ۷-۳ همبستگی قیمت با دو متغیر برون‌زا: پیش‌بینی روزپیش بار و پیش‌بینی روزپیش تولید بادی و خورشیدی. ۳۴
- ۸-۳ همبستگی غلتان قیمت با متغیرهای برون‌زا در طول زمان؛ شدت رابطه ثابت نمی‌ماند. ۳۴
- ۹-۳ کل سری قیمت ساعتی به‌همراه شکست‌های ساختاری شناسایی‌شده. ۳۵
- ۱۰-۳ سری بار پایه‌ی روزانه: میانگین ۲۴ قیمت ساعتی هر روز. ۳۵
- ۱-۴ اهمیت سراسری ویژگی‌ها بر پایه‌ی میانگین قدرمطلق مقادیر SHAP، افق ساعتی. ۷۸
- ۲-۴ نمودار زنبوری (beeswarm) مقادیر SHAP در افق ساعتی: پراکندگی سهم هر ویژگی در تک‌تک نمونه‌ها، نه تنها میانگین آن. ۷۸
- ۳-۴ تفکیک سهم SHAP بر حسب ساعت شبانه‌روز. ۷۹
- ۴-۴ مقایسه‌ی اهمیت ویژگی‌ها میان روزهای آرام و روزهای پرتنش. ۸۰
- ۵-۴ مقایسه‌ی اهمیت ویژگی‌ها میان افق ساعتی و افق روزانه. ۸۱
- ۶-۴ نمودار آبخاری برای یک روز منفرد: تجزیه‌ی فاصله‌ی میان پیش‌بینی آن روز و میانگین پیش‌بینی‌ها به سهم تک‌تک ویژگی‌ها. ۸۲
- ۱-۵ ابزار EnergyMarket-PriceCast: پیش‌بینی ساعتی روز بعد در برابر قیمت محقق‌شده، به‌همراه هشدار دقتی که خود ابزار نمایش می‌دهد. ۹۵

فهرست جداول

جدول

صفحه

۱-۲	مقایسه‌ی جنبه‌های روش‌شناختی چند مطالعه‌ی شاخص با پژوهش حاضر (بر پایه‌ی آنچه در منابع گزارش شده است).	۲۰
۱-۳	وزن‌های برازش‌شده‌ی مدل ترکیبی بر پنجره‌ی برازش وزن (۳۵۷ مبدأ، از ۱۲ ژانویه‌ی ۲۰۱۵ تا ۳ ژانویه‌ی ۲۰۱۶). ستون نخست وزن‌های ترکیب ایستا و دو ستون بعد وزن‌های ترکیب رژیم‌محور است. هر ستون به یک جمع می‌شود. تقسیم رژیمی این پنجره ۳۲۰ روز آرام و ۳۷ روز پرتنش است.	۵۷
۱-۴	دقت پیش‌بینی ساعتی بر دوره‌ی آزمون EPEX-DE، از ۴ ژانویه‌ی ۲۰۱۶ تا ۳۱ دسامبر ۲۰۱۷ (۷۲۸ مبدأ). واحد MAE و RMSE یورو بر مگاوات‌ساعت، sMAPE درصد، و rMAE بی‌بعد. مقدار کمتر بهتر است. مدل ساده مرجع است و نه رقیب.	۶۱
۲-۴	دقت پیش‌بینی بار پایه‌ی روزانه بر همان دوره‌ی آزمون (۷۲۸ روز)، به تفکیک دو مسیر: مدل‌سازی مستقیم هدف روزانه، و میانگین‌گیری از ۲۴ پیش‌بینی ساعتی. مقدار کمتر بهتر است. مدل‌های ترکیبی مسیر مستقیم ندارند، چون اعضایشان ساعتی‌اند.	۶۴
۳-۴	مقایسه‌ی مستقیم دو مسیر رسیدن به هدف روزانه بر معیار MAE. ستون «اختلاف» مقدار مسیری تجمیعی منهای مسیر مستقیم است؛ مقدار منفی یعنی تجمیع بهتر بوده است. مدل ساده در هر دو مسیر یکسان است.	۶۶
۴-۴	p-مقدارهای خام آزمون دیبولد-ماریانو با تصحیح HAC، افق ساعتی، ۷۲۸ مبدأ. هر درایه احتمال آن است که مدل سطر بهتر از مدل ستون نباشد؛ مقدار نزدیک به صفر یعنی سطر بهتر است. ستون‌ها به همان ترتیب سطرها شماره‌گذاری شده‌اند. این ستون خام است و به‌تنهایی مبنای هیچ ادعای معناداری قرار نمی‌گیرد — جدول ۴-۵ را ببینید.	۶۹
۵-۴	نتیجه‌ی تصحیح هولم-بونفرونی بر خانواده‌ی اکتشافی ۲۱ آزمونه. «مقاوم» یعنی نتیجه پس از تصحیح نیز در سطح 0.05 برقرار می‌ماند.	۶۹
۶-۴	تفکیک برتری ترکیب رژیم‌محور بر ترکیب ایستا به تفکیک رژیم بازار. MAE بر حسب یورو بر مگاوات‌ساعت.	۷۱

- ۷-۴ حساسیت نتیجه‌ی «رژیم‌محور در برابر ایستا» به طول بلوک در بوت‌استرپ بلوکی.
- ۷۲ ستون آخر p-مقدار HAC برای همان زیرمجموعه است و در هر سطر ثابت می‌ماند. .
- ۸-۴ مدل‌های این پژوهش در برابر انتخابی از گونه‌های منتشرشده‌ی لاگو و همکاران [۱]،
بر بازار EPEX-DE و همان دوره‌ی آزمون. تمام اعداد با کد سنج‌ی این پژوهش از
فایل‌های پیش‌بینی منتشرشده محاسبه شده‌اند. مرتب‌شده بر پایه‌ی MAE.
- ۷۳ ۹-۴ آزمون دیبولد-ماریانو با تصحیح HAC، ترکیب رژیم‌محور این پژوهش در برابر گونه‌های
منتشرشده. ستون p احتمال آن است که مدل این پژوهش بهتر نباشد.
- ۷۳ ۱۰-۴ اثر میانگین‌گیری بر چهار بذر LSTM. **تکمیلی** — این اعداد جایگزین نتایج تثبیت‌شده
نمی‌شوند و در هیچ جدول دیگری تکرار نمی‌گردند.
- ۷۵ ۱۱-۴ میانگین قدرمطلق مقادیر SHAP به تفکیک خانواده‌ی ویژگی، بر حسب یورو بر
مگاوات‌ساعت، برای مدل LightGBM. exog_1 پیش‌بینی بار و exog_2 پیش‌بینی
تولید تجدیدپذیر است؛ پسوند D0 یعنی مقدار خودِ روز هدف و D-n یعنی مقدار n
روز پیش. مقادیر پررنگ، بیشترین مقدار هر ستون است.
- ۷۷ ۱-۵ مدل‌های تثبیت‌شده بر ۱۷۳ روز داده‌ی زنده‌ی ۲۰۲۶، بدون بازآموزی. ستون آخر
افزایش MAE نسبت به همان مدل بر دوره‌ی آزمون بنچمارک است. مقادیر rMAE
بزرگ‌تر از 1.0 یعنی بدتر از پیش‌بینی ساده. انتساب داده در بخش ۳-۳-۲ آمده است. ۹۱
- ۲-۵ rMAE پیش و پس از تصحیح اریبی غلتان با پنجره‌ی ۷ روزه، بر ۱۶۶ روز مشترک.
- ۹۲ مقدار مثبت در ستون آخر یعنی تصحیح به آن مدل آسیب زده است.

فهرست نمادها

نماد	مفهوم
p_t	قیمت محقق شده در روز t
$\hat{p}$	قیمت پیش بینی شده
x_t	بردار ویژگی روز t
N	شمار نقاط ارزیابی
T	شمار روزهای پنجره‌ی آموزش
J	شمار ویژگی‌ها
β	بردار ضرایب رگرسیون
λ	ضریب جریمه‌ی لاسو
M	شمار اعضای ترکیب
w_m	وزن مدل m در ترکیب
τ	آستانه‌ی رژیم
μ_{train}	میانگین قیمت بر داده‌ی آموزش
σ_{train}	انحراف معیار قیمت بر داده‌ی آموزش
k	ضریب آستانه‌ی رژیم
$\bar{d}$	میانگین تفاضل زیان در آزمون دیبولد—ماریانو
$\widehat{\text{Var}}_{\text{HAC}}$	واریانس تصحیح شده به روش HAC
$\text{MAE}_{\text{naive}}$	خطای مطلق میانگین مدل ساده‌ی مرجع

فصل اول

مقدمه

۱-۱ انگیزه و اهمیت موضوع

با آزادسازی و مقررات‌زدایی از بازارهای برق در دهه‌های اخیر، قیمت برق از متغیری تحت کنترل نهادهای متمرکز به یک سیگنال اقتصادی رقابتی بدل شده است که در بورس‌های برق و عمدتاً از طریق حراج‌های روز-پیش تعیین می‌شود. در این ساختار، تولیدکنندگان، خرده‌فروشان و معامله‌گران به‌طور مستقیم در معرض ریسک و نوسان قیمت قرار می‌گیرند و توان رقابت و بقای اقتصادی آنان به دقت پیش‌بینی قیمت گره خورده است [۲، ۳]. به همین سبب، پیش‌بینی قیمت برق به یکی از ارکان بنیادی تصمیم‌گیری در بازارهای برق تبدیل شده است.

آنچه این مسئله را از دیگر سری‌های زمانی متمایز و دشوار می‌سازد، مجموعه‌ای از ویژگی‌های خاص برق به‌عنوان یک کالا است: فصلی بودن در مقیاس‌های روزانه، هفتگی و سالانه، لزوم تعادل پیوسته میان تولید و مصرف، و وابستگی شدید به شرایط بیرونی و محیطی. این ویژگی‌ها موجب می‌شوند سری قیمت، نوسان‌های شدید، جهش‌های ناگهانی و ناهمگنی واریانس (heteroscedasticity) از خود نشان دهد [۳]. افزون بر این، گسترش روزافزون منابع تجدیدپذیر و وابستگی تولید آن‌ها به شرایط جوی، بر پیچیدگی و بی‌ثباتی قیمت افزوده و پیش‌بینی آن را دشوارتر ساخته است [۴، ۲]. در بازارهایی با نفوذ بالای تجدیدپذیرها، حتی پدیده‌هایی مانند قیمت‌های منفی نیز به واقعیتی متداول بدل شده‌اند که مدل‌سازی آن‌ها را چالش‌برانگیزتر می‌کند.

شکل‌گیری قیمت برق برآیند تعامل مجموعه‌ای از عوامل بنیادی است؛ از میزان تقاضا و بار مصرفی گرفته تا ترکیب منابع تولید — به‌ویژه سهم منابع تجدیدپذیر — و شرایط جوی. پژوهش‌ها نشان داده‌اند که لحاظ کردن این عوامل تعیین‌کننده می‌تواند دقت مدل‌های پیش‌بینی را به‌طور چشمگیری بهبود بخشد، هرچند درباره‌ی این که کدام عوامل و به چه شماری باید در نظر گرفته شوند هنوز اجماعی وجود ندارد [۵]. همین وابستگی چندعاملی، در کنار ماهیت پرنوسان قیمت، پیش‌بینی دقیق را به مسئله‌ای دشوار و چندوجهی بدل می‌کند.

اهمیت اقتصادی این مسئله را نمی‌توان نادیده گرفت. پیش‌بینی دقیق قیمت روز-پیش، مبنای مستقیم تصمیم‌گیری در مناقصه‌گذاری (bidding)، زمان‌بندی بهره‌برداری از واحدها (scheduling) و مدیریت ریسک است [۴]، و خطا در آن مستقیماً به زیان مالی برای بازیگران بازار ترجمه می‌شود [۵]. با افزایش سهم ذخیره‌سازها و منابع انعطاف‌پذیر در شبکه، ارزش هر واحد بهبود در دقت پیش‌بینی نیز پیوسته فزونی می‌یابد.

در پاسخ به این نیاز، در حدود ۲۵ سال گذشته حجم گسترده‌ای از پژوهش‌ها به توسعه‌ی روش‌های

پیش‌بینی قیمت اختصاص یافته است [۶]؛ از مدل‌های آماری کلاسیک مبتنی بر سری زمانی و مدل‌های علی گرفته تا رویکردهای مبتنی بر هوش مصنوعی [۷]. مرور پژوهش‌های اخیر نشان می‌دهد که این حوزه به سرعت به سمت روش‌های یادگیری ماشین و یادگیری عمیق حرکت کرده و به‌ویژه مدل‌های ترکیبی و گروهی (ensemble) در بازار روز-پیش عملکردی قدرتمند از خود نشان داده‌اند [۴، ۵].

با این‌همه، رشد سریع این حوزه با یک کاستی روش‌شناختی جدی همراه بوده است: بسیاری از الگوریتم‌های تازه بر روی مجموعه داده‌های خصوصی و غیرقابل دسترس، در بازه‌های آزمون کوتاه و محدود به یک بازار، و بدون مقایسه با مدل‌های ساده‌ی مرجع یا آزمون معناداری آماری تفاوت‌ها ارزیابی شده‌اند؛ چنین رویه‌ای تشخیص این‌که کدام روش واقعاً برتر است را ناممکن می‌کند [۱]. از این‌رو، گذار به سوی پروتکل‌های ارزیابی شفاف، تکرارپذیر و متکی بر بنچمارک‌های عمومی، خود به ضرورتی در این حوزه بدل شده است.

پژوهش حاضر با تمرکز بر بازار برق آلمان — از بزرگ‌ترین و پرنفوذترین بازارهای برق اروپا با سهمی چشمگیر از منابع تجدیدپذیر — به مسئله‌ی پیش‌بینی قیمت روز-پیش می‌پردازد؛ بازاری که پیش‌تر با رویکردهای آماری و یادگیری عمیق مورد مطالعه قرار گرفته است [۸]. نوسان بالا و رفتار پیچیده‌ی این بازار، آن را به بستری واقع‌گرایانه و در عین حال چالش‌برانگیز برای سنجش و مقایسه‌ی روش‌های پیش‌بینی بدل می‌کند. اتکا به این بازار در کنار به‌کارگیری یک پروتکل ارزیابی استاندارد و عمومی، امکان مقایسه‌ی منصفانه و تکرارپذیر روش‌های گوناگون را فراهم می‌آورد؛ موضوعی که در فصل‌های بعد به تفصیل بدان پرداخته خواهد شد.

۲-۱ بیان مسئله

مسئله‌ی محوری این پژوهش، ارائه‌ی پیش‌بینی دقیق و قابل اتکا از قیمت روز-پیش برق در بازار آلمان است؛ آن هم بر روی دو افق هدف: برداری از ۲۴ قیمت ساعتی برای روز پیش‌رو، و متوسط بار پایه‌ی روزانه. در حالت آرمانی، بازیگران بازار باید بتوانند در همه‌ی شرایط بازار — از دوره‌های آرام تا دوره‌های پرتنش — به پیش‌بینی‌هایی دست یابند که هم دقیق باشند و هم شواهدی شفاف درباره‌ی این‌که کدام روش و چرا بهتر عمل می‌کند، در اختیار بگذارند.

اما آنچه دستیابی به این هدف را دشوار می‌سازد، ماهیت خاص سری قیمت برق است. نوسان‌های شدید، جهش‌های ناگهانی و جابه‌جایی میان رژیم‌های آرام و پرتنش سبب می‌شوند که عملکرد یک مدل واحد و ثابت در تمام شرایط بازار پایدار نماند [۲]. افزون بر این، رشد سریع روش‌های پیش‌بینی با

ضعف‌هایی روش‌شناختی در ارزیابی همراه بوده و تشخیص این که کدام روش واقعاً برتر است را دشوار ساخته است [۱]. مرورهای اخیر نیز کیفیت داده، تفسیرپذیری مدل‌ها و تعمیم‌پذیری آن‌ها به شرایط تازه را از جمله چالش‌های همچنان گشوده‌ی این حوزه برمی‌شمارند [۴]. پیامد این کاستی‌ها آن است که خطای پیش‌بینی مستقیماً به تصمیم‌های نادرست و زیان مالی می‌انجامد، انتخاب مدل بر پایه‌ی ناستوار صورت می‌گیرد، و مدل‌هایی که در یک دوره عملکرد خوبی داشته‌اند ممکن است با تغییر شرایط بازار به‌طور ناگهانی و بی‌هشدار دچار افت شوند.

درست به همین سبب، یک مطالعه‌ی تک‌مدلی که تنها بر دقت در همان توزیع داده‌ی آموزش تمرکز کند برای پاسخ‌گویی به این مسئله کافی نیست. نخست، از آنجا که برتری نسبی خانواده‌های گوناگون مدل — از روش‌های آماری کلاسیک تا یادگیری ماشین و یادگیری عمیق — به شرایط بازار و افق پیش‌بینی وابسته است [۴، ۳]، ترکیب مدل‌ها و تطبیق آن‌ها با رژیم‌های متفاوت بازار می‌تواند از هر مدل منفرد راه‌گشا تر باشد. دوم، دقت بالا به‌تنهایی بسنده نیست؛ در یک تصمیم مالی پرمخاطره، دانستن این که کدام عوامل پیش‌بینی را شکل می‌دهند به‌اندازه‌ی خود پیش‌بینی اهمیت دارد. سوم، عملکرد خوب در گذشته تضمینی برای پایداری در آینده نیست، و رفتار مدل هنگام تغییر ساختاری بازار باید به‌صراحت سنجیده شود.

با توجه به این ملاحظات، مسئله‌ی اصلی این پژوهش را می‌توان چنین صورت‌بندی کرد: توسعه و ارزیابی نظام‌مند مجموعه‌ای از مدل‌های پیش‌بینی قیمت روز-پیش برای بازار برق آلمان، در چارچوب یک پروتکل ارزیابی استاندارد، تکرارپذیر و متکی بر بنچمارک عمومی. این مسئله چند بُعد به‌هم‌پیوسته دارد: دقت پیش‌بینی در مقایسه با روش‌های مرجع منتشرشده در ادبیات؛ شیوه‌ی پیش‌بینی بار پایه‌ی روزانه، به‌صورت مستقیم یا از راه تجمیع پیش‌بینی‌های ساعتی؛ رفتار مدل‌ها در رژیم‌های متفاوت بازار؛ پایداری آن‌ها در برابر تغییر توزیع داده در گذر زمان؛ و تفسیرپذیری عوامل مؤثر بر پیش‌بینی. این ابعاد در قالب سؤالات پژوهش، در بخش بعد به‌صورت رسمی صورت‌بندی می‌شوند.

۳-۱ سؤالات پژوهش

مسئله و ابعادی که در بخش پیشین برشمرده شد، این پژوهش را حول چهار پرسش اصلی سامان می‌دهند. این پرسش‌ها چنان صورت‌بندی شده‌اند که هر یک با شواهد تجربی به‌دست‌آمده در فصل چهارم، و در همان دامنه‌ای که طرح شده‌اند، پاسخ داده شوند:

۱. در پیش‌بینی روز-پیش قیمت برق بازار EPEX-DE^۱، پنج مدل منتخب — ساده، SARIMAX^۲، LEAR-LASSO^۳، LightGBM^۴ و LSTM^۵ — تحت یک پروتکل اعتبارسنجی پیش‌رونده یکسان، بر پایه معیارهای MAE^۶، RMSE^۷، sMAPE^۸ و rMAE^۹، چه عملکردی نسبت به یکدیگر دارند، و کدام تفاوت‌ها بر اساس آزمون دیبولد-ماریانو با تصحیح HAC^{۱۰} از نظر آماری معنادار است؟

۲. آیا ترکیب وزن دار مدل‌های پایه دقت را نسبت به بهترین تک‌مدل بهبود می‌دهد، و آیا مشروط کردن وزن‌ها به رژیم بازار — که با آستانه‌ای صرفاً بر پایه داده اعتبارسنجی به دو حالت آرام و پرتنش تفکیک می‌شود — بهبود بیشتری نسبت به وزن‌دهی ایستا ایجاد می‌کند؟ این بهبود، در صورت وجود، تحت کدام شرایط بازار پدید می‌آید؟

۳. بر پایه مقادیر SHAP^{۱۱} محاسبه‌شده برای مدل LightGBM، کدام خانواده‌های ویژگی بیشترین سهم را در پیش‌بینی دارند، و آیا این سهم میان روزهای آرام و پرتنش، و میان افق ساعتی و روزانه، تغییر می‌کند؟

۴. برای پیش‌بینی میانگین بار پایه روزانه، کدام مسیر دقت بالاتری دارد: مدل‌سازی مستقیم هدف روزانه، یا میانگین‌گیری از ۲۴ پیش‌بینی ساعتی؟ و آیا این نتیجه برای هر پنج مدل یکسان است؟

۴-۱ نوآوری‌ها و دستاوردهای پژوهش

این پژوهش می‌کوشد فراتر از یک مطالعه‌ی محک‌زنی متعارف حرکت کند و افزون بر مقایسه‌ی دقیق و منصفانه‌ی مدل‌ها، چند مؤلفه‌ی نوآورانه را نیز در بر گیرد که آن را از یک ورودی صرف به جدول‌های رتبه‌بندی متمایز می‌کند. مهم‌ترین نوآوری‌ها و دستاوردهای این کار را می‌توان چنین برشمرد:

^۱ European Power Exchange, Germany

^۲ Seasonal AutoRegressive Integrated Moving Average with exogenous inputs

^۳ LASSO-Estimated AutoRegressive

^۴ Light Gradient Boosting Machine

^۵ Long Short-Term Memory

^۶ Mean Absolute Error

^۷ Root Mean Square Error

^۸ symmetric Mean Absolute Percentage Error

^۹ relative Mean Absolute Error

^{۱۰} Heteroskedasticity- and Autocorrelation-Consistent

^{۱۱} SHapley Additive exPlanations

۱. **ارزیابی نظام‌مند و تکرارپذیر بر پایه‌ی یک بنچمارک عمومی:** این پژوهش مجموعه‌داده و پروتکل ارزیابی باز و منتشرشده‌ی لاگو و همکاران [۱] را برای بازار برق آلمان (EPEX-DE) به کار می‌گیرد و طیفی از مدل‌ها — از مدل ساده‌ی مبنا و مدل‌های آماری (SARIMAX و LEAR-LASSO) تا مدل‌های یادگیری ماشین و یادگیری عمیق (LSTM و LightGBM) — را در یک چارچوب یکسان مقایسه می‌کند. ارزیابی بر پایه‌ی روش پیش‌رونده‌ی گام‌به‌گام با واسنجی روزانه و یک دوره‌ی آزمون کنار گذاشته‌ی دوساله انجام می‌شود و تفاوت‌های میان مدل‌ها با آزمون معناداری آماری تصحیح‌شده سنجیده می‌شوند؛ چنان‌که نتایج به‌طور مستقیم و منصفانه با نتایج پیشرفته‌ی منتشرشده در ادبیات قابل مقایسه باشد.

۲. **پوشش هم‌زمان دو افق هدف:** به‌جای تمرکز بر یک هدف، هم قیمت‌های ساعتی روز آینده در قالب برداری از ۲۴ مقدار پیش‌بینی می‌شوند و هم متوسط بار پایه‌ی روزانه. افزون بر این، بار پایه‌ی روزانه به دو شیوه تولید می‌شود — آموزش مستقیم بر سری روزانه، و تجمیع (میانگین‌گیری) پیش‌بینی‌های ساعتی — و این دو رویکرد به‌صراحت با یکدیگر مقایسه می‌شوند تا روشن شود کدام یک دقیق‌تر است.

۳. **وزن‌دهی گروهی رژیم‌محور (regime-aware ensemble):** این پژوهش به‌جای یک ترکیب وزنی ثابت برای همه‌ی روزها، دو مجموعه‌وزن جداگانه برای دوره‌های «آرام» و «پرتنش» بازار تعریف می‌کند و بر پایه‌ی یک آستانه‌ی قیمتی — که تنها از داده‌ی پیش از دوره‌ی آزمون به‌دست می‌آید تا از نشت اطلاعات جلوگیری شود — میان آن‌ها جابه‌جا می‌شود. برچسب پرتنش برای هر روز بر مبنای قیمت‌های محقق‌شده‌ی روز پیش از آن تعیین می‌شود، به‌گونه‌ای که خود برچسب نیز قابل نشت نباشد.

۴. **آزمون پایداری برون توزیعی (out-of-distribution):** مدل‌های آموزش‌دیده بر داده‌ی بنچمارک، بدون هرگونه بازآموزی، روی داده‌ی زنده‌ی سال ۲۰۲۶ از منبع Energy-Charts (مؤسسه‌ی فراونهوفر ISE^{۱۲}) ارزیابی می‌شوند تا رفتار آن‌ها هنگام تغییر ساختاری بازار در گذر زمان سنجیده شود. این آزمون به یک یافته‌ی محدودکننده و درخور تأمل درباره‌ی تعمیم‌پذیری مدل‌ها می‌انجامد که در فصل پنجم به تفصیل بررسی می‌شود.

۵. **تحلیل تفسیرپذیری مبتنی بر SHAP:** سهم هر خانواده از ویژگی‌ها — قیمت‌های باوقفه و

^{۱۲} Institute for Solar Energy Systems

متغیرهای برون‌زا — در شکل‌گیری پیش‌بینی کمی می‌شود و این سهم میان رژیم‌های آرام و پرتنش و نیز میان افق ساعتی و روزانه مقایسه می‌شود؛ چنین تحلیلی آشکار می‌کند که مدل‌ها در شرایط گوناگون بر چه عواملی بیشتر تکیه می‌کنند.

۶. **توسعه‌ی یک ابزار عملیاتی:** یافته‌های پژوهش در قالب سامانه‌ی EnergyMarket-PriceCast پیاده‌سازی شده‌اند تا پیش‌بینی‌ها به‌شکلی کاربردی و تعاملی در دسترس قرار گیرند.

مجموعه‌ی این دستاوردها، به‌جای تکیه بر برتری در یک جدول رتبه‌بندی، بر استحکام روش‌شناختی، تفسیرپذیری و واقع‌گرایی ارزیابی استوار است؛ رویکردی که هدف آن، ارائه‌ی تصویری صادقانه از توانایی‌ها و محدودیت‌های واقعی این مدل‌ها در پیش‌بینی قیمت برق است.

۵-۱ ساختار پایان‌نامه

این پایان‌نامه در پنج فصل سازمان یافته است. فصل نخست — همین فصل — به بیان انگیزه و اهمیت موضوع، طرح مسئله، سؤالات پژوهش و نوآوری‌ها و دستاوردهای کار اختصاص دارد و محدوده و مفروضات کلی پژوهش را نیز مشخص می‌کند.

فصل دوم مروری بر پیشینه‌ی پژوهش ارائه می‌دهد؛ این فصل ادبیات پیش‌بینی قیمت برق را از مرورهای نظام‌مند و مطالعات کتاب‌سنجی آغاز می‌کند و سپس به‌ترتیب روش‌های آماری کلاسیک، یادگیری ماشین کلاسیک، یادگیری عمیق، مدل‌های ترکیبی و مکانیزم توجه، تفسیرپذیری و هوش مصنوعی توضیح‌پذیر، مطالعات کاربردی و بازارهای خاص، و پیش‌بینی بلندمدت و احتمالاتی را بررسی می‌کند و با تبیین شکاف پژوهشی و جایگاه کار حاضر به پایان می‌رسد.

فصل سوم روش تحقیق را تشریح می‌کند: از مفروضات بنیادی و معرفی داده‌ها و بازار مورد مطالعه — شامل داده‌ی بنچمارک و داده‌ی زنده — و تحلیل اکتشافی داده، تا مهندسی ویژگی، چارچوب اعتبارسنجی و معیارهای ارزیابی، و در نهایت معرفی مدل‌ها، از مدل‌های پایه تا مدل‌های یادگیری ماشین و یادگیری عمیق (LightGBM و LSTM) و روش‌های ترکیبی.

فصل چهارم به ارائه‌ی نتایج و تحلیل آن‌ها می‌پردازد؛ شامل نتایج پیش‌بینی ساعتی و روزانه، مقایسه‌ی روش مستقیم و تجمیعی، آزمون معناداری آماری (دیبولد-ماریانو) در برابر مدل‌های این پژوهش و مدل‌های مرجع، تحلیل تفسیرپذیری مبتنی بر SHAP، و سرانجام پاسخ صریح به سؤالات پژوهش.

فصل پنجم با جمع‌بندی یافته‌ها، بحث درباره‌ی محدودیت‌ها، معرفی ابزار EnergyMarket-PriceCast

و ارائه‌ی پیشنهادهایی برای پژوهش‌های آینده، به نتیجه‌گیری نهایی می‌رسد.

۱-۶ محدوده و مفروضات کلی پروژه

برای آن‌که این پژوهش کانونی، و نتایج آن تکرارپذیر و منصفانه باقی بماند، دامنه‌ی آن به‌عمد محدود شده است. مطالعه بر بازار برق آلمان (EPEX-DE) و تنها بر افق پیش‌بینی روز-پیش (day-ahead) متمرکز است و بازارهای درون‌روز و تعادلی را در بر نمی‌گیرد. تمرکز بر بازار روز-پیش با کانون غالب ادبیات این حوزه نیز هم‌راستاست؛ چنان‌که تا نزدیک به ۹۰ درصد از پژوهش‌های پیش‌بینی قیمت به همین بازار پرداخته‌اند و بازار روز-پیش به‌عنوان نماینده‌ی متعارف «قیمت برق» شناخته می‌شود [۶]. کانون کار، پیش‌بینی نقطه‌ای است و نه پیش‌بینی بازه‌ای یا احتمالاتی؛ و دو هدف دنبال می‌شود: بردار قیمت‌های ساعتی روز آینده و بار پایه‌ی روزانه.

داده‌های مورد استفاده در دو دسته جای می‌گیرند. بخش اصلی مطالعه بر مجموعه داده‌ی بنچمارک عمومی لاگو و همکاران [۱] برای این بازار استوار است که مقایسه‌ی مستقیم با نتایج منتشرشده را ممکن می‌سازد و یک بازه‌ی چندساله را با دوره‌ی آزمون کنارگذاشته‌ی دوساله در بر می‌گیرد. افزون بر آن، برای آزمون پایداری برون‌توزیعی، از حدود شش ماه داده‌ی زنده‌ی سال ۲۰۲۶ از منبع Energy-Charts (مؤسسه‌ی فراونهوفر ISE) استفاده می‌شود؛ این داده تنها برای ارزیابی برون‌توزیعی به کار می‌رود و هیچ نقشی در آموزش مدل‌ها ندارد.

از نظر مدل‌ها، مجموعه‌ای منتخب و ثابت بررسی می‌شود که طیفی از یک مدل ساده‌ی مبنا، مدل‌های آماری، مدل‌های یادگیری ماشین و یادگیری عمیق، و روش‌های ترکیبی را در بر می‌گیرد. هدف، مقایسه‌ی نظام‌مند این خانواده‌ها در یک چارچوب یکسان است، نه مرور جامع همه‌ی معماری‌های ممکن. در انتخاب ورودی‌ها نیز محدودیتی آگاهانه اعمال شده است. تنها متغیرهای برون‌زایی به کار می‌روند که در چارچوب پروتکل بنچمارک در دسترس‌اند — یعنی پیش‌بینی روز-پیش بار مصرفی و پیش‌بینی روز-پیش تولید (عمدتاً از منابع تجدیدپذیر) — در کنار مقادیر باوقفه‌ی خود قیمت. در مقابل، متغیرهایی مانند قیمت سوخت (گاز و زغال سنگ)، متغیرهای جوی و جریان‌های تبادلی مرزی به‌عمد از دامنه‌ی پژوهش کنار گذاشته شده‌اند. این کنارگذاری یک تصمیم سنجیده است و نه یک غفلت: افزودن داده‌های برون‌زای فراتر از پروتکل، مقایسه‌ی منصفانه با نتایج منتشرشده را ناممکن می‌کند، و افزون بر آن برخی از این سری‌ها — به‌ویژه قیمت سوخت — به‌صورت باز و تمیز در دسترس نیستند. بدین ترتیب، این محدودسازی به‌جای آن‌که ضعف به‌شمار آید، اعتبار ادعای مقایسه‌ای پژوهش را تقویت می‌کند.

این پژوهش بر چند فرض بنیادی زیر استوار است:

۱. متغیرهای برون‌زای مورد استفاده، پیش‌بینی‌های روز-پیش در دسترس پیش از بسته‌شدن بازارند و نه مقادیر محقق‌شده؛ این فرض با شرایط واقعی بهره‌برداری و با پروتکل بنچمارک سازگار است.
۲. قیمت‌های منفی بخشی حقیقی از رفتار این بازارند و حذف یا برش داده نمی‌شوند؛ در نتیجه، معیارهای خطایی که در حضور مقادیر صفر یا منفی نامعتبر می‌شوند (مانند $MAPE^{۱۲}$) کنار گذاشته می‌شوند و به‌جای آن‌ها معیارهای مبتنی بر خطای مطلق به‌کار می‌روند.
۳. مجموعه داده‌ی بنچمارک به‌همان شکل منتشرشده و به‌مثابه‌ی مرجع متعارف پذیرفته می‌شود تا تکرارپذیری مقایسه حفظ شود.
۴. رفتار بازار میان رژیم‌های «آرام» و «پرتنش» ناهمگن است؛ همین ناهمگنی، مبنای رویکرد گروهی رژیم‌محور در این پژوهش است.
۵. در آزمون پایداری برون‌توزیعی، مدل‌ها پس از آموزش بر داده‌ی بنچمارک «منجمد» می‌مانند و بازآموزی نمی‌شوند، تا هر تغییر در عملکرد، بازتاب تغییر توزیع داده باشد و نه سازگاری دوباره‌ی مدل با شرایط تازه.

Mean Absolute Percentage Error^{۱۲}

فصل دوم

مروری بر پیشینه پژوهش

۱-۲ مرورهای نظام‌مند و مطالعات کتاب‌سنجی

پیش‌بینی قیمت برق در حدود ۲۵ سال گذشته به یکی از حوزه‌های فعال پژوهشی در اقتصاد انرژی بدل شده و بخش عمده‌ی این پژوهش‌ها — تا نزدیک به ۹۰ درصد — بر بازار روز-پیش متمرکز بوده‌اند؛ بازاری که به‌عنوان نماینده‌ی متعارف «قیمت برق» شناخته می‌شود [۶]. این حوزه نقشی بنیادی در تصمیم‌گیری بازیگران بازار در محیط‌های آزادسازی‌شده و رقابتی دارد [۳، ۲، ۴]، و با گسترش منابع تجدیدپذیر و نوسان‌پذیری ناشی از آن، بر اهمیت و دشواری آن افزوده شده است [۴، ۲].

مرورهای این حوزه، روش‌های پیش‌بینی را در چند خانواده‌ی اصلی دسته‌بندی می‌کنند. یکی از نخستین مرورهای جامع، این روش‌ها را به سه گروه سری‌های زمانی تصادفی، مدل‌های علی، و مدل‌های مبتنی بر هوش مصنوعی تقسیم کرده و آن‌ها را بر پایه‌ی افق پیش‌بینی، متغیرهای ورودی و عوامل مؤثر بر قیمت مقایسه می‌کند [۷]. مرورهای متأخرتر این دسته‌بندی را گسترش داده و روش‌های یادگیری ماشین، یادگیری عمیق، و معماری‌های ترکیبی و گروهی را نیز در بر می‌گیرند [۴]. روند کلی ادبیات، حرکتی آشکار از روش‌های آماری به سوی روش‌های مبتنی بر هوش مصنوعی را نشان می‌دهد [۳، ۴]؛ گرایشی که تنها به پیش‌بینی قیمت محدود نیست، چنان‌که مروری گسترده‌تر بر کاربردهای یادگیری ماشین در مطالعات بازار برق — فراتر از پیش‌بینی قیمت و شامل حوزه‌هایی چون طراحی بازار — نیز همین گسترش را بازتاب می‌دهد [۹]. با این‌همه، مرورها تأکید می‌کنند که هیچ روشی به‌طور مطلق برتر نیست و هر خانواده مزایا و محدودیت‌های خود را دارد [۳].

در سطح یافته‌ها، یک مرور نظام‌مند اخیر که ۶۲ اثر منتشرشده میان سال‌های ۲۰۱۲ و ۲۰۲۲ را بررسی کرده است، بر چند نکته‌ی مشترک انگشت می‌گذارد [۵]. نخست، لحاظ کردن عوامل تعیین‌کننده‌ی قیمت می‌تواند دقت مدل‌ها را به‌طور چشمگیری بهبود دهد، هرچند بر سر این که کدام عوامل و به چه شماری باید در نظر گرفته شوند اجماعی وجود ندارد. دوم، بخش عمده‌ی پژوهش‌ها بر پیش‌بینی نقطه‌ای متمرکزند، در حالی که پیش‌بینی بازه‌ای و احتمالاتی — که به دامنه و عدم قطعیت تغییرات قیمت پاسخ‌گوتر است — کمتر بررسی شده است. افزون بر این، عملکرد نسبی مدل‌ها به بخش بازار وابسته است: مروری که بازارهای روز-پیش، درون‌روز و تعادلی را کنار هم می‌سنجد، برتری مدل‌های ترکیبی و گروهی را در بازار روز-پیش، غلبه‌ی شبکه‌های عصبی بازگشتی را در بازار درون‌روز، و کارآمدی نسبی مدل‌های آماری ساده‌تری مانند LEAR را در بازار تعادلی گزارش می‌کند [۴].

در کنار این یافته‌ها، مرورها به یک کاستی روش‌شناختی مشترک نیز اشاره می‌کنند که برای پژوهش حاضر اهمیتی محوری دارد. علی‌رغم انبوه روش‌های پیشنهادی، ارزیابی نظام‌مند و گسترده هنوز کمیاب

است: بسیاری از الگوریتم‌ها بر مجموعه داده‌های خصوصی و غیرقابل دسترس، در بازه‌های آزمون کوتاه و محدود به یک بازار ارزیابی شده‌اند، به‌ندرت با مدل‌های ساده‌ی مرجع مقایسه شده‌اند، و معناداری آماری تفاوت‌ها کمتر آزموده شده است [۱، ۵]. مطالعات کتاب‌سنجی نیز، در کنار ترسیم نقشه‌ی انتشارات این حوزه و تمایز میان پرارجاع‌ترین و دقیق‌ترین مدل‌ها، بر ضرورت اثبات دقت از راه آزمون معناداری آماری تأکید می‌کنند [۱۰]. سرانجام، مرورها کیفیت داده، تفسیرپذیری مدل‌ها و تعمیم‌پذیری آن‌ها به شرایط تازه را از جمله چالش‌های همچنان گشوده‌ی این حوزه برمی‌شمارند [۴]. همین کاستی‌ها — نبود ارزیابی تکرارپذیر و مبتنی بر بنچمارک، و کم‌توجهی به تفسیرپذیری و تعمیم‌پذیری — چارچوب انگیزشی این پژوهش را شکل می‌دهند و در بخش‌های بعدی همین فصل، به تفکیک هر خانواده از روش‌ها، با جزئیات بیشتری بررسی خواهند شد.

۲-۲ روش‌های آماری کلاسیک

نخستین نسل ابزارهای پیش‌بینی قیمت در بازارهای رقابتی بر تحلیل سری‌های زمانی استوار بود؛ خانواده‌ای که مرورها آن را در زمره‌ی رویکردهای بنیادین این حوزه دسته‌بندی می‌کنند [۷]. در این چارچوب، قیمت هر ساعت بر پایه‌ی مقادیر گذشته‌ی خود و مجموعه‌ای از متغیرهای برون‌زا مدل می‌شود. در یکی از نخستین کارها بر این پایه، دو ابزار دقیق و کارآمد — رگرسیون پویا و مدل‌های تابع تبدیل — معرفی و بر داده‌های واقعی بازارهای اسپانیا و کالیفرنیا آزموده شد [۱۱]. شکل عمومی این خانواده را می‌توان به‌صورت یک مدل خودبازگشتی با ورودی‌های برون‌زا نوشت:

$$p_t = c + \sum_{i=1}^p \varphi_i p_{t-i} + \sum_{j=1}^m \beta_j x_{j,t} + \varepsilon_t \quad (1-2)$$

که در آن p_t قیمت در ساعت t ، جملات p_{t-i} قیمت‌های باوقفه تا مرتبه‌ی p ، متغیرهای $x_{j,t}$ ورودی‌های برون‌زا (مانند بار مصرفی و تولید)، ضرایب φ_i و β_j پارامترهای مدل، و ε_t جمله‌ی خطای نوفه‌ی سفید است.

یکی از پرکاربردترین خانواده‌های آماری، مدل‌های ARIMA^۱ است که ساختار خودبازگشتی و میانگین متحرک را با تفاضل‌گیری برای رویارویی با نایستایی ترکیب می‌کند. این کلاس را به‌صورت

^۱ AutoRegressive Integrated Moving Average

فشرده و با کمک عملگرِ پس‌رو چنین می‌نویسند:

$$\varphi(B)(1-B)^d p_t = \theta(B)\varepsilon_t \quad (2-2)$$

که در آن B عملگرِ پس‌رو است (به‌گونه‌ای که $Bp_t = p_{t-1}$)، توان d مرتبه‌ی تفاضل‌گیری برای ایستاسازیِ سری، و $\varphi(B)$ و $\theta(B)$ به‌ترتیب چندجمله‌ای‌های بخشِ خودبازگشتی و میانگین متحرک‌اند. بر همین پایه، روشی دومرحله‌ای پیشنهاد شده است: نخست سری نامنظم قیمت با تبدیلِ موجک به مجموعه‌ای از سری‌های خوش‌رفتارتر تجزیه می‌شود، سپس برای هر مؤلفه مدل ARIMA مناسبی برازش می‌گردد و سرانجام با تبدیلِ موجک معکوس، رفتارِ آتی قیمت بازسازی می‌شود [۱۲].

مدلِ خودبازگشتی با متغیرهای برون‌زا نه تنها یک ابزارِ پیش‌بینی، بلکه یک مرجعِ سنجش (بنچمارک) متعارف در این حوزه است؛ در مطالعه‌ای بر بازارهای یونان و مجارستان، همین مدلِ اقتصادسنجی به‌عنوان معیارِ پایه به‌کار رفته و روش‌های غیرخطی برای غلبه بر سوگیریِ خطیّت برآوردگرِ کمترین مربعات با آن سنجیده شده‌اند [۱۳]. با این‌همه، خانواده‌ی آماری جایگاهِ خود را از دست نداده است؛ مرورهای اخیر نشان می‌دهند که مدل‌های خطی منظم‌شده مانند LEAR در برخی بخش‌های بازار همچنان از دقیق‌ترین گزینه‌ها به‌شمار می‌روند [۴]. برتریِ اصلی این مدل‌ها در سادگی، کارآمدیِ محاسباتی و تفسیرپذیریِ آن‌هاست؛ اما محدودیتِ بنیادپیشان فرضِ خطیّت است که با ماهیتِ پرنوسان، جهش‌دار و نایستای قیمتِ برق به‌طورِ کامل سازگار نیست [۳]. همین محدودیت، انگیزه‌ی اصلیِ روی‌آوردن به روش‌های یادگیریِ ماشین و یادگیریِ عمیق بوده است که در بخش‌های بعد بررسی می‌شوند.

۳-۲ یادگیریِ ماشینِ کلاسیک

با آشکارشدنِ محدودیتِ مدل‌های خطیِ آماری در بازنماییِ رفتارِ غیرخطیِ قیمت، پژوهش‌ها به تدریج به سوی روش‌های یادگیریِ ماشینِ چرخیدند؛ روش‌هایی که می‌توانند روابطِ پیچیده را بی‌آن که ساختاری خطی از پیش فرض کنند، از داده بیاموزند. شبکه‌های عصبیِ مصنوعی و ماشین‌های بردارِ پشتیبان از نخستین و پرکاربردترینِ این روش‌ها بوده‌اند؛ در یک مطالعه‌ی مقایسه‌ای، این دو روش برای پیش‌بینیِ قیمت به‌کار رفتند و نشان داده شد که انتخابِ ویژگی با الگوریتمِ کلونیِ مورچگان، با کاستن از فضای ویژگی، دقتِ شبکه‌ی عصبی را به‌طورِ چشمگیری بهبود می‌بخشد [۱۴]. اهمیتِ ورودی‌های برون‌زا در

این خانواده نیز برجسته است؛ رویکردی مبتنی بر برنامه‌نویسی ژنتیک با بهره‌گیری از متغیرهایی چون شرایط جوی، قیمت نفت و گواهی‌های CO₂^۲، قیمت را برای افق ۲۴ ساعت آینده در بزرگ‌ترین بازارهای اروپا با دقتی بالاتر پیش‌بینی کرد [۱۵].

تنوع روش‌های یادگیری ماشین در ادبیات چشمگیر است. برخی مطالعات مدل‌های ترکیبی استنتاج فازی-عصبی و رگرسیون بردار پشتیبان را با ورودی‌های سری‌زمانی و خودبازگشتی به کار گرفته‌اند [۱۶]، و برخی دیگر کارآمدی این روش‌ها را در شرایط خاص و پرنوسان — مانند دوره‌ی همه‌گیری کرونا و بازار MISO^۲ در ایالات متحده — سنجیده‌اند [۱۷]. کاربردهای این روش‌ها حتی به حوزه‌هایی چون مدیریت انرژی مراکز داده و رایانش ابری نیز گسترش یافته است [۱۸]. در مقایسه‌های مستقیم با مدل‌های مرجع آماری نیز، روش‌هایی مانند ماشین بردار پشتیبان اغلب به‌عنوان بهترین جایگزین غیرخطی ظاهر شده‌اند [۱۳].

جمع‌بندی این بخش آن است که قدرت اصلی روش‌های یادگیری ماشین در توان آن‌ها برای مدل‌سازی غیرخطی و بهره‌گیری انعطاف‌پذیر از متغیرهای برون‌زا است؛ توانی که با مهندسی ویژگی و انتخاب ورودی‌های مناسب تقویت می‌شود. با این‌همه، بخش عمده‌ی این مطالعات بر یک بازار خاص و در بازه‌ای محدود انجام شده‌اند و از پروتکل‌های ارزیابی یکسان و مقایسه‌ی گسترده بی‌بهره مانده‌اند؛ کاستی‌ای که در بخش پایانی این فصل بار دیگر بدان بازخواهیم گشت. همین محدودیت‌ها، در کنار ظهور معماری‌های تواناتر، زمینه‌ساز گذار به روش‌های یادگیری عمیق بوده‌اند.

۴-۲ یادگیری عمیق

نسل بعدی روش‌ها با ورود یادگیری عمیق به این حوزه شکل گرفت. در حالی که این خانواده تا میانه‌ی دهه‌ی گذشته کمتر در پیش‌بینی قیمت به کار رفته بود، مطالعه‌ای بنیادین با معرفی چهار مدل یادگیری عمیق و مقایسه‌ی گسترده‌ی آن‌ها با ۲۷ روش متداول نشان داد که این رویکردها می‌توانند دقت پیش‌بینی را به‌طور محسوسی افزایش دهند [۱۹]. در میان معماری‌های عمیق، شبکه‌های عصبی بازگشتی جایگاهی ویژه یافتند، زیرا برای یادگیری وابستگی‌های زمانی طراحی شده‌اند. حالت پنهان این شبکه‌ها را می‌توان به‌صورت زیر توصیف کرد:

^۲Carbon Dioxide

^۳Midcontinent Independent System Operator

$$h_t = \tanh(W_x x_t + W_h h_{t-1} + b_h) \quad (3-2)$$

که در آن h_t حالت پنهان در گام زمانی t ، ورودی همان گام، و W_x و W_h ماتریس‌های وزن‌اند. واحدهای پیشرفته‌تر این خانواده، مانند حافظه‌ی کوتاه‌مدت بلند (LSTM) و واحد بازگشتی گیت‌دار (GRU)^۴، برای مقابله با چالش وابستگی‌های بلندمدت توسعه یافته‌اند و به‌طور خاص برای سری‌های زمانی قیمت مناسب‌اند [۲۰].

کاربردهای متنوعی از این معماری‌ها گزارش شده است. مدلی پیمانه‌ای که ترکیبی از شبکه‌های کانولوشنی و بازگشتی را بر بازار آلمان به کار می‌برد، پیش‌بینی پایه را با افزودن پیش‌بینی تولید بادی و خورشیدی غنی می‌سازد [۲۱]؛ مطالعات دیگری از شبکه‌های LSTM برای پیش‌بینی قیمت روز-پیش [۲۲]، از ماشین یادگیری فرین در شبکه‌های هوشمند [۲۳]، و از مدل‌های هوش مصنوعی برای پیش‌بینی قیمت روزانه در بازار ایران [۲۴] بهره برده‌اند. نکته‌ی مشترک این مطالعات آن است که با افزایش سهم منابع تجدیدپذیر و نوسان ناشی از آن، مدل‌های عمیق به ابزار غالب ادبیات بدل شده‌اند [۲۲].

با این همه، مرورها هشدار می‌دهند که به‌رغم توان بالای این مدل‌ها، هیچ معماری‌ای به‌طور پیوسته و در همه‌ی شرایط بر دیگری برتری ندارد؛ تنوع روش‌ها همچنان پابرجاست و انتخاب بهترین مدل به بازار و شرایط وابسته است [۲۰]. همین نکته، در کنار هزینه‌ی محاسباتی و نیاز به داده‌ی فراوان، انگیزه‌ی روی آوردن به مدل‌های ترکیبی را فراهم کرده است.

۵-۲ مدل‌های ترکیبی و مکانیزم توجه

محدودیت‌های مدل‌های منفرد — چه آماری و چه یادگیری عمیق — پژوهشگران را به سوی مدل‌های ترکیبی سوق داده است؛ رویکردی که می‌کوشد نقاط قوت چند روش را کنار هم بگذارد. منطق بنیادی بسیاری از این روش‌ها، ترکیب وزن‌دار خروجی چند مدل پایه است:

$$\hat{y} = \sum_{k=1}^K w_k \hat{y}_k \quad (4-2)$$

Gated Recurrent Unit^۴

که در آن $\hat{y}_k$ پیش‌بینی مدل k ام، w_k وزن آن، و $\hat{y}$ پیش‌بینی نهایی ترکیب است. این ایده در ادبیات به شکل‌های گوناگون تحقق یافته است؛ از ترکیب رگرسیون خطی و درخت‌های تصادفی کیسه‌ای [۲۵] تا مدل‌های گروهی متشکل از روش‌های آماری و شبکه‌های عصبی [۲۶].

الگوی پرتکرار دیگر، ترکیب پیش‌پردازش و تجزیه‌ی سیگنال با یادگیری عمیق است. رویکردهایی مبتنی بر تجزیه‌ی مد متغیر و حذف نوفه، سری قیمت را پیش از مدل‌سازی به مؤلفه‌های ساده‌تر تجزیه می‌کنند و سپس آن‌ها را به شبکه‌های بازگشتی می‌سپارند [۲۷، ۲۸]. چارچوب‌های چندپیمانه‌ای نیز پیشنهاد شده‌اند که در آن‌ها مازول‌های جداگانه‌ای برای پیش‌پردازش، پیش‌بینی نقطه‌ای، جبران خطا و پیش‌بینی احتمالاتی تعبیه شده است [۲۹، ۳۰]. افزودن مکانیزم توجه و شبکه‌های کانولوشنی-بازگشتی نیز از جدیدترین گرایش‌ها در این حوزه است [۳۱، ۳۲، ۳۳].

سومین گرایش، بهره‌گیری از الگوریتم‌های بهینه‌سازی برای تنظیم ابرپارامترها و ساختار مدل است [۳۴]، و برخی چارچوب‌ها فراتر از پیش‌بینی نقطه‌ای، پیش‌بینی بازه‌ای و چندخروجی را نیز پوشش می‌دهند [۳۵]. جمع‌بندی این بخش آن است که مدل‌های ترکیبی و گروهی، به‌ویژه در بازار روز-پیش، عملکردی قدرتمند از خود نشان می‌دهند؛ اما این قدرت به بهای پیچیدگی بیشتر، دشواری تفسیر و خطر بیش‌برازش به‌دست می‌آید. همین دو نکته — کارآمدی بالای ترکیب از یک سو و کاهش تفسیرپذیری از سوی دیگر — به‌طور مستقیم به دو محور اصلی این پایان‌نامه، یعنی وزن‌دهی گروهی رژیم‌محور و تحلیل تفسیرپذیری، پیوند می‌خورد.

۶-۲ تفسیرپذیری و هوش مصنوعی توضیح‌پذیر

با پیچیده‌تر و دقیق‌تر شدن مدل‌های یادگیری ماشین و یادگیری عمیق، پرسشی تازه اهمیت یافته است: چرا مدل یک پیش‌بینی خاص را ارائه می‌دهد؟ مرورهای اخیر، تفسیرپذیری مدل‌ها را در کنار کیفیت داده و تعمیم‌پذیری، از جمله چالش‌های همچنان گشوده‌ی این حوزه برمی‌شمارند [۴]. بسیاری از مدل‌های پرکاربرد — به‌ویژه معماری‌های عمیق — ماهیتی جعبه‌سیاه دارند و بی‌آن‌که سازوکار درونی آن‌ها روشن باشد، صرفاً بر پایه‌ی دقت خروجی ارزیابی می‌شوند. در پاسخ به این نیاز، دو رویکرد کلی شکل گرفته است: تعبیه‌ی تفسیرپذیری در خود ساختار مدل، و تحلیل پسینی مدل‌های پیچیده با روش‌های هوش مصنوعی توضیح‌پذیر.

رویکرد نخست را می‌توان در مدل‌های اقتصادسنجی‌ای دید که با محدود کردن ضرایب به بازه‌هایی برخاسته از مدل‌های بنیادی، هم‌زمان دقت و تفسیرپذیری را دنبال می‌کنند [۳۶]. رویکرد دوم، که در

سال‌های اخیر توجه بیشتری یافته، بر روش‌های تحلیل پسینی استوار است. برجسته‌ترین این روش‌ها، مقادیر شپلی افزایشی (SHAP) است؛ روشی برخاسته از نظریه‌ی بازی‌های همکارانه که به هر ویژگی سهمی افزایشی در تفاوت یک پیش‌بینی مشخص با مقدار میانگین نسبت می‌دهد و بدین ترتیب، تصمیم مدل‌های جعبه‌سیاه را ردیابی پذیر می‌سازد [۳۷].

کاربرد این روش در پیش‌بینی قیمت برق، به‌ویژه در بازار آلمان، نتایجی روشن‌گر به‌دست داده است. در پژوهشی که بازار روز-پیش آلمان را با کمک SHAP تحلیل کرده و سپس بر پایه‌ی همان بینش‌ها شبکه‌های LSTM را برای پیش‌بینی به‌کار گرفته است، نشان داده شد که بار مصرفی و تولید بادی و خورشیدی از عوامل برون‌زای اصلی محرک قیمت‌اند و در این میان، تولید بادی اثری بیش از خورشیدی دارد؛ همچنین قیمت سوخت‌ها به‌شکلی غیرساده بر قیمت اثر می‌گذارد و شیب‌های بزرگ تغییر تولید، به‌سبب انعطاف‌پذیری محدود نیروگاه‌های هسته‌ای و زغال‌سنگی، با قیمت‌های بالا هم‌بسته‌اند [۳۷]. این مطالعه نمونه‌ای گویا از آن است که چگونه تحلیل تفسیرپذیری می‌تواند نه‌تنها اعتماد به مدل را افزایش دهد، بلکه در طراحی بهتر خود مدل پیش‌بینی نیز به‌کار آید.

با این‌همه، در قیاس با انبوه مطالعات متمرکز بر دقت، شمار کارهایی که به‌طور نظام‌مند سهم عوامل گوناگون را در پیش‌بینی قیمت می‌کاوند همچنان اندک است. همین کم‌توجهی، یکی از شکاف‌های اصلی این حوزه و از انگیزه‌های محوری پژوهش حاضر است؛ پژوهشی که در آن تحلیل تفسیرپذیری مبتنی بر SHAP در کنار سنجش دقت، و به‌تفکیک رژیم‌های آرام و پرتنش و افق‌های ساعتی و روزانه، به‌کار گرفته می‌شود.

۷-۲ مطالعات کاربردی و بازارهای خاص

پیش‌بینی قیمت برق ذاتاً وابسته به بازار است؛ ساختار حراج، سبد تولید و میزان نفوذ تجدیدپذیرها از بازاری به بازار دیگر تفاوت دارد و همین امر، مطالعات کاربردی متمرکز بر بازارهای خاص را ضروری می‌سازد. دامنه‌ی این مطالعات گسترده است: از بازارهای اسپانیا [۱۱، ۱۲] و ایالات متحده [۱۷، ۲۹] تا بازار نورد پول [۲۵]، یونان و مجارستان [۱۳]، استرالیا [۳۵، ۳۰]، ترکیه [۲۰]، هند [۲۶] و بازار تعادلی بریتانیا [۳۸]. حتی بازارهایی با ساختار متفاوت، مانند سازوکار پرداخت به‌قیمت پیشنهادی ایران، نیز موضوع پژوهش بوده‌اند [۲۴]. افزون بر بازارهای واقعی، برخی مطالعات به سناریوهای شبیه‌سازی‌شده‌ی بازارهای آینده و انتقال‌پذیری روش‌ها میان آن‌ها پرداخته‌اند [۳۹].

در میان این بازارها، بازار برق آلمان جایگاهی ویژه در این پژوهش دارد، زیرا داده و پروتکل بنچمارک

مورد استفاده به همین بازار تعلق دارد و از این رو، مطالعات متمرکز بر آن تنها مرجع‌هایی‌اند که نتایج این پایان‌نامه مستقیماً با آن‌ها قابل‌مقایسه است. این بازار به‌طور گسترده مطالعه شده است: از تجزیه‌ی قیمت لحظه‌ای به مؤلفه‌های فصلی و تصادفی [۸]، تا مدل‌های عمیق غنی‌شده با پیش‌بینی تولید بادی و خورشیدی [۲۱]، و مدل‌های کانولوشنی-بازگشتی بر بازارهای آلمان و بریتانیا [۳۲]، و تحلیل تفسیرپذیری مبتنی بر SHAP از عوامل محرک قیمت در همین بازار [۳۷]. افق زمانی این مطالعات نیز از روز-پیش‌فراتر رفته و پیش‌بینی میان‌مدت و بلندمدت را در بر می‌گیرد [۳۶، ۴۰].

جمع‌بندی این بخش دو نکته را برجسته می‌کند. نخست، به‌رغم اشتراک در روش‌ها، رفتار مدل‌ها و مجموعه‌ی متغیرهای مؤثر از بازاری به بازار دیگر تفاوت معنادار دارد؛ دوم، انبوه مطالعات متمرکز بر بازار آلمان، آن را به بستری بالغ و در عین حال چالش‌برانگیز برای سنجش روش‌های تازه بدل کرده است. پژوهش حاضر بر همین بستر و در چارچوب یک پروتکل عمومی مقایسه‌پذیر بنا شده است.

۸-۲ پیش‌بینی بلندمدت و احتمالاتی

بخش عمده‌ی ادبیات پیش‌بینی قیمت — از جمله پژوهش حاضر — بر افق روز-پیش و بر پیش‌بینی نقطه‌ای متمرکز است. با این‌همه، دو شاخه‌ی مکمل نیز در ادبیات وجود دارد که مرزهای این حوزه را گسترش می‌دهند: پیش‌بینی افق‌های بلندتر و پیش‌بینی احتمالاتی.

پیش‌بینی میان‌مدت و بلندمدت، برخلاف افق روز-پیش، برای تصمیم‌های سرمایه‌گذاری و سیاست‌گذاری ضروری است؛ اما ادبیات این حوزه به‌مراتب کم‌حجم‌تر است [۴۰]. مطالعاتی کوشیده‌اند این خلأ را با روش‌های یادگیری ماشین برای پیش‌بینی بلندمدت کالاهای انرژی و پشتیبانی از تصمیم‌های سرمایه‌گذاری پر کنند [۴۱]. رویکردهای اقتصادسنجی اخیر نیز افق روز-پیش را به میان‌مدت و بلندمدت گسترش داده‌اند و برای پایداری‌سازی پیش‌بینی‌های بلندمدت، از انتظارات فصلی متغیرهایی چون بار و تجدیدپذیرها بهره می‌گیرند [۳۶].

شاخه‌ی دوم، پیش‌بینی احتمالاتی است. همان‌گونه که پیش‌تر اشاره شد، بخش عمده‌ی پژوهش‌ها بر پیش‌بینی نقطه‌ای متمرکزند، در حالی که پیش‌بینی بازه‌ای و چگالی به عدم قطعیت ذاتی قیمت پاسخ‌گوتر است [۵]. به همین سبب، برخی چارچوب‌های ترکیبی ماژولی برای پیش‌بینی احتمالاتی در کنار پیش‌بینی نقطه‌ای تعبیه کرده‌اند [۲۹، ۳۵]. این دو شاخه، هرچند از دامنه‌ی پژوهش حاضر بیرون‌اند، جهت‌های طبیعی گسترش آن به‌شمار می‌روند و در فصل پایانی به‌عنوان کارهای آینده بدان‌ها بازخواهیم گشت.

۹-۲ شکاف پژوهشی و جایگاه کار حاضر

مرور ادبیات این فصل، در کنار گستردگی چشمگیر روش‌ها، چند شکاف نظام‌مند را نیز آشکار می‌سازد که پژوهش حاضر می‌کوشد بدان‌ها بپردازد.

نخستین و مهم‌ترین شکاف، ضعف ارزیابی نظام‌مند و تکرارپذیر است. با آن‌که صدها روش پیشنهاد شده، بسیاری از آن‌ها بر داده‌های خصوصی، در بازه‌های آزمون کوتاه و محدود به یک بازار، و بدون مقایسه با مدل‌های ساده‌ی مرجع یا آزمون معناداری آماری ارزیابی شده‌اند [۱، ۵]؛ کاستی‌ای که مطالعات کتاب‌سنجی نیز بر آن صحنه گذاشته و بر ضرورت اثبات دقت از راه آزمون معناداری تأکید کرده‌اند [۱۰]. پژوهش حاضر با اتکا به یک مجموعه داده و پروتکل ارزیابی عمومی و منتشرشده، و با به کارگیری آزمون معناداری آماری تصحیح‌شده، مستقیماً به این شکاف پاسخ می‌دهد.

دومین نکته، انتخاب بازار است. از آن‌جا که تا نزدیک به ۹۰ درصد از ادبیات بر بازار روز-پیش متمرکز است [۶] و بازار آلمان یکی از پرمطالعه‌ترین و پرنفوذترین بازارهای اروپاست [۸]، تمرکز بر همین بازار امکان مقایسه‌ی مستقیم با مجموعه‌ای از مطالعات قابل‌قیاس را فراهم می‌کند و جایگاه کار حاضر را در نقشه‌ی ادبیات به‌روشنی مشخص می‌سازد.

سومین و چهارمین شکاف به دو چالش همچنان گشوده بازمی‌گردد که مرورها بارها بر آن‌ها انگشت گذاشته‌اند: تفسیرپذیری و تعمیم‌پذیری [۴]. چنان‌که در بخش تفسیرپذیری دیدیم، شمار مطالعاتی که به‌طور نظام‌مند سهم عوامل مختلف را در پیش‌بینی می‌کاوند اندک است؛ و پایداری مدل‌ها در برابر تغییر توزیع داده در گذر زمان نیز به‌ندرت آزموده شده است. پژوهش حاضر با افزودن تحلیل تفسیرپذیری و آزمون پایداری برون‌توزیعی به یک مطالعه‌ی محک‌زنی دقیق، می‌کوشد این دو خلأ را نیز بپوشاند.

برای جمع‌بندی این شکاف‌ها، جدول ۱-۲ چند مطالعه‌ی شاخص — از جمله مطالعات متمرکز بر بازار آلمان — را از منظر شش جنبه‌ی کلیدی روش‌شناختی با پژوهش حاضر مقایسه می‌کند.

همان‌گونه که جدول نشان می‌دهد، هر یک از این جنبه‌ها اهمیتی مستقل دارد. اتکا به یک مجموعه داده و پروتکل عمومی، تکرارپذیری و مقایسه‌ی منصفانه را ممکن می‌سازد؛ آزمون معناداری آماری تضمین می‌کند که تفاوت میان مدل‌ها واقعی است و نه حاصل نوسان تصادفی؛ وزن‌دهی رژیم‌محور به این واقعیت پاسخ می‌دهد که رفتار قیمت در دوره‌های آرام و پرتنش یکسان نیست؛ تفسیرپذیری، اعتماد به مدل و شناخت عوامل مؤثر بر پیش‌بینی را فراهم می‌آورد؛ و آزمون برون‌توزیعی روشن می‌کند که آیا مدل در برابر تغییر شرایط بازار در گذر زمان پایدار می‌ماند یا نه. چنان‌که پیداست، هیچ‌یک از مطالعات پیشین این شش جنبه را هم‌زمان پوشش نمی‌دهند؛ برخی از استحکام ارزیابی برخوردارند اما به

جدول ۱-۲: مقایسه‌ی جنبه‌های روش‌شناختی چند مطالعه‌ی شاخص با پژوهش حاضر (بر پایه‌ی آنچه در منابع گزارش شده است).

مطالعه	داده‌ی عمومی	چندخانواده	معناداری	رژیم‌محور	تفسیرپذیری	برون‌توزیعی
[۱] Lago	✓	✓	✓	×	×	×
[۸] Poggi	×	✓	×	×	×	×
[۳۷] Trebbien	×	×	×	×	✓	×
[۳۶] Ghelasi	×	×	×	×	✓	×
[۲۰] Ugurlu	×	نسبی	×	×	×	×
[۲۹] Zhang	×	×	×	×	×	×
[۳۹] Nitsch	×	نسبی	×	×	×	نسبی
پژوهش حاضر	✓	✓	✓	✓	✓	✓

تفسیرپذیری، رژیم یا پایداری نمی‌پردازند، و برخی دیگر تفسیرپذیری را در نظر می‌گیرند اما بر بستری تکرارپذیر و همراه با آزمون معناداری بنا نشده‌اند.

بر این اساس، جایگاه این پایان‌نامه را می‌توان چنین خلاصه کرد: نه صرفاً افزودن روشی تازه به انبوه روش‌های موجود، بلکه ارائه‌ی یک ارزیابی منصفانه، تکرارپذیر و تفسیرپذیر بر بستری استاندارد، که هم‌زمان به رفتار رژیم‌محور و پایداری برون‌توزیعی مدل‌ها توجه دارد.

فصل سوم

روش تحقیق

۱-۳ مقدمه

این فصل روش پژوهش را چنان شرح می‌دهد که خواننده بتواند آن را بازتولید کند. ترتیب بخش‌ها از داده به سوی مدل و سپس به سوی سنجش پیش می‌رود، زیرا هر حلقه از این زنجیره اعتبار حلقه‌های پس از خود را تعیین می‌کند: ماتریس ویژگی آلوده، هر مدلی را که از آن تغذیه کند بی‌اعتبار می‌سازد، و چارچوب اعتبارسنجی سهل‌گیر، هر عدد دقتی را که تولید کند خوش‌بینانه می‌کند.

بخش ۲-۳ شش فرض بنیادی پژوهش را — همان‌گونه که در پیشنهادی مصوب صورت‌بندی شده‌اند — می‌آورد و از همان آغاز روشن می‌کند که شواهد فصل‌های چهارم و پنجم کدام یک از آن‌ها را تأیید نکرده‌اند. **بخش ۳-۳** داده‌ها را معرفی می‌کند: مجموعه داده بنچمارک EPEX-DE که تمام نتایج پایان‌نامه بر آن استوار است، مجموعه‌ای داده‌ی زنده که تنها برای آزمون برون‌توزیعی و ابزار عملیاتی به کار می‌رود، و تحلیل اکتشافی‌ای که تصمیم‌های روش‌شناختی پس از خود را توجیه می‌کند. **بخش ۴-۳** مهندسی ویژگی و قید علی حاکم بر آن را تشریح می‌کند.

بخش ۵-۳ چارچوب اعتبارسنجی، معیارهای دقت و آزمون معناداری را تعریف می‌کند. اینکه این بخش پیش از معرفی مدل‌ها می‌آید تصادفی نیست: معیارها و پروتکل ارزیابی پیش از دیده‌شدن هر نتیجه‌ای تثبیت شده‌اند، و همین پیش‌تعهد است که به اعداد فصل چهارم اعتبار می‌بخشد. بخش‌های ۶-۳ و ۷-۳ به ترتیب مدل‌های پایه (ساده، SARIMAX، LEAR-LASSO) و مدل‌های یادگیری ماشین و یادگیری عمیق (LSTM، LightGBM) را معرفی می‌کنند، و **بخش ۸-۳** مدل ترکیبی و وزن‌دهی گروهی رژیم‌محور را.

سه قید در سرتاسر این فصل تکرار می‌شود و بهتر است از همین جا صریح باشد. نخست، هم‌سانی: همه‌ی مدل‌ها از یک منبع یکتای ویژگی تغذیه می‌شوند، بر یک پروتکل یکسان رانده می‌شوند و با یک پیمانه‌ی معیار سنجیده می‌شوند، تا اختلاف عملکرد به خودِ مدل بازگردد و نه به تفاوت در شرایط. دوم، هم‌ارزی با پروتکل منتشرشده‌ی لاگو و همکاران [۱]، که مقایسه‌ی فصل چهارم با اعداد مرجع را ممکن می‌کند. سوم، ثبت انحراف‌ها: هر جا پیاده‌سازی از پروتکل مرجع فاصله گرفته است — به‌ویژه در آهنگ واسنجی SARIMAX و LSTM — این فاصله در متن تصریح شده است، به‌جای آنکه در کد پنهان بماند.

۲-۳ فرضیات بنیادی پژوهش

هر پژوهش تجربی بر فرض‌هایی استوار است که اگر ناگفته بمانند، خواننده نمی‌داند نتایج تا کجا معتبرند. شش فرض زیر همان‌هایی است که در پیشنهادی مصوب این پایان‌نامه صورت‌بندی شده است. آن‌ها را در همین‌جا کامل می‌آوریم و برای هر یک تصریح می‌کنیم که شواهد این پژوهش آن را تأیید کرده‌اند یا نه. این تصریح، عقب‌نشینی از پیشنهاد نیست؛ بازگشت مستند به آن است، و **بخش ۵-۲** حلقه‌ی همین بازگشت را می‌بندد.

فرض یکم: ایستایی

فرض می‌شود ساختار آماری سری قیمت — یا دست‌کم آن بخشی از آن که مدل‌ها بر آن تکیه می‌کنند — در طول دوره‌ی آموزش و آزمون به‌قدر کافی پایدار است که الگوی آموخته‌شده بر گذشته، بر آینده نیز برقرار بماند.

این فرض در صورت قوی خود برقرار نیست، و پژوهش نیز به آن نیازی ندارد. میانگین سالانه‌ی قیمت در دوره‌ی مطالعه از 42.89 یورو بر مگاوات‌ساعت در سال ۲۰۱۲ به 28.98 در سال ۲۰۱۶ افت می‌کند و سپس به 34.20 در سال ۲۰۱۷ بازمی‌گردد؛ سطح قیمت آشکارا ثابت نیست. آنچه پژوهش در عمل فرض می‌کند صورت ضعیف‌تر آن است: واسنجی مجدد روزانه بر پنجره‌ی غلتان ۱۰۹۲ روزه (**بخش ۳-۵**) مدل را پیوسته با سطح جاری بازار هم‌تراز نگه می‌دارد، به‌طوری‌که تنها ایستایی محلی لازم است و نه ایستایی سراسری. این تمایز در فصل پنجم اهمیت پیدا می‌کند، آنجا که مدل‌ها بدون هیچ واسنجی مجدد به کار گرفته می‌شوند.

فرض دوم: در دسترس بودن داده

فرض می‌شود داده‌های لازم برای پیش‌بینی — قیمت‌های تاریخی و پیش‌بینی‌های روزپیش‌بار و تولید تجدیدپذیر — پیش از مبدأ پیش‌بینی در دسترس‌اند.

این فرض برقرار است، و در **بخش ۳-۴** به قیدی آزموده ترجمه شده است: هر ستون ماتریس ویژگی باید تاریخ در دسترس بودن خود را اعلام کند، وگرنه ساخت ماتریس متوقف می‌شود. با این‌همه فرض دوم یک هزینه‌ی ثبت‌شده دارد. چند متغیر که ادبیات آن‌ها را مؤثر می‌داند — به‌ویژه قیمت سوخت — در این پژوهش در دسترس نبودند، زیرا سری‌های مرجعشان تجاری و دارای مجوزند. **بخش ۳-۳** این محدودیت و دلیل آن را ثبت می‌کند؛ آنچه اینجا اهمیت دارد این است که فرض دوم برای مجموعه‌ی

ویژگی به کاررفته برقرار است، نه برای هر مجموعه‌ی ویژگی مطلوب.

فرض سوم: کیفیت داده

فرض می‌شود داده‌های ورودی از خطای اندازه‌گیری، جاافتادگی و ناسازگاری تعریفی مبرا هستند. برای مجموعه‌داده بنچمارک این فرض برقرار است: 52,416 سطر ساعتی، بدون هیچ مقدار گم‌شده و بدون هیچ برچسب زمانی تکراری. اما برای مجموعه‌ی داده‌ی زنده — که تنها در آزمون برون توزیعی به کار می‌رود — این فرض نقض شده است، و نقض آن یکی از یافته‌های همین پژوهش است. متغیر برون‌زای نخست در دوره‌ی آموزش پیش‌بینی بار ناحیه‌ی کنترلی Amprion است و در دوره‌ی سرویس‌دهی پیش‌بینی بار ملی آلمان: دو تعریف متفاوت زیر یک نام. اندازه‌ی این ناهم‌خوانی سنجیده شده و در **بخش ۲-۵** گزارش می‌شود.

تصریح این نکته در همین جا اهمیت دارد، چون تعیین می‌کند شکست برون‌توزیعی فصل پنجم را باید به کدام فرض نسبت داد. ناهم‌خوانی تعریفی، نقضی در مسیر داده‌ی خود ماست و ذیل همین فرض سوم می‌نشیند، نه ذیل فرض پنجم.

فرض چهارم: تعمیم‌پذیری مدل

فرض می‌شود مدلی که بر داده‌ی تاریخی آموزش دیده، بر داده‌ای که ندیده است نیز عملکرد قابل‌قبولی دارد.

درون دوره‌ی بنچمارک این فرض برقرار است: دوره‌ی آزمون دوساله‌ی ۷۲۸ مبدایی به‌طور کامل کنار گذاشته شده و هیچ مدلی در هیچ مرحله‌ای — نه در برازش، نه در تنظیم ابرپارامتر و نه در برازش وزن‌های ترکیبی — آن را ندیده است.

بیرون از آن دوره، این فرض برقرار نیست. مدل‌های تثبیت‌شده بر دوره‌ی بنچمارک، هنگام ارزیابی بر ۱۷۳ روز داده‌ی زنده‌ی سال ۲۰۲۶، همگی از مدل ساده‌ی مرجع عقب می‌مانند و ترتیب آن‌ها وارونه می‌شود. این صریح‌ترین نقض فرض در سرتاسر پژوهش است، و نکته‌ی مهم آنکه بر هر دو خوانش ممکن برقرار می‌ماند: چه بخشی از افت را به تغییر بازار نسبت دهیم و چه به ناهم‌خوانی تعریفی فرض سوم، در هر دو حالت مدل‌ها در شرایطی که برای آن آموزش ندیده بودند شکست خورده‌اند. **بخش ۲-۵** اعداد آن را می‌آورد.

فرض پنجم: پایداری شرایط بازار

فرض می‌شود شرایط کلان بازار میان دوره‌ی آموزش و دوره‌ی کاربرد به قدر کافی پایدار می‌ماند. این فرض درباره‌ی بازار است، و همین آن را از فرض چهارم جدا می‌کند. نسبت دادن کامل شکست برون‌توزیعی به این فرض، خطایی است که این پژوهش عاقدانه از آن پرهیز می‌کند. بخشی از آن افت — و بر پایه‌ی سنجش، بخش عمده‌ی سهم قابل اندازه‌گیری آن — از ناهم‌خوانی تعریفی مسیر سرویس‌دهی خود ما برمی‌خیزد، یعنی از فرض سوم، و نه از حرکت بازار آلمان. آنچه با صداقت می‌توان گفت این است: فرض پنجم تنها با آن باقی‌مانده‌ای به چالش کشیده می‌شود که پس از کنار گذاشتن سهم ناهم‌خوانی برجای می‌ماند، و این پژوهش آن باقی‌مانده را جدا نکرده است. سهم بازار در این افت — برخلاف سهم ناهم‌خوانی — به‌طور مستقل کمی نشده است، و **بخش ۵-۲** آن را به همین صورت گزارش می‌کند، نه صفر و نه غالب.

فرض ششم: تفسیرپذیری مدل

فرض می‌شود می‌توان سهم ویژگی‌ها در خروجی مدل را به‌صورتی قابل‌فهم استخراج کرد. در پیشنهادی مصوب، تفسیرپذیری یک فرض بود؛ در این پژوهش به یک تحویل‌دادنی بدل شده است. مرورهای اخیر نیز تفسیرپذیری را در کنار کیفیت داده و تعمیم‌پذیری از چالش‌های همچنان گشوده‌ی این حوزه برمی‌شمارند [۴]. **بخش ۴-۶** تحلیل SHAP را با دو قید صریح ارائه می‌کند: این تحلیل تنها بازوی درختی مدل را پوشش می‌دهد و درباره‌ی اطلاعاتی که مدل خطی یا شبکه‌ی بازگشتی به کار می‌گیرند ادعایی نمی‌کند، و مدلی که تفسیر می‌شود همزاد وفادار مدل گزارش شده است و نه خود آن. فرض ششم با این دو قید برقرار است.

جمع‌بندی

از شش فرض بالا، فرض‌های دوم و ششم بی‌قید برقرارند؛ فرض یکم تنها در صورت ضعیف و محلی خود لازم و برقرار است؛ فرض سوم برای داده‌ی بنچمارک برقرار و برای داده‌ی زنده نقض شده است؛ فرض چهارم درون دوره‌ی بنچمارک برقرار و بیرون از آن نقض شده است؛ و فرض پنجم تنها تا اندازه‌ای به چالش کشیده می‌شود که این پژوهش آن را از فرض سوم جدا نکرده است. **بخش ۵-۲** با شواهد عددی به همین فهرست بازمی‌گردد.

۳-۳ داده‌ها و بازار مورد مطالعه

این پژوهش از دو مجموعه‌ی داده استفاده می‌کند که نقش آن‌ها را نباید با یکدیگر اشتباه گرفت. مجموعه‌ی نخست، داده‌ی بنچمارکِ باز EPEX-DE است که لاگو و همکاران آن را همراه پروتکل ارزیابی خود منتشر کرده‌اند [۱]؛ تمام اعداد دقت، آزمون‌های معناداری و تحلیل تفسیرپذیری این پایان‌نامه بر همین مجموعه تولید شده‌اند. مجموعه‌ی دوم، داده‌ی زنده‌ی سامانه‌ی Energy-Charts است که کاربرد آن به دو مورد محدود می‌ماند: آزمون برون‌توزیعی **بخش ۲-۵** و ابزار عملیاتی **بخش ۳-۵**.

این تفکیک یک قاعده‌ی ثبت‌شده‌ی پژوهش است و نه ترتیبی اتفاقی. هیچ عددی از مجموعه‌ی دوم وارد جدول‌های نتایج فصل چهارم نمی‌شود، زیرا آن جدول‌ها باید با اعداد منتشرشده‌ی مرجع هم‌مقیاس بمانند. **بخش ۱-۳-۳** مجموعه‌ی بنچمارک را معرفی می‌کند، **بخش ۲-۳-۳** مجموعه‌ی زنده و محدوده‌ی مجاز استفاده از آن را، و **بخش ۳-۳-۳** تحلیل اکتشافی‌ای را که تصمیم‌های روش‌شناختی بخش‌های بعدی از آن برمی‌خیزد.

۱-۳-۳ مجموعه‌داده بنچمارک EPEX-DE

ساختار و دامنه

داده‌ی اصلی این پژوهش، سری ساعتی قیمت بازار روز-پیش آلمان در بورس EPEX است، که در قالب مجموعه‌داده‌ی باز لاگو و همکاران و همراه با پروتکل ارزیابی آن منتشر شده است [۱]. انتخاب این مجموعه به‌جای گردآوری مستقل داده، یک تصمیم روش‌شناختی است: تنها در این حالت است که اعداد فصل چهارم را می‌توان مستقیماً و بدون هیچ ابهام تعریفی در کنار اعداد منتشرشده‌ی مرجع نشان داد. مجموعه از ۹ ژانویه ۲۰۱۲ تا ۳۱ دسامبر ۲۰۱۷ را پوشش می‌دهد و شامل 52,416 سطر ساعتی است. هر سطر سه متغیر دارد:

• price — قیمت تسویه‌ی ساعتی بازار روز-پیش، به یورو بر مگاوات-ساعت؛ متغیر هدف پژوهش.

• exog_1 — پیش‌بینی روزپیش بار مصرفی برای ناحیه‌ی کنترلی Amprion.

• exog_2 — پیش‌بینی روزپیش تولید بادی و خورشیدی.

هر دو متغیر برون‌زا پیش‌بینی هستند و نه مقدار محقق‌شده، و پیش از حراج روز-پیش منتشر می‌شوند. این نکته صرفاً توصیفی نیست؛ مبنای مجاز بودن استفاده از مقادیر خودِ روز هدف این دو متغیر در ماتریس ویژگی است، که **بخش ۴-۳** آن را به تفصیل توجیه می‌کند.

نام ناحیه‌ای متغیر نخست را باید به‌خاطر سپرد. $exog_1$ بار ناحیه‌ی Amprion است و نه بار ملی آلمان — تمایزی که در دوره‌ی بنچمارک هیچ اثری ندارد، چون آموزش و آزمون هر دو روی همان تعریف انجام می‌شوند، اما در آزمون برون‌توزیعی **بخش ۵-۲** به هسته‌ی اصلی یافته بدل می‌شود.

تقسیم آموزش و آزمون

تقسیم داده مطابق پروتکل مرجع انجام می‌شود: دو سال پایانی به‌طور کامل به‌عنوان دوره‌ی آزمون کنار گذاشته می‌شود. دوره‌ی آزمون از ۴ ژانویه‌ی ۲۰۱۶ تا ۳۱ دسامبر ۲۰۱۷ ادامه دارد و شامل ۷۲۸ مبدأ پیش‌بینی و ۱۷,۴۷۲ ساعت است؛ دوره‌ی آموزش ۳۴,۹۴۴ ساعت (۱,۴۵۶ روز) پیش از آن را در بر می‌گیرد.

این کنارگذاری کامل است. هیچ مشاهده‌ای از دوره‌ی آزمون در برازش مدل‌ها، در تنظیم ابرپارامترها، در برازش وزن‌های مدل ترکیبی و در تعیین آستانه‌ی رژیم نقشی ندارد. پنجره‌ی تنظیم ابرپارامتر (۵ ژانویه‌ی ۲۰۱۵ تا ۳ ژانویه‌ی ۲۰۱۶) و پنجره‌ی برازش وزن‌ها (۱۲ ژانویه‌ی ۲۰۱۵ تا ۳ ژانویه‌ی ۲۰۱۶) هر دو اکیداً پیش از آغاز دوره‌ی آزمون پایان می‌یابند، و این قید در کد با یک تابع تصریحی اعمال می‌شود، نه صرفاً رعایت می‌گردد (**بخش ۳-۵**).

آمار توصیفی قیمت

میانگین قیمت در کل دوره ۳۴.۶۸ یورو بر مگاوات‌ساعت با انحراف معیار ۱۵.۹۴ است، و میانه ۳۳.۴۵ — یعنی توزیع در ناحیه‌ی مرکزی تقریباً متقارن است. اما دنباله‌های آن چنین نیستند: کمینه منفی ۲۲۱.۹۹ و بیشینه ۲۱۰.۰۰ یورو بر مگاوات‌ساعت است، چولگی منفی ۰.۵۲ و کشیدگی ۱۶.۲۷. کشیدگی بسیار بالا در کنار چولگی منفی، تصویر روشنی می‌دهد: سری بیشتر وقت‌ها آرام است و گاه با جهش‌های شدید — به‌ویژه رو به پایین و تا ناحیه‌ی منفی — از آن آرامش خارج می‌شود.

قیمت‌های منفی در این بازار پدیده‌ای واقعی‌اند و نه خطای داده: ۵۳۸ ساعت از کل دوره (۱.۰۳ درصد) قیمت منفی دارند، که ۲۹۷ ساعت آن در دوره‌ی آموزش و ۲۴۱ ساعت در دوره‌ی آزمون قرار می‌گیرد. نسبت آن‌ها در دوره‌ی آزمون بیشتر است (۱.۳۸ در برابر ۰.۸۵ درصد)، یعنی پدیده در طول دوره تشدید می‌شود. ادبیات نیز همین ویژگی‌ها — نوسان شدید، جهش‌های ناگهانی و ناهمگنی واریانس — را از خصوصیات ذاتی سری قیمت برق برمی‌شمارد [۳].

وجود قیمت منفی یک پیامد مستقیم بر انتخاب معیار دارد: هر معیاری که بر خود قیمت تقسیم کند، در همسایگی صفر تعریف‌ناپذیر یا انفجاری می‌شود. **بخش ۳-۵** بر همین پایه MAPE را کنار می‌گذارد.

سطح قیمت در طول دوره ثابت نمی ماند. میانگین سالانه از 42.89 در سال ۲۰۱۲ به 37.78 در ۲۰۱۳، 32.76 در ۲۰۱۴، 31.63 در ۲۰۱۵ و 28.98 در ۲۰۱۶ کاهش می یابد و آنگاه در ۲۰۱۷ به 34.20 بازمی گردد. این روند نزولی و بازگشت آن، همان چیزی است که فرض ایستایی در صورت قوی خود را رد می کند (بخش ۲-۳) و واسنجی مجدد روزانه را ضروری می سازد.

کیفیت و بازتولیدپذیری

مجموعه‌ی داده کامل است: هیچ مقدار گم شده‌ای در هیچ یک از سه ستون وجود ندارد و هیچ برچسب زمانی تکراری نیست. این وضعیت با اسکرپت واریس مستقلی راستی آزمایی می شود که پیش از هر اجرای نتایج، ابعاد، بازه‌ی زمانی و پیوستگی نمایه‌ی ساعتی را می سنجد.

بازتولیدپذیری در این پژوهش با یک قاعده‌ی سخت اداره می شود: داده‌ی بیرونی یکبار دریافت و در یک تصویر ثابت با اثر انگشت sha256 ثبت می شود، در مخزن پروژه نگهداری می گردد، و از آن پس تنها از همان جا خوانده می شود. علت این سخت گیری آن است که یک واسط برنامه نویسی زنده فردا ممکن است پاسخ دیگری بدهد و این کار را در سکوت انجام دهد؛ آنگاه نتایج منتشر شده دیگر بازتولیدپذیر نیستند بی آنکه کسی متوجه شود. دریافت مجدد این مجموعه در ۲۹ اوت ۲۰۲۶ بایت به بایت با تصویر ثبت شده یکسان بود.

افزون بر آن، کد مهندسی ویژگی از دسترسی به شبکه منع شده است و این منع با آزمون خودکار اعمال می شود، نه با قرارداد. توضیح این سازوکار در بخش ۳-۴ آمده است.

۲-۳-۳ داده زنده Energy-Charts

دامنه مجاز استفاده

مجموعه‌ی دوم این پژوهش از سامانه‌ی Energy-Charts مؤسسه‌ی Fraunhofer ISE دریافت شده است. کاربرد آن به صراحت محدود است و این محدودیت باید پیش از هر توصیفی ثبت شود: این داده تنها در آزمون برون توزیعی بخش ۲-۵ و در ابزار عملیاتی بخش ۳-۵ به کار می رود، و هیچ عددی از آن وارد جدول های نتایج فصل چهارم نمی شود.

دلیل این تفکیک، حفظ هم مقیاسی مقایسه است. تمام ادعاهای دقت فصل چهارم در برابر اعداد منتشر شده‌ی مرجع سنجیده می شوند و این سنجش تنها بر همان مجموعه داده، همان دوره و همان تعریف متغیرها معنا دارد. آمیختن دو منبع، مقایسه را در سکوت بی اعتبار می کرد.

مشخصات

داده از ناحیه‌ی پیشنهاددهی DE-LU گرفته شده و ۱۷۳ روز کامل سال ۲۰۲۶، معادل 4,343 سطر ساعتی و بدون جافتادگی، را پوشش می‌دهد. واسط برنامه‌نویسی این سامانه بدون کلید و بدون ثبت نام در دسترس است، که آن را با قاعده‌ی بازتولیدپذیری پژوهش سازگار می‌کند. داده‌های اخیر با تفکیک پانزده دقیقه‌ای عرضه می‌شوند و در بارگذار پروژه به تفکیک ساعتی تجمیع می‌گردند تا با شمای مشترک دو مجموعه هم‌شکل شوند.

یک ناپیوستگی تعریفی در سطح ناحیه نیز شایان ذکر است: ناحیه‌ی پیشنهاددهی پیش از یکم اکتبر ۲۰۱۸ DE-AT-LU بوده و پس از آن به DE-LU تفکیک شده است. دوره‌ی بنچمارک پیش از این تفکیک و دوره‌ی زنده پس از آن قرار می‌گیرد.

انتشار این داده تحت پروانه‌ی CC BY 4.0 است و اسناد آن، ذکر منبع را الزامی می‌کند. عبارت ارجاع، به شکلی که پروانه اقتضا می‌کند، چنین است:

Data: Energy-Charts (Fraunhofer ISE) / Bundesnetzagentur SMARD.de, CC BY 4.0

یک ناهم‌خوانی تعریفی که باید همین‌جا ثبت شود

میان این مجموعه و مجموعه‌ی بنچمارک دو ناهم‌خوانی وجود دارد که خواننده باید پیش از رسیدن به نتایج فصل پنجم از آن‌ها آگاه باشد. ثبت کردن آن‌ها در همین‌جا — یعنی پیش از آنکه نتیجه‌ای گزارش شود — تصمیمی آگاهانه است: این ناهم‌خوانی سازوکار اصلی یافته‌ی منفی **بخش ۵-۲** است، و اگر تنها در کنار همان نتیجه معرفی شود، شبیه توجیه پس از وقوع به نظر می‌رسد.

ناهم‌خوانی نخست جغرافیایی است. متغیر برون‌زای بار در دوره‌ی آموزش پیش‌بینی بار ناحیه‌ی کنترلی Amprion است، حال آنکه در دوره‌ی سرویس‌دهی پیش‌بینی بار ملی آلمان دریافت می‌شود. سهم Amprion از بار آلمان حدود چهل درصد است، پس دو سری زیر یک نام در دو مقیاس متفاوت قرار می‌گیرند. اندازه‌ی دقیق این اختلاف و پیامد آن برای هر مدل در **بخش ۵-۲** سنجیده و گزارش می‌شود. ناهم‌خوانی دوم در دامنه‌ی متغیرهاست. سطح قیمت در سال ۲۰۲۶ به مراتب بالاتر از دوره‌ی بنچمارک است و بازه‌ی نوسان آن نیز گسترده‌تر؛ یعنی مدل‌ها در دوره‌ی سرویس‌دهی با مقادیری روبه‌رو می‌شوند که در دوره‌ی آموزش نظیری نداشته‌اند.

هیچ‌یک از این دو، آزمون برون‌توزیعی را بی‌اعتبار نمی‌کند؛ اما هر دو معنای آن را تغییر می‌دهند. آن آزمون، ترکیبی از تغییر واقعی بازار و ناهم‌خوانی مسیر داده‌ی خود ما را می‌سنجد، و **بخش ۵-۲** این

دو را تا آنجا که سنجش اجازه می‌دهد از هم تفکیک می‌کند.


بازتولیدپذیری و اسناد

همان قاعده‌ی تصویر ثابت که در بخش ۱-۳-۳ برای مجموعه‌ی بنچمارک شرح داده شد، بر این مجموعه نیز حاکم است: پنجره‌ی ۱۷۳ روزه یک‌بار دریافت، با اثر انگشت sha256 ثبت و در مخزن نگهداری شده است، و ارزیابی‌های بخش ۲-۵ تنها از همان تصویر خوانده می‌شوند. بدون این قید، آزمون برون‌توزیعی با هر بار اجرا عدد دیگری می‌داد و هیچ‌یک از آن اعداد قابل استناد نبود.

۳-۳-۳ تحلیل اکتشافی داده

هدف این بخش توصیف داده به‌خاطر خود توصیف نیست. هر یک از شش الگوی زیر، تصمیمی روش‌شناختی را در بخش‌های بعدی توجیه می‌کند، و همین پیوند است که تحلیل اکتشافی را از یک ضمیمه‌ی تشریفاتی جدا می‌سازد.

توزیع قیمت




شکل ۱-۳: توزیع قیمت‌های ساعتی بازار روز-پیش EPEX-DE در دوره‌ی ۲۰۱۲ تا ۲۰۱۷، شامل ناحیه‌ی قیمت‌های منفی.

شکل ۱-۳: توزیع قیمت‌های ساعتی را نشان می‌دهد. توده‌ی اصلی توزیع در بازه‌ی تقریبی ۲۰ تا ۵۰ یورو بر مگاوات‌ساعت متمرکز است، اما دنباله‌ی چپ تا ناحیه‌ی منفی امتداد می‌یابد و دنباله‌ی راست تا بیش از دو برابر میانگین کشیدگی ۱۶.۲۷ در برابر مقدار سه برای توزیع نرمال، سنج‌های عددی از همین دنباله‌های سنگین است.


قیمت‌های منفی — ۵۳۸ ساعت، معادل ۱.۰۳ درصد کل دوره — پیامد ساختاری نفوذ بالای

تجدیدپذیرها هستند و نه نوفه‌ی داده [۴]. این ویژگی دو پیامد روش‌شناختی دارد که در بخش ۳-۵ به آن‌ها بازمی‌گردیم: کنارگذاشتن MAPE، و انتخاب معیارهایی که به علامت مخرج حساس نباشند.

فصلی‌بودن چندگانه




شکل ۳-۲: نیم‌رخ درون‌روزی قیمت: میانگین قیمت به تفکیک ساعت شبانه‌روز.



شکل ۳-۳: نیم‌رخ هفتگی قیمت: میانگین قیمت به تفکیک روز هفته.

سری قیمت برق هم‌زمان در سه مقیاس فصلی است، و شکل‌های ۲-۳ تا ۴-۳ هر سه را نشان می‌دهند. این چندلایگی از خصوصیات شناخته‌شده‌ی این سری است [۲].

در مقیاس شبانه‌روزی، میانگین قیمت از کمینه‌ی ۲۲.۷۸ در ساعت سه بامداد تا بیشینه‌ی ۴۶.۰۱ در ساعت نوزده نوسان می‌کند — یعنی بیش از دو برابر. الگو دو قله دارد: یک قله‌ی صبحگاهی حوالی ساعت هشت (۴۲.۲۰) و قله‌ی اصلی عصرگاهی. همین دامنه‌ی وسیع، دلیل تصمیمی است که در بخش‌های ۳-۶ و ۳-۷ تکرار می‌شود: به جای یک مدل واحد برای همه‌ی ساعت‌ها، به‌ازای هر ساعت شبانه‌روز یک مدل مستقل برازش می‌شود، چون رفتار آماری ساعت سه بامداد و ساعت نوزده یکی نیست.




شکل ۳-۴: نیم‌رخ سالانه‌ی قیمت در سراسر دوره‌ی مطالعه.

در مقیاس هفتگی، تفاوت میان روزهای کاری و تعطیل چشمگیر است: میانگین یکشنبه 23.33 و شنبه 30.08 در برابر 38.70 برای سه‌شنبه، پرقیمت‌ترین روز هفته. این شکاف، هم متغیرهای مجازی روز هفته در ماتریس ویژگی (بخش ۳-۴) و هم قاعده‌ی رفتاری مدل ساده‌ی مرجع را توجیه می‌کند؛ آن قاعده برای دوشنبه به آخرین روز کاری و برای تعطیلات به هم‌تای هفته‌ی پیشین ارجاع می‌دهد، دقیقاً چون میانگین یکشنبه از میانگین دوشنبه بسیار دور است.

در مقیاس سالانه، روند نزولی ۲۰۱۲ تا ۲۰۱۶ و بازگشت سال ۲۰۱۷ که در بخش ۳-۳-۱ گزارش شد، در شکل ۳-۴ دیده می‌شود.

خوشه‌بندی نوسان و مقادیر حدی




شکل ۳-۵: خوشه‌بندی نوسان: دوره‌های آرام و پرتلاطم به‌صورت خوشه‌ای در زمان کنار هم می‌نشینند.

شکل ۳-۵ خوشه‌بندی نوسان را نشان می‌دهد: دوره‌های آرام و دوره‌های پرتلاطم به‌صورت خوشه‌ای کنار هم می‌نشینند و به‌طور تصادفی در زمان پراکنده نیستند. این ناهمگنی واریانس، ویژگی شناخته‌شده‌ی سری قیمت برق است [۳].

این مشاهده مستقیماً به بخش ۳-۸ راه می‌برد. اگر رفتار بازار میان دوره‌های آرام و پرتنش به‌قدر کافی متفاوت باشد، مجموعه‌ی وزنی که در حالت آرام بهینه است لزوماً در حالت پرتنش بهینه نیست — و همین، منطقِ وزن‌دهیِ گروهیِ رژیم‌محور است. تعریف عملیاتیِ دو رژیم و آستانه‌ی تفکیک آن‌ها در بخش ۳-۸ می‌آید، نه اینجا: آستانه بر پایه‌ی داده‌ی اعتبارسنجی و با قاعده‌ای تصریح‌شده تعیین می‌شود، و استخراج آن از یک نمودار اکتشافی همان انتخابِ درون‌نمونه‌ای است که پژوهش از آن پرهیز می‌کند.

ساختار خودهمبستگی



شکل ۳-۶: توابع خودهمبستگی و خودهمبستگی جزئی سری قیمت ساعتی.

شکل ۳-۶ توابع خودهمبستگی (ACF)^۱ و خودهمبستگی جزئی (PACF)^۲ را نشان می‌دهد. خودهمبستگی در وقفه‌ی یک ساعت 0.9337، در وقفه‌ی ۲۴ ساعت 0.6598 و در وقفه‌ی ۱۶۸ ساعت (یک هفته) 0.5855 است.


قله‌های آشکار در وقفه‌های ۲۴ و ۱۶۸ ساعت، دو دوره‌ی تناوبِ روزانه و هفتگی را تأیید می‌کنند و مبنای دو تصمیم‌اند. نخست، انتخاب وقفه‌های قیمتی ماتریس ویژگی — روزهای D-1، D-2، D-3 و D-7 — که همان قرارداد مرجع است [۱] و اینجا شاهد تجربی خود را در داده می‌یابد. دوم، انتخاب مرتبه‌ی فصلی هفت‌روزه برای مدل SARIMAX در بخش ۳-۶: بُعد شبانه‌روزی پیشاپیش با تفکیک

^۱ Autocorrelation Function

^۲ Partial Autocorrelation Function

۲۴ گانه‌ی مدل‌ها جذب شده است، پس آنچه برای مؤلفه‌ی فصلی باقی می‌ماند تناوب هفتگی است.

متغیرهای برون‌زا



شکل ۳-۷: همبستگی قیمت با دو متغیر برون‌زا: پیش‌بینی روزپیش بار و پیش‌بینی روزپیش تولید بادی و خورشیدی.




شکل ۳-۸: همبستگی غلتان قیمت با متغیرهای برون‌زا در طول زمان؛ شدت رابطه ثابت نمی‌ماند.

شکل ۳-۷ رابطه‌ی قیمت با دو متغیر برون‌زا را نشان می‌دهد و علامت‌ها همان است که نظریه‌ی دستور تولید انتظار دارد. همبستگی قیمت با پیش‌بینی بار مثبت و برابر 0.6109 است؛ تقاضای بیشتر، واحدهای گران‌تر را وارد مدار می‌کند. همبستگی آن با پیش‌بینی تولید بادی و خورشیدی منفی و برابر 0.3885 است؛ تولید تجدیدپذیر با هزینه‌ی نهایی نزدیک به صفر، منحنی عرضه را به سمت راست می‌راند و قیمت تسویه را پایین می‌آورد.


شکل ۳-۸ همین همبستگی‌ها را به صورت غلتان در طول زمان نشان می‌دهد و روشن می‌کند که شدت آن‌ها ثابت نیست. این ناپایداری رابطه، یکی از دلایلی است که واسنجی مجدد روزانه را ضروری می‌کند؛ ضرایبی که بر داده‌ی سال ۲۰۱۳ برازش شده‌اند، برای سال ۲۰۱۷ همان ضرایب درست نیستند.

شکست‌های ساختاری و سری روزانه

شکل ۳-۹ کل سری را همراه با شکست‌های ساختاری آن نشان می‌دهد. وجود این شکست‌ها، تصمیم استفاده از پنجره‌ی واسنجی غلتان ۹۲ روزه به جای آموزش بر کل تاریخچه را توجیه می‌کند؛ پنجره‌ی



شکل ۳-۹: کل سری قیمت ساعتی به همراه شکست‌های ساختاری شناسایی شده.



شکل ۳-۱۰: سری بار پایه‌ی روزانه: میانگین ۲۴ قیمت ساعتی هر روز.

غلطان، داده‌ی کهنه‌ی متعلق به رژیم‌های پیشین بازار را به تدریج کنار می‌گذارد.

شکل ۳-۱۰ سری بار پایه‌ی روزانه — یعنی میانگین ۲۴ قیمت ساعتی هر روز — را نشان می‌دهد. این سری ۲,۱۸۴ روز دارد، با میانگین ۳۴.۶۸، انحراف معیار ۱۱.۹۷، کمینه‌ی منفی ۵۶.۸۷ و بیشینه‌ی ۱۰۱.۹۲. انحراف معیار آن به روشنی کمتر از انحراف معیار سری ساعتی (۱۵.۹۴) است، چون میانگین‌گیری بخشی از نوسان درون‌روزی را حذف می‌کند.

همین کاهش نوسان، پرسش پژوهشی چهارم را می‌سازد. اگر هدف روزانه ذاتاً هموارتر از هدف ساعتی است، آیا بهتر است آن را مستقیماً مدل کرد، یا از میانگین‌گیری ۲۴ پیش‌بینی ساعتی به دست آورد؟ هر دو مسیر در این پژوهش ساخته و در بخش ۴-۴ با هم سنجیده می‌شوند.

۴-۳ مهندسی ویژگی

تنظیم مسئله

صورت‌بندی مسئله در این پژوهش چنین است: در مبدأ پیش‌بینی، یعنی روز O و پیش از بسته‌شدن حراج روز-پیش، هر بیست و چهار قیمت ساعتی روز $O+1$ پیش‌بینی می‌شود. خروجی هر مدل یک بردار ۲۴ مؤلفه‌ای است و نه یک عدد؛ همین انتخاب، افق پیش‌بینی را با ساختار واقعی حراج هم‌شکل می‌کند،

چون در بازار روز-پیش نیز هر بیست و چهار ساعت به صورت یک جا و در یک حراج تسویه می شوند. ماتریس ویژگی حاصل ۲۱۷۷ سطر و ۲۴۷ ستون دارد. هر سطر یک روز هدف است و هر ستون یک ویژگی. این ماتریس، منبع یکتای ویژگی برای هر پنج مدل پژوهش است: مدل ساده، SARIMAX، LEAR-LASSO، LightGBM و LSTM همگی از همین ماتریس تغذیه می شوند و هیچ یک مسیر ویژگی سازی اختصاصی ندارد.

این یکتایی، تصمیمی روش شناختی است و نه سهولت مهندسی. اگر هر مدل ماتریس خودش را می ساخت، دو هزینه پدید می آمد. نخست، هر مسیر تازه سطح تازه ای برای نشت اطلاعات می گشود که آزمون های این بخش آن را پوشش نمی دادند. دوم، و مهم تر، بخشی از اختلاف دقت فصل چهارم دیگر به خود مدل نسبت دادنی نبود؛ می توانست از تفاوت در ورودی برخاسته باشد. مقایسه ی منصفانه ایجاب می کند که تنها یک متغیر میان مدل ها تغییر کند، و آن متغیر خود مدل باشد.

قید علی: خط قرمز پژوهش

قاعده ی حاکم بر کل این بخش یک جمله است: هیچ ویژگی ای نباید از اطلاعات پس از مبدأ پیش بینی استفاده کند.

نقض این قاعده، شایع ترین و مخرب ترین خطای این حوزه است، چون بی سروصدا رخ می دهد. مدلی که یک ستون آلوده دریافت کرده باشد، بدون هیچ خطا یا هشدار آموزش می بیند، اعداد دقت چشمگیری تولید می کند، و آن اعداد در عمل بی معنا هستند. تفاوت میان یک پژوهش معتبر و یک پژوهش بی اعتبار در این حوزه، اغلب یک ستون است.

به همین دلیل این قاعده در پروژه به صورت قرارداد رعایت نمی شود، بلکه با دو سازوکار اجرایی اعمال می گردد.

سازوکار نخست: اعلان تصریحی در دسترس بودن. هر ستون ماتریس ویژگی باید در یک سامانه ی ثبت، منبع خود و میزان وقفه اش نسبت به روز هدف را اعلام کند. سپس تابعی تصریحی کل مجموعه ی ستون ها را می پیماید و در صورت یافتن ستونی که اعلان نشده باشد، یا ستونی که اعلانش با نامش نخواند، اجرا را با خطا متوقف می کند. نکته ی طراحی مهم آنکه حالت پیش فرض این واریسی سخت گیرانه است: ستونی که فراموش شده اعلام شود، مجاز فرض نمی شود، بلکه مردود است. سامانه ای که ستون ناشناخته را در سکوت بپذیرد، دقیقاً همان چیزی است که باید از آن محافظت کند.

سازوکار دوم: آزمون خودکار. یک آزمون در مجموعه ی آزمون های پروژه، این ادعا را بر ماتریس

واقعی و با پیکربندی واقعی می‌سنگد، نه بر نمونه‌ای ساختگی. آزمون دومی نیز دسترسی کد مهندسی ویژگی به شبکه را ممنوع می‌کند. علت آن، هم بازتولیدپذیری است و هم همین قید علی: کدی که بتواند در زمان ساخت ویژگی به یک واسط زنده وصل شود، می‌تواند مقداری متأخرتر از مبدأ پیش‌بینی را دریافت کند، بی‌آنکه در متن برنامه چیزی به آن اشاره کند.

چهار خانواده ویژگی

مجموعه‌ی ویژگی‌ها عیناً از قرارداد مدل مرجع LEAR پیروی می‌کند [۱، ۱۹]. این پیروی، انتخابی آگاهانه و محدودکننده است: می‌شد مجموعه‌ی غنی‌تری ساخت، اما آنگاه مقایسه‌ی فصل چهارم با اعداد منتشرشده دیگر هم‌مقیاس نبود و هر تفاوتی در دقت را می‌شد به تفاوت در ورودی نسبت داد، نه به مدل. ساختار ۲۴۷ ستون به شرح زیر است.

وقفه‌های قیمت (۹۶ ستون)

بردار کامل ۲۴ ساعته‌ی قیمت برای چهار روز گذشته نسبت به روز هدف: D-1، D-2، D-3 و D-7. چهار روز ضربدر ۲۴ ساعت، ۹۶ ستون می‌شود. انتخاب همین چهار وقفه — و نه مثلاً پنج یا ده — دو توجیه دارد که یکدیگر را تقویت می‌کنند. توجیه نخست، هم‌ارزی با قرارداد مرجع است. توجیه دوم تجربی است و در بخش ۳-۳-۳ نشان داده شد: تابع خودهمبستگی قلّه‌های آشکاری در وقفه‌های ۲۴ و ۱۶۸ ساعت دارد (به ترتیب 0.6598 و 0.5855)، یعنی روز پیشین و همان روز در هفته‌ی پیشین بیشترین اطلاع را درباره‌ی روز هدف دارند. وقفه‌های D-2 و D-3 فاصله‌ی میان این دو را پر می‌کنند و برای دوشنبه‌ها نقش ویژه دارند، چون آخرین روز کاری پیش از دوشنبه، جمعه است.

وقفه‌های متغیرهای برون‌زا (۹۶ ستون)

بردار ۲۴ ساعته‌ی دو متغیر برون‌زا — پیش‌بینی بار و پیش‌بینی تولید بادی و خورشیدی — برای دو وقفه‌ی D-1 و D-7. دو متغیر ضربدر دو وقفه ضربدر ۲۴ ساعت، ۹۶ ستون.

متغیرهای برون‌زای خودِ روز هدف (۴۸ ستون)

دو متغیر برون‌زا برای خودِ روز هدف، یعنی روزی که قیمتش هنوز پیش‌بینی نشده است. دو متغیر ضربدر ۲۴ ساعت، ۴۸ ستون.

این خانواده تنها جایی است که ماتریس ویژگی مقداری از روز هدف را در بر می‌گیرد، و بنابراین تنها جایی است که خواننده حق دارد از نشت اطلاعات بپرسد. پاسخ در ماهیت این دو سری است و باید صریح گفته شود.

exog_1 و exog_2 مقدار محقق‌شده‌ی بار و تولید تجدیدپذیر نیستند؛ پیش‌بینی روزپیش آن‌ها هستند، که بهره‌بردار شبکه پیش از بسته‌شدن حراج روز-پیش منتشر می‌کند. یعنی در مبدأ پیش‌بینی، این اعداد پیشاپیش منتشر شده و در دسترس هر شرکت‌کننده‌ی بازار هستند. استفاده از آن‌ها نه تنها نشت نیست، بلکه بازتاب همان اطلاعاتی است که یک معامله‌گر واقعی در همان لحظه در اختیار دارد. مدلی که آن‌ها را نادیده بگیرد، از اطلاعات مجاز در دسترس استفاده نکرده است.

تمایز کلیدی میان «مقدار محقق‌شده‌ی روز هدف» و «پیش‌بینی منتشرشده‌ی روز هدف» است. اولی نشت است، دومی نیست. سامانه‌ی اعلان در دسترس بودن نیز همین تمایز را رمزگذاری می‌کند: این ستون‌ها با وقفه‌ی صفر اما با منبع «پیش‌بینی منتشرشده» اعلام می‌شوند، و ستونی که مقدار محقق‌شده با وقفه‌ی صفر اعلام کند، مردود می‌شود.

متغیرهای مجازی روز هفته (۷ ستون)

هفت متغیر مجازی دودویی برای روز هفته‌ی روز هدف. **بخش ۳-۳-۳** شکاف بزرگی میان روزهای هفته نشان داد — میانگین یکشنبه 23.33 در برابر 38.70 برای سه‌شنبه — که وجود این ستون‌ها را توجیه می‌کند. با این‌همه، تحلیل تفسیرپذیری **بخش ۴-۶** نشان خواهد داد که سهم آن‌ها در حضور وقفه‌های قیمتی ناچیز است؛ یعنی اطلاعات روز هفته پیشاپیش در خود قیمت‌های گذشته رمزگذاری شده است. جمع چهار خانواده: ۹۶ به‌علاوه‌ی ۹۶ به‌علاوه‌ی ۴۸ به‌علاوه‌ی ۷ برابر ۲۴۷ ستون. این تطابق عددی با فرمول ویژگی خود کتابخانه‌ی مرجع، در کد راستی‌آزمایی می‌شود و صرفاً ادعا نمی‌شود.

آنچه عمداً در مجموعه ویژگی نیست

چند متغیر که ادبیات آن‌ها را مؤثر می‌داند در این ماتریس نیستند، و تصریح دلیل آن، بخشی از صداقت روش‌شناختی این پژوهش است.

قیمت سوخت. پژوهش‌ها نشان داده‌اند که قیمت حامل‌های انرژی از عوامل تعیین‌کننده‌ی قیمت برق است و لحاظ‌کردن آن می‌تواند دقت را بهبود دهد [۵، ۳۷]. با این‌حال، سری‌های مرجع گاز و زغال‌سنگ تجاری و دارای مجوزند و در چارچوب بازتولیدپذیری این پژوهش قابل استفاده نبودند؛

منابعی هم که سری‌های مشتق‌شده از آن‌ها را بازنشر می‌کنند، در این پژوهش به‌عنوان مرجع استناد به کار می‌روند و نه به‌عنوان منبع داده. پیامد مستقیم این محدودیت آن است که شاخص‌های حاشیه‌ی سوخت — مانند اسپرد تمیز — در این پایان‌نامه ساختنی نبودند.

هواشناسی و جریان‌های مرزی. این دو نیز عمداً کنار گذاشته شده‌اند، اما به دلیل متفاوتی افزودن آن‌ها هم‌مقیاسی مقایسه با اعداد منتشرشده‌ی مرجع را از میان می‌برد. این تصمیم، مبادله‌ای آگاهانه است و نه غفلت. پژوهش، دقت ممکن را در ازای امکان مقایسه‌ی معتبر محدود کرده است، و **بخش ۴-۵** افزودن این متغیرها را به‌عنوان مسیر طبیعی پژوهش‌های آینده پیشنهاد می‌کند.

ساختار کد این امکان را حفظ کرده است: بلوک‌های ویژگی فیزیکی به‌صورت افزودنی و به‌طور پیش‌فرض خاموش پیاده‌سازی شده‌اند، به‌طوری‌که مسیر پیش‌فرض ساخت ویژگی دقیقاً همان مجموعه‌ی ۲۴۷ ستونی است که نتایج تثبیت‌شده‌ی فصل چهارم از آن تولید شده‌اند. بلوکی که به داده‌ی ثبت‌نام‌محور نیاز دارد نیز، به‌جای جایگزین کردن یک سری تقریبی، با خطا متوقف می‌شود؛ یعنی نبود داده در سکوت به یک عدد ساختگی بدل نمی‌گردد.

هدف روزانه

افزون بر هدف ساعتی، پژوهش هدف دومی نیز دارد: میانگین بار پایه‌ی روزانه، یعنی میانگین ۲۴ قیمت ساعتی هر روز. این هدف از دو مسیر متفاوت ساخته می‌شود، و همین دوگانگی است که پرسش پژوهشی چهارم را پاسخ می‌دهد.

مسیر نخست، مدل‌سازی مستقیم است: هدف روزانه به‌عنوان یک متغیر تک‌مؤلفه‌ای تعریف و مدل مستقیماً بر آن برازش می‌شود. مسیر دوم، تجمیع است: مدل ساعتی پیش‌بینی خود را تولید می‌کند و سپس از ۲۴ مؤلفه‌ی آن میانگین گرفته می‌شود.

برای آنکه مقایسه‌ی این دو مسیر معنادار بماند، هر دو از همان ماتریس ویژگی، همان مبادی پیش‌بینی و همان بودجه‌ی تنظیم ابرپارامتر استفاده می‌کنند. اگر مسیر مستقیم بودجه‌ی تنظیم کمتری می‌گرفت، هر برتری مسیر تجمیعی می‌توانست صرفاً بازتاب همان نابرابری باشد. برابری بودجه، همان چیزی است که مقایسه‌ی **بخش ۴-۴** را از یک مصنوع طراحی مصون می‌دارد.

۳-۵ چارچوب اعتبارسنجی و معیارهای ارزیابی

اعتبارسنجی پیش‌رونده

در پیش‌بینی قیمت برق، ترتیب زمانی داده‌ها خود اطلاعات است. هر شکلی از تقسیم تصادفی داده به مجموعه‌های آموزش و آزمون، اطلاعات آینده را به گذشته نشت می‌دهد و خطای مدل را به‌صورتی غیرواقع‌بینانه کم برآورد می‌کند. از این رو در این پژوهش، مطابق پروتکل مرجع لاگو و همکاران [۱]، منحصرأ از اعتبارسنجی پیش‌رونده با مبدأ غلتان استفاده شده است.

سازوکار چنین است: برای هر مبدأ پیش‌بینی، یعنی روز D، مدل تنها بر پنجره‌ی واسنجی انتهایی شامل ۱۰۹۲ روز متوالی منتهی به روز پیش از مبدأ آموزش می‌بیند و بردار ۲۴ مؤلفه‌ای قیمت‌های ساعتی روز D+1 را پیش‌بینی می‌کند؛ سپس مبدأ یک روز جلو می‌رود و کل فرایند تکرار می‌شود. طول پنجره‌ی واسنجی — ۱۰۹۲ روز، معادل سه سال ۳۶۴ روزه — مقدار پیش‌فرض خود پیاده‌سازی مرجع است و نه انتخابی از سوی نگارنده؛ همین هم‌ارزی دقیق با پروتکل منتشرشده، مبنای منصفانه‌بودن مقایسه‌ی فصل چهارم با اعداد مرجع است.

دوره‌ی آزمون، مطابق همان مرجع، دو سال کامل ۲۰۱۶ و ۲۰۱۷ است: ۷۲۸ مبدأ پیش‌بینی و 17,472 ساعت به‌ازای هر مدل.

جداسازی سخت‌گیرانه‌ی پنجره‌ی اعتبارسنجی از آزمون

برای تنظیم ابرپارامترها (۵۰ آزمایش Optuna به‌ازای هر مدل؛ بخش ۳-۷) پنجره‌ی ۳۶۴ روزه از انتهای داده‌ی آموزش جدا می‌شود. قید بنیادین آن است که این پنجره اکیداً پیش از آغاز دوره‌ی آزمون پایان یابد.

این قید صرفاً یک قرارداد نیست. در کد با تابعی تصریحی اعمال می‌شود که در صورت هر تخطی — از جمله پنجره‌ی تهی، که قابل راستی‌آزمایی نیست — اجرای برنامه را متوقف می‌کند. آزمون یکپارچه‌ای نیز با مقادیر واقعی پیکربندی می‌سجد که حتی یک روز از دوره‌ی آزمون در پنجره‌ی آموزش نخستین مبدأ حضور نداشته باشد. بدین ترتیب ادعای «اعتبارسنجی اکیداً پیش از آزمون» در این پایان‌نامه ادعایی آزموده است، نه فرضی ضمنی.

سه مصنوع مدل، و اینکه کدام عددی را تولید می کند

مخزن این پژوهش سه دسته مصنوع مدل نگه می دارد که کاربرشان کاملاً متفاوت است. چون یکی از آن ها بر پنجره ای آموزش دیده که دوره ی آزمون را در بر می گیرد، تفکیک آن ها باید پیش از هر عدد دقتی و به صراحت انجام شود؛ در غیر این صورت خواننده حق دارد نشت اطلاعات را فرض بگیرد.

یکم: مدل های چارچوب پیش رونده — تنها منبع اعداد فصل چهارم. در این چارچوب، به ازای هر یک از ۷۲۸ مبدأ، مدل بر پنجره ی ۱۰۹۲ روزه ای برازش می شود که اکیداً پیش از همان مبدأ پایان می یابد، و تنها روز بعد از آن را پیش بینی می کند. تمام معیارهای دقت و تمام آزمون های معناداری فصل چهارم از همین مسیر می آیند. هیچ عدد گزارش شده ای در فصل چهارم به مدلی تکیه ندارد که روز مورد پیش بینی را دیده باشد.

دوم: مدل تثبیت شده بر کل داده — هیچ عددی از آن گزارش نمی شود. این مصنوع بر پنجره ی ۱۰۹۲ روزه ی منتهی به ۳۱ دسامبر ۲۰۱۷ برازش شده است، یعنی پنجره ای که دوره ی آزمون را در بر می گیرد. به همین دلیل این مدل هرگز برای تولید هیچ معیار دقتی به کار نمی رود. کاربرد آن تنها ابزار عملیاتی **بخش ۵-۳** است، که برای پیش بینی فردا باید از تازه ترین داده ی موجود استفاده کند و اساساً در وضعیت ارزیابی قرار ندارد.

سوم: مدل تفسیر — برازشی جداگانه، اکیداً پیش از دوره ی آزمون. تحلیل SHAP در **بخش ۴-۶** نه بر مدل های چارچوب پیش رونده انجام می شود و نه بر مدل تثبیت شده بر کل داده. دلیل کنارگذاشتن مورد دوم روشن است: توضیح دادن روزهایی که مدل آن ها را در آموزش دیده، تفسیری درون نمونه ای است. پس **بخش ۴-۶** مدلی مستقل را تفسیر می کند که پنجره ی آموزشش هم طول همان ۱۰۹۲ روز است اما اکیداً پیش از مرز دوره ی آزمون پایان می یابد، و بنابراین هر روزی که توضیح داده می شود واقعاً دیده نشده است. این تضمین در کد زندگی می کند و با آزمون خودکار سنجیده می شود؛ پیاده سازی حتی از برازش بر پنجره ای کوتاه تر سر باز می زند، تا این همزاد در سکوت از مدل گزارش شده فاصله نگیرد.

خلاصه ی قابل واری: اعداد از مصنوع نخست می آیند، ابزار از مصنوع دوم، و نمودارهای تفسیرپذیری از مصنوع سوم. تنها مصنوعی که دوره ی آزمون را دیده است، هیچ عددی در این پایان نامه تولید نمی کند.

معیارهای ارزیابی

چهار معیار دقت گزارش می شود. برای پیش بینی $\hat{p}_i$ و مقدار واقعی p_i بر N نقطه:

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |p_i - \hat{p}_i| \quad (1-3)$$

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (p_i - \hat{p}_i)^2} \quad (2-3)$$

$$\text{sMAPE} = \frac{100}{N} \sum_{i=1}^N \frac{|p_i - \hat{p}_i|}{(|p_i| + |\hat{p}_i|) / 2} \quad (3-3)$$

$$\text{rMAE} = \frac{\text{MAE}}{\text{MAE}_{\text{naive}}} \quad (4-3)$$

که در آن‌ها N شمار نقاط ارزیابی، p_i قیمت محقق‌شده، $\hat{p}_i$ قیمت پیش‌بینی‌شده، و $\text{MAE}_{\text{naive}}$ خطای مطلق میانگین یک پیش‌بینی ساده‌ی مرجع است. مقدار rMAE کوچک‌تر از یک یعنی مدل از آن مرجع بهتر است و مقدار بزرگ‌تر از یک یعنی بدتر.

دو مدل ساده که نباید با هم اشتباه شوند

نکته‌ای که اگر تصریح نشود شبیه تناقض به نظر می‌رسد: مدل ساده‌ی این پژوهش rMAE برابر 0.849 دارد، یعنی ظاهراً مرجعی را که خودش تعریف می‌کند شکست می‌دهد.

توضیح آن است که دو مدل ساده‌ی متفاوت در کار است و هر دو استاندارد. مدل ساده‌ی گزارش‌شده در جدول‌های فصل چهارم، قاعده‌ی «روز مشابه» است که [بخش ۳-۶](#) آن را تعریف می‌کند. اما مخرج معیار rMAE بنا بر تعریف مرجع، پیش‌بینی ساده‌ی وقفه‌ی هفتگی است: همان ساعت در هفته‌ی پیش. پس 0.849 یعنی قاعده‌ی روز مشابه حدود پانزده درصد از وقفه‌ی هفتگی محض بهتر عمل می‌کند — که دقیقاً همان چیزی است که باید بکند، و سنجه‌ای از ارزش منطق رفتاری روز هفته.

چرا MAPE گزارش نمی‌شود، و چرا sMAPE با آن ناسازگار نیست

از گزارش MAPE متعارف آگاهانه صرف‌نظر شده است. در بازار برق آلمان قیمت‌های منفی واقعاً رخ می‌دهند — ۲۹۷ ساعت در داده‌ی آموزش و ۲۴۱ ساعت در دوره‌ی آزمون — و MAPE بر خود p_i تقسیم می‌کند؛ مخرجی که هم علامت‌پذیر است و هم در صفر تعریف‌ناپذیر. یک ساعت نزدیک به صفر کافی است تا این معیار بدون کران منفجر شود.

اما sMAPE گزارش می‌شود، و باید توضیح داد چرا این دو رفتار متفاوتی دارند. مخرج sMAPE میانگین قدرمطلق مقدار واقعی و پیش‌بینی است، پس تنها در حالتی مشکل‌ساز می‌شود که هر دو هم‌زمان به صفر نزدیک باشند — حالتی به مراتب نادرتر.

شاهد تجربی این تفاوت در خود داده‌ی مرجع موجود است: بر پیش‌بینی‌های یکسان، مقاله‌ی مرجع مقادیر MAPE در بازه‌ی تقریبی ۷۷ تا ۱۳۷ درصد را در برابر sMAPE در بازه‌ی ۱۴ تا ۱۷ درصد گزارش می‌کند — حدود ده برابر — و خود آن مقاله نیز MAPE را در این بازار نامطمئن می‌داند [۱].

با این‌همه، جمله‌ی تعیین‌کننده این است: هیچ نتیجه‌ای در این پایان‌نامه بر $sMAPE$ استوار نیست. تمام آزمون‌های معناداری بر زیان قدرمطلق محاسبه می‌شوند و هر ادعای سرشناسی بر MAE یا rMAE بنا شده است؛ sMAPE تنها برای امکان مقایسه با جدول منتشرشده گزارش می‌گردد. پیاده‌سازی هر چهار معیار مستقیماً از کتابخانه‌ی مرجع فراخوانی می‌شود و بازنویسی نشده است، تا اعداد فصل چهارم بدون هیچ ابهام پیاده‌سازی با اعداد منتشرشده هم‌مقیاس بمانند.

آزمون معناداری دیبولد-ماریانو

برتری عددی یک مدل بر مدل دیگر ممکن است محصول نوفه باشد. برای هر زوج مدل، آزمون دیبولد-ماریانو^۲ بر سری تفاضل زیان روزانه اجرا می‌شود. اگر d_t تفاضل زیان دو مدل در روز t باشد، آماره‌ی آزمون چنین است:

$$DM = \frac{\bar{d}}{\sqrt{\widehat{\text{Var}}_{\text{HAC}}(\bar{d})}} \quad (۵-۳)$$

که در آن $\bar{d}$ میانگین تفاضل زیان و مخرج، خطای معیار آن با تصحیح HAC است. این تصحیح

^۲Diebold-Mariano

ضروری است: خطاهای پیش‌بینی در روزهای متوالی همبسته‌اند و نادیده گرفتن این همبستگی، معناداری را به صورت کاذب بزرگ نشان می‌دهد. تمام p -مقدارهای این پایان‌نامه یک‌طرفه و تصحیح‌شده‌اند، و هیچ‌جا مقدار تصحیح‌نشده نقل نمی‌شود.

دو خانوادگی آزمون: تأییدی و اکتشافی

بخش ۴-۵-۱ ماتریسی هفت در هفت از مقایسه‌های زوجی گزارش می‌کند، که ۲۱ آزمون مستقل می‌شود. در چنین شماری، در سطح معناداری پنج درصد به‌طور میانگین حدود یک برنده‌ی کاذب انتظار می‌رود. اعلام‌نکردن این نکته، هر نتیجه‌ی نزدیک به مرز را بی‌اعتبار می‌کند.

از این رو، پیش از آنکه هیچ p -مقداری نقل شود، دو خانوادگی آزمون به‌صراحت تفکیک می‌شوند. **خانوادگی تأییدی، شامل یک فرضیه‌ی از پیش تعیین‌شده: مقایسه‌ی وزن‌دهی رژیم‌محور با وزن‌دهی ایستا.** این فرضیه در دفتر تصمیمات پروژه ثبت شده است، در تاریخی که هنوز مدل ترکیبی رژیم‌محور ساخته نشده و هیچ مدل ترکیبی‌ای بر دوره‌ی آزمون سنجیده نشده بود. پس این فرضیه نمی‌توانسته با نگاه کردن به نتایج انتخاب شده باشد. یک فرضیه‌ی واحد از پیش تعیین‌شده در سطح پنج درصد و بدون تصحیح آزموده می‌شود؛ این رویه‌ی استاندارد است و مدخل تاریخ‌دار همان چیزی است که آن را قابل واریسی می‌کند.

خانوادگی اکتشافی، شامل کل ماتریس ۲۱‌تایی: برای این خانواده، هم p -مقدار خام و هم p -مقدار تصحیح‌شده با روش هولم-بونفرونی گزارش می‌شود. گزارش کردن تنها مقدار خام نادرست است و پنهان کردن آن گریزگرایانه به نظر می‌رسد؛ پس هر دو ستون می‌آید.

پیامد عملی این تفکیک در **بخش ۴-۵-۱** دیده می‌شود و به سود پژوهش نیست: یکی از تفاوت‌هایی که در نگاه نخست معنادار می‌نماید، پس از تصحیح دوام نمی‌آورد و در متن نیز به‌عنوان تفاوت معنادار گزارش نمی‌شود.

تکرارپذیری

بذر تصادفی سراسری ۴۲ در تمام اجزای تصادفی — نمونه‌گیر جست‌وجوی ابرپارامتر، مدل‌های درختی و شبکه‌های عصبی — تثبیت شده و در کد به‌گونه‌ای تحمیل می‌شود که هیچ فایل پیکربندی یا ابرپارامتر تنظیم‌شده‌ای نتواند آن را بازنویسی کند. هر تصمیم غیربديهی روش‌شناختی نیز با تاریخ در دفتر ثبت تصمیمات پروژه مستند شده است، تا مسیر رسیدن به هر انتخاب پس از پایان کار نیز قابل بازسازی

باشد.

۳-۶ مدل‌های پایه

هر سه مدل این بخش بر یک واسط مشترک پیاده‌سازی شده‌اند و همگی از منبع یکتای ویژگی بخش ۳-۴ تغذیه می‌کنند. در نتیجه چارچوب اعتبارسنجی بخش ۳-۵ هر سه را بدون هیچ حالت خاصی می‌راند، و تفاوت عملکرد تنها به خودِ مدل بازمی‌گردد و نه به تفاوت در خوراک داده.

این یکدستی، تصمیم طراحی آگاهانه‌ای است و نه راحتی مهندسی. هر مدلی که مسیر ویژگی‌سازی مخصوص خود را داشته باشد، سطح تازه‌ای برای نشت اطلاعات می‌گشاید که آزمون بخش ۳-۴ آن را پوشش نمی‌دهد؛ و هر تفاوتی در پنجره‌ی آموزش یا ترتیب ستون‌ها، بخشی از اختلاف دقت را به عاملی جز خودِ مدل نسبت می‌دهد. سه مدل این بخش، مرجع‌هایی هستند که مدل‌های بخش ۳-۷ در برابر آن‌ها سنجیده می‌شوند؛ اعتبار آن سنجش تماماً به یکسان بودن شرایط بستگی دارد.

مدل ساده‌ی مرجع

مدل ساده‌ی «روز مشابه»، مطابق تعریف مرجع [۱]، چنین است: برای سه‌شنبه تا جمعه، قیمت‌های ۲۴‌گانه‌ی روز پیش (D-1)؛ برای دوشنبه، قیمت‌های جمعه‌ی پیش (D-3)؛ و برای شنبه و یکشنبه، قیمت‌های همان روز در هفته‌ی پیش (D-7).

منطق این قاعده رفتاری است و شاهد تجربی‌اش در بخش ۳-۳-۳ آمد: دوشنبه با یکشنبه‌ی پیش از خود شباهت ساختاری ندارد، پس به آخرین روز کاری ارجاع داده می‌شود، و روزهای تعطیل به هم‌تای خود در هفته‌ی پیشین.

این مدل هیچ پارامتری برازش نمی‌کند و صرفاً انتخاب ستون از ماتریس ویژگی مشترک است؛ متد برازش آن عامدانه بی‌اثر است و تنها برای پایبندی به واسط مشترک وجود دارد. لازمه‌ی آن این است که فهرست وقفه‌های قیمتی در پیکربندی، دربردارنده‌ی وقفه‌های ۱، ۳ و ۷ باشد، که پیکربندی پیش‌فرض آن را برآورده می‌کند.

نقش این مدل دوگانه است: کفِ عملکرد برای سنجش سایر مدل‌ها، و نقطه‌ی مرجع تفسیر معیار rMAE بر دوره‌ی آزمون، MAE ساعتی آن 7.750 و rMAE آن 0.849 است. درباره‌ی اینکه چرا این عدد برابر یک نیست، بخش ۳-۵ توضیح داده است.

مدل SARIMAX

به عنوان نماینده‌ی رویکرد کلاسیک آماری، ۲۴ مدل SARIMAX مستقل — یکی به ازای هر ساعت شبانه‌روز — برازش می‌شود. این تجزیه‌ی ساعت‌به‌ساعت با ساختار مدل LEAR-LASSO هم‌قرینه است و با ادبیات بازار برق سازگار، زیرا هر ساعت از شبانه‌روز رفتار آماری متمایزی دارد [۳]؛ بخش ۳-۳ دامنه‌ی این تفاوت را نشان داد.

مرتبه‌ی مدل $(1, 1, 1)_v$ و مرتبه‌ی فصلی $(1, 0, 1)_v$ با دوره‌ی تناوب هفت‌روزه انتخاب شده است — یعنی فصلی‌بودن در مقیاس هفته و نه شبانه‌روز، چرا که بعد ساعتی پیشاپیش با تفکیک ۲۴ گانه‌ی مدل‌ها جذب شده است. متغیرهای برون‌زا، پیش‌بینی‌های روزپیش‌بار و تولید تجدیدپذیر برای خودِ روز هدف‌اند که، بنا بر استدلال بخش ۳-۴، پیش از مبدأ منتشر می‌شوند و استفاده از آن‌ها نشت اطلاعات نیست.

بر خلاف دو مدل دیگر این بخش، SARIMAX افزوده‌ی خودِ این پژوهش است و در فهرست مدل‌های مقاله‌ی مرجع جایی ندارد؛ نقش آن، تأمین یک مرجع کلاسیک و تفسیرپذیر در کنار مرجع خطی ادبیات است.

انحراف ثبت‌شده از پروتکل واسنجی روزانه. برازش کامل ۲۴ مدل فصلی در ۷۲۸ مبدأ، یعنی نزدیک به هفده هزار و پانصد برازش، عملی نیست؛ و برخلاف LEAR، سابقه‌ای در ادبیات مرجع برای آهنگ واسنجی SARIMAX وجود ندارد که رعایت آن الزامی باشد. لذا برازش کامل هر هفت روز انجام می‌شود و در میانه‌ی آن از به‌روزرسانیِ ارزانِ فضای حالت استفاده می‌گردد: مشاهدات تازه به فیلتر افزوده می‌شوند و حالت مدل پیش می‌رود، بی‌آنکه پارامترها دوباره بهینه شوند.

نکته‌ی مهم آنکه پیش‌بینی هم‌چنان برای هر مبدأ روزانه تولید می‌شود — گام چارچوب پیش‌رونده هم‌چنان یک روز است — پس شمار و افق پیش‌بینی‌ها میان مدل‌ها یکسان و مقایسه‌ی روزانه منصفانه باقی می‌ماند؛ تنها پارامترهای برازشی خودِ SARIMAX است که میان دو بازبرازش ثابت نگه داشته می‌شود. این تصمیم با تاریخ در دفتر تصمیمات ثبت شده است، به‌جای آنکه در سکوت در کد بماند. بر دوره‌ی آزمون، MAE ساعتی این مدل 4.351 و rMAE آن 0.477 است: به‌روشنی بهتر از مدل ساده، اما ضعیف‌ترین عضو در میان مدل‌های برازشی.

مدل LEAR-LASSO

مدل LEAR، یعنی رگرسیون خودتوضیح با تنظیم لاسو، مدل خطی مرجع ادبیات این حوزه است [۱۹، ۱]. به ازای هر ساعت، یک رگرسیون لاسو بر ۲۴۷ ویژگی **بخش ۳-۴** برازش می‌شود. تابع هدف لاسو برای بردار ضرایب β چنین است:

$$\hat{\beta} = \arg \min_{\beta} \left\{ \sum_{t=1}^T (p_t - x_t^\top \beta)^2 + \lambda \sum_{j=1}^J |\beta_j| \right\} \quad (۳-۶)$$

که در آن p_t قیمت محقق شده در روز t ، بردار ویژگی همان روز، T شمار روزهای پنجره‌ی واسنجی، J شمار ویژگی‌ها و λ ضریب جریمه است. جمله‌ی دوم، مجموع قدرمطلق ضرایب را جریمه می‌کند و در نتیجه بسیاری از آن‌ها را دقیقاً صفر می‌کند؛ همین ویژگی است که لاسو را برای ماتریسی با ۲۴۷ ستون و پنجره‌ای با ۱۰۹۲ سطر مناسب می‌سازد.

ضریب λ با معیار اطلاعات آکائیکه انتخاب می‌شود و واسنجی مدل روزانه است. پنجره‌ی واسنجی ۱۰۹۲ روز است، همان مقداری که در فایل پیکربندی ارزیابی به عنوان منبع یکتای این عدد برای کل خط لوله تعریف شده است. نکته‌ی مهم آنکه λ در هر برازش از نو انتخاب می‌شود؛ یعنی این مدل ابرپارامتر دست‌ی تنظیم شده‌ای ندارد و برخلاف مدل‌های **بخش ۳-۷** نیازمند جست‌وجوی Optuna نیست.

پیاده‌سازی از واسط سطح پایین خود کتابخانه‌ی مرجع استفاده می‌کند، اما ماتریس‌های ویژگی از خط لوله‌ی نشت‌آزموده‌ی **بخش ۳-۴** به آن داده می‌شود و نه از سازنده‌ی داخلی خود کتابخانه. علت این انتخاب همان اصل ابتدای بخش است: اعتماد به یک سازنده‌ی ویژگی دوم، مسیر دومی برای نشت می‌ساخت که آزمون‌های ما آن را نمی‌پوشاند. ترتیب و شمار ستون‌ها دقیقاً با فرمول ویژگی مرجع منطبق است.

راستی آزمای زنجیره‌ی کامل. صحت کل زنجیره — بارگذار داده، مهندسی ویژگی، چارچوب پیش‌رونده و پیاده‌سازی مدل — با مقایسه‌ی مستقیم خروجی این مدل با پیش‌بینی‌های خام منتشرشده‌ی خود مقاله‌ی مرجع بر همان دوره‌ی آزمون راستی‌آزمایی شد.

نخست هم‌سانی داده احراز شد: بیشینه‌ی اختلاف مطلق میان سری قیمت واقعی دو خط لوله، بر تمام 17,472 ساعت، صفر بود. سپس MAE ساعتی مدل ما 3.899 در برابر 3.930 برای گونه‌ی منتشرشده‌ی LEAR 1092 به دست آمد — یعنی بازتولیدی وفادار با همان پروتکل و همان داده.

قیدی که باید همراه این عدد بیاید. این هم‌ترازی را نباید به ادعای «شکست بنچمارک» تعمیم داد. در همان مقایسه، گونه‌های ترکیبی منتشرشده همچنان پیش‌اند: DNN Ensemble^۴ با 3.413 و LEAR Ensemble با 3.609. آنچه این بخش مجاز به ادعای آن است «کیفیت بازتولید» است و نه برتری. همین قید، مبنای تصمیم ایست‌بازرسی میانی پروژه بود که خط دفاعی پژوهش را از شکست بنچمارک به مسیر نوآوری محور تغییر داد. جدول کامل و آزمون‌های معناداری آن در بخش ۴-۵-۲ می‌آید.

۷-۳ مدل‌های یادگیری ماشین و یادگیری عمیق

دو مدل غیرخطی در این پژوهش به کار می‌روند: LightGBM به‌عنوان نماینده‌ی خانواده‌ی درختی و LSTM به‌عنوان نماینده‌ی خانواده‌ی یادگیری عمیق. این دو، پرکاربردترین خانواده‌های غیرخطی در ادبیات اخیر پیش‌بینی قیمت برق‌اند [۳، ۴].

فهرست مدل‌ها عامدانه کوتاه است. جنگل تصادفی، XGBoost، ماشین بردار پشتیبان و GRU همگی بررسی و از دامنه‌ی پژوهش کنار گذاشته شدند. منطق این محدودسازی آن است که افزودن گونه‌های بیشتر از یک خانواده، به‌جای پاسخ به پرسش «کدام خانواده‌ی مدل در این بازار بهتر عمل می‌کند»، بودجه‌ی تنظیم و توان تحلیل را میان گونه‌هایی پخش می‌کند که رفتار مشابهی دارند. یک نماینده‌ی خوب تنظیم‌شده از هر خانواده، اطلاعات بیشتری می‌دهد تا پنج نماینده‌ی کم‌تنظیم.

سه قید بر هر دو مدل این بخش یکسان اعمال می‌شود، و همین یکسانی است که مقایسه‌ی آن‌ها را معنادار می‌کند.

نخست، بودجه‌ی برابر تنظیم: هر دو مدل با ۵۰ آزمایش Optuna تنظیم شده‌اند، بر پنجره‌ی اعتبارسنجی یکسان که اکیداً پیش از دوره‌ی آزمون قرار دارد. این برابری، پاسخ پیشاپیش پرسشی است که به‌درستی پرسیده خواهد شد: آیا مدل عمیق صرفاً کم‌تنظیم نشده است؟ بودجه یکسان بوده و در متن ثبت شده است.

دوم، تابع زیان هم‌تراز: هر دو مدل بر زیان قدرمطلق آموزش می‌بینند، هم‌راستا با معیار سرشناس گزارش در فصل چهارم. بدون این هم‌ترازی، بخشی از اختلاف میان دو مدل به تفاوت در تابع زیان بازمی‌گشت و مقایسه به مصنوعی از انتخاب زیان بدل می‌شد.

سوم، منبع یکنای ویژگی: هر دو از همان ماتریس ۲۴۷ ستونی بخش ۳-۴ تغذیه می‌کنند و هیچ یک مسیر ویژگی‌سازی اختصاصی ندارد.

بخش ۱-۷-۳ مدل درختی و **بخش ۲-۷-۳** مدل عمیق را شرح می‌دهد. در هر دو، آهنگ واسنجی، رویه‌ی تنظیم و سازوکارهای تضمین بازتولیدپذیری به تفصیل می‌آید، چون همین جزئیات‌اند که تعیین می‌کنند اعداد فصل چهارم تکرارپذیر باشند یا نه.

۱-۷-۳ LightGBM

نخستین مدل غیرخطی این پژوهش LightGBM است: پیاده‌سازی کارآمدی از تقویت گرادیانی بر درخت‌های تصمیم، که در ادبیات پیش‌بینی قیمت برق به عنوان نماینده‌ی استاندارد خانواده‌ی مدل‌های درختی به کار می‌رود [۳، ۴]. انتخاب آن — به جای جنگل تصادفی یا XGBoost که هر دو آگاهانه از دامنه‌ی پژوهش کنار گذاشته شدند — بر دو ملاحظه استوار است: کارایی محاسباتی، که واسنجی روزانه را در ۷۲۸ مبدأ ممکن می‌سازد، و توان بالای آن در داده‌های جدولی با ویژگی‌های ناهمگن، که دقیقاً ساختار ماتریس ویژگی **بخش ۳-۴** است.

ساختار مدل

به ازای هر ساعت شبانه‌روز یک رگرسور مستقل برازش می‌شود؛ یعنی ۲۴ مدل مجزا که هیچ‌یک از دیگری اطلاعی ندارد. این تصمیم عامدانه با ساختار ساعت‌به‌ساعت **LEAR-LASSO** و **SARIMAX** (**بخش ۳-۶**) هم‌قرینه است، تا اختلاف عملکرد میان مدل خطی و مدل درختی به خود خانواده‌ی مدل بازگردد و نه به تفاوت در نحوه‌ی تجزیه‌ی افق پیش‌بینی.

هر یک از این ۲۴ مدل، کل ماتریس ویژگی مشترک را دریافت می‌کند: هر ۲۴۷ ستون، شامل وقفه‌های قیمتی، وقفه‌ها و مقادیر روزپیش متغیرهای برون‌زا، و متغیرهای مجازی روز هفته. هیچ مسیر ویژگی‌سازی جداگانه‌ای برای این مدل وجود ندارد و در نتیجه سطح دومی برای نشت اطلاعات ایجاد نمی‌شود.

یادداشت پیاده‌سازی: پیمانه‌ی این مدل عامدانه نامی متفاوت از خود بسته‌ی LightGBM دارد، تا در هیچ شرایطی با آن اشتباه گرفته نشود یا آن را سایه نیندازد.

آهنگ واسنجی

برخلاف SARIMAX که برازش کامل آن در هر مبدأ عملی نبود (**بخش ۳-۶**)، LightGBM بر پنجره‌ی واسنجی ۱۰۹۲ روزه در چند ثانیه برازش می‌شود. از این رو هیچ مصالحه‌ای در آهنگ واسنجی لازم نیست و مدل در هر مبدأ به طور کامل بازبرازش می‌گردد — یعنی دقیقاً همان پروتکل واسنجی روزانه‌ای

که مدل مرجع LEAR از آن پیروی می کند [۱]. این هم‌ترازی، مقایسه‌ی مستقیم دو مدل را از شبیه‌ی «تفاوت در تازگی برازش» پاک می کند.

تنظیم ابرپارامترها

ابرپارامترها با ۵۰ آزمایش Optuna تنظیم شده‌اند. پنجره‌ی اعتبارسنجی، از ۵ ژانویه‌ی ۲۰۱۵ تا ۳ ژانویه‌ی ۲۰۱۶، اکیداً پیش از دوره‌ی آزمون قرار دارد، و پنجره‌ی برازش آن، از ۱۶ ژانویه‌ی ۲۰۱۲ تا ۴ ژانویه‌ی ۲۰۱۵، پیش از خود پنجره‌ی اعتبارسنجی است. بدین ترتیب هیچ مشاهده‌ای از دوره‌ی آزمون در انتخاب ابرپارامترها نقشی ندارد. بذر نمونه‌بردار جست‌وجو نیز ۴۲ تثبیت شده تا خود فرایند تنظیم بازتولیدپذیر بماند.

تابع هدف بر زیان قدرمطلق تنظیم شده است تا زیان آموزش با معیار سرشناس گزارش هم‌راستا باشد؛ همین انتخاب برای LSTM نیز تکرار می شود تا مقایسه‌ی آن دو مخدوش نشود. بهترین پیکربندی یافت‌شده، با MAE اعتبارسنجی 3.7316، چنین است: شمار درخت‌ها ۹۶۳، نرخ یادگیری 0.0245، شمار برگ‌ها ۱۵، کمینه‌ی نمونه در برگ ۱۱، نسبت ویژگی 0.542، نسبت نمونه‌گیری 0.513 با تناوب ۳، و جریمه‌های L1 و L2 به ترتیب 0.316 و 7.04e-08.

جهت‌گیری این جست‌وجو خود گویاست. نسبت به مقادیر پیش‌فرض، شمار برگ‌ها از ۶۳ به ۱۵ کاهش و در مقابل شمار درخت‌ها از ۵۰۰ به ۹۶۳ افزایش یافته و نرخ یادگیری نصف شده است. یعنی جست‌وجو به سمت مدلی کوچک‌تر، منظم‌تر و آهسته‌تر حرکت کرده — الگویی که با ماهیت پرنوفه‌ی سری قیمت برق و خطر بیش‌برازش بر ویژگی‌های فراوان سازگار است.

تضمین بازتولیدپذیری

سه پارامتر، فارغ از محتوای فایل پیکربندی یا نتیجه‌ی تنظیم، در خود کد تحمیل می‌شوند: بذر تصادفی ۴۲، پرچم جبرگرایی، و مهم‌تر از هر دو، شمار ثابت نخ‌های پردازش.

علت تثبیت صریح شمار نخ‌ها — به‌جای واگذاری آن به مقدار خودکار — ظریف و ضروری است: تضمین جبرگرایی این کتابخانه تنها به‌ازای شمار نخ یکسان برقرار است. اگر این مقدار با مشخصات ماشین شناور بماند، اجرای همان کد بر سخت‌افزاری دیگر می‌تواند اعدادی متفاوت تولید کند، و آنگاه ادعای بازتولیدپذیری نتایج تثبیت‌شده بی‌اعتبار می‌شود. این مقدار پس از آنکه آزمایش‌های تک‌نخی تنظیم به درازا کشید افزایش یافت، و تغییر آن به‌عنوان یک انتخاب ثبت‌شده و نه یک تنظیم محیطی، در دفتر تصمیمات درج شده است.

عملکرد و ارجاع به فصل چهارم

بر دوره‌ی آزمون ۷۲۸ مبدایی، MAE ساعتی این مدل 3.968 و rMAE آن 0.435 است؛ جدول کامل در بخش ۲-۴ می‌آید. دو ملاحظه‌ی صادقانه باید همین‌جا ثبت شود.

نخست آنکه این مدل غیرخطی، مدل خطی LEAR-LASSO را در MAE ساعتی پشت سر نمی‌گذارد: 3.968 در برابر 3.899. برتری روش‌های انعطاف‌پذیر بر مدل خطی مرجع، در این بازار و این دوره محقق نشده است.

دوم آنکه در آزمون برون‌توزیعی فصل پنجم، همین مدل بیشترین افت را در میان تمام مدل‌ها نشان می‌دهد، با rMAE برابر 1.828. تفسیر این دو یافته در کنار یکدیگر — یعنی اینکه انعطاف‌پذیری بالاتر در درون‌دوره مزیتی نساخت اما در برون‌توزیع هزینه‌ی سنگین‌تری تراشید — در بخش ۲-۵ می‌آید.

LSTM ۲-۷-۳

بازوی یادگیری عمیق این پژوهش یک شبکه‌ی حافظه‌ی کوتاه‌مدت بلند است. انگیزه‌ی انتخاب آن، ساختار توالی‌وار سری قیمت است: قیمت هر روز نه یک بردار منفرد، بلکه حلقه‌ای از زنجیره‌ای است که روزهای پیشین آن را شکل داده‌اند، و لایه‌ی بازگشتی سازوکاری صریح برای مدل‌سازی همین وابستگی زمانی در اختیار می‌گذارد [۲۹، ۲۰] — چیزی که نه مدل خطی LEAR و نه مدل درختی LightGBM به‌صراحت ندارند و تنها از طریق ویژگی‌های وقفه‌ای به آن دسترسی می‌یابند.

معماری دوشاخه

شبکه دو ورودی مجزا دارد که در میانه‌ی مسیر به هم می‌پیوندند.

شاخه‌ی توالی. به‌ازای هر وقفه‌ی قیمتی پیکربندی‌شده — به‌ترتیب از کهنه به تازه: D-7، D-3، D-2 و D-1 — یک گام زمانی ساخته می‌شود و محتوای هر گام، بردار ۲۴ ساعته‌ی قیمت همان روز وقفه است. حاصل، دنباله‌ای چهارگامی با بُعد ۲۴ در هر گام است که به لایه‌ی بازگشتی خورانده می‌شود. انتخاب ستون‌ها صریحاً بر اساس نام ستون انجام می‌گیرد و هرگز بر پایه‌ی موقعیت آن؛ اگر ستونی از قلم بیفتد، مدل با خطا متوقف می‌شود و به‌آرامی روی ستون اشتباه برآزش نمی‌شود. این تمایز اهمیت دارد، چون برآزش بر ستون اشتباه هیچ نشانه‌ی بیرونی ندارد.

شاخه‌ی ایستا. تمام ستون‌های باقی‌مانده‌ی ماتریس ویژگی — وقفه‌های متغیرهای برون‌زا، پیش‌بینی‌های روزپیش خود روز هدف، و متغیرهای مجازی روز هفته — به‌صورت یک بردار مسطح وارد می‌شوند.

خروجی لایه‌ی بازگشتی با بردار ایستا الحاق می‌شود، از یک لایه‌ی چگال با تابع فعال‌ساز ^۵ReLU می‌گذرد، و در نهایت به لایه‌ی چگال ^{۲۴}تایی می‌رسد که همان بردار قیمت ساعتی روز $D+1$ است. بهینه‌ساز آموزش Adam^۶ است.

نکته‌ی روش‌شناختی مهم در این معماری آن است که هر دو شاخه از همان ماتریس ویژگی مشترک تغذیه می‌شوند که سایر مدل‌ها مصرف می‌کنند. مسیر جداگانه‌ای برای ساخت توالی وجود ندارد. اگر چنین مسیری ساخته می‌شد، سطح دومی برای نشت اطلاعات پدید می‌آمد که آزمون بخش ۳-۴ آن را پوشش نمی‌داد؛ در عوض، تنها یک منبع ویژگی وجود دارد و همان یک منبع ممیزی شده است.

مقیاس‌بندی

هر سه جزء — دنباله‌ی ورودی، بردار ایستا و خودِ هدف — استاندارد می‌شوند و پیش‌بینی‌ها در انتها به مقیاس اصلی بازگردانده می‌شوند.

تصریح ضروری آن است که این مقیاس‌گرها تنها بر برش آموزش همان بازبرازش برآزش می‌شوند، نه بر کل سری. برآزش مقیاس‌گر بر تمام داده، میانگین و انحراف معیار دوره‌ی آزمون را به مرحله‌ی آموزش نشت می‌داد؛ نشتی ظریف که هیچ خطایی تولید نمی‌کند و تنها نتیجه را به آرامی خوش‌بینانه می‌سازد.

تابع زیان

زیان آموزش، خطای مطلق میانگین است. این انتخاب دو کارکرد دارد: هم‌راستایی با معیار سرشناس گزارش در فصل چهارم، و هم‌ترازی با تابع هدف LightGBM (بخش ۳-۷-۱). بدون این هم‌ترازی، بخشی از اختلاف میان دو مدل به تفاوت در تابع زیان بازمی‌گشت و مقایسه، به جای پاسخ به پرسش «کدام خانواده‌ی مدل بهتر است»، به مصنوعی از انتخاب زیان تبدیل می‌شد.

آهنگ واسنجی و پاسداشت ترتیب زمانی

بازآموزی کامل یک شبکه‌ی عصبی در هر یک از ۷۲۸ مبدأ، بر سخت‌افزار این پژوهش عملی نبود. لذا بازبرازش کامل هر هفت روز انجام می‌شود و شبکه در فاصله‌ی میان دو بازبرازش بدون تغییر به کار می‌رود. با این همه پیش‌بینی همچنان برای هر مبدأ روزانه تولید می‌شود، پس افق و شمار پیش‌بینی‌ها میان مدل‌ها یکسان می‌ماند. این انحراف از پروتکل واسنجی روزانه، هم‌سنگ انحراف ثبت‌شده برای

^۵ Rectified Linear Unit
^۶ Adaptive Moment Estimation

SARIMAX (بخش ۳-۶)، به صراحت در دفتر تصمیمات ثبت شده است و نه به عنوان جزئیاتی پنهان در پیاده سازی.

افزون بر آن، پیاده سازی یک پاسبان صریح دارد: اگر پنجره‌ی آموزش درخواستی پایانی پیش از آخرین بازپرازش کامل داشته باشد، مدل با خطا متوقف می‌شود. چنین حالتی به معنای پاسخ دادن به یک مبدأ گذشته با شبکه‌ای است که بر داده‌ی متأخرتر آموزش دیده — یعنی نشت اطلاعات واقعی. چارچوب پیش‌رونده مبادی را یکنواخت و صعودی تولید می‌کند، پس فعال شدن این پاسبان تنها می‌تواند نشانه‌ی اشکال در فراخوان باشد.

تنظیم ابرپارامترها

همانند LightGBM، ۵۰ آزمایش Optuna با بذر نمونه بردار ۴۲، بر پنجره‌ی اعتبارسنجی ۵ ژانویه‌ی ۲۰۱۵ تا ۳ ژانویه‌ی ۲۰۱۶ و پنجره‌ی برازش ۱۶ ژانویه‌ی ۲۰۱۲ تا ۴ ژانویه‌ی ۲۰۱۵ — هر دو اکیداً پیش از دوره‌ی آزمون. بهترین پیکربندی: ۲۹ واحد پنهان، ۴۷ دوره‌ی آموزش، اندازه‌ی دسته‌ی ۳۲ و نرخ یادگیری 0.00083، با MAE اعتبارسنجی 3.696.

شایان توجه است که جست‌وجو شبکه‌ای کوچک‌تر از پیش‌فرض را برگزید — ۲۹ واحد در برابر ۶۴ — همان جهت‌گیری منظم‌سازانه‌ای که در تنظیم LightGBM نیز دیده شد، و نشانه‌ی محدودبودن اطلاعات قابل استخراج از این سری در برابر ظرفیت مدل است.

جبرگرایی

پیش از هر ساخت و برازش، بذر تصادفی سراسری ۴۲ تثبیت و جبرگرایی عملیات فعال می‌شود؛ شمار نخ‌های پردازش نیز بر مقداری ثابت تنظیم می‌گردد تا هم نتیجه بازتولیدپذیر بماند و هم اجراهای هم‌زمان چارچوب پیش‌رونده بی‌ثبات نشوند. اگر جبرگرایی عملیات در محیطی در دسترس نباشد، پیاده‌سازی هشدار صریح می‌دهد، به جای آنکه در سکوت تضمین بازتولیدپذیری را از دست بدهد.

عملکرد، و آنچه درباره‌ی آن نباید ادعا شود

بر دوره‌ی آزمون، MAE ساعتی این مدل 3.873 و rMAE آن 0.424 است — یعنی بهترین مدل منفرد در جدول ۴-۱. اما این عدد به تنهایی گمراه‌کننده است و سه قید باید همراه آن بیاید.

نخست، آزمون دیبولد-ماریانو با تصحیح HAC نشان می‌دهد که برتری این مدل بر LEAR-LASSO معنادار نیست: p برابر 0.404. این یک تساوی آماری است، نه یک پیروزی، و در سرتاسر پایان‌نامه به

همین صورت گزارش می‌شود.

برتری آن بر LightGBM نیز، برخلاف آنچه نگاه نخست به p -مقدار خام (0.0405) نشان می‌دهد، از تصحیح چندگانگی جان به در نمی‌برد: در خانواده‌ی اکتشافی ۲۱ تایی که بخش ۳-۵ آن را اعلام کرد، مقدار تصحیح‌شده با روش هولم-بونفرونی برابر 0.1215 است. پس آنچه می‌توان گفت این است که LSTM برآورد نقطه‌ای پایین‌تری دارد، و این تفاوت پس از تصحیح برای چندگانگی دوام نمی‌آورد. خوانش صادقانه آن است که LEAR-LASSO، LightGBM و LSTM متقابلاً تفکیک‌ناپذیرند.

دوم، در آزمون برون‌توزیعی بر داده‌ی زنده‌ی ۲۰۲۶، همین مدل دومین افت شدید را پس از LightGBM نشان می‌دهد: rMAE برابر 1.520 در برابر 1.087 برای LEAR-LASSO. یعنی مدلی که مزیت درون‌دوره‌اش از نظر آماری قابل تفکیک نبود، در برابر تغییر شرایط شکننده‌تر نیز هست. سوم، تحلیل SHAP بخش ۴-۶ بر یک برازش ایستای انجام شده و نه بر مدلی که در هر مبدأ بازواسنجی می‌شود؛ لذا نمودارهای اهمیت ویژگی، تصویر همان مدلی که اعداد دقت را تولید کرده است نیستند. آن برازش، مطابق تفکیکی که بخش ۳-۵ میان سه مصنوع مدل قائل شد، پنجره‌ی آموزشی اکیداً پیش از مرز دوره‌ی آزمون دارد و بنابراین هر روز توضیح‌داده‌شده برای آن دیده‌نشده است؛ همزادی وفادار است و نه همان مدل. این قید در بخش ۴-۶ نیز تصریح شده است.

جمع‌بندی صادقانه آن است که مدل عمیق در این پژوهش بهترین عدد میانگین را تولید کرد، بدون آنکه برتری‌اش بر مدل خطی مرجع از حد نوسان آماری فراتر رود، و با هزینه‌ای آشکار در تعمیم‌پذیری بیرون از دوره‌ی آموزش. تفصیل این بحث در بخش‌های ۴-۵ و ۵-۲ می‌آید.

۸-۳ مدل ترکیبی

چرا ترکیب

هر یک از چهار مدل برازشی این پژوهش خطای متفاوتی مرتکب می‌شود. مدل خطی در شرایطی می‌لغزد که مدل درختی از پس آن برمی‌آید و بالعکس. ترکیب وزن‌دار، همین ناهم‌بستگی خطاها را به دقت تبدیل می‌کند و در ادبیات پیش‌بینی قیمت برق از راه‌های شناخته‌شده‌ی بهبود دقت است [۲]؛ گونه‌های ترکیبی خود مقاله‌ی مرجع نیز بهترین اعداد آن مقاله‌اند [۱].

این بخش دو مدل ترکیبی معرفی می‌کند: نخست ترکیب ایستا، سپس ترکیب رژیم‌محور که سهم مشارکت پژوهش حاضر است.

ترکیب ایستا

ترکیب ایستا یک بردار وزن ثابت بر چهار مدل برازشی — LightGBM, LEAR-LASSO, SARIMAX و LSTM — اعمال می‌کند. مدل ساده در ترکیب شرکت داده نمی‌شود، چون نقش آن مرجع است و نه عضو.

وزن‌ها با کمینه‌سازی خطای مطلق میانگین بر پنجره‌ی برازش وزن به دست می‌آیند، با دو قید که ترکیب را محدب نگه می‌دارند:

$$\hat{w} = \arg \min_w \frac{1}{N} \sum_{i=1}^N \left| p_i - \sum_{m=1}^M w_m \hat{p}_{m,i} \right| \quad \text{به شرط} \quad w_m \geq 0, \quad \sum_{m=1}^M w_m = 1 \quad (7-3)$$

که در آن M شمار مدل‌های عضو، $\hat{p}_{m,i}$ پیش‌بینی مدل m در نقطه‌ی i ، و w_m وزن آن مدل است. قید نامنفی بودن و قید جمع‌شدن به یک، هر دو عامدانه‌اند: بدون آن‌ها بهینه‌ساز می‌تواند وزن‌های بزرگ و مخالف علامت پیدا کند که بر پنجره‌ی برازش عالی عمل می‌کنند و بیرون از آن ناپایدارند.

پیاده‌سازی در برابر شکست خاموش محافظت شده است: اگر بهینه‌ساز همگرا نشود یا وزن‌هایی بازگرداند که به یک جمع نمی‌شوند، اجرا با خطا متوقف می‌شود، به جای آنکه وزن‌های یکنواخت را در سکوت جایگزین کند و جدول‌های پس از آن همچنان برچسب «وزن‌های بهینه» را حمل کنند.

افشای نخست. وزن‌ها بر پنجره‌ی تنظیم خود اعضا برازش شده‌اند، یعنی بازه‌ای که آن اعضا ابرپارامترهایشان را از آن گرفته‌اند. این را باید گفت. آنچه آن را مهار می‌کند این است که مقایسه‌ای که این وزن‌ها تغذیه می‌کنند — یعنی رژیم‌محور در برابر ایستا — همین مزیت را به‌طور یکسان به هر دو طرف می‌دهد، پس تفاوت میان آن دو از این بابت مخدوش نمی‌شود. آنچه مخدوش می‌شود مقایسه‌ی ترکیب با تک‌مدل‌هاست، که با احتیاط بیشتری باید خوانده شود.

تعریف رژیم بازار

بخش ۳-۳-۳ نشان داد که نوسان در این سری خوشه‌ای است: دوره‌های آرام و پرتلاطم کنار هم می‌نشینند. اگر رفتار بازار در این دو حالت به‌قدر کافی متفاوت باشد، بردار وزنی که در حالت آرام بهینه است لزوماً در حالت پرتنش بهینه نیست. ترکیب رژیم‌محور بر همین فرض استوار است. دو رژیم تعریف می‌شود — آرام و پرتنش — و مرز آن‌ها یک آستانه‌ی قیمتی است:

$$\tau = \mu_{\text{train}} + k \cdot \sigma_{\text{train}} \quad (۸-۳)$$

که در آن μ_{train} و σ_{train} میانگین و انحراف معیارِ قیمت بر بخشی از داده‌ی آموزش، و k ضریبی است که باید انتخاب شود. مقادیر عددی چنین است: میانگین 37.6876 و انحراف معیار 16.6742 بر قیمت‌های تا پایان ۴ ژانویه ۲۰۱۵، که با k برابر 1.5 آستانه‌ی 62.6989 یورو بر مگاوات‌ساعت را می‌دهد. سه ویژگی این تعریف را باید صریح گفت، چون هر سه پرسش‌هایی را پیشاپیش می‌بندند که حتماً پرسیده می‌شوند.

یکم: مبنای محاسبه‌ی آستانه پیش از هر پنجره‌ی آلوده‌کننده تمام می‌شود. برش ۴ ژانویه ۲۰۱۵ اکیداً پیش از هر دو پنجره‌ی قرار دارد که می‌توانستند آن را آلوده کنند: پنجره‌ی تنظیم ابرپارامتر و پنجره‌ی برازش وزن، که هر دو از ۲۰۱۵ آغاز می‌شوند. آستانه بنابراین نه از دوره‌ی آزمون و نه از پنجره‌های تنظیم، اطلاعی ندارد. این مقدار در آزمون‌های پروژه در برابر داده‌ی خام سنجیده می‌شود، یعنی خاصیت واریسی می‌شود و نه صرفاً در یک توضیح ادعا.

دوم: k با قاعده‌ای صرفاً بر پایه‌ی داده‌ی اعتبارسنجی انتخاب شده است. قاعده این بود: بزرگ‌ترین k از میان مقادیر 2.0، 2.5، 3.0 و 1.5 که به ازای آن هر دو رژیم دست کم بیست روز در پنجره‌ی اعتبارسنجی داشته باشند. مقدار 2.0 تنها ده روز پرتنش باقی می‌گذاشت و 1.5 سی‌وهفت روز؛ پس 1.5 انتخاب شد. دوره‌ی آزمون هرگز در این انتخاب مشورت نشد. انتخاب آستانه بر پایه‌ی رفتار آن روی دوره‌ی آزمون، گزینش درون‌نمونه‌ای می‌بود و کل نتیجه‌ی بخش ۴-۵-۱ را بی‌اعتبار می‌کرد. تقسیم حاصل چنین است: در پنجره‌ی اعتبارسنجی ۳۷ روز پرتنش در برابر ۳۲۰ روز آرام (از مجموع ۳۵۷ مبدأ)، و در دوره‌ی آزمون ۷۷ روز پرتنش از مجموع ۷۲۸ روز.

سوم: برچسب رژیم از روز پیش خوانده می‌شود. یک روز زمانی پرتنش برچسب می‌خورد که قیمت‌های محقق‌شده‌ی روز پیش از آن از آستانه عبور کرده باشند. این قید در کد اعمال می‌شود، نه در توضیح. اگر برچسب از قیمت‌های خودِ روز هدف خوانده می‌شد، خودِ برچسب حامل اطلاعاتی از آینده می‌بود و کل سازوکار به نشت اطلاعات آلوده می‌گشت.

نکته‌ی اصطلاح‌شناختی: در سطح تقریبی یک‌ونیم انحراف معیار، آنچه علامت‌گذاری می‌شود یک روز بالاتر از معمول است و نه یک جهش قیمتی. برچسب «پرتنش» عامدانه انتخاب شده تا این تمایز حفظ شود.

ترکیب رژیم‌محور

ترکیب رژیم‌محور به جای یک بردار وزن، دو بردار دارد: یکی برازش‌شده بر روزهای آرام پنجره‌ی برازش و دیگری بر روزهای پرتنش همان پنجره. در زمان پیش‌بینی، برچسب رژیم روز هدف — که، مطابق بالا، از روز پیش خوانده می‌شود — تعیین می‌کند کدام بردار وزن به کار رود. به جز همین سوئیچ، هیچ تفاوت دیگری با ترکیب ایستا وجود ندارد: همان اعضا، همان پنجره‌ی برازش، همان بهینه‌ساز و همان قیده‌های محدب.

این طراحی حداقلی عامدانه است. اگر ترکیب رژیم‌محور هم‌زمان اعضای دیگری می‌گرفت یا پنجره‌ی متفاوتی به کار می‌برد، تفاوت عملکرد آن با ترکیب ایستا دیگر به شرطی کردن وزن‌ها قابل نسبت‌دادن نبود.

یادآوری تفکیک **بخش ۳-۵**: پیش‌بینی‌هایی که این وزن‌ها بر آن‌ها اعمال می‌شوند، خروجی مدل‌های چارچوب پیش‌رونده‌اند و نه مدل تثبیت‌شده بر کل داده؛ یعنی هر پیش‌بینی عضو، از مدلی می‌آید که اکیداً پیش از مبدأ خود برازش شده است. وزن‌ها نیز، همان‌گونه که گفته شد، بر پنجره‌ای پیش از دوره‌ی آزمون برازش می‌شوند. پس هیچ مرحله‌ای از این زنجیره دوره‌ی آزمون را نمی‌بیند.

وزن‌های برازش‌شده

جدول ۳-۱ سه بردار وزن را در کنار هم می‌آورد: بردار ایستا، و دو بردار رژیم‌محور آرام و پرتنش. هر سه با همان رویه‌ی بالا و بر همان پنجره‌ی برازش به دست آمده‌اند.

جدول ۳-۱: وزن‌های برازش‌شده‌ی مدل ترکیبی بر پنجره‌ی برازش وزن (۳۵۷ مبدأ، از ۱۲ ژانویه‌ی ۲۰۱۵ تا ۳ ژانویه‌ی ۲۰۱۶). ستون نخست وزن‌های ترکیب ایستا و دو ستون بعد وزن‌های ترکیب رژیم‌محور است. هر ستون به یک جمع می‌شود. تقسیم رژیم‌ی این پنجره ۳۲۰ روز آرام و ۳۷ روز پرتنش است.

رژیم‌محور		ایستا	عضو
پرتنش	آرام		
0.063	0.140	0.134	SARIMAX
0.375	0.237	0.245	LEAR-LASSO
0.281	0.388	0.382	LightGBM
0.281	0.235	0.239	LSTM

مقایسه‌ی دو ستون آخر، خود سازوکار را آشکار می‌کند و از هر توضیح کلامی گویاتر است. در رژیم آرام، بردار وزن عملاً همان بردار ایستاست؛ اختلاف‌ها در حد چند هزارم‌اند. این انتظارپذیر است، چون روزهای آرام اکثریت پنجره‌ی برازش را می‌سازند و بردار ایستا نیز عمدتاً از همان‌ها شکل

می‌گیرد.

در رژیم پرتنش اما آرایش وزن‌ها به‌روشنی جابه‌جا می‌شود. سهم LEAR-LASSO از 0.237 به 0.375 می‌رسد و به بزرگ‌ترین وزن بدل می‌گردد، سهم LightGBM از 0.388 به 0.281 افت می‌کند، و سهم SARIMAX بیش از نصف کاهش می‌یابد و از 0.140 به 0.063 می‌رسد.

خوانش این جابه‌جایی چنین است: در روزهای پرتنش، بهینه‌ساز وزن را از مدل درختی به سمت مدل خطی می‌برد. این با مشاهده‌ی RMSE در **بخش ۲-۴** سازگار است، جایی که مدل درختی خطاهای حدی بزرگ‌تری از مدل خطی نشان می‌دهد؛ درخت تصمیم در دنباله‌های توزیع اشباع می‌شود، حال آنکه مدل خطی در همان ناحیه برون‌یابی می‌کند. روزهای پرتنش دقیقاً همان روزهایی‌اند که قیمت به دنباله‌ی توزیع نزدیک می‌شود.

باید تصریح کرد که این تفسیر، پس از دیدن وزن‌ها نوشته شده است و نه پیش از آن؛ بنابراین توضیحی است بر یک الگوی مشاهده‌شده و نه فرضیه‌ای که آزموده شده باشد. آنچه آزموده شده، تنها این است که وزن‌دهی رژیم‌محور دقت را بهبود می‌دهد یا نه، و پاسخ آن در **بخش ۱-۵-۴** می‌آید.

یک مرجع مفید: کران اوراکل

برای آنکه بتوان قضاوت کرد بهبود رژیم‌محوری چه اندازه است، مرجعی لازم است: بهترین دقتی که هر بردار وزن ایستا می‌توانست بر دوره‌ی آزمون به دست آورد، اگر آن را با دانستن پاسخ انتخاب می‌کردیم. این کران اوراکل بر مجموعه‌ی اعضای تثبیت‌شده برابر 3.5580 است.

مقایسه گویاست و در **بخش ۱-۵-۴** بسط می‌یابد: ترکیب ایستای واقعی به 3.5742 می‌رسد، یعنی اندکی بالاتر از کران، که طبیعی است چون وزن‌هایش را بدون دیدن دوره‌ی آزمون برازش کرده است. ترکیب رژیم‌محور به 3.5569 می‌رسد — یعنی به عددی اندکی بهتر از بهترین وزن ایستای ممکن. این خود ادعای **بخش ۸-۳** را می‌سازد: بهبود از شرطی کردن وزن‌ها بر رژیم می‌آید و نه از یافتن وزن ایستای بهتر، چون هیچ وزن ایستایی نمی‌توانست به آن برسد.

بخش ۱-۵-۴ نشان خواهد داد که این بهبود کجا رخ می‌دهد، و پاسخ — تماماً بر روزهای پرتنش — همان چیزی است که این طراحی برای آن ساخته شده بود.

فصل چهارم

نتایج و تحلیل

۱-۴ مقدمه

این فصل نتایج را گزارش می‌کند. ساختار آن از پرسش‌های پژوهش پیروی می‌کند: **بخش ۲-۴** دقت افق ساعتی، **بخش ۳-۴** دقت افق روزانه، و **بخش ۴-۴** مقایسه‌ی دو مسیر رسیدن به هدف روزانه را می‌آورد. **بخش ۵-۴** آزمون‌های معناداری را در دو سطح ارائه می‌کند: نخست میان مدل‌های خود این پژوهش و سپس در برابر اعداد منتشرشده‌ی مرجع. **بخش ۶-۴** تحلیل تفسیرپذیری و **بخش ۷-۴** پاسخ صریح به چهار پرسش پژوهش را در بر می‌گیرد.

سه قید بر تمام اعداد این فصل حاکم است و یک‌بار در همین جا گفته می‌شود تا در هر بخش تکرار نشود.

قید نخست: اعداد تثبیت‌شده‌اند. تمام نتایج این فصل از یک نسخه‌ی تثبیت‌شده‌ی نتایج خوانده می‌شوند که پس از تولید، هرگز بازتولید نشده است. دلیل این تثبیت آن است که نگارش بر اعدادی متکی است که باید ثابت بمانند؛ اگر هر بار که متنی نوشته می‌شود مدلی دوباره اجرا شود، هیچ عددی در متن قابل استناد نخواهد بود. همه‌ی اعداد بر دوره‌ی آزمون یکسانی محاسبه شده‌اند: بازار EPEX-DE، از ۴ ژانویه ۲۰۱۶ تا ۳۱ دسامبر ۲۰۱۷، مبدأ پیش‌بینی.

قید دوم: مدل عمیق گزارش‌شده، مدل تک‌بذری است. تمام اعداد سرشناس این فصل، تحلیل تفسیرپذیری **بخش ۶-۴** و آزمون برون‌توزیعی فصل پنجم، بر شبکه‌ی عصبی آموزش‌دیده با بذر تصادفی ۴۲ استوارند. در **بخش ۲-۵-۴** مجموعه‌ای مکمل از اعداد نیز می‌آید که از میانگین‌گیری چند بذر به دست آمده است؛ آن مجموعه به‌صراحت با برچسب «مکمل» جدا شده و هرگز نباید با اعداد سرشناس آمیخته شود.

قید سوم: تمام p-مقدارها تصحیح‌شده‌اند. هیچ مقدار تصحیح‌نشده‌ای در این فصل نقل نمی‌شود، و برای خانواده‌ی اکتشافی بیست‌ویک‌تایی که **بخش ۵-۳** اعلام کرد، هر دو ستون خام و تصحیح‌شده گزارش می‌گردد.

چهار یافته‌ی ناخوشایند که این فصل پنهانشان نمی‌کند

خواندن این فصل با انتظار یک پیروزی یک‌دست، گمراه‌کننده خواهد بود. چهار نتیجه در آن هست که به سود روایت ساده نیستند، و هر چهار به‌صراحت گزارش می‌شوند؛ زیرا هر چهار در ده دقیقه برای یک داور قابل کشف‌اند، و یافته‌ی ناخوشایند گزارش‌شده به‌مراتب قوی‌تر از یافته‌ی ناخوشایند کشف‌شده است. نخست، این پژوهش بهترین مدل منتشرشده‌ی مرجع را شکست نمی‌دهد. با دو گونه از پنج گونه‌ی

منتشر شده تفاوت معناداری ندارد و از بهترین آن‌ها عقب می‌ماند [۱]. بخش ۴-۵-۲ این را با عدد و آزمون می‌آورد.

دوم، بهبود حاصل از وزن‌دهی رژیم‌محور، در حالت تجمیعی مرزی است. بخش ۴-۵-۱ آن را همراه با بازه‌ی حساسیتش گزارش می‌کند و نه به صورت یک عدد منفرد.

سوم، بهترین مدل آماری و بهترین مدل عمیق از نظر آماری تفکیک‌ناپذیرند. این خود یک یافته است درباره‌ی اینکه یادگیری عمیق در این بازار و این دوره چه چیزی می‌خرد، و در بخش ۴-۵-۱ به همین صورت گزارش می‌شود.

چهارم، مدل‌ها بیرون از دوره‌ی آموزش شکست می‌خورند. این یافته به فصل پنجم تعلق دارد، اما از همین‌جا اعلام می‌شود تا اعداد چشمگیر این فصل بدون آن خوانده نشوند.

۲-۴ نتایج پیش‌بینی ساعتی

این بخش دقت پیش‌بینی بردار ۲۴ مؤلفه‌ای قیمت‌های ساعتی روز بعد را گزارش می‌کند: هدف اصلی پژوهش، و پایه‌ای که نتایج بخش‌های بعدی بر آن بنا می‌شوند. تمام اعداد بر ۷۲۸ مبدأ پیش‌بینی و 17,472 ساعت دوره‌ی آزمون محاسبه شده‌اند.

جدول ۴-۱: دقت پیش‌بینی ساعتی بر دوره‌ی آزمون EPEX-DE، از ۴ ژانویه ۲۰۱۶ تا ۳۱ دسامبر ۲۰۱۷ (۷۲۸ مبدأ). واحد MAE و RMSE یورو بر مگاوات‌ساعت، sMAPE درصد، و rMAE بی‌بعد. مقدار کمتر بهتر است. مدل ساده مرجع است و نه رقیب.

rMAE	sMAPE	RMSE	MAE	مدل
0.8491	28.5954	13.2573	7.7501	ساده
0.4767	18.0349	7.1166	4.3507	SARIMAX
0.4272	16.6572	6.4750	3.8988	LEAR-LASSO
0.4347	15.7218	7.5024	3.9678	LightGBM
0.4244	15.5994	7.0198	3.8734	LSTM
0.3916	14.6710	6.6097	3.5742	ترکیب ایستا
0.3897	14.6439	6.5575	3.5569	ترکیب رژیم‌محور

ترتیب مدل‌ها

بر معیار MAE، ترتیب چنین است: ترکیب رژیم‌محور با 3.5569، ترکیب ایستا با 3.5742، LSTM با 3.8734، LEAR-LASSO با 3.8988، LightGBM با 3.9678، SARIMAX با 4.3507 و مدل ساده با

سه مشاهده از این ترتیب برمی خیزد که هر سه در **بخش ۴-۵-۱** با آزمون معناداری سنجیده می شوند؛ در اینجا تنها به عنوان مشاهده‌ی عددی ثبت می گردند.

یکم: فاصله‌ی میان سه مدل میانی بسیار کوچک است. LSTM, LEAR-LASSO و LightGBM در بازه‌ای به پهنای حدود هفت صدم یورو بر مگاوات ساعت جای می گیرند (3.8734 تا 3.9678). در برابر انحراف معیار خود سری قیمت، که 15.94 است، این فاصله ناچیز است. **بخش ۴-۵-۱** نشان می دهد که هیچ یک از تفاوت های درون این سه مدل، پس از تصحیح برای چندگانگی، معنادار نیست.

دوم: مدل خطی از مدل درختی جلوتر است. LEAR-LASSO با 3.8988 از LightGBM با 3.9678 بهتر عمل می کند. این نتیجه‌ای است که انتظار متعارف را برآورده نمی کند و باید بی تعدیل گزارش شود: در این بازار و این دوره، انعطاف پذیری مدل درختی به دقت بیشتر ترجمه نشد.

سوم: هر دو ترکیب از تمام اعضایشان بهترند. کوچک ترین MAE در میان تک مدل ها 3.8734 است، حال آنکه ترکیب ایستا به 3.5742 و ترکیب رژیم محور به 3.5569 می رسد. این بهبود از هر بهبودی که میان خود تک مدل ها دیده می شود بزرگ تر است، و برخلاف آن ها از آزمون معناداری نیز عبور می کند.

معیارها همیشه هم داستان نیستند

جدول ۴-۱ یک ناسازگاری آموزنده دارد که پوشاندنش آسان و گزارش کردنش درست تر است: بهترین مدل بر معیار RMSE، ترکیب رژیم محور نیست، بلکه LEAR-LASSO با 6.4750 است.

توضیح در تفاوت این دو معیار نهفته است. RMSE خطاها را به توان دو می رساند و در نتیجه به خطاهای بزرگ حساسیت به مراتب بیشتری دارد تا MAE. یک مدل می تواند میانگین خطای مطلق بهتری داشته باشد و هم زمان چند خطای بسیار بزرگ تر مرتکب شود. مقایسه‌ی LEAR-LASSO و LightGBM همین را نشان می دهد: مدل درختی در sMAPE بهتر است (15.7218 در برابر 16.6572) اما در RMSE به روشنی بدتر (7.5024 در برابر 6.4750) — یعنی خطاهای معمولی کوچک تر اما خطاهای حدی بزرگ تر، که با ماهیت درختی و اشباع شدن آن در دنباله ها سازگار است.

این ناسازگاری بر هیچ نتیجه‌ای در این پایان نامه اثر نمی گذارد، چون — همان گونه که **بخش ۳-۵** تصریح کرد — تمام آزمون های معناداری بر زیان قدر مطلق محاسبه می شوند و هر ادعای سرشناسی بر MAE یا rMAE بنا شده است. اما ثبت کردنش لازم است: انتخاب معیار، ترتیب مدل ها را تغییر می دهد، و پژوهشی که تنها معیار مساعد به حال خود را گزارش کند، همین واقعیت را پنهان کرده است.

خواندن معیار rMAE

ستون rMAE همان اطلاعات MAE را در مقیاسی تفسیرپذیر می‌دهد: نسبت خطای مدل به خطای پیش‌بینی ساده‌ی وقفه‌ی هفتگی. مقدار 0.3897 برای ترکیب رژیم‌محور یعنی این مدل حدود شصت و یک درصد از خطای آن مرجع را حذف می‌کند.

مقدار 0.8491 برای مدل ساده نیز، همان‌گونه که [بخش ۳-۵](#) توضیح داد، تناقض نیست: مدل ساده‌ی گزارش‌شده قاعده‌ی روز مشابه است، حال آنکه مخرج rMAE پیش‌بینی وقفه‌ی هفتگی محض است، و قاعده‌ی روز مشابه حدود پانزده درصد از آن بهتر عمل می‌کند.

آنچه این بخش ادعا نمی‌کند

اعداد این جدول به یک بازار، یک پنجره‌ی دوساله، یک معماری به‌ازای هر خانواده‌ی مدل و یک بودجه‌ی تنظیم پنجاه‌آزمایشی محدودند. این بخش نمی‌گوید که یادگیری عمیق بر روش‌های آماری برتری دارد یا ندارد؛ می‌گوید که در این شرایط مشخص، اختلاف آن‌ها کوچک بود. تعمیم این مشاهده به یک حکم کلی درباره‌ی خانواده‌های مدل، فراتر از شواهدی است که در دست است.

مقایسه با اعداد منتشرشده‌ی مرجع در [بخش ۴-۵-۲](#) می‌آید، و پرسش اینکه کدام‌یک از این تفاوت‌ها معنادارند در [بخش ۴-۵-۱](#) پاسخ داده می‌شود.

۴-۳ نتایج پیش‌بینی روزانه

هدف دوم پژوهش، میانگین بار پایه‌ی روزانه است: میانگین ۲۴ قیمت ساعتی هر روز. این بخش دقت هر دو مسیر رسیدن به آن را گزارش می‌کند، و [بخش ۴-۴](#) آن دو را مستقیماً با هم می‌سنجد.

هدف روزانه آسان‌تر از هدف ساعتی است

نخستین مشاهده، مقایسه‌ی این جدول با [جدول ۴-۱](#) است. بهترین MAE ساعتی 3.5569 بود؛ بهترین MAE روزانه 2.6484 است. یعنی خطا حدود بیست‌وشش درصد کمتر می‌شود.

توضیح این تفاوت در [بخش ۳-۳-۳](#) آمد: میانگین‌گیری روی ۲۴ ساعت، بخشی از نوسان درون‌روزی را حذف می‌کند. انحراف معیار سری روزانه 11.97 است در برابر 15.94 برای سری ساعتی، پس هدف روزانه ذاتاً هموارتر و قابل پیش‌بینی‌تر است.

جدول ۴-۲: دقت پیش‌بینی بار پایه‌ی روزانه بر همان دوره‌ی آزمون (۷۲۸ روز)، به تفکیک دو مسیر: مدل‌سازی مستقیم هدف روزانه، و میانگین‌گیری از ۲۴ پیش‌بینی ساعتی. مقدار کمتر بهتر است. مدل‌های ترکیبی مسیر مستقیم ندارند، چون اعضایشان ساعتی‌اند.

rMAE		MAE		مدل
تجمیعی	مستقیم	تجمیعی	مستقیم	
0.7949	0.7949	6.3575	6.3575	ساده
0.4088	0.3998	3.2691	3.1976	SARIMAX
0.3550	0.3625	2.8389	2.8989	LEAR-LASSO
0.3742	0.4128	2.9928	3.3012	LightGBM
0.3476	0.3970	2.7804	3.1753	LSTM
0.3347	–	2.6768	–	ترکیب ایستا
0.3311	–	2.6484	–	ترکیب رژیم‌محور

نکته‌ی مهم آنکه این مقایسه را نباید به‌عنوان برتری یک روش بر روش دیگر خواند. دو هدف متفاوت‌اند و کاربردهای متفاوت دارند: پیش‌بینی ساعتی برای پیشنهاددهی در حراج لازم است و پیش‌بینی روزانه برای قراردادهای بار پایه. سنجه‌ی rMAE نیز همین را تأیید می‌کند که آسان‌تر شدن مسئله تنها بخشی از ماجراست: مدل ساده در افق روزانه rMAE برابر 0.7949 دارد در برابر 0.8491 در افق ساعتی، یعنی خودِ مرجع هم آسان‌تر شده است.

ترتیب مدل‌ها در مسیر تجمیعی

در مسیر تجمیعی، ترتیب چنین است: ترکیب رژیم‌محور 2.6484، ترکیب ایستا 2.6768، LSTM 2.7804، LEAR-LASSO 2.8389، LightGBM 2.9928، SARIMAX 3.2691 و مدل ساده 6.3575. این ترتیب با ترتیب افق ساعتی یکسان است، و همین یکسانی خود اطلاعاتی می‌دهد: رتبه‌بندی نسبی خانواده‌های مدل به انتخاب افق حساس نیست. مدلی که در افق ساعتی بهتر بود، در افق روزانه نیز بهتر است.

ترتیب مدل‌ها در مسیر مستقیم، و یک استثنا

در مسیر مستقیم اما ترتیب تغییر می‌کند، و این تغییر موضوع اصلی بخش ۴-۴ است. LEAR-LASSO با 2.8989 بهترین مدل مستقیم است، و SARIMAX با 3.1976 از LightGBM با 3.3012 جلو می‌افتد — در حالی که در مسیر تجمیعی عکس آن برقرار بود. جابه‌جایی SARIMAX از جایگاه آخر در میان مدل‌های برازشی به جایگاه سوم، تصادفی نیست.

مدل مستقیم بر یک سری تک‌بعدی هموار برازش می‌شود، و این دقیقاً همان ساختاری است که یک مدل کلاسیک سری زمانی برای آن ساخته شده است. مدل درختی و شبکه‌ی عصبی، در مقابل، بخشی از توانشان را در همان ماتریس ۲۴۷ ستونی به کار می‌گیرند که برای هدف ساعتی طراحی شده بود.

ترکیب در افق روزانه نیز کار می‌کند

هر دو مدل ترکیبی، در افق روزانه نیز از تمام اعضایشان بهترند: 2.6484 و 2.6768 در برابر بهترین تک‌مدل تجمیعی با 2.7804. فاصله‌ی میان ترکیب رژیم‌محور و ترکیب ایستا در این افق 0.0284 است، در برابر 0.0173 در افق ساعتی.

با این‌همه، آزمون معناداری رسمی این تفاوت در **بخش ۴-۵-۱** تنها برای افق ساعتی گزارش می‌شود، چون فرضیه‌ی از پیش تعیین‌شده‌ی پژوهش بر همان افق تعریف شده بود. تفاوت روزانه به‌عنوان یک مشاهده‌ی عددی هم‌راستا ثبت می‌گردد و نه به‌عنوان یک نتیجه‌ی آزموده؛ خواندن آن به‌صورت یک ادعای معنادار، همان چیزی است که اعلام خانواده‌ی آزمون در **بخش ۳-۵** برای جلوگیری از آن انجام شد.

آنچه این بخش ادعا نمی‌کند

همان قید **بخش ۴-۲** در اینجا نیز برقرار است. اعداد این جدول به یک بازار و یک پنجره‌ی دوساله محدودند. افزون بر آن، مسیر مستقیم تنها برای چهار مدل برازشی و مدل ساده وجود دارد و برای مدل‌های ترکیبی تعریف نشده است، چون اعضای آن‌ها ساعتی‌اند؛ پس مقایسه‌ی **بخش ۴-۴** نیز به همان چهار مدل محدود می‌ماند.

۴-۴ مقایسه روش مستقیم و تجمیعی

پرسش پژوهشی چهارم مستقیم است: برای پیش‌بینی میانگین بار پایه‌ی روزانه، کدام مسیر دقت بالاتری دارد — مدل‌سازی مستقیم هدف روزانه، یا میانگین‌گیری از ۲۴ پیش‌بینی ساعتی؟ و آیا پاسخ برای همه‌ی مدل‌ها یکسان است؟

پاسخ به بخش دوم پرسش منفی است، و همین آن را به یافته بدل می‌کند.

جدول ۳-۴: مقایسه‌ی مستقیم دو مسیر رسیدن به هدف روزانه بر معیار MAE. ستون «اختلاف» مقدار مسیر تجمیعی منهای مسیر مستقیم است؛ مقدار منفی یعنی تجمیع بهتر بوده است. مدل ساده در هر دو مسیر یکسان است.

مدل	مستقیم	تجمیعی	اختلاف	برنده
SARIMAX	3.1976	3.2691	+0.0715	مستقیم
LEAR-LASSO	2.8989	2.8389	-0.0600	تجمیعی
LightGBM	3.3012	2.9928	-0.3084	تجمیعی
LSTM	3.1753	2.7804	-0.3949	تجمیعی
ساده	6.3575	6.3575	0.0000	یکسان

تجمیع در سه مورد از چهار مورد برنده است

برای LightGBM، LSTM و LEAR-LASSO، میانگین‌گیری از ۲۴ پیش‌بینی ساعتی دقیق‌تر از مدل‌سازی مستقیم است. اندازه‌ی این برتری یکسان نیست: برای LEAR-LASSO تنها 0.0600 است، اما برای LightGBM 0.3084 و برای LSTM 0.3949.

توضیح این الگو در مقدار اطلاعاتی است که هر مسیر در اختیار مدل می‌گذارد. مسیر تجمیعی، مدل را وادار می‌کند ساختار درون‌روزی را یاد بگیرد — یعنی ۲۴ هدف مجزا با ۲۴ الگوی متفاوت — و سپس آن ۲۴ پیش‌بینی را میانگین می‌گیرد. خطاهای ساعت‌های مختلف کاملاً هم‌پسته نیستند، پس بخشی از آن‌ها در میانگین‌گیری یکدیگر را خنثی می‌کنند. مسیر مستقیم، در مقابل، این ساختار را از همان ابتدا دور می‌ریزد و تنها یک عدد در روز را هدف می‌گیرد.

اینکه بیشترین سود از آن دو مدل غیرخطی است نیز با همین توضیح سازگار است: مدل‌های انعطاف‌پذیرتر توان بیشتری برای بهره‌بردن از ۲۴ الگوی مجزا دارند، و در مقابل، وقتی به یک هدف تک‌بعدی محدود شوند بیشترین سهم از ظرفیتشان بلااستفاده می‌ماند.

SARIMAX استثناست، و این استثنا واقعی است

SARIMAX تنها مدلی است که مسیر مستقیم برایش بهتر عمل می‌کند: 3.1976 در برابر 3.2691. این نتیجه را نباید به‌عنوان نطفه کنار گذاشت یا در میانگینی پنهان کرد؛ توضیحی ساختاری دارد. SARIMAX یک مدل کلاسیک سری زمانی است که برای سری‌های تک‌بعدی با ساختار خودهمبستگی و مؤلفه‌ی فصلی طراحی شده است. سری بار پایه‌ی روزانه دقیقاً چنین سری‌ای است: هموار، تک‌بعدی، با تناوب هفتگی روشن. وقتی این مدل مستقیماً بر آن سری برازش می‌شود، در زیستگاه طبیعی خودش قرار دارد.

در مسیر تجمیعی، همین مدل باید ۲۴ سری ساعتی به مراتب پرنوفه‌تر را مدل کند و سپس نتایج را میانگین بگیرد. هر یک از آن ۲۴ برازش، خطای خود را دارد، و برخلاف مدل‌های انعطاف‌پذیرتر، SARIMAX نمی‌تواند از ساختار مشترک میان ساعت‌ها بهره ببرد، چون ۲۴ مدل کاملاً مستقل‌اند. افزون بر آن، همان‌گونه که بخش ۳-۶ ثبت کرد، این مدل تنها هر هفت روز به‌طور کامل بازبرازش می‌شود، و این محدودیت در ۲۴ سری پرنوفه هزینه‌ی بیشتری دارد تا در یک سری هموار.

چرا این مقایسه منصفانه است

اعتبار این بخش تماماً به یک نکته بستگی دارد: هر دو مسیر باید تلاش برابری دریافت کرده باشند. اگر مسیر مستقیم بودجه‌ی تنظیم کمتری می‌گرفت، هر برتری مسیر تجمیعی می‌توانست صرفاً بازتاب همان نابرابری باشد و نه خاصیت خود مسیر.

سه چیز میان دو مسیر یکسان نگه داشته شده است: همان ماتریس ویژگی، همان مبادی پیش‌بینی، و همان بودجه‌ی تنظیم پنجاه‌آزمایشی به‌ازای هر مدل. مسیر مستقیم پیکربندی تنظیم‌شده‌ی مستقل خود را دارد، که با همان شمار آزمایش و بر همان پنجره‌ی اعتبارسنجی به دست آمده است. این برابری، طراحی آگاهانه بوده و همان چیزی است که نتیجه‌ی این بخش را از یک مصنوع طراحی جدا می‌کند.

آنچه این بخش ادعا نمی‌کند

این بخش قاعده‌ای کلی درباره‌ی تجمیع زمانی در پیش‌بینی ارائه نمی‌دهد. چهار مدل، یک بازار، یک پنجره‌ی دوساله. آنچه می‌گوید این است که در این شرایط، تجمیع برای سه مدل از چهار مدل بهتر بود و استثنای چهارم توضیح ساختاری دارد — و اینکه پرسش پژوهشی عامدانه چنان صورت‌بندی شده بود که این استثنا بخشی از پاسخ باشد و نه دردسری برای آن.

۴-۵ آزمون دیبولد-ماریانو

جدول‌های جدول‌های ۱-۴ تا ۳-۴ اختلاف‌های عددی را نشان دادند، اما اختلاف عددی به‌تنهایی چیزی را اثبات نمی‌کند. دو مدل که بر ۷۲۸ مبدأ پیش‌بینی، میانگین خطایی با فاصله‌ی چند صدم یورو دارند، ممکن است صرفاً بازتاب همان نمونه‌ی خاص باشند. آزمون دیبولد-ماریانو دقیقاً همین را می‌سنجد: آیا سری اختلاف زیان دو مدل، میانگینی به‌طور نظام‌مند متفاوت از صفر دارد؟

سه قید که در بخش ۳-۵ تثبیت شد و در سراسر این بخش برقرار است:

- تمام p -مقدارها با تصحیح HAC برای خودهمبستگی و ناهمسانی واریانس محاسبه شده‌اند. p -مقدارهای تصحیح‌نشده در هیچ جای این فصل نقل نمی‌شوند.
- آزمون‌ها یک‌طرفه‌اند. در هر جدول، p احتمال آن است که مدل سطر بهتر از مدل ستون نباشد؛ پس مقدار کوچک یعنی سطر بهتر است.
- دو خانواده‌ی آزمون از پیش اعلام شده‌اند و اینجا از هم جدا می‌مانند.

خانواده‌ی نخست — خانواده‌ی تأییدی — تنها یک فرضیه دارد: اینکه وزن‌دهی رژیم‌محور بر وزن‌دهی ایستا برتری دارد. این فرضیه در تاریخ یازدهم ژوئیه ۲۰۲۶ در دفتر تصمیم‌های پروژه ثبت شد، یعنی زمانی که هنوز هیچ ترکیبی بر پنجره‌ی آزمون امتیازدهی نشده بود. یک فرضیه‌ی از پیش تعیین‌شده بدون تصحیح در سطح 0.05 آزموده می‌شود.

خانواده‌ی دوم — خانواده‌ی اکتشافی — کل ماتریس ۲۱ تایی مقایسه‌های دوجه‌دوی **بخش ۱-۵-۴** است. برای این خانواده، هم p -مقدار خام و هم p -مقدار تصحیح‌شده با روش هولم-بونفرونی گزارش می‌شود، و هر ادعای معناداری تنها بر پایه‌ی ستون تصحیح‌شده بیان می‌گردد. گزارش کردن تنها ستون خام، در ماتریسی با ۲۱ آزمون، به‌طور متوسط یک برنده‌ی کاذب تولید می‌کند. **بخش ۱-۵-۴** مدل‌های این پژوهش را با یکدیگر می‌سنجد و **بخش ۲-۵-۴** آن‌ها را در برابر پیش‌بینی‌های منتشرشده‌ی لاگو و همکاران [۱] قرار می‌دهد.

۱-۵-۴ مقایسه مدل‌های این پژوهش

ماتریس کامل مقایسه‌های دوجه‌دو

هفت مدل — پنج مدل منفرد و دو ترکیب — ۲۱ مقایسه‌ی دوجه‌دو تولید می‌کنند. **جدول ۴-۴** همه‌ی آن‌ها را می‌آورد. هیچ سلولی حذف نشده است؛ گزینش سلول‌ها پس از دیدن نتیجه، همان کاری است که تصحیح چندگانگی برای مهارش وجود دارد.

ماتریس پس از تصحیح هولم-بونفرونی

اعمال روش هولم-بونفرونی بر هر ۲۱ آزمون، ۱۷ آزمون را دست‌نخورده باقی می‌گذارد و ۴ آزمون را از فهرست نتایج معنادار بیرون می‌برد. **جدول ۵-۴** خلاصه‌ی آن است. هیچ مدلی برای این محاسبه بازاجرا نشد؛ تصحیح صرفاً بر همان p -مقدارهای تثبیت‌شده‌ی **جدول ۴-۴** انجام گرفته است.

جدول ۴-۴: p-مقدارهای خام آزمون دیبولد-ماریانو با تصحیح HAC، افق ساعتی، ۷۲۸ مبدأ. هر درایه احتمال آن است که مدل سطر بهتر از مدل ستون نباشد؛ مقدار نزدیک به صفر یعنی سطر بهتر است. ستون‌ها به همان ترتیب سطرها شماره‌گذاری شده‌اند. این ستون خام است و به‌تنهایی مبنای هیچ ادعای معناداری قرار نمی‌گیرد — جدول ۵-۴ را ببینید.

مدل	۱	۲	۳	۴	۵	۶	۷
۱ ساده	—	1.000	1.000	1.000	1.000	1.000	1.000
۲ SARIMAX	0.000	—	1.000	0.9999	1.000	1.000	1.000
۳ LEAR-LASSO	0.000	0.000	—	0.2665	0.5964	1.000	1.000
۴ LightGBM	0.000	0.0001	0.7335	—	0.9595	1.000	1.000
۵ LSTM	0.000	0.000	0.4036	0.0405	—	1.000	1.000
۶ ترکیب ایستا	0.000	0.000	0.000	0.000	0.000	—	0.9774
۷ ترکیب رژیم‌محور	0.000	0.000	0.000	0.000	0.000	0.0226	—

جدول ۵-۴: نتیجه‌ی تصحیح هولم-بونفرونی بر خانواده‌ی اکتشافی ۲۱ آزمونه. «مقاوم» یعنی نتیجه پس از تصحیح نیز در سطح 0.05 برقرار می‌ماند.

مقایسه	p خام	p هولم	وضعیت
هر شش مدل در برابر ساده	0.000	0.000	مقاوم
دو ترکیب در برابر هر عضو (۸ آزمون)	$\leq 4.8e-06$	$\leq 3.4e-05$	مقاوم
SARIMAX در برابر سه مدل دیگر	$\leq 1.0e-04$	$\leq 5.1e-04$	مقاوم
ترکیب رژیم‌محور در برابر ایستا	0.0226	0.0903	مقاوم نیست
LSTM در برابر LightGBM	0.0405	0.1215	مقاوم نیست
LEAR-LASSO در برابر LightGBM	0.2665	0.5329	از ابتدا تهی
LEAR-LASSO در برابر LSTM	0.4036	0.5329	از ابتدا تهی

هرچه ساختاری است، دست نخورده می ماند. اینکه هر چهار مدل آموخته بر مدل ساده برتری دارند و اینکه هر دو ترکیب بر تک تک اعضای خود برتری دارند، پس از تصحیح نیز با فاصله‌ی زیادی برقرار است. آنچه از دست می رود، دو ادعای مرزی است.

سه مدل که از هم جدا نمی شوند

LSTM با 3.8734، LEAR-LASSO با 3.8988 و LightGBM با 3.9678 در فاصله‌ی کمتر از یک‌دهم یورو بر مگاوات ساعت از یکدیگر قرار دارند، و آزمون هیچ کدام را از دیگری جدا نمی کند.

مقایسه‌ی LSTM با LEAR-LASSO حتی پیش از تصحیح نیز تهی است: p برابر 0.4036. این عدد جای تفسیر ظریف ندارد. بهترین مدل آماری و بهترین مدل یادگیری عمیق این پژوهش، بر این بازار و این پنجره، از یکدیگر تفکیک پذیر نیستند.

مقایسه‌ی LSTM با LightGBM ظریف تر است و باید با دقت نوشته شود. p -مقدار خام 0.0405 است، که در نگاه نخست معنادار به نظر می رسد. اما این آزمون در خانواده‌ی اکتشافی ۲۱ تایی قرار دارد و پس از تصحیح هولم به 0.1215 می رسد. بنابراین: LSTM بر آورد نقطه‌ای پایین تری دارد، و این تفاوت تصحیح برای چندگانگی را تاب نمی آورد.

این تصمیم نوشتاری، برخلاف ظاهرش، پاسخ به پرسش پژوهشی نخست را تقویت می کند. خوانش صادقانه این می شود که سه خانواده‌ی مدلی متفاوت — خطی منظم شده، درخت تقویت شده و شبکه‌ی بازگشتی — با بودجه‌ی تنظیم برابر به دقتی می رسند که آزمون آماری از هم تمیزشان نمی دهد؛ و تنها ترکیب است که از این سه فاصله می گیرد. ادعای ضعیف تر اما مقاوم «تفکیک ناپذیرند» بسیار دفاع پذیرتر از ادعای قوی تر «LSTM بهتر است» است که با یک تصحیح استاندارد فرو می ریزد.

ترکیب: تنها جدایی مقاوم

هر دو ترکیب بر تک تک اعضای خود برتری دارند، و این هشت مقایسه پس از تصحیح هولم نیز با p حداکثر $3.4e-05$ برقرار می ماند. این مقاوم ترین یافته‌ی این بخش پس از برتری بدیهی بر مدل ساده است.

اندازه‌ی این برتری اما متواضع است. ترکیب ایستا 3.5742 و ترکیب رژیم محور 3.5569 در برابر بهترین عضو منفرد با 3.8734؛ یعنی بهبودی حدود هشت درصد. بخش ۳-۸ کرانِ اوراکل را 3.5580 گزارش کرد: بهترین وزن های ایستایی که با دانستن کامل دوره‌ی آزمون قابل انتخاب بودند. ترکیب ایستای واقعی 3.5742 است، پس فاصله تا آن کران کمتر از دو صدم یورو بر مگاوات ساعت است. عملاً

هیچ وزن‌دهی ایستایی نمی‌توانست از این بهتر عمل کند، و این خود توضیح می‌دهد که چرا گام بعدی مشروط کردن وزن‌ها به رژیم بود و نه جست‌وجوی وزن‌های بهتر.

وزن‌دهی رژیم‌محور: آزمون تأییدی

این تنها فرضیه‌ی خانواده‌ی تأییدی است، و باید با هر سه عددش با هم بیان شود.

بر مجموع ۷۲۸ روز، ترکیب رژیم‌محور با 3.5569 در برابر 3.5742 برتری دارد و p برابر 0.0226 است. به‌عنوان یک فرضیه‌ی از پیش ثبت‌شده، این در سطح 0.05 معنادار است. اما دو قید باید بی‌درنگ کنارش بیاید. نخست آنکه اگر همین آزمون از خانواده‌ی اکتشافی برداشته شده بود، پس از تصحیح هولم به 0.0903 می‌رسید و معنادار نمی‌ماند؛ دفاع از آن تماماً بر ثبت تاریخ‌دار پیش از اجرا استوار است، نه بر اندازه‌ی خودِ عدد. دوم آنکه، چنان‌که **جدول ۴-۷** نشان می‌دهد، تحت محافظه‌کارانه‌ترین فرض وابستگی، همین p از 0.05 عبور می‌کند.

جدول ۴-۶ نشان می‌دهد این بهبود از کجا می‌آید، و پاسخ تیزتر از چیزی است که میانگین کل نشان می‌دهد.

جدول ۴-۶: تفکیک برتری ترکیب رژیم‌محور بر ترکیب ایستا به تفکیک رژیم بازار. MAE بر حسب یورو بر مگاوات‌ساعت.

زیرمجموعه	روز	رژیم‌محور	ایستا	p
کل دوره	۷۲۸	3.5569	3.5742	0.0226
روزهای پرتنش	۷۷	5.5132	5.6830	0.0063
روزهای آرام	۶۵۱	3.3255	3.3248	0.8465

تمام بهبود از ۷۷ روز پرتنش می‌آید. آنجا اختلاف 0.1698 یورو بر مگاوات‌ساعت و p برابر 0.0063 است. بر ۶۵۱ روز آرام، ترکیب رژیم‌محور به‌اندازه‌ی ده‌هزارم یورو بدتر است و p برابر 0.8465؛ یعنی هیچ. این دقیقاً همان چیزی است که سازوکار برای انجامش ساخته شده بود. وزن‌های رژیم آرام و وزن‌های ایستا تقریباً یکسان‌اند — **جدول ۳-۱** این را نشان می‌دهد — چون ۳۲۰ روز از ۳۵۷ روز پنجره‌ی برازش آرام بودند و عملاً همان وزن‌ها را تعیین کردند. تفاوت تنها در سبد پرتنش پدید می‌آید. پس بیان درست ادعا این است: مشروط کردن وزن‌ها به رژیم، در روزهای پرتنش کمک می‌کند و در روزهای آرام بی‌اثر است. این ادعایی محدودتر از «ترکیب رژیم‌محور بهتر است» می‌باشد و برخلاف آن، هم با اعداد سازگار است و هم با هدف اعلام‌شده‌ی طراحی.

آزمون مقاومت: بوت استرپ بلوکی

آزمون دیبولد-ماریانو با تصحیح HAC خودهمبستگی سری اختلاف زیان را تا مرتبه‌ای معین جبران می‌کند. برای سنجش حساسیت نتیجه به این فرض، همان مقایسه با بوت استرپ بلوکی در طول‌های بلوک ۳ تا ۱۰ روز نیز اجرا شد.

جدول ۴-۷: حساسیت نتیجه‌ی «رژیم‌محور در برابر ایستا» به طول بلوک در بوت استرپ بلوکی. ستون آخر p-مقدار HAC برای همان زیرمجموعه است و در هر سطر ثابت می‌ماند.

زیرمجموعه	طول بلوک	p بوت استرپ	HAC p
کل دوره	۳	0.0129	0.0226
کل دوره	۵	0.0269	0.0226
کل دوره	۷	0.0396	0.0226
کل دوره	۱۰	0.0571	0.0226
پرتنش	۳	0.0081	0.0063
پرتنش	۵	0.0193	0.0063
پرتنش	۷	0.0311	0.0063
پرتنش	۱۰	0.0439	0.0063
آرام	۳	0.8525	0.8465
آرام	۱۰	0.8399	0.8465

نتیجه‌ی این آزمون باید بی‌کم‌وکاست گزارش شود. بر کل دوره، p از 0.0129 در بلوک‌های سه‌روزه تا 0.0571 در بلوک‌های ده‌روزه تغییر می‌کند — یعنی زیر محافظه کارانه‌ترین فرض وابستگی، از آستانه‌ی 0.05 عبور می‌کند. بر زیرمجموعه‌ی پرتنش، بازه 0.0081 تا 0.0439 است و در سراسر آن معنادار می‌ماند. بر روزهای آرام، p در حدود 0.84 تا 0.85 ثابت است.

جمع‌بندی صادقانه چنین است: نتیجه‌ی تجمیع‌شده مرزی است و نتیجه‌ی زیرمجموعه‌ی پرتنش پابرجاست. این دو جمله با هم، همان ادعایی را می‌سازند که این پژوهش می‌تواند از آن دفاع کند، و نوشتن جمله‌ی نخست، جمله‌ی دوم را نیز مشکوک می‌کرد.

۴-۵-۲ مقایسه با نتایج منتشرشده

چه چیزی با چه چیزی سنجیده می‌شود

لاگو و همکاران [۱] علاوه بر جدول‌های مقاله، فایل‌های پیش‌بینی خام مدل‌هایشان را نیز منتشر کرده‌اند. این پژوهش از همان فایل‌ها استفاده می‌کند و آن‌ها را با کد سنجی خود این پژوهش دوباره امتیازدهی می‌نماید. پس مقایسه‌ی زیر بر یک بازار، یک پنجره‌ی آزمون، یک مجموعه‌ی مبادی و یک پیاده‌سازی

واحد سنجها انجام می‌شود. اگر به‌جای این کار اعداد چاپ‌شده‌ی مقاله در برابر اعداد ما گذاشته می‌شد، دو مسیر محاسبه‌ی متفاوت با هم مقایسه می‌شدند و تفاوت‌های کوچک بی‌معنا می‌بود.

جدول ۴-۸: مدل‌های این پژوهش در برابر منتخبی از گونه‌های منتشرشده‌ی لاگو و همکاران [۱]، بر بازار EPEX-DE و همان دوره‌ی آزمون. تمام اعداد با کد سنج‌ی این پژوهش از فایل‌های پیش‌بینی منتشرشده محاسبه شده‌اند. مرتب‌شده بر پایه‌ی MAE.

مدل	منبع	MAE	rMAE
DNN Ensemble	لاگو و همکاران	3.4135	0.3740
ترکیب رژیم‌محور	این پژوهش	3.5569	0.3897
ترکیب ایستا	این پژوهش	3.5742	0.3916
DNN 4	لاگو و همکاران	3.5917	0.3935
LEAR Ensemble	لاگو و همکاران	3.6091	0.3954
LSTM	این پژوهش	3.8734	0.4244
LEAR-LASSO	این پژوهش	3.8988	0.4272
LEAR 1092	لاگو و همکاران	3.9298	0.4306

نتیجه‌ی آزمون، بدون تلطیف

جدول ۴-۹: چهار مقایسه‌ی مستقیم ترکیب رژیم‌محور با گونه‌های لاگو را می‌آورد.

جدول ۴-۹: آزمون دیبولد-ماریانو با تصحیح HAC، ترکیب رژیم‌محور این پژوهش در برابر گونه‌های منتشرشده. ستون p احتمال آن است که مدل این پژوهش بهتر نباشد.

در برابر	MAE آن‌ها	p	نتیجه
DNN Ensemble	3.4135	0.9873	آن‌ها بهتر است
DNN 4	3.5917	0.3222	تفاوت معنادار نیست
LEAR Ensemble	3.6091	0.1271	تفاوت معنادار نیست
LEAR 1092	3.9298	1.0e-07	آن‌ها بهتر است

جمله‌ای که باید نوشته شود، همین است و نه بیش از آن: این پژوهش بهترین مدل منتشرشده را شکست نمی‌دهد. ترکیب DNN آن‌ها با 3.4135 در برابر 3.5569 برتری دارد و این برتری معنادار است (p برابر 0.0127 در جهت مقابل). در برابر دو گونه‌ی دیگر آن‌ها — DNN 4 و LEAR Ensemble — تفاوت معنادار نیست، یعنی مدل این پژوهش با آن‌ها هم‌تراز است. و بر LEAR 1092 برتری روشن دارد.

این نتیجه در فصل نخست پیش‌بینی نشده بود که رخ ندهد؛ برعکس، پس از نقطه‌ی بازبینی هفته‌ی پنجم، دفاع پروژه آگاهانه از مسیر «بهبود جدول امتیازها» به مسیر «مشارکت روش‌شناختی» منتقل

شد. آنچه این بخش نشان می‌دهد — هم‌ترازی با میانه‌ی گونه‌های منتشرشده، با ترکیبی از خانواده‌های مدلی متفاوت — پشتوانه‌ی همان تصمیم است، نه شاهده‌ی بر شکست آن.

یک یافته‌ی بازتولیدپذیری که ارزش ثبت دارد

هنگام امتیازدهی دوباره‌ی فایل‌های منتشرشده، یک ناهم‌خوانی نظام‌مند آشکار شد که شایسته‌ی ثبت است، چون درباره‌ی خود ادبیات مرجع چیزی می‌گوید.

سطرهای DNN دقیقاً بازتولید می‌شوند. DNN Ensemble در مقاله 3.413 چاپ شده و از فایل‌ها 3.4135 به دست می‌آید؛ DNN 4 در مقاله 3.592 و از فایل‌ها 3.5917. اختلاف تنها در گرد کردن است. سطرهای LEAR بازتولید نمی‌شوند. LEAR Ensemble در جدول مقاله 3.955 است اما از فایل‌های منتشرشده 3.6091 امتیاز می‌گیرد؛ LEAR 1092 در مقاله 4.108 است و از فایل‌ها 3.9298. الگو یکنواخت است: در تمام گونه‌های LEAR، فایل‌های منتشرشده بهتر از جدول چاپ‌شده امتیاز می‌گیرند. انتخاب این پژوهش، استفاده از فایل‌های منتشرشده بوده است. باید توجه داشت که این محافظه‌کارانه‌ترین انتخاب ممکن است: فایل‌ها مدل‌های آن‌ها را بهتر نشان می‌دهند، پس فاصله‌ی این پژوهش تا آن‌ها را بیشتر می‌کند، نه کمتر. اگر اعداد چاپ‌شده مبنا قرار می‌گرفت، ترکیب این پژوهش بر هر دو گونه‌ی LEAR برتری آشکار پیدا می‌کرد. علت این ناهم‌خوانی از بیرون قابل تعیین نیست — می‌تواند نسخه‌ای متفاوت از کد، پنجره‌ای متفاوت یا اشتباهی در نگارش جدول باشد — و این پژوهش هیچ‌یک را ادعا نمی‌کند. آنچه ادعا می‌شود صرفاً همین است که این دو منبع با هم نمی‌خوانند، و پژوهشگری که به یکی از آن‌ها استناد کند نتیجه‌ای متفاوت از دیگری خواهد گرفت.

افزوده‌ی تکمیلی: ترکیب بذرها

آنچه در ادامه می‌آید تکمیلی است و هیچ عددی از آن وارد نتایج اصلی این پایان‌نامه نمی‌شود. تمام جدول‌های بخش ۲-۴ تا بخش ۲-۵-۴، تحلیل بخش ۴-۶ و آزمون برون‌توزیعی بخش ۵-۲ همگی بر مدل LSTM با بذر تثبیت‌شده‌ی ۴۲ استوارند و با این افزوده تغییر نمی‌کنند.

مدل‌های شبکه‌ی عصبی به مقدار اولیه‌ی تصادفی حساس‌اند. برای سنجش اینکه چه مقدار از فاصله‌ی این پژوهش تا لاگو ناشی از همین حساسیت است، LSTM با چهار بذر ۴۲ تا ۴۵ آموزش داده شد و میانگین پیش‌بینی‌های آن‌ها به جای مدل تک‌بذری در ترکیب نشست.

اثر آن قابل توجه است. خود LSTM از 3.8734 به 3.6460 می‌رسد، و ترکیب رژیم‌محور از 3.5569 به 3.4994. مهم‌تر از عدد، تغییر نتیجه‌ی آزمون است: برتری DNN Ensemble که با مدل تثبیت‌شده

جدول ۴-۱۰: اثر میانگین‌گیری بر چهار بذر LSTM. تکمیلی — این اعداد جایگزین نتایج تثبیت‌شده نمی‌شوند و در هیچ جدول دیگری تکرار نمی‌گردند.

rMAE	MAE	پیکربندی
0.4244	3.8734	LSTM، بذر ۴۲ (تثبیت‌شده)
0.3995	3.6460	LSTM، ترکیب چهار بذر
0.3916	3.5742	ترکیب ایستا، با LSTM تثبیت‌شده
0.3863	3.5260	ترکیب ایستا، با ترکیب بذرها
0.3897	3.5569	ترکیب رژیم‌محور، با LSTM تثبیت‌شده
0.3834	3.4994	ترکیب رژیم‌محور، با ترکیب بذرها
0.3740	3.4135	DNN Ensemble (مرجع)

در p برابر 0.0127 معنادار بود، با ترکیب بذرها به 0.0803 می‌رسد و دیگر معنادار نیست. این نکته را باید با احتیاط خواند. آنچه نشان می‌دهد این نیست که این پژوهش با DNN Ensemble برابر است؛ نشان می‌دهد که بخشی از فاصله‌ی سنجیده‌شده، نوفه‌ی مقداردهی اولیه است و نه تفاوت روش. ضمناً مقایسه به این شکل کاملاً منصفانه نیست، چون گونه‌ی مرجع خود یک ترکیب است و مدل تثبیت‌شده‌ی این پژوهش تک‌اجرا. اما دلیل اینکه این اعداد جای اعداد اصلی را نمی‌گیرند، ساده و انضباطی است: تثبیت نتایج پیش از آغاز نگارش انجام شد، و جابه‌جا کردن پس از آن، هر تضمینی را که آن تثبیت فراهم می‌کند باطل می‌کرد. کرانِ اوراکل برای پیکربندی ترکیب‌بذری 3.5019 است، در برابر 3.5580 برای پیکربندی تثبیت‌شده.

۴-۶ تحلیل تفسیرپذیری SHAP

پرسش، و آنچه این بخش می‌تواند و نمی‌تواند پاسخ دهد

بخش‌های پیشین نشان دادند کدام مدل چقدر دقیق است. این بخش پرسش دیگری را دنبال می‌کند: مدل بر چه چیزی تکیه می‌کند، و آیا این تکیه‌گاه با تغییر شرایط بازار جابه‌جا می‌شود؟ روش، مقادیر SHAP است [۴۲]: چارچوبی که سهم هر ویژگی در فاصله‌ی میان پیش‌بینی یک نمونه و میانگین پیش‌بینی‌ها را به صورت جمعی تجزیه می‌کند. مزیت آن نسبت به شاخص‌های اهمیت سنتی درختی این است که سهم‌ها جمع‌شونده و نمونه‌به‌نمونه‌اند، پس می‌توان آن‌ها را روی هر زیرمجموعه‌ای از روزها میانگین گرفت و مقایسه کرد — و کل این بخش دقیقاً بر همین خاصیت بنا شده است. کاربرد آن در پیش‌بینی قیمت برق سابقه دارد [۳۷].

پیش از هر عددی، سه قید دامنه باید ثبت شود.

یکم: این تحلیل مختص LightGBM است. پیاده‌سازی از TreeExplainer استفاده می‌کند که برای مدل‌های درختی، مقادیر SHAP را دقیق و نه تقریبی محاسبه می‌کند. چهار مدل دیگر این پژوهش تحلیل نمی‌شوند، و هیچ نتیجه‌ای از این بخش به آن‌ها تعمیم داده نمی‌شود. LEAR-LASSO سازوکار تفسیرپذیری خودش را دارد — ضرایبی که بخشی‌شان صفر شده‌اند — و LSTM هیچ‌کدام را ندارد. اینکه سه مدل با دقت آماری تفکیک‌ناپذیر (بخش ۴-۵-۱) از اطلاعات یکسانی استفاده می‌کنند یا نه، پرسشی است که این پژوهش به آن پاسخ نمی‌دهد.

دوم، و مهم‌تر: مدلی که توضیح داده می‌شود، همان شیئی نیست که نتایج از آن گزارش شده است. این نکته باید صریح نوشته شود، چون در غیر این صورت خواننده‌ای که خودش کشفش کند آن را نقص می‌بیند. مدل‌های اعتبارسنجی پیش‌رونده که تمام اعداد بخش ۴-۲ تا بخش ۴-۵-۲ از آن‌ها می‌آید، هر یک تنها تا پیش از مبدأ خود آموزش دیده‌اند. توضیح‌دادن پیش‌بینی آن مدل‌ها روی همان روزهایی که در آموزششان بوده‌اند، توضیحی درون‌نمونه‌ای می‌بود. بنابراین برای این بخش یک برازش جداگانه انجام شده است: LightGBM بر پنجره‌ی متحرک ۱۰۹۲ روزه‌ای که در ۳۱ دسامبر ۲۰۱۷ پایان می‌یابد، با همان ابرپارامترهای تنظیم‌شده و همان بذر ۴۲.

این برازش، همزاد وفادار مدل گزارش‌شده است و نه خود آن. سه چیز میان آن دو یکسان است: پیکربندی ابرپارامترها، ماتریس ویژگی، و طول پنجره‌ی آموزش. آنچه متفاوت است، مبدأ پایانی ثابت به‌جای مبدأ متحرک است. مازول تحلیل عامدانه از برازش بر پنجره‌ی کوتاه‌تر امتناع می‌کند، دقیقاً برای آنکه این همزاد نتواند بی‌سروصدا از مدل اصلی فاصله بگیرد. بخش ۳-۵ این را به‌عنوان سومین شیء مدلی پروژه تفکیک کرده و گفته است که هیچ عددی از آن وارد جدول‌های دقت نمی‌شود؛ اینجا نیز چنین است. دلیل این ممنوعیت صریح است: پنجره‌ی آموزش این همزاد روزهای دوره‌ی آزمون را نیز در بر می‌گیرد، پس برای سنجش دقت معتبر نیست و تنها برای تفسیر به کار می‌رود. مدل‌های گزارش‌شده در بخش ۴-۲ تا بخش ۴-۵-۲، برعکس، هیچ‌یک فراتر از مبدأ خود آموزش ندیده‌اند و قاعده‌ی نشت را نقض نمی‌کنند.

سوم: SHAP نسبت‌دادن است، نه علیت. آنچه اندازه گرفته می‌شود، سهم یک ویژگی در خروجی یک مدل است. اگر مدل بر ویژگی‌ای تکیه کند که تنها همبسته‌ی علت واقعی است، SHAP همان ویژگی همبسته را برجسته نشان می‌دهد. هیچ جمله‌ای در این بخش نباید چنین خوانده شود که «فلان متغیر قیمت برق آلمان را تعیین می‌کند».

تصویر کلی

جدول ۱۱-۴ میانگین قدرمطلقِ مقادیر SHAP را به تفکیک خانواده‌ی ویژگی و در چهار حالت گزارش می‌کند. واحد، یورو بر مگاوات‌ساعت است، و تفسیر مستقیم دارد: میانگینِ اندازه‌ی جابه‌جایی که آن خانواده در پیش‌بینی ایجاد می‌کند.


جدول ۱۱-۴: میانگین قدرمطلقِ مقادیر SHAP به تفکیک خانواده‌ی ویژگی، بر حسب یورو بر مگاوات‌ساعت، برای مدل LightGBM. $exog_1$ پیش‌بینی بار و $exog_2$ پیش‌بینی تولید تجدیدپذیر است؛ پسوند D0 یعنی مقدارِ خودِ روز هدف و D-n یعنی مقدار n روز پیش. مقادیر پررنگ، بیشترین مقدار هر ستون است.

خانواده‌ی ویژگی	ساعتی		روزانه	
	آرام	پرتنش	آرام	پرتنش
price_D-1	3.4833	6.1471	3.1109	5.1335
price_D-2	0.8610	1.2550	0.3778	0.5177
price_D-3	0.8279	1.0302	0.3328	0.3916
price_D-7	1.7454	2.1473	1.0802	1.4784
exog_1_D-1	0.6591	0.6735	0.2479	0.2611
exog_1_D-7	0.7131	0.7487	0.3699	0.3991
exog_1_D0	3.5197	3.3680	3.4393	3.0130
exog_2_D-1	0.9947	0.9221	0.4077	0.3986
exog_2_D-7	0.6740	0.7761	0.2230	0.2754
exog_2_D0	5.8422	5.9761	4.4929	5.0366
dow	0.1464	0.1358	0.0395	0.0379


سه واقعیت از **جدول ۱۱-۴** و **شکل ۱-۴** بیرون می‌آید.

پیش‌بینی تجدیدپذیرِ روز هدف، بزرگ‌ترین سهم را دارد. $exog_2_D0$ با 5.8422 در حالت آرام و 5.9761 در حالت پرتنش، در هر دو حالتِ افقِ ساعتی بالاترین است. این با سازوکار بازار سازگار است: تولید بادی و خورشیدیِ پیش‌بینی‌شده، منحنی عرضه‌ی باقی‌مانده را جابه‌جا می‌کند و مستقیماً بر قیمت تسویه اثر می‌گذارد. اینکه مدل چنین وزنی به آن می‌دهد، نشانه‌ی خوبی است که چیزی واقعی را آموخته و صرفاً پایداریِ سری را دنبال نمی‌کند.

دو ویژگیِ روز هدف، بیشتر از هر لگی وزن دارند. $exog_1_D0$ و $exog_2_D0$ روی هم بخش بزرگی از کل اهمیت را می‌گیرند. این همان استدلالی است که **بخش ۳-۴** برای مجاز شمردنِ ویژگی‌های D0 آورد: پیش‌بینی بار و تجدیدپذیرِ روز هدف، پیش از بسته‌شدن مزایده در دسترس شرکت‌کنندگان است، پس استفاده از آن‌ها نشت اطلاعات نیست. اگر این ویژگی‌ها کنار گذاشته می‌شدند، مدل از دو مؤثرترین منبع اطلاعاتی خود محروم می‌ماند.




شکل ۴-۱: اهمیت سراسری ویژگی‌ها بر پایه‌ی میانگین قدرمطلق مقادیر SHAP، افق ساعتی.



شکل ۴-۲: نمودار زنبوری (beeswarm) مقادیر SHAP در افق ساعتی: پراکندگی سهم هر ویژگی در تک تک نمونه‌ها، نه تنها میانگین آن.

روز هفته تقریباً بی‌اثر است. dow با 0.1464 در افق ساعتی و 0.0395 در افق روزانه، حدود یک‌چهارم بزرگ‌ترین خانواده است. این به معنای نبود الگوی هفتگی نیست — بخش ۳-۳-۳ نشان داد که چنین الگویی هست — بلکه به این معناست که لگ هفتگی قیمت، price_D-7 با 1.7454، همان اطلاعات را در شکلی غنی‌تر منتقل می‌کند. وقتی لگ‌ها حاضرند، متغیر تقویمی چیزی برای افزودن ندارد.

نیم‌رخ ساعتی




شکل ۳-۴: تفکیک سهم SHAP بر حسب ساعت شبانه‌روز.

شکل ۳-۴ همان تجزیه را بر محور ساعت شبانه‌روز باز می‌کند. این تفکیک یادآور می‌شود که میانگین‌های جدول ۱۱-۴ روی ۲۴ ساعتِ ناهمگن گرفته شده‌اند: ساعت‌های میانه‌ی روز، که تولید خورشیدی در آن‌ها متمرکز است، رفتاری متفاوت از ساعت‌های شب دارند، و بخش ۳-۳-۳ همین ناهمگنی را در سطح خودِ قیمت نشان داده بود (کمینه‌ی میانگین در ساعت ۳ و بیشینه در ساعت ۱۹).

آرام در برابر پرتنش: یافته‌ی اصلی این بخش

مقایسه‌ی دو ستون نخستِ جدول ۱۱-۴ روشن‌ترین یافته‌ی این بخش را می‌دهد، و شکل ۴-۴ همان را به‌صورت تصویری نشان می‌دهد.

اهمیت price_D-1 زیر تنش 76.5 درصد افزایش می‌یابد، از 3.4833 به 6.1471. هیچ خانواده‌ی



شکل ۴-۴: مقایسه‌ی اهمیت ویژگی‌ها میان روزهای آرام و روزهای پرتنش.

دیگری چنین جابه‌جایی‌ای ندارد. وقتی بازار پرتنش است، مدل به‌مراتب سنگین‌تر بر قیمت دیروز تکیه می‌کند.

در جهت مخالف، $exog_1_D0$ — پیش‌بینی بار روز هدف — از 3.5197 به 3.3680 کاهش می‌یابد، یعنی حدود چهار درصد افت. و $exog_2_D0$ با 5.8422 در برابر 5.9761 عملاً ثابت می‌ماند.


خوانش این سه عدد با هم، سازوکار روشنی می‌سازد. در بازار آرام، قیمت را می‌توان تا حد خوبی از بنیان‌های همان روز — بار و تجدیدپذیر — ساخت. وقتی بازار پرتنش می‌شود، همان بنیان‌ها دیگر برای تعیین سطح قیمت کافی نیستند، چون قیمت‌های بالا از کمیابی و رفتار پیشنهاددهی می‌آیند که در متغیرهای بنیادی پیدا نیست. مدل در پاسخ، سطح را از آخرین مشاهده‌ی محقق‌شده می‌گیرد و بنیان‌ها را برای تعیین شکل درون‌روزی نگه می‌دارد.

سایر لگ‌های قیمت نیز در همین جهت حرکت می‌کنند اما با شدت کمتر: $price_D-2$ از 0.8610 به 1.2550 و $price_D-7$ از 1.7454 به 2.1473. پس این افزایش اتکا، مختص یک لگ نیست بلکه به کل بلوک لگ‌های قیمت مربوط است، با بیشترین سهم برای نزدیک‌ترین آن‌ها.

این یافته با نتیجه‌ی بخش ۴-۵-۱ پیوند مستقیم دارد و آن را از سوی دیگری تأیید می‌کند. آنجا نشان داده شد که تمام سود وزن‌دهی رژیم‌محور از همان ۷۷ روز پرتنش می‌آید. اینجا دیده می‌شود که چرا: رفتار مدل در آن روزها واقعاً متفاوت است، و نه فقط خطایش. دو تحلیل کاملاً مستقل — یکی بر

پایه‌ی زیان پیش‌بینی و دیگری بر پایه‌ی نسبت‌دادن ویژگی — به یک نتیجه می‌رسند. این هم‌گرایی، خود شاهدی است بر اینکه تفکیک دو رژیم صرفاً یک برش دلبخواه داده نبوده است.

ساعتی در برابر روزانه



شکل ۴-۵: مقایسه‌ی اهمیت ویژگی‌ها میان افق ساعتی و افق روزانه.

دو ستون آخر **جدول ۴-۱۱** همان تحلیل را برای هدف روزانه تکرار می‌کنند، و الگویی متفاوت اما سازگار پدید می‌آورند.

بیشتر اهمیت‌ها در افق روزانه کوچک‌تر می‌شوند، که انتظار می‌رفت: هدف روزانه میانگین ۲۴ عدد است و دامنه‌ی نوسان آن کمتر، پس اندازه‌ی جابه‌جایی‌ها هم کمتر است. آنچه معنا دارد، نه اندازه‌ی مطلق بلکه نسبت‌هاست.


دو تغییر نسبی برجسته است. نخست، لگ‌های میانی به شدت افت می‌کنند: price_D-2 از 0.8610 به 0.3778 و price_D-3 از 0.8279 به 0.3328، یعنی بیش از نصف. دوم، exog_1_D0 تقریباً دست‌نخورده می‌ماند: 3.5197 در افق ساعتی در برابر 3.4393 در افق روزانه. در واقع پیش‌بینی بار در افق روزانه به بزرگ‌ترین ویژگی در حالت آرام بدل می‌شود.

توضیح، در ماهیت خود دو هدف است. بخش بزرگی از کاری که لگ‌های قیمت در افق ساعتی انجام می‌دهند، بازسازیِ شکلِ درون‌روزی است — اینکه ساعت ۱۹ گران‌تر از ساعت ۳ است. در هدف روزانه

این شکل با میانگین‌گیری از میان می‌رود و آن بخش از کارکرد لگ‌ها بی‌مصرف می‌شود. آنچه باقی می‌ماند، تعیین سطح است، که بار و تجدیدپذیرِ جمع‌شده‌ی همان روز آن را به‌خوبی توضیح می‌دهند. این با یافته‌ی بخش ۴-۴ کاملاً هم‌خوان است. آنجا دیده شد که برای سه مدل از چهار مدل، میانگین‌گیری از ۲۴ پیش‌بینی ساعتی بهتر از مدل‌سازی مستقیم هدف روزانه است. اینجا سازوکارش دیده می‌شود: مسیر مستقیم، مدل را از اطلاعات ساختار درون‌روزی محروم می‌کند و همان اطلاعات است که در تحلیل SHAP به‌صورت افت اهمیت لگ‌های میانی خود را نشان می‌دهد.

الگوی رژیمی در افق روزانه نیز تکرار می‌شود: price_D-1 از 3.1109 به 5.1335 می‌رسد، یعنی حدود ۶۵ درصد افزایش، و exog_1_D0 از 3.4393 به 3.0130 افت می‌کند. پس این یافته مختص افق ساعتی نیست.

یک روز، به تفصیل



شکل ۴-۶: نمودار آشنایی برای یک روز منفرد: تجزیه‌ی فاصله‌ی میان پیش‌بینی آن روز و میانگین پیش‌بینی‌ها به سهم تک‌تک ویژگی‌ها.

تمام آنچه تا اینجا آمد، میانگین بر هزاران نمونه بود. شکل ۴-۶ همان تجزیه را برای یک روز منفرد نشان می‌دهد، و کارکردی متفاوت دارد.

میانگین‌ها به پرسش‌های پژوهشی پاسخ می‌دهند، اما در کاربرد عملی، آنچه به کار می‌آید تبیین همان پیش‌بینی خاصی است که پیش‌روست. نمودار آشنایی نشان می‌دهد که پیش‌بینی یک روز مشخص چگونه از میانگین فاصله گرفته و کدام ویژگی‌ها آن را به کدام سو برده‌اند. همین قابلیت است

که ابزار عملیاتی بخش ۳-۵ بر آن بنا شده است: عددی که با تبیین همراه باشد، برای بهره‌بردار قابل ارزیابی است، و عددی که تنها یک عدد باشد، نیست.

آنچه این بخش ادعا نمی‌کند

سه چیز از این تحلیل نتیجه نمی‌شود، و نوشتنشان دعوت به بدخوانی است. این‌ها «عوامل تعیین‌کننده‌ی قیمت برق آلمان» نیستند. این‌ها ویژگی‌هایی هستند که یک مدل درختی، آموخته بر یک مجموعه داده و در یک پنجره‌ی زمانی، بیش از بقیه به آن‌ها تکیه کرده است. SHAP خروجی مدل را تجزیه می‌کند، نه بازار را. این‌ها به چهار مدل دیگر تعمیم نمی‌یابند. LEAR-LASSO، LSTM و SARIMAX تحلیل نشده‌اند. اینکه دقت آن‌ها از LightGBM تفکیک‌پذیر نیست، به هیچ روی به معنای آن نیست که از اطلاعات یکسانی استفاده می‌کنند؛ ممکن است سه مسیر متفاوت به دقتی مشابه رسیده باشند، و این خود پرسشی است که این پژوهش باز می‌گذارد.

هم‌بستگی میان ویژگی‌ها، سهم‌ها را میان اعضای یک خانواده جابه‌جا می‌کند. لگ‌های قیمت به شدت با هم هم‌بسته‌اند، و وقتی چنین است، توزیع اهمیت میان price_D-1 و price_D-2 تا حدی به ساختار خودِ درخت وابسته است. به همین دلیل تمام تفسیرهای این بخش در سطح خانواده‌ی ویژگی بیان شده‌اند و نه در سطح ستون‌های منفرد، و تمام مقایسه‌ها میان دو حالتِ همان خانواده انجام شده است — جایی که ساختار هم‌بستگی ثابت می‌ماند و اثرش تا حد زیادی حذف می‌شود.

۷-۴ پاسخ به سؤالات پژوهش

این بخش چهار پرسش پژوهشی فصل نخست را، به ترتیب و در همان دامنه‌ای که پرسیده شده‌اند، پاسخ می‌دهد. هر پاسخ دو بخش دارد: آنچه شواهد پشتیبانی می‌کنند، و آنچه پشتیبانی نمی‌کنند. بخش دوم به اندازه‌ی بخش نخست جدی گرفته شده است، چون فاصله‌ی میان این دو، همان جایی است که یک نتیجه‌ی درست به ادعایی نادرست بدل می‌شود.

یادآوری یک نکته‌ی صوری پیش از پاسخ‌ها: طرح مصوب، پرسش پژوهشی شماره‌گذاری شده ندارد و به جای آن شش هدف و شش فرض را برمی‌شمارد. چهار پرسشی که در ادامه پاسخ داده می‌شود، صورت‌بندی عملیاتی همان اهداف است، نه افزوده‌ای بر آن‌ها.

پرسش نخست: دقت مقایسه‌ای پنج خانواده‌ی مدلی

پنج مدل منتخب تحت یک پروتکل اعتبارسنجی پیش‌رونده‌ی یکسان چه عملکردی نسبت به یکدیگر دارند، و کدام تفاوت‌ها از نظر آماری معنادار است؟

پاسخ. بر ۷۲۸ مبدأ پیش‌بینی از چهارم ژانویه‌ی ۲۰۱۶ تا سی‌ویکم دسامبر ۲۰۱۷، ترتیب MAE در افق ساعتی چنین است: LSTM با 3.8734، LEAR-LASSO با 3.8988، LightGBM با 3.9678، SARIMAX با 4.3507 و مدل ساده با 7.7501.

اما ترتیب، پاسخ نیست. آزمون دیبولد-ماریانو نشان می‌دهد که سه مدل نخست از یکدیگر تفکیک‌پذیر نیستند. LSTM در برابر LEAR-LASSO حتی پیش از هر تصحیحی p برابر 0.4036 می‌دهد. LSTM در برابر LightGBM برآورد نقطه‌ای پایین‌تری دارد، اما این تفاوت پس از تصحیح هولم-بونفرونی بر خانواده‌ی ۲۱ آزمون دوام نمی‌آورد (p خام 0.0405، p تصحیح‌شده 0.1215).

سه نتیجه‌ی مقاوم باقی می‌ماند. هر چهار مدل آموخته بر مدل ساده برتری دارند با p عملاً برابر صفر. SARIMAX از سه مدل دیگر پایین‌تر است، با p تصحیح‌شده‌ی حداکثر 5.1×10^{-4} و هر دو ترکیب بر تک‌تک اعضای خود برتری دارند، با p تصحیح‌شده‌ی حداکثر 3.4×10^{-5} .

تساوی، خود یافته است. اینکه بهترین مدل آماری و بهترین مدل یادگیری عمیق این پژوهش تفکیک‌ناپذیرند، نتیجه‌ای است درباره‌ی اینکه یادگیری عمیق در این مسئله چه قدر می‌افزاید، و نه ناکامی در جداکردن مدل‌ها. طراحی برابر آزمایش — ماتریس ویژگی یکسان، مبادی یکسان، بودجه‌ی پنجاه‌آزمایشی تنظیم برای هر مدل — همان چیزی است که این تساوی را به یافته بدل می‌کند؛ بدون آن، می‌شد آن را به تنظیم ناکافی یکی از دو طرف نسبت داد.

آنچه ادعا نمی‌شود. این پاسخ نمی‌گوید یادگیری عمیق به‌طور کلی بر روش‌های آماری برتری دارد یا ندارد. یک معماری از هر خانواده، یک بازار، یک پنجره‌ی دوساله، یک بودجه‌ی تنظیم.

پرسش دوم: ترکیب و وزن‌دهی رژیم‌محور

آیا ترکیب وزن‌دار دقت را نسبت به بهترین تک‌مدل بهبود می‌دهد، و آیا مشروط‌کردن وزن‌ها به رژیم بازار بهبود بیشتری نسبت به وزن‌دهی ایستا ایجاد می‌کند؟ این بهبود، در صورت وجود، تحت کدام شرایط بازار پدید می‌آید؟

بخش نخست، بله. ترکیب ایستا با 3.5742 و ترکیب رژیم‌محور با 3.5569 هر دو از بهترین عضو

منفرد — LSTM با 3.8734 — بهترند، و هر هشت مقایسه‌ی ترکیب با اعضایش پس از تصحیح هولم نیز با p حداکثر $3.4e-05$ برقرار می‌ماند. این مقاوم‌ترین یافته‌ی فصل است.

بخش دوم، بله اما مشروط. ترکیب رژیم‌محور بر ترکیب ایستا با p برابر 0.0226 برتری دارد. این آزمون، تنها عضو خانواده‌ی تأییدی است و به همین دلیل بدون تصحیح چندگانگی در سطح 0.05 خوانده می‌شود؛ ثبت تاریخ‌دار آن در یازدهم ژوئیه‌ی ۲۰۲۶، پیش از آنکه هر ترکیبی بر پنجره‌ی آزمون امتیاز بگیرد، تنها چیزی است که این خوانش را مجاز می‌کند. دو قید باید همراهش بیاید: اگر همین آزمون از خانواده‌ی اکتشافی می‌آمد، پس از تصحیح به 0.0903 می‌رسید و معنادار نمی‌ماند؛ و بوت‌استرپ بلوکی بر کل دوره بازه‌ی 0.0129 تا 0.0571 می‌دهد، یعنی در بلوک‌های ده‌روزه از آستانه عبور می‌کند.

بخش سوم پرسش، پاسخ تیزی دارد و مهم‌ترین بخش این جواب است. تمام بهبود از ۷۷ روز پرتنش می‌آید، با 5.5132 در برابر 5.6830 و p برابر 0.0063 — که در سراسر بازه‌ی بوت‌استرپ نیز معنادار می‌ماند (0.0081 تا 0.0439). بر ۶۵۱ روز آرام، ترکیب رژیم‌محور به‌اندازه‌ی ده‌هزارم یورو بدتر است و p برابر 0.8465.

نتیجه‌ی تهی روزهای آرام، خود یک یافته است. وزن‌دهی رژیم‌محور بهبودی عمومی نیست؛ سازوکاری است که در شرایط پرتنش کار می‌کند و در شرایط آرام بی‌اثر است. این دقیقاً همان چیزی است که برایش طراحی شده بود، و تحلیل SHAP در **بخش ۴-۶** از راهی کاملاً مستقل همین را تأیید می‌کند: رفتار مدل در روزهای پرتنش واقعاً متفاوت است.

آنچه ادعا نمی‌شود. این پاسخ نمی‌گوید وزن‌دهی رژیم‌محور به‌طور کلی بر وزن‌دهی ایستا برتری دارد. می‌گوید بر این بازار و این پنجره، در روزهای پرتنش برتری داشت و در روزهای آرام نداشت.

پرسش سوم: تفسیرپذیری

کدام خانواده‌های ویژگی بیشترین سهم را در پیش‌بینی دارند، و آیا این سهم میان روزهای آرام و پرتنش، و میان افق ساعتی و روزانه، تغییر می‌کند؟

پاسخ. برای مدل LightGBM، پیش‌بینی تولید تجدیدپذیر روز هدف (exog_2_D0) بزرگ‌ترین سهم منفرد را دارد — 5.8422 در حالت آرام و 5.9761 در حالت پرتنش — و در برابر تغییر رژیم پایدار است.

بله، سهم‌ها میان دو رژیم تغییر می‌کنند، و تغییر یکنواخت نیست. اهمیت price_D-1 زیر تنش 76.5 درصد افزایش می‌یابد، از 3.4833 به 6.1471، در حالی که پیش‌بینی بار روز هدف (exog_1_D0)

از 3.5197 به 3.3680 کاهش می‌یابد. مدل در شرایط پرتنش سطح قیمت را از آخرین مشاهده می‌گیرد و بنیان‌های روز را برای تعیین شکل نگه می‌دارد.

بله، سهم‌ها میان دو افق نیز تغییر می‌کنند. در افق روزانه لگ‌های میانی بیش از نصف اهمیتشان را از دست می‌دهند (price_D-2 از 0.8610 به 0.3778) در حالی که پیش‌بینی بار روز هدف تقریباً دست‌نخورده می‌ماند (3.5197 در برابر 3.4393) و در حالت آرام به بزرگ‌ترین ویژگی بدل می‌شود. روز هفته، وقتی لگ‌ها حاضرند، تقریباً بی‌اثر است: 0.1464 در افق ساعتی.

یک افشای لازم. مدلی که در **بخش ۴-۶** توضیح داده شده، برازشی جداگانه بر پنجره‌ی ۱۰۹۲ روزه‌ی منتهی به سی‌ویکم دسامبر ۲۰۱۷ است و نه همان مدل‌های اعتبارسنجی پیش‌رونده‌ای که اعداد دقت از آن‌ها گزارش شده؛ توضیح‌دادن آن مدل‌ها روی روزهای آموزششان، تحلیلی درون‌نمونه‌ای می‌بود. **آنچه ادعا نمی‌شود.** این‌ها «عوامل قیمت برق آلمان» نیستند و به چهار مدل دیگر تعمیم نمی‌یابند. SHAP خروجی یک مدل را تجزیه می‌کند، نه بازار را.

پرسش چهارم: مسیر مستقیم در برابر مسیر تجمیعی

برای پیش‌بینی میانگین بار پایه‌ی روزانه، کدام مسیر دقت بالاتری دارد، و آیا این نتیجه برای هر پنج مدل یکسان است؟

پاسخ بخش نخست: تجمیع، برای سه مدل از چهار مدل. میانگین‌گیری از ۲۴ پیش‌بینی ساعتی برای LEAR-LASSO (2.8389 در برابر 2.8989)، LightGBM (2.9928 در برابر 3.3012) و LSTM (2.7804 در برابر 3.1753) بهتر عمل می‌کند. مدل ساده در هر دو مسیر یکسان است.

پاسخ بخش دوم: خیر، یکسان نیست. SARIMAX استثناست و مسیر مستقیم برایش بهتر است (3.1976 در برابر 3.2691). این استثنا توضیح ساختاری دارد و در **بخش ۴-۴** آمده است: سری بار پایه‌ی روزانه دقیقاً همان نوع سری هموار تک‌بعدی است که مدل‌های کلاسیک سری زمانی برایش ساخته شده‌اند.

اینکه پرسش عامدانه دو بخشی صورت‌بندی شده بود، همین استثنا را به بخشی از پاسخ بدل می‌کند و نه دردسری برای آن.

آنچه ادعا نمی‌شود. این یک قاعده‌ی کلی درباره‌ی تجمیع زمانی در پیش‌بینی نیست. چهار مدل، یک بازار، یک پنجره.

یک یافته که هیچ پرسشی آن را نمی‌پوشاند

آزمون برون‌توزیعی — ارزیابی مدل‌های تثبیت‌شده بر داده‌ی زنده‌ی ۲۰۲۶ — پس از تصویب طرح پیشنهادی به پروژه افزوده شد و به همین دلیل زیر هیچ‌یک از چهار پرسش بالا قرار نمی‌گیرد. با این حال، به گمان این پژوهش، مهم‌ترین یافته‌ی کار است. نتیجه‌ی آن، همراه با آنچه درباره‌ی محدودیت‌های این پژوهش می‌گوید، در [بخش ۵-۲](#) گزارش می‌شود.

فصل پنجم

جمع‌بندی، بحث و پیشنهادات

۱-۵ جمع‌بندی نتایج

هدف این پژوهش، پیش‌بینی قیمت روز بعد برق در بازار آلمان بود، بر دو افق ساعتی و میانگین روزانه، با پنج خانواده‌ی مدل و دو ترکیب، در چارچوبی که بتوان نتیجه‌اش را هم بازتولید کرد و هم در برابر ادبیات منتشرشده سنجید. **بخش ۴-۷** پاسخ‌ها را یک‌به‌یک در برابر پرسش‌های پژوهش گذاشت؛ آنچه در ادامه می‌آید، جمع‌بندی همان پاسخ‌هاست و هیچ عدد تازه‌ای به آن‌ها نمی‌افزاید.

آنچه ساخته شد

خط لوله‌ای کامل از داده‌ی خام تا پیش‌بینی امتیازدهی‌شده: بارگذار داده با دریافت یک‌باره و ثبت اثر انگشت sha256، ماتریس ویژگی ۲۴۷ ستونی که هیچ ستونش از پس از مبدأ پیش‌بینی تغذیه نمی‌شود، تنظیم ابرپارامتر با ۵۰ آزمایش بر پنجره‌ای که کاملاً پیش از دوره‌ی آزمون قرار دارد، و ارزیابی پیش‌رونده بر ۷۲۸ مبدأ از ۴ ژانویه ۲۰۱۶ تا ۳۱ دسامبر ۲۰۱۷. سه شیء مدلی متمایز — پیش‌رونده، تثبیت‌شده، و برازش تفسیری — از یکدیگر تفکیک شدند تا هیچ عددی از مسیر نادرست وارد جدول‌ها نشود.

دقت

بهترین پیکربندی، ترکیب رژیم‌محور بود با MAE برابر 3.5569 یورو بر مگاوات‌ساعت در افق ساعتی، در برابر 7.7501 برای مدل ساده. هر پنج مدل آموزش‌دیده از مدل ساده بهتر بودند و این برتری پس از تصحیح چندگانگی نیز پابرجا ماند. اما میان خودِ مدل‌های خوب، فاصله‌ها بسیار کمتر از چیزی است که جدول‌های مرتب‌شده القا می‌کنند: LSTM و LEAR-LASSO از یکدیگر تفکیک‌پذیر نیستند (p برابر 0.4036)، و برتری عددی LSTM بر LightGBM تصحیح برای چندگانگی را تاب نمی‌آورد. یعنی در این پیکربندی، هزینه‌ی یادگیری عمیق مزیت قابل‌دفاعی بر یک مدل خطی تنظیم‌شده نخرید.

ترکیب و رژیم

هر دو ترکیب از تک‌تک اعضای خود بهتر بودند، با فاصله‌ای که تصحیح چندگانگی را به سادگی تاب می‌آورد. وزن‌دهی رژیم‌محور نیز ترکیب ایستا را بهبود داد، اما دقیقاً آنجا که برای آن طراحی شده بود: تمام بهبود بر ۷۷ روز پرتنش متمرکز است (p برابر 0.0063)، و بر ۶۵۱ روز آرام اثر عملاً صفر است (p برابر 0.8465). نتیجه‌ی تجمیعی — p برابر 0.0226 — به‌عنوان یک فرضیه‌ی پیش‌اعلام‌شده‌ی تأییدی

دفاع می‌شود، و **بخش ۴-۵-۱** صریحاً نوشت که همین عدد اگر از خانواده‌ی اکتشافی برداشته می‌شد، از تصحیح هولم عبور نمی‌کرد.

افق روزانه

برای سه مدل از چهار مدل، میانگین‌گیری از پیش‌بینی‌های ساعتی بهتر از آموزش مستقیم بر سری روزانه بود. SARIMAX استثناست و در **بخش ۴-۴** استثنا بودنش توضیح داده شد، نه میانگین گرفته شد.

تفسیرپذیری

تحلیل SHAP نشان داد رفتار مدل میان دو رژیم واقعاً تغییر می‌کند: سهم قیمت روز پیش در شرایط پرتنش به شدت بالا می‌رود و سهم پیش‌بینی بار پایین می‌آید. این یافته از مسیری کاملاً مستقل از آزمون‌های آماری به همان نتیجه‌ای می‌رسد که وزن‌دهی رژیم‌محور بر آن استوار است، و همین هم‌گرایی است که آن را از یک همبستگی اتفاقی جدا می‌کند.

آنچه به دست نیامد

سه نتیجه‌ی منفی نیز به همان اندازه بخشی از جمع‌بندی‌اند. نخست، این پژوهش بهترین مدل منتشرشده‌ی مرجع را شکست نمی‌دهد؛ با دو گونه‌ی آن هم‌تراز است و به یکی می‌بازد. دوم، برتری یادگیری عمیق بر خط‌مبناهای خطی قوی در این پیکربندی اثبات‌پذیر نبود. سوم، و مهم‌تر از هر دو، مدل‌های تثبیت‌شده در انتقال به داده‌ی خارج از توزیع شکست خوردند. آن نتیجه ذیل هیچ‌یک از پرسش‌های پژوهش نمی‌گنجد و موضوع **بخش ۵-۲** است.

۲-۵ محدودیت‌ها

بخشی از آنچه در این بخش می‌آید، محدودیت به معنای متعارف است: کاری که با داده و زمان در دسترس نمی‌شد کرد. اما مهم‌ترین بند این بخش محدودیت نیست، نتیجه است — نتیجه‌ای منفی که پس از تثبیت مدل‌ها به دست آمد، ذیل هیچ‌یک از پرسش‌های پژوهش نمی‌گنجد، و به گمان این پژوهش مهم‌ترین یافته‌ی آن است.

آزمون خارج از توزیع

مدل‌های تثبیت‌شده‌ی دوره‌ی بنچمارک، بدون هیچ بازآموزی، بر ۱۷۳ روز کامل داده‌ی زنده‌ی سال ۲۰۲۶ اجرا شدند: ۴۳۴۳ ردیف ساعتی، بدون شکاف، از منطقه‌ی مزایده‌ی DE-LU. فاصله‌ی زمانی میان پایان آموزش و این پنجره نزدیک به یک دهه است. هدف این نبود که مدلی خوب جلوه کند؛ این بود که سنجیده شود مدلی که بر شرایط ۲۰۱۷ تثبیت شده، در برخورد با بازار امروز چه می‌کند.

جدول ۵-۱: مدل‌های تثبیت‌شده بر ۱۷۳ روز داده‌ی زنده‌ی ۲۰۲۶، بدون بازآموزی. ستون آخر افزایش MAE نسبت به همان مدل بر دوره‌ی آزمون بنچمارک است. مقادیر rMAE بزرگ‌تر از 1.0 یعنی بدتر از پیش‌بینی ساده. انتساب داده در **بخش ۳-۲-۳** آمده است.

مدل	MAE	RMSE	rMAE	اختلاف MAE
ساده	29.1828	48.7322	0.8076	3.7655
LEAR-LASSO	39.2667	65.3144	1.0867	10.0715
SARIMAX	41.3913	56.5039	1.1455	9.5137
ترکیب رژیم‌محور	42.1713	53.3753	1.1671	11.8561
ترکیب ایستا	44.4331	55.5191	1.2297	12.4315
LSTM	54.9286	67.5062	1.5201	14.1812
LightGBM	66.0582	77.3488	1.8281	16.6485

جمله‌ای که این جدول اجازه می‌دهد، صریح است: هر پنج مدل آموزش‌دیده و هر دو ترکیب، از یک پیش‌بینی ساده‌ی مبتنی بر تأخیر هفتگی شکست خوردند. rMAE همه‌ی آن‌ها بالای 1.0 است و تنها مدل ساده زیر آن می‌ماند. بدتر آنکه ترتیب وارونه می‌شود: LSTM و LightGBM که بر بنچمارک در صدر بودند، اینجا در قعرند، و LEAR-LASSO که ساده‌ترین مدل یادگیرنده است، کم‌ترین آسیب را می‌بیند.

تصحیح اریبی: نشانه، نه علت

برای آنکه روشن شود این شکست از چه جنسی است، یک تصحیح اریبی غلتان با پنجره‌ی ۷ روزه بر خروجی‌ها اعمال شد. **جدول ۵-۲** پیش و پس از آن را بر همان ۱۶۶ روزی که این پنجره پشتیبانی می‌کند گزارش می‌کند.

الگو گویاست: تصحیح دقیقاً آنجا بیشترین کمک را می‌کند که شکست بدترین بوده (LightGBM و LSTM)، و به دو مدلی که از ابتدا کم‌اریب‌ترین بودند آسیب می‌زند (ساده و LEAR-LASSO). یعنی سهم بزرگی از خطا یک جابه‌جایی سطح است و نه فروپاشی ساختار آموخته‌شده؛ مدل‌ها هنوز ساعت‌ها را نسبت به هم درست مرتب می‌کنند، فقط اریب‌اند. اما این توصیف نشانه است، نه تشخیص علت، و

جدول ۵-۲: rMAE پیش و پس از تصحیح اریبی غلتان با پنجره‌ی ۷ روزه، بر ۱۶۶ روز مشترک. مقدار مثبت در ستون آخر یعنی تصحیح به آن مدل آسیب زده است.

مدل	rMAE خام	rMAE تصحیح‌شده	تغییر
ساده	0.8035	0.8678	+0.0643
LEAR-LASSO	1.0919	1.1323	+0.0405
SARIMAX	1.1547	1.1295	-0.0252
ترکیب رژیم‌محور	1.1756	0.8946	-0.2809
ترکیب ایستا	1.2390	0.9064	-0.3327
LSTM	1.5354	1.0135	-0.5218
LightGBM	1.8258	1.0784	-0.7474

نوشتن آن به‌تنهایی گمراه‌کننده می‌بود.

سازوکاری که زیر آن نشانه پیدا شد

یک تشخیص پشتیبانی‌ویژگی، توزیع هر سری را در آموزش و در سرویس‌دهی مقایسه کرد. بخش ۳-۲ وجود این ناهم‌خوانی را پیش از گزارش هر نتیجه‌ای ثبت کرده و سنجش اندازه‌ی آن را به همین‌جا سپرده بود؛ آنچه در پی می‌آید، همان سنجش است. نتیجه، خطای خود این پژوهش را آشکار می‌کند. $exog_1$ — پیش‌بینی بار، که بخش ۴-۶ آن را در شمار مؤثرترین ویژگی‌ها نشان داد — همپوشانی هیستوگرامی برابر 0.0002 با توزیع آموزشی خود دارد، و 99.86 درصد مقادیر سرویس‌داده‌شده بالاتر از بیشینه‌ی کل دوره‌ی آموزش‌اند. ضرب در یک عدد ثابت، همپوشانی را به 0.8681 باز می‌گرداند و نسبت بیرون‌ازپشتیبانی را به صفر می‌رساند. آن عدد 2.553 است، و سهم منطقه‌ی کنترلی $Amprion$ از بار ملی آلمان حدود ۳۹ درصد است ($1/2.553 = 0.392$). یعنی مدل‌ها بر پیش‌بینی بار یک منطقه‌ی کنترلی آموزش دیده‌اند و در سرویس‌دهی، جمع ملی به آن‌ها داده شده است. بار مصرفی آلمان در این سال‌ها 2.5 برابر نشده است؛ تعریف متغیر زیر مسیر سرویس‌دهی عوض شده است.

دو روایت با هم سازگارند، و همین نکته است. تغذیه‌ی بار با مقیاس 2.553 یک درخت را در بالاترین آستانه‌ی انشعابش اشباع می‌کند — پس LightGBM با 1.8281 بدترین است — در حالی که یک مدل خطی صرفاً بر امتداد ضریب خود برون‌یابی می‌کند — پس LEAR-LASSO با 1.0867 کم‌آسیب‌ترین. این همان ترتیبی است که انتقال هم‌متغیر پیش‌بینی می‌کند، و نه ترتیبی که یک جابه‌جایی سطح صرف قیمت پیش‌بینی می‌کرد. و اریبی سامان‌مندی که از آن پدید می‌آید، همان چیزی است که تصحیح غلتان بعداً برمی‌دارد. پس کارکردن تصحیح اریبی شاهده‌ی انتقال هم‌متغیر نیست؛ دقیقاً شکل ظاهری آن است پس از یک وصله‌ی سطحی.

جمله‌ی درست این است: ارزیابی خارج از توزیع، تغییر واقعی بازار را با یک ناسازگاری تعریف میان آموزش و سرویس‌دهی در هم می‌آمیزد؛ این تشخیص آن دو را از هم جدا می‌کند؛ و جمله‌ی سنجش‌پذیر غالب، ناسازگاری تعریف است — که قابل تصحیح است و از آن خود ماست.

آنچه ادعا نمی‌شود. اینکه مقیاس‌بندی دوباره پیش‌بینی‌ها را درست می‌کند. هیچ امتیازدهی تازه‌ای انجام نشده است. بازیابی پشتیبانی و ویژگی، بازیابی خطا نیست، و اجرایی که آن را نشان دهد وجود ندارد، چون انجامش نتایج تثبیت‌شده‌ی v1.1-ood را دوباره باز می‌کرد. این کار به پژوهش آینده سپرده شده و در **بخش ۴-۵** می‌آید.

محدودیت‌های داده

اسپرد پاک گازی و اسپرد زغالی — دو متغیر توضیحی متعارف در ادبیات قیمت برق — در این پژوهش قابل ساخت نبودند. این کاستی را باید جدی گرفت: پژوهش‌های پیشین، از جمله تحلیلی تفسیرپذیر بر همین بازار آلمان، قیمت حامل‌های انرژی را از عوامل تعیین‌کننده‌ی قیمت برق یافته‌اند [۵، ۲۷]. اما قراردادهای آتی گاز و زغال‌سنگ مجوز تجاری دارند، و منابعی که آزادانه در دسترس‌اند تنها سری‌های مشتق‌شده از آن‌ها را بازنشر می‌کنند، که آن‌ها را به استناد بدل می‌کند و نه به منبع داده. دو منبع دیگر نیز به دلیل شرایط استفاده و بازتولیدناپذیری کنار گذاشته شدند. این یک محدودیت واقعی است و بیانش بهتر از پرسیده‌شدنش است.

سه قید دیگر نیز باید نوشته شود. نخست، تمام نتایج بر یک بازار، یک پنجره‌ی آزمون و یک تاریخ تثبیت به دست آمده‌اند؛ تعمیم آن‌ها به بازارهای دیگر آزموده نشده است. دوم، منطقه‌ی مزایده‌ی آلمان تا اکتبر ۲۰۱۸ شامل اتریش نیز بود، و این گسست میان دوره‌ی آموزش و پنجره‌ی زنده وجود دارد. سوم، وزن‌های ترکیب بر همان پنجره‌ی اعتبارسنجی برازش شده‌اند که اعضای ترکیب بر آن تنظیم شده بودند؛ این پنجره کاملاً پیش از دوره‌ی آزمون است و نشتی رخ نمی‌دهد، اما وزن‌ها را باید تخمین‌هایی خوش‌بینانه دانست.

بازگشت به شش فرض

بخش ۲-۳ شش فرض رسمی طرح مصوب را نقل کرد. اکنون می‌توان گفت شواهد با کدامیک همراه نشد.

فرض تعمیم‌پذیری مدل صریح‌ترین مورد است و از هر دو روایت آسیب می‌بیند: مدل‌ها در شرایطی

که برایشان آموزش ندیده بودند شکست خوردند، چه آن شرایط را تغییر بازار بدانیم و چه ناسازگاری تعریف. فرض کیفیت داده همان فرضی است که ناسازگاری آموزش و سرویس‌دهی مستقیماً آن را نقض می‌کند، و باید با همین نام نوشته شود.

اما فرض ثبات شرایط بازار را نباید مقصر جلوه داد. آن فرض درباره‌ی بازار است، و یک خطای واحد در مسیر سرویس‌دهی خود ما شاهدهی علیه آن نیست. این فرض تنها به اندازه‌ی باقیمانده‌ای به چالش کشیده می‌شود که پس از رفع ناسازگاری برجا می‌ماند، و این پژوهش آن باقیمانده را جدا نکرده است. پس عبارت درست این است که سهم بازار به‌طور جداگانه کمی نشده است — نه اینکه صفر است و نه اینکه غالب. فرض ایستایی نیز به همین ترتیب و با همان قید زیر پرسش می‌رود.


سه فرض دیگر پابرجا ماندند: داده در دسترس بود، مدل‌ها تفسیرپذیر بودند (بخش ۴-۶)، و کیفیت داده در دوره‌ی بنچمارک — که تمام اعداد گزارش‌شده از آن می‌آید — با بازتولید بایت‌به‌بایت عکس فوری داده تأیید شد.

۳-۵ ابزار EnergyMarket-PriceCast

خروجی کاربردی این پژوهش، یک ابزار تعاملی است که همان خط لوله‌ی فصل سوم را از دریافت داده تا پیش‌بینی ۲۴ ساعت روز بعد، در یک رابط کاربری در دسترس می‌گذارد. هدف از ساختن آن، نشان‌دادن اجراپذیری روش بود و نه ارائه‌ی یک سامانه‌ی معاملاتی؛ و همان‌طور که در ادامه می‌آید، خود ابزار این تمایز را به کاربرش اعلام می‌کند.

آنچه ابزار انجام می‌دهد

کاربر یک منبع داده را از میان سه گزینه برمی‌گزیند: عکس فوری ذخیره‌شده که بدون اتصال به شبکه کار می‌کند، فراخوانی زنده‌ی API انرژی‌چارتس، یا بارگذاری یک فایل CSV با همان طرحواره. سپس روز هدف را از میان روزهای دارای تاریخچه‌ی کافی انتخاب می‌کند. ابزار برای آن روز ۲۴ قیمت ساعتی تولید می‌کند، آن‌ها را در کنار قیمت‌های محقق‌شده رسم می‌کند، و میانگین روزانه‌ی پیش‌بینی، میانگین روزانه‌ی واقعی، MAE همان روز و بدترین ساعت را گزارش می‌دهد. جدول کامل ۲۴ مقدار نیز در یک بخش بازشونده در دسترس است.



شکل ۵-۱: ابزار EnergyMarket-PriceCast: پیش‌بینی ساعتی روز بعد در برابر قیمت محقق‌شده، به‌همراه هشدار دقتی که خودِ ابزار نمایش می‌دهد.

ساختار

منطق پیش‌بینی از رابط کاربری جدا نگه داشته شده است. لایه‌ی سرویس، مدل LightGBM تثبیت‌شده را از پوشه‌ی مدل‌های منجمد بارگذاری می‌کند، پنجره‌ی تاریخچه‌ی لازم را می‌سازد، و اگر تاریخچه برای ساختن ویژگی‌های تأخیری کافی نباشد خطای صریح می‌دهد به‌جای آنکه ورودی ناقص را با مقدار جایگزین پر کند. همین جدایی معنایی بیش از نظم کد دارد: ابزار همان تابع ویژگی‌سازی و همان شیء مدلی را فرامی‌خواند که نتایج فصل چهارم از آن آمده است، پس آنچه روی صفحه دیده می‌شود بازپیاپی‌سازی تقریبی روش نیست، خودِ آن است. انتساب داده‌ی انرژی‌چارتس نیز، همان عبارتی که پروانه‌ی CC BY 4.0 اقتضا می‌کند، در تمام حالت‌ها در پایین صفحه نمایش داده می‌شود.

هشدار که ابزار درباره‌ی خودش می‌دهد

بالای هر پیش‌بینی، کادری ثابت این جمله را نشان می‌دهد که این پیش‌بینی‌ها بر قیمت‌های امروز دقیق نیستند، و این یک یافته است نه یک ایراد. سپس همان اعداد **بخش ۵-۲** را نقل می‌کند: مدل بر شرایط ۳۱ دسامبر ۲۰۱۷ تثبیت شده و بر داده‌ی زنده‌ی ۲۰۲۶ rMAE برابر ۱.۸۳ می‌گیرد، یعنی بدتر از پیش‌بینی ساده با ۰.۸۱. این اعداد در ابزار نوشته نشده‌اند، بلکه از فایل نتیجه‌ی تثبیت‌شده‌ی همان آزمون خوانده می‌شوند؛ اگر آن نتیجه تغییر کند، متن هشدار نیز تغییر می‌کند و امکان ندارد از آن عقب

بماند.

نمونه‌ی شکل ۵-۱ همین را نشان می‌دهد: منحنی پیش‌بینی، شکل روزانه‌ی قیمت را دنبال می‌کند و اوج عصرگاهی را در جای درست قرار می‌دهد، اما در تراز به کلی پایین‌تر از قیمت محقق‌شده می‌ایستد — همان جابه‌جایی سطحی که بخش ۵-۲ سازوکارش را شکافت، این بار به جای یک ستون در جدول، در یک نمودار.

قراردادن این هشدار در معرض دید، تصمیمی آگاهانه بود. ابزاری که پیش‌بینی‌های نادرست را بی‌هیچ قیدی نمایش دهد، در بهترین حالت بی‌فایده و در بدترین حالت گمراه‌کننده است. ابزاری که کیفیت خود را اعلام می‌کند، هم مصداقِ اجراپذیریِ روش است و هم مصداقِ برخورد درست با یک نتیجه‌ی منفی.

۴-۵ پیشنهادات برای تحقیقات آینده

پیشنهادهای زیر عمومی نیستند. هر کدام از یک محدودیت مشخص برمی‌خیزد که این پژوهش واقعاً به آن برخورد و در بخش ۵-۲ نامش را برد.

یک: جداکردن دو سازوکار درهم‌آمیخته

مهم‌ترین کارِ نکرده‌ی این پژوهش، اجرای دوباره‌ی آزمون خارج از توزیع با مسیر سرویس‌دهی تصحیح‌شده است. تشخیصِ پشتیبانیِ ویژگی نشان داد که سری بار در آموزش و در سرویس‌دهی دو تعریف متفاوت داشته است، اما هیچ امتیازدهی تازه‌ای انجام نشد، چون این کار نتایج تثبیت‌شده را دوباره باز می‌کرد. پژوهشی که بار را با تعریف یکسان تغذیه کند و سپس همان هفت مدل را دوباره امتیاز دهد، برای نخستین بار باقیمانده را می‌سجد: آن بخش از افت دقت که پس از رفع ناسازگاری برجا می‌ماند و تنها آن را می‌توان به تغییر بازار نسبت داد. تا پیش از آن اجرا، سهم بازار کمی نشده باقی می‌ماند. این پیشنهاد، مشخص‌ترین و کم‌هزینه‌ترین پیشنهاد این فهرست است: نه مدل تازه‌ای لازم دارد، نه داده‌ی تازه‌ای.

دو: بازآموزی و تصحیح، به عنوان یک سیاست مشروط

جدول ۵-۲ نشان داد تصحیح اربیبی غلتان به مدل‌هایی که بیشترین انحراف را داشتند کمک چشمگیری می‌کند و به دو مدل کم‌اریب آسیب می‌زند. پس یک سیاستِ «همیشه تصحیح کن» نادرست است.

آنچه لازم است، معیاری است که تصمیم بگیرد تصحیح چه زمانی روشن شود — برای مثال بر پایه‌ی پایش پیوسته‌ی همان سنجه‌ی پشتیبانی ویزگی، که در این پژوهش تنها یک بار و پس از وقوع شکست محاسبه شد. سنجه‌ای که هر روز محاسبه شود می‌تواند پیش از افت دقت هشدار دهد، چون بیرون‌رفتِ ورودی از پشتیبانی آموزشی زودتر از بالارفتنِ خطا دیده می‌شود.

سه: گزارش توزیع بذر، نه یک اجرای منفرد

نتیجه‌ی تکمیلی بخش ۴-۵-۲ نشان داد که تنها با میانگین‌گیری بر چند بذر تصادفی، MAE شبکه‌ی LSTM از 3.8734 به 3.6460 می‌رسد. این تفاوت از فاصله‌ی میان چند مدل رقیب در جدول اصلی بزرگ‌تر است. نتیجه‌ی روشن آن است که یک اجرای تک‌بذری از یک مدل عمیق، پایه‌ی محکمی برای رتبه‌بندی نیست. پژوهش آینده باید مدل‌های عمیق را با توزیعی از بذرها گزارش کند، نه با یک عدد — و آزمون‌های معناداری را نیز بر همان توزیع بنا کند. این پژوهش برای حفظ انسجام با نتایج تثبیت‌شده‌ی خود این کار را نکرد و همان انتخاب را صریح اعلام کرد.

چهار: تکرار بر بازارها و پنجره‌های دیگر

تمام آنچه گزارش شد، بر یک بازار، یک پنجره‌ی آزمون و یک تاریخ تثبیت به دست آمده است. به‌ویژه یافته‌ی رژیم‌محور به تکرار نیاز دارد: کل بهبود آن بر ۷۷ روز پرتنش متکی است، و ۷۷ روز برای توان آماری راحت کم است. تکرار همان روش بر بازاری دیگر — که در این پروژه تنها یک تغییر پیکربندی است — یا بر پنجره‌ای طولانی‌تر، مشخص می‌کند که این یافته خاصیتِ روش است یا خاصیتِ این دو سال. همچنین باید آزموده شود که آستانه‌ی رژیم، که اینجا یک عدد ثابت از آمار دوره‌ی آموزش است، در برابر تعریفی که خود در طول زمان به‌روز می‌شود چگونه عمل می‌کند.

پنج: مجموعه‌ی ویژگی غنی‌تر از آنچه بنچمارک اجازه می‌داد

بخش ۳-۴ فهرستی از متغیرهایی را آورد که عمداً در ماتریس ویژگی نیستند، و برای هر کدام دلیلی متفاوت ذکر کرد. قیمت سوخت به دلیل مجوز تجاری کنار ماند، و هواشناسی و جریان‌های مرزی به دلیلی که به داده ربطی نداشت: افزودنشان هم‌مقیاسی مقایسه با اعداد منتشرشده را از میان می‌برد. آن مبادله برای این پژوهش درست بود، چون مقایسه‌پذیری شرط لازم ارزیابی روش بود؛ اما برای پژوهشی که دیگر خود را به پروتکل مرجع مقید نمی‌داند، درست نیست.

بنابراین مسیر طبیعی بعدی، رهاکردن آگاهانه‌ی همان قید و افزودن این متغیرهاست: هواشناسی، جریان‌های مرزی، و — در صورت دسترسی مجاز به داده — شاخص‌های حاشیه‌ی سوخت. ساختار کد این را از پیش پیش‌بینی کرده است: بلوک‌های ویژگی فیزیکی به‌صورت افزودنی و به‌طور پیش‌فرض خاموش پیاده‌سازی شده‌اند، پس افزودن آن‌ها مسیر پیش‌فرضی را که نتایج تثبیت‌شده از آن آمده‌اند تغییر نمی‌دهد. نکته‌ی مهم آن است که چنین پژوهشی دیگر نمی‌تواند نتیجه‌ی خود را مستقیماً در برابر اعداد مرجع بگذارد، و باید این را صریح بنویسد.

شش: از پیش‌بینی نقطه‌ای به پیش‌بینی احتمالاتی

هر عددی در این پایان‌نامه یک پیش‌بینی نقطه‌ای است. اما شکست خارج از توزیع دقیقاً از جنسی بود که یک پیش‌بینی نقطه‌ای نمی‌تواند بیان کند: مدل‌ها با همان اطمینان ظاهری همیشه، اعدادی می‌دادند که به‌طور سامان‌مند پایین بودند. پیش‌بینی احتمالاتی [۴۰] می‌تواند این وضعیت را به شکل بازه‌هایی گزارش کند که هنگام دورشدن ورودی‌ها از دامنه‌ی آموزش پهن می‌شوند، و برای تصمیم‌گیرنده‌ای که با خروجی چنین مدلی کار می‌کند، این پهن‌شدن اطلاعاتی است که یک عدد تنها هرگز نمی‌دهد.

۵-۵ نتیجه‌گیری نهایی

این پایان‌نامه با پرسشی متعارف آغاز شد — اینکه قیمت روز بعد برق آلمان را چگونه می‌توان بهتر پیش‌بینی کرد — و با پاسخی پایان می‌یابد که بخشی از آن مثبت است و بخشی نه. هر دو بخش گزارش شده‌اند، و همین انتخاب، بیش از هر عددی، چیزی است که این کار می‌خواهد از خود بر جای بگذارد.

آنچه این پژوهش افزود

سه چیز.

نخست، وزن‌دهی رژیم‌محور در ترکیب مدل‌ها. این روش ترکیب ایستا را بهبود می‌دهد، اما نه به‌طور یکنواخت: تمام بهبود بر روزهای پرتنش متمرکز است و بر روزهای آرام عملاً هیچ است. همین محدودبودن اثر، ادعای قوی‌تری است تا یک بهبود مبهم سراسری، چون دقیقاً همان چیزی است که روش برای آن طراحی شده بود. تحلیل تفسیرپذیری نیز از مسیری مستقل به همان جا رسید و نشان داد رفتار مدل میان دو رژیم واقعاً تغییر می‌کند.

دوم، **آزمون خارج از توزیع و تشخیصی که زیر آن نشست**. اجرای مدل‌های تثبیت‌شده بر داده‌ی امروز، شکستی آشکار را نشان داد؛ اما کار آنجا متوقف نشد. سنجش پشتیبانی ویژگی معلوم کرد که بخش سنجش‌پذیر غالب آن شکست، ناسازگاری تعریف در مسیر سرویس‌دهی خود ما بوده است و نه صرفاً دگرگونی بازار. تفکیک این دو، هم نتیجه را دقیق‌تر می‌کند و هم بار مسئولیت را در جای درست می‌گذارد.

سوم، **یک زنجیره‌ی کامل و بازتولیدپذیر**، از عکس فوری داده با اثر انگشت رمزنگاشتی تا ابزاری که همان مدل تثبیت‌شده را اجرا می‌کند و کیفیت خود را به کاربر اعلام می‌نماید. مقایسه با نتایج منتشرشده نیز بر همان زنجیره و با کد سنجی واحد انجام شد، نه با نقل اعداد چاپ‌شده.

آنچه این پژوهش نمی‌گوید

این پژوهش بهترین مدل منتشرشده‌ی مرجع را شکست نمی‌دهد. با دو گونه‌ی آن هم‌تراز است و به بهترین گونه‌اش می‌بازد. این نتیجه از آغاز پنهان نشد و مسیر دفاع پروژه پس از ایست‌بازرسی میانی آگاهانه از رقابت بر سر جدول امتیازها به سمت مشارکت روش‌شناختی تغییر کرد.

همچنین نشان داده نشد که یادگیری عمیق در این پیکربندی بر یک مدل خطی تنظیم‌شده مزیت دارد. دو خانواده از یکدیگر تفکیک‌پذیر نبودند، و آنجا که تفاوتی به سود مدل عمیق دیده شد، تصحیح برای چندگانگی آن را باقی نگذاشت. این خود یافته‌ای است درباره‌ی آنکه در این مسئله، پیچیدگی بیشتر چقدر می‌خرد.

و سرانجام، هیچ‌یک از اعداد دقت این پایان‌نامه ادعایی درباره‌ی بازار امروز نیست. آن‌ها بر دوره‌ای معتبرند که مدل‌ها بر آن آموزش دیده و آزموده شده‌اند، و **بخش ۵-۲** نشان داد بیرون از آن دوره چه رخ می‌دهد.

جمله‌ی پایانی

اگر قرار باشد از این کار یک نکته بماند، این است که در پیش‌بینی قیمت برق، سختی اصلی نه در ساختن مدلی دقیق‌تر، که در دانستن حدود اعتبار همان مدل است. مدل‌های این پژوهش بر دوره‌ی آزمون خود خوب عمل کردند و در برخورد با شرایطی که برای آن ساخته نشده بودند، از یک قاعده‌ی سرانگشتی هم عقب ماندند. آنچه این فاصله را قابل فهم کرد، نه مدل بهتر بود و نه داده‌ی بیشتر؛ سنجه‌ای بود که پرسید ورودی امروز اصلاً در دامنه‌ای که مدل دیده است قرار دارد یا نه. پیش‌بینی قابل‌اتکا، پیش از آنکه

مسئله‌ی دقت باشد، مسئله‌ی دانستنِ زمانِ بی‌اعتباری است.

کتاب نامه

- [1] Lago, Jesus, Marcjasz, Grzegorz, De Schutter, Bart, and Weron, Rafał. Forecasting day-ahead electricity prices: A review of state-of-the-art algorithms, best practices and an open-access benchmark. *Applied Energy*, 293:116983, July 2021.
- [2] Cerjan, Marin, Krzelj, Ivana, Vidak, Marko, and Delimar, Marko. A literature review with statistical analysis of electricity price forecasting methods. in *Eurocon 2013*, pp. 756–763, Zagreb, Croatia, July 2013. IEEE.
- [3] Jiang, LianLian and Hu, Guoqiang. A Review on Short-Term Electricity Price Forecasting Techniques for Energy Markets. in *2018 15th International Conference on Control, Automation, Robotics and Vision (ICARCV)*, pp. 937–944, Singapore, Singapore, November 2018. IEEE.
- [4] O’Connor, Ciaran, Bahloul, Mohamed, Prestwich, Steven, and Visentin, Andrea. A Review of Electricity Price Forecasting Models in the Day-Ahead, Intra-Day, and Balancing Markets. *Energies*, 18(12):3097, June 2025.
- [5] Chai, Shanglei, Li, Qiang, Abedin, Mohammad Zoynul, and Lucey, Brian M. Forecasting electricity prices from the state-of-the-art modeling technology and the price determinant perspectives. *Research in International Business and Finance*, 67:102132, January 2024.

-
- [6] Jedrzejewski, Arkadiusz, Lago, Jesus, Marcjasz, Grzegorz, and Weron, Rafal. Electricity Price Forecasting: The Dawn of Machine Learning. *IEEE Power and Energy Mag.*, 20(3):24–31, May 2022.
- [7] Aggarwal, Sanjeev Kumar, Saini, Lalit Mohan, and Kumar, Ashwani. Electricity price forecasting in deregulated markets: A review and evaluation. *International Journal of Electrical Power & Energy Systems*, 31(1):13–22, January 2009.
- [8] Poggi, Aurora, Di Persio, Luca, and Ehrhardt, Matthias. Electricity Price Forecasting via Statistical and Deep Learning Approaches: The German Case. *AppliedMath*, 3(2):316–342, April 2023.
- [9] Mohammadi, Saeed, Hesamzadeh, Mohammad Reza, Vafamehr, Ali, and Ferdowsi, Farzad. A Review of Machine Learning Applications in Electricity Market Studies. in *2020 3rd International Colloquium on Intelligent Grid Metrology (SMAGRIMET)*, pp. 1–8, Cavtat, Dubrovnik, Croatia, October 2020. IEEE.
- [10] Zema, Tomasz and Sulich, Adam. Models of Electricity Price Forecasting: Bibliometric Research. *Energies*, 15(15):5642, August 2022.
- [11] Nogales, Francisco J, Contreras, Javier, Conejo, Antonio J, and Espínola, Rosario. Forecasting Next-Day Electricity Prices by Time Series Models. *IEEE Transactions on Power Systems*, 17(2):342–348, 2002.
- [12] Conejo, A.J., Plazas, M.A., Espinola, R., and Molina, A.B. Day-Ahead Electricity Price Forecasting Using the Wavelet Transform and ARIMA Models. *IEEE Trans. Power Syst.*, 20(2):1035–1042, May 2005.
- [13] Halužan, Marko, Verbič, Miroslav, and Zorić, Jelena. Performance of alternative electricity price forecasting methods: Findings from the Greek and Hungarian power exchanges. *Applied Energy*, 277:115599, November 2020.

- [14] Foruzan, Elham, Scott, Stephen D., and Lin, Jeremy. A comparative study of different machine learning methods for electricity prices forecasting of an electricity market. in *2015 North American Power Symposium (NAPS)*, pp. 1–6, Charlotte, NC, USA, October 2015. IEEE.
- [15] Castelli, Mauro, Groznik, Aleš, and Popovič, Aleš. Forecasting Electricity Prices: A Machine Learning Approach. *Algorithms*, 13(5):119, May 2020.
- [16] Yousaf, Adnan, Asif, Rao Muhammad, Shakir, Mustafa, Rehman, Ateeq Ur, Alassery, Fawaz, Hamam, Habib, and Cheikhrouhou, Omar. A Novel Machine Learning-Based Price Forecasting for Energy Management Systems. *Sustainability*, 13(22):12693, November 2021.
- [17] Arya, K. and Vijaya Chandrakala, K.R.M. Machine Learning Based Prediction and Forecasting of Electricity Price During COVID-19. in *2021 IEEE International Power and Renewable Energy Conference (IPRECON)*, pp. 1–6, Kollam, India, September 2021. IEEE.
- [18] Albahli, Saleh, Shiraz, Muhammad, and Ayub, Nasir. Electricity Price Forecasting for Cloud Computing Using an Enhanced Machine Learning Model. *IEEE Access*, 8:200971–200981, 2020.
- [19] Lago, Jesus, De Ridder, Fjo, and De Schutter, Bart. Forecasting spot electricity prices: Deep learning approaches and empirical comparison of traditional algorithms. *Applied Energy*, 221:386–405, July 2018.
- [20] Ugurlu, Umut, Oksuz, Ilkay, and Tas, Oktay. Electricity Price Forecasting Using Recurrent Neural Networks. *Energies*, 11(5):1255, May 2018.
- [21] Zhang, Wenjie, Cheema, Farwa, and Srinivasan, Dipti. Forecasting of Electricity Prices Using Deep Learning Networks. in *2018 IEEE PES Asia-Pacific Power and Energy Engineering Conference (APPEEC)*, pp. 451–456, Kota Kinabalu, October 2018. IEEE.

- [22] Miletic, Marija, Pavic, Ivan, Pandzic, Hrvoje, and Capuder, Tomislav. Day-ahead Electricity Price Forecasting Using LSTM Networks. in *2022 7th International Conference on Smart and Sustainable Technologies (SpliTech)*, pp. 1–6, Split / Bol, Croatia, July 2022. IEEE.
- [23] Naz, Aqdas, Javed, Muhammad Umar, Javaid, Nadeem, Saba, Tanzila, Alhussein, Musaed, and Aurangzeb, Khursheed. Short-Term Electric Load and Price Forecasting Using Enhanced Extreme Learning Machine Optimization in Smart Grids. *Energies*, 12(5):866, March 2019.
- [24] Heidarpناه, Mohammadreza, Hooshyaripor, Farhad, and Fazeli, Meysam. Daily electricity price forecasting using artificial intelligence models in the Iranian electricity market. *Energy*, 263:126011, January 2023.
- [25] Alkawaz, Ali Najem, Abdellatif, Abdallah, Kanesan, Jeevan, Khairuddin, Anis Salwa Mohd, and Gheni, Hassan Muwafaq. Day-Ahead Electricity Price Forecasting Based on Hybrid Regression Model. *IEEE Access*, 10:108021–108033, 2022.
- [26] Shah, Rishi, Shah, Harsh, Bhim, Swarnendu, Heistrene, Leena, and Pandya, Vivek. Short-term Electricity Price Forecasting using Ensemble Machine Learning Technique. in *2021 1st International Conference in Information and Computing Research (iCORE)*, pp. 145–150, Manila, Philippines, December 2021. IEEE.
- [27] Yang, Wendong, Sun, Shaolong, Hao, Yan, and Wang, Shouyang. A novel machine learning-based electricity price forecasting model based on optimal model selection strategy. *Energy*, 238:121989, January 2022.
- [28] Moradzadeh, Arash, Mouhammadpourfard, Mostafa, Weng, Yang, Pol, Suhas, and Muyeen, S. M. Hybrid Deep Learning Model for Accurate Short-Term Electricity Price Forecasting. in *2025 IEEE Texas Power and Energy Conference (TPEC)*, pp. 1–6, College Station, TX, USA, February 2025. IEEE.

- [29] Zhang, Rongquan, Li, Gangqiang, and Ma, Zhengwei. A Deep Learning Based Hybrid Framework for Day-Ahead Electricity Price Forecasting. *IEEE Access*, 8:143423–143436, 2020.
- [30] Ghimire, Sujana, Deo, Ravinesh C., Casillas-Pérez, David, and Salcedo-Sanz, Sancho. Two-step deep learning framework with error compensation technique for short-term, half-hourly electricity price forecasting. *Applied Energy*, 353:122059, January 2024.
- [31] Pourdayaei, Alireza, Mohammadi, Mohammad, Mubarak, Hamza, Abdellatif, Abdallah, Karimi, Mazaher, Gryazina, Elena, and Terzija, Vladimir. A new framework for electricity price forecasting via multi-head self-attention and CNN-based techniques in the competitive electricity market. *Expert Systems with Applications*, 235:121207, January 2024.
- [32] Mubarak, Hamza, Abdellatif, Abdallah, Ahmad, Shameem, Zohurul Islam, Mohammad, Muyeen, S.M., Abdul Mannan, Mohammad, and Kamwa, Innocent. Day-Ahead electricity price forecasting using a CNN-BiLSTM model in conjunction with autoregressive modeling and hyperparameter optimization. *International Journal of Electrical Power & Energy Systems*, 161:110206, October 2024.
- [33] Kuo, Ping-Huan and Huang, Chiou-Jye. An Electricity Price Forecasting Model by Hybrid Structured Deep Neural Networks. *Sustainability*, 10(4):1280, April 2018.
- [34] Sun, Caixin, Pan, Xiaofeng, Li, Gang, Li, Pengfei, Gao, Guoqing, Tian, Ye, and Xu, Gesheng. Day-Ahead Electricity Price Forecasting Strategy Based on Machine Learning and Optimization Algorithm. in *2022 4th Asia Energy and Electrical Engineering Symposium (AEEES)*, pp. 254–259, Chengdu, China, March 2022. IEEE.
- [35] Jiang, Ping, Nie, Ying, Wang, Jianzhou, and Huang, Xiaojia. Multivariable short-term electricity price forecasting using artificial intelligence and multi-input multi-output scheme. *Energy Economics*, 117:106471, January 2023.

- [36] Ghelasi, Paul and Ziel, Florian. From day-ahead to mid and long-term horizons with econometric electricity price forecasting models. *Renewable and Sustainable Energy Reviews*, 217:115684, July 2025.
- [37] Trebbien, Julius. Explainable Artificial Intelligence and Deep Learning for Analysis and Forecasting of Complex Time Series: Applications to Electricity Prices. Master's thesis, University of Cologne, March 2023.
- [38] Lucas, Alexandre, Pegios, Konstantinos, Kotsakis, Evangelos, and Clarke, Dan. Price Forecasting for the Balancing Energy Market Using Machine-Learning Regression. *Energies*, 13(20):5420, October 2020.
- [39] Nitsch, Felix, Schimeczek, Christoph, and Bertsch, Valentin. Applying machine learning to electricity price forecasting in simulated energy market scenarios. *Energy Reports*, 12:5268–5279, December 2024.
- [40] Ziel, Florian and Steinert, Rick. Probabilistic mid- and long-term electricity price forecasting. *Renewable and Sustainable Energy Reviews*, 94:251–266, October 2018.
- [41] Yousefi, Ashkan, Sianaki, Omid Ameri, and Sharafi, Dean. Long-Term Electricity Price Forecast Using Machine Learning Techniques. in *2019 IEEE Innovative Smart Grid Technologies - Asia (ISGT Asia)*, pp. 2909–2913, Chengdu, China, May 2019. IEEE.
- [42] Lundberg, Scott M. and Lee, Su-In. A unified approach to interpreting model predictions. in *Advances in Neural Information Processing Systems*, vol. 30, pp. 4765–4774, 2017.

پیوست

موضوعات مرتبط با متن گزارش پایان نامه که در یکی از گروه‌های زیر قرار می‌گیرد، در بخش پیوست‌ها آورده شوند:

۱. اثبات‌های ریاضی یا عملیات ریاضی طولانی.
۲. داده و اطلاعات نمونه (های) مورد مطالعه (Case Study) چنانچه طولانی باشد.
۳. نتایج کارهای دیگران چنانچه نیاز به تفصیل باشد.
۴. مجموعه تعاریف متغیرها و پارامترها، چنانچه طولانی بوده و در متن به انجام نرسیده باشد.

کد میپل

```
with(DifferentialGeometry):  
with(Tensor):  
DGsetup([x, y, z], M)  
frame name: M  
a := evalDG(D_x)  
D_x  
b := evalDG(-2 y z D_x+2 x D_y/z^3-D_z/z^2)
```

واژه‌نامه‌ی فارسی به انگلیسی

European Power . . . بورس برق اروپا، آلمان	آ
Exchange, Germany (EPEX-DE)	
پ	آزمون دیبولد—ماریانو . . Diebold–Mariano
	test
Calibration window . . . پنجره‌ی واسنجی	آستانه‌ی رژیم Regime threshold
Probabilistic پیش‌بینی احتمالاتی	ا
forecasting	
Naive forecast پیش‌بینی ساده	ابرپارامتر Hyperparameter
ت	اعتبارسنجی پیش‌رونده Walk-forward
	validation
Autocorrelation تابع خودهمبستگی	انتقال هم‌متغیر Covariate shift
Function (ACF)	ایستایی Stationarity
Partial تابع خودهمبستگی جزئی	ب
Autocorrelation Function (PACF)	
Holm–Bonferroni . تصحیح هولم—بنفرونی	بار پایه Baseload
correction	بازار روز-پیش Day-ahead market
Interpretability تفسیرپذیری	برآورد گشتاور تطبیقی Adaptive Moment . .
Gradient boosting تقویت گرادیان	Estimation (Adam)

Block bootstrap . . . خودگردان‌سازی بلوکی	Ensemble ترکیب مدل‌ها
د	SHapley Additive توضیح‌های افزایشی شپلی
Carbon Dioxide (CO ₂) . . . دی‌اکسید کربن	exPlanations (SHAP)
ر	ح
Regime رژیم	Long Short-Term حافظه‌ی کوتاه‌مدت بلند
ریشه‌ی میانگین مربعات خطا . . .	Memory (LSTM)
Square Error (RMSE)	خ
س	Out-of-distribution خارج از توزیع
سازگار با ناهمسانی واریانس و خودهمبستگی	Mean Absolute Error خطای مطلق میانگین
Heteroskedasticity- and Autocorrelation-Consistent (HAC)	(MAE)
ش	relative Mean خطای مطلق میانگین نسبی
شبکه‌ی عصبی عمیق Deep Neural Network (DNN)	Absolute Error (rMAE)
م	Mean خطای درصدی مطلق میانگین
ماشین تقویت گرادیان سبک Light Gradient Boosting Machine (LightGBM)	Absolute Percentage Error (MAPE)
مبدأ پیش‌بینی Forecast origin	خطای درصدی مطلق میانگین متقارن
متغیر برون‌زا Exogenous variable	symmetric Mean Absolute Percentage Error (sMAPE)
مؤسسه‌ی سامانه‌های انرژی خورشیدی	خودبازگشتی برآوردشده با لاسو - LASSO
Institute for Solar Energy Systems (ISE)	Estimated AutoRegressive (LEAR)
	خودبازگشتی جمعی میانگین متحرک
	AutoRegressive Integrated Moving Average (ARIMA)

Bidding zone منطقه‌ی مزایده

Feature engineering مهندسی ویژگی

ه

Overlap (histogram) همپوشانی هیستوگرامی

و

Gated Recurrent واحد بازگشتی دروازه‌دار
Unit (GRU)

Rectified Linear Unit یکسوشده
(ReLU)

واژه‌نامه‌ی انگلیسی به فارسی

A	Covariate shift انتقال هم‌متغیر
Adaptive Moment برآورد گشتاور تطبیقی	D
Estimation (Adam)	Day-ahead market بازار روز-پیش
Autocorrelation تابع خودهمبستگی	Deep Neural Network شبکه‌ی عصبی عمیق
Function (ACF)	(DNN)
خودبازگشتی جمعی میانگین متحرک	Diebold–Mariano آزمون دیبولد—ماریانو
AutoRegressive Integrated Moving Av-	test
erage (ARIMA)	E
B	Ensemble ترکیب مدل‌ها
Baseload بار پایه	European Power بورس برق اروپا، آلمان
Bidding zone منطقه‌ی مزایده	Exchange, Germany (EPEX-DE)
Block bootstrap خودگردان‌سازی بلوکی	Exogenous variable متغیر برون‌زا
C	F
Calibration window پنجره‌ی واسنجی	Feature engineering مهندسی ویژگی
Carbon Dioxide (CO ₂) دی‌اکسید کربن	Forecast origin مبدأ پیش‌بینی
	G

Gated Recurrent Unit (GRU) . . واحد بازگشتی دروازه‌دار	Mean Absolute Error (MAE) خطای مطلق میانگین
Gradient boosting تقویت گرادیان	Mean خطای درصدی مطلق میانگین
H	Absolute Percentage Error (MAPE)
سازگار با ناهمسانی واریانس و خودهمبستگی	بهره‌بردار مستقل سامانه‌ی میان‌قاره
Heteroskedasticity- and Autocorrelation-Consistent (HAC)	Midcontinent Independent System Operator (MISO)
N	
Holm–Bonferroni . تصحیح هولم—بنفرونی	Naive forecast پیش‌بینی ساده
correction	
O	
Hyperparameter ابرپارامتر	Out-of-distribution خارج از توزیع
I	
مؤسسه‌ی سامانه‌های انرژی خورشیدی	Overlap (histogram) همپوشانی هیستوگرامی
Institute for Solar Energy Systems (ISE)	P
Interpretability تفسیرپذیری	تابع خودهمبستگی جزئی
L	Autocorrelation Function (PACF)
LASSO- . . . خودبازگشتی برآوردشده با لاسو	پیش‌بینی احتمالاتی
Estimated AutoRegressive (LEAR)	forecasting
R	
ماشین تقویت گرادیان سبک	Rectified Linear Unit یکسوشده
Boosting Machine (LightGBM)	(ReLU)
Long Short-Term . حافظه‌ی کوتاه‌مدت بلند	Regime رژیم
Memory (LSTM)	خطای مطلق میانگین نسبی . relative Mean
M	Absolute Error (rMAE)

ریشه‌ی میانگین مربعات خطا . . .	exPlanations (SHAP)
Square Error (RMSE)	
S	ایستایی Stationarity
خودبازگشتی جمعی میانگین متحرک فصلی با	خطای درصدی مطلق میانگین متقارن
Seasonal AutoRe-	symmetric Mean Absolute Percentage Er-
rorodی برون‌زا	ror (sMAPE)
gressive Integrated Moving Average with	W
eXogenous inputs (SARIMAX)	اعتبارسنجی پیش‌رونده Walk-forward
SHapley Additive توضیح‌های افزایشی شپلی	validation

Abstract

This thesis addresses day-ahead electricity price forecasting for the German market (EPEX-DE) on two horizons: the 24-value vector of hourly prices for the following day, and the daily baseload average. Five model families – naive, SARIMAX, LEAR-LASSO, LightGBM and LSTM – together with a regime-aware weighted ensemble, are implemented and evaluated on the public dataset and protocol of Lago et al. Evaluation is walk-forward with daily recalibration, and results are reported using MAE, RMSE, sMAPE and rMAE alongside Diebold-Mariano tests with HAC correction and Holm-Bonferroni correction for multiplicity. Model behaviour is further examined through SHAP interpretability analysis, and the frozen models are subjected to an out-of-distribution stress test on live 2026 data.

The best configuration is the regime-aware ensemble, with an MAE of 3.5569 EUR/MWh against 7.7501 for the naive model. Its improvement, however, is concentrated on the 77 stressed days ($p = 0.0063$) and is effectively zero on calm days. The best deep model and the best linear model are statistically indistinguishable (LSTM versus LEAR-LASSO, $p = 0.4036$), meaning deep learning bought no defensible advantage in this configuration. This work does not beat the best published model: it ties two of the reference variants and loses to their DNN ensemble ($p = 0.0127$). The SHAP analysis shows that the previous day's price is the most influential feature and that its share rises sharply under stressed conditions. The most important finding, however, is a negative one: on 2026 data every fitted model falls behind a naive weekly baseline ($rMAE > 1$) and the ordering of the models inverts.

The overall conclusion is that reliable forecasting is as much a matter of knowing when a model has ceased to be valid as it is a matter of accuracy.

Key Words:

Electricity Price Forecasting; Daily Price; Machine Learning; Deep Learning; Energy Markets; Predictive Modeling; Market Dynamics; Forecast Accuracy.



**Amirkabir University of Technology
(Tehran Polytechnic)**

Department of Electrical Engineering

M. Sc. Thesis

Daily and Hourly Electricity Price Forecasting Using Machine Learning Approaches

By

Mohammad Azimpour Charandabi

Supervisors

Dr. Seyed Hossein Hosseinian and Dr. Behrooz Vahidi

Advisor

Dr. Mohammad Hassan Nazari

[Month & Year of Defense]